

THESE DE DOCTORAT DE

NANTES UNIVERSITE

ECOLE DOCTORALE N° 640

Sciences économiques et sciences de gestion - Pays de Loire

Spécialité : « *Sciences économiques* »

Par

Alain QUARTIER-LA-TENTE

Estimation en temps réel de la tendance-cycle à l'aide de moyennes mobiles : apports dans l'analyse conjoncturelle

Thèse présentée et soutenue à Nantes, le 09 décembre 2025

Unité de recherche : Laboratoire d'Économie et de Management Nantes-Atlantique (LEMNA)

Rapporteurs avant soutenance :

Catherine DOZ	Professeure des Universités, Université Paris 1 Panthéon-Sorbonne
Valérie MIGNON	Professeure des Universités, Université Paris Nanterre

Composition du Jury :

Président :	Hamza BENNANI	Professeur des Universités, Nantes Université
Examineurs :	Hamza BENNANI	Professeur des Universités, Nantes Université
	Catherine DOZ	Professeure des Universités, Université Paris 1 Panthéon-Sorbonne
	Laurent FERRARA	Professeur, SKEMA Business School
	Valérie MIGNON	Professeure des Universités, Université Paris Nanterre
	Jean PALATE	Inspecteur général honoraire, Banque Nationale de Belgique
Dir. de thèse :	Olivier DARNÉ	Professeur des Universités, Nantes Université
Co-enc. de thèse :	Dominique LADIRAY	Inspecteur général honoraire, Insee

Table des matières

Remerciements	5
1 Introduction générale	7
2 Estimation de la tendance-cycle et formule générale de construction des moyennes mobiles	17
2.1 Introduction	17
2.2 Quelques propriétés sur les moyennes mobiles	19
2.2.1 Fonctions de gain et de déphasage	20
2.2.2 Propriétés souhaitables d'une moyenne mobile	22
2.2.3 Estimation en temps réel et moyennes mobiles asymétriques	23
2.3 Régression non paramétrique et régression polynomiale locale	27
2.3.1 Régression polynomiale : approche de Proietti et Luati	28
2.3.2 Paramétrisation locale des filtres asymétriques	34
2.3.3 Extension avec le critère de <i>timeliness</i>	37
2.3.4 Régression polynomiale : Gray et Thomson	38
2.3.5 Reproducing Kernel Hilbert Space (RKHS) : approche de Dagum et Bianconcini	41
2.4 Approche <i>Fidelity-Smoothness-Timeliness</i> (FST)	46
2.5 Filtres dépendant des données : trilemme ATS	49
2.6 Comparaison des différentes méthodes	52
2.6.1 Séries simulées	52
2.6.2 Série réelle	57
2.6.3 Discussion	62
2.7 Conclusion	66
2.8 Annexes	68
2.8.1 Synthèse des liens entre les différentes méthodes de construction de moyennes mobiles	68
2.8.2 Coefficients, fonctions de gain et de déphasage	75
2.8.3 Exemple sous R	79
2.8.4 Noyaux et régression locale	86
3 Amélioration des estimations de tendance-cycle grâce à la paramétrisation locale des filtres de régression polynomiale	89
3.1 Introduction	89

3.2	Local trend-cycle models and moving averages	90
3.2.1	Gain and phase shift functions	91
3.2.2	Desirable properties of a moving average	94
3.2.3	Real-time estimation and asymmetric moving average	94
3.3	Non-parametric regression and local polynomial regression	96
3.3.1	Symmetric moving averages and local polynomial regression	97
3.3.2	Asymmetric moving averages and local polynomial regression	99
3.3.3	Extension with the timeliness criterion	101
3.3.4	Local parametrisation of asymmetric filters	102
3.4	Comparison of different methods	105
3.4.1	Simulated series	106
3.4.2	Comparison	108
3.4.3	Real series	110
3.4.4	Discussion	115
3.5	Conclusion	119
3.6	Annexes	121
3.6.1	Coefficients, gain and phase shift functions	121
3.6.2	Different specifications for the estimation of the slope and concavity	124
3.6.3	Impact of the span used to detect the ARIMA model	128
3.6.4	Nearest neighbour bandwidth	129
3.6.5	Quarterly data	133
4	Estimation de la tendance-cycle avec des méthodes robustes aux points atypiques	135
4.1	Introduction	135
4.2	Méthodologie	136
4.2.1	Méthodes robustes	139
4.2.2	Moyennes mobiles linéaires classiques	141
4.2.3	Construction de moyennes mobiles robustes	144
4.2.4	Construction d'intervalles de confiance pour des moyennes mobiles	147
4.3	Résultats	151
4.3.1	Séries simulées	151
4.3.2	Séries réelles	164
4.4	Conclusion	173
4.5	Annexes	176
4.5.1	Moyennes mobiles utilisées	176
4.5.2	Calcul du degré de liberté de la variance	178
4.5.3	Autres exemples sur des séries réelles	180
4.5.4	Moindres carrés médians (LMS) et moindres carrés élagués (LTS) avec une tendance de degré 2	195
5	Et si l'on publiait la tendance-cycle ?	198
5.1	Introduction	198

5.2	Qu'est-ce que la composante tendance-cycle, pourquoi l'estimer et la publier ?	199
5.3	Comment estimer une tendance-cycle ?	202
5.3.1	Moyenne mobile de Henderson et de Musgrave	203
5.3.2	Cascade Linear Filters (CLF)	206
5.3.3	Que faire en cas de rupture de tendance ?	208
5.3.4	Quelle méthode choisir ?	211
5.4	Recommandations de présentation de la tendance-cycle	212
5.4.1	Refléter l'incertitude des dernières estimations	213
5.4.2	Graphique <i>lollypop</i> (en bâtonnet)	217
5.4.3	Représentation des taux de croissance	218
5.5	Comment mettre en place une chaîne de production automatique ? .	219
5.5.1	Bloc series : informations sur les séries à publier	220
5.5.2	Bloc methods : méthodes d'estimation	221
5.5.3	Bloc plots : paramètres graphiques	223
5.6	Conclusion	224
6	Conclusion générale	227
	Bibliographie	232
	Résumé	239

Remerciements

La réalisation de cette thèse a été le fruit d'un long travail, rendu possible grâce à la rencontre et au soutien de nombreuses personnes que je souhaite ici remercier.

Avant tout, je souhaiterais remercier Dominique, sans qui le projet de cette thèse n'aurait jamais eu lieu. En effet, l'idée de commencer une thèse est arrivée par un concours de circonstances : après deux ans à travailler sur la désaisonnalisation (notamment avec Dominique), j'étais de retour en 2019 sur les bancs de l'école en 2^e année à l'Ensaë. Début 2020, mes plans de stage à l'étranger ayant été annulés du fait du COVID-19, je contactais Dominique pour savoir s'il n'avait pas des idées de travaux qui pourraient faire l'objet d'une thèse et s'il n'aurait pas connaissance d'un potentiel directeur pour celle-ci : c'est ainsi que j'ai réalisé un premier stage pour construire le projet qui a abouti à une inscription en thèse en 2021. Dominique, je te remercie pour tout ton soutien au cours de cette aventure, pour tout ce que tu m'as apporté et de m'avoir aidé à me poser de plus en plus de questions.

Ensuite, je souhaiterais remercier Olivier, mon directeur de thèse, sans qui cette thèse serait restée à l'étape de projet. Merci beaucoup d'avoir accepté de m'encadrer. Tu as toujours fait preuve de gentillesse, de bienveillance et de compréhension (notamment face aux différentes contraintes personnelles et professionnelles qui ralentissaient parfois l'avancement de la thèse). Merci d'avoir été présent et de m'avoir guidé dans ce périple théorique, empirique et administratif, de m'avoir soutenu soutenu dans toutes les pistes explorées.

Merci également à Jean, sans qui cette thèse n'aurait jamais eu cette dimension informatique. Merci de m'avoir introduit dans le monde informatique autour de JDemetra+ et d'avoir fait confiance pour le développement du premier package R associé. Merci également de m'avoir ensuite accueilli en stage pour construire ce sujet de thèse et d'avoir été discutant de mon premier article associé. Tous tes conseils m'ont permis de progresser et d'avoir de nombreuses idées pour la suite de ces travaux.

Une thèse ne pourrait avoir lieu sans un comité de suivi individuel (CSI), merci beaucoup à Marie et Laurent d'avoir accepté ce rôle, sans savoir que cela impliquerait de me suivre tant d'années. Nos échanges ont toujours été très utiles, m'ont permis de mettre en avant des points intéressants de mes travaux, de me recadrer lorsque je me perdais dans les pistes à explorer et de réfléchir à des extensions de mes travaux.

Cette thèse n'aurait jamais été soutenue sans un jury de soutenance. Merci beaucoup à Catherine et Valérie d'avoir accepté le rôle de rapporteur et pour toute l'attention que vous avez portée à mes travaux. Merci à Hamza, Jean et Laurent de compléter ce jury.

Enfin, réaliser cette thèse n'aurait pas eu de sens sans le soutien d'amis et de la famille. Pour ne citer que quelques personnes, merci à Romain d'essayer de me motiver avec la perspective d'un bon repas. Merci à Odile pour tes interrogations sur mes travaux, même si la discussion virait assez rapidement très loin du sujet initial. Merci à mon Papa d'avoir été fier que je me lance dans cette aventure, je sais que tu aurais tant souhaité être présent pour ma soutenance. Merci à ma maman de m'avoir donné l'envie d'apprendre. Merci à Lucie, dont l'arrivée m'a poussé à me dépêcher de finaliser cette thèse, merci de te coucher suffisamment tôt pour que je puisse finaliser la rédaction. Et bien sûr merci à Kim pour ce rayon de soleil quotidien et tes encouragements, me permettant de progresser et d'avoir le courage de terminer tous ces projets. Il y a dix ans, je te remerciais déjà en indiquant que tes cycles d'humeur m'avaient aidé à comprendre les cycles de la conjoncture : la base de données étant aujourd'hui plus grande, j'ai pu me rendre compte des aléas important autour des cycles (de l'irrégulier), nécessitant donc un lissage de la série pour mieux analyser la tendance et la position dans le cycle.

Deux citations résument le cheminement parcouru lors de ce doctorat :


- « La science, mon garçon, est faite d'erreurs, mais d'erreurs qu'il est bon de commettre, car elles mènent peu à peu à la vérité. » prononcée par le professeur Lidenbrock son *Voyage au centre de la Terre*.
- « Croire ou ne pas croire, cela n'a aucune importance. Ce qui est intéressant c'est de se poser de plus en plus de questions. » de l'Encyclopédie du Savoir Relatif et Absolu d'Edmond Wells.

Encore merci à tous ceux qui m'ont aidé à me poser de plus en plus de questions, lors de séminaires, discussions professionnelles ou amicales, de m'avoir permis de faire des erreurs et, directement ou indirectement, de m'avoir encouragé à avancer.

1 Introduction générale

Une *série chronologique* ou *série temporelle* est une suite de valeurs numériques ordonnées dans le temps qui permet d'analyser l'évolution d'une variable au fil du temps. Les séries chronologiques sont utilisées dans de nombreux domaines : économie, finance, météorologie, astronomie, musique... Par exemple, le plus ancien diagramme temporel connu du monde occidental (selon Kendall 1973), reproduit par Funkhouser (1936), daterait du X^e siècle et serait une représentation de l'inclinaison des orbites des planètes en fonction du temps qui proviendrait du *Commentaire au Songe de Scipion* de Macrobie (figure 1.1). Ce diagramme montre des schémas qui semblent se répéter (variations à la hausse et à la baisse à intervalles réguliers), mais ce n'est que bien plus tard, aux XVIII^e et XIX^e siècles, que les techniques mathématiques permettront l'analyse des séries chronologiques, notamment grâce à l'approche fréquentielle.

FIGURE 1.1 – Inclinaison des orbites des planètes en fonction du temps, diagramme du X^e siècle reproduit par Funkhouser (1936)



L'*analyse fréquentielle* (ou *analyse harmonique*) naît grâce à la contribution de Fourier (1822) qui établit que toute fonction du temps peut être décomposée en une somme de termes périodiques exprimés par des fonctions sinusoïdales et cosinusoidales. Avec

le développement du périodogramme, Schuster (1898) montre comment, à partir de la décomposition précédente, on peut mettre en évidence des phénomènes qui se répètent à intervalles réguliers : il montre alors qu'il y a un phénomène cyclique dans les taches solaires. Vingt ans plus tard, Persons (1919) propose une approche globale de décomposition des séries temporelles en quatre composantes inobservables : tendancielle, cyclique, saisonnière et résiduelle (ou irrégulière). Ces quatre composantes sont décrites de la façon suivante :

1. Une *tendance de long terme* ou *tendance séculaire* qui correspond à l'augmentation ou diminution régulière de la série. Elle peut également être appelée *l'élément de croissance*.
2. Un *mouvement ondulatoire* ou *cyclique* qui se superpose à la tendance de long terme, dont les pics sont atteints durant les périodes de prospérité industrielle et les creux pendant les périodes de dépression, constituant ainsi le cycle des affaires.
3. Un *mouvement saisonnier* infra-annuel qui doit être systématique d'une année à l'autre.
4. Des *variations résiduelles* ou *irrégulières* affectant des séries particulières ou des événements majeurs, tels que des guerres ou des catastrophes nationales, affectant plusieurs séries simultanément. Ces variations peuvent aussi provenir d'une grève, de tempêtes ou d'inondations inhabituelles, d'une décision de justice affectant les transactions boursières, etc.

Du fait de la difficulté de séparer la tendance de long terme et le cycle de court terme, la solution utilisée dans les méthodes de désaisonnalisation (dont l'objectif est d'estimer la composante saisonnière afin de la supprimer) est d'estimer ces deux composantes conjointement : on parle alors de composante tendance-cycle. En effet, ces composantes étant inobservables, il n'existe pas de définition unique puisque le concept de « long terme » est relatif (comment différencier un cycle long de la tendance de long terme ?). De façon similaire, comme souligné par Persons (1919), il est également difficile de séparer un cycle court de l'irrégulier. Par ailleurs, les méthodes de construction des séries chronologiques sont périodiquement révisées pour tenir compte des évolutions économiques et sociales : le concept de tendance de long terme peut ainsi perdre de son importance. Par exemple, dans le cadre des enquêtes de conjoncture de l'Insee, la formulation des questions a pu évoluer au cours du temps pour une harmonisation européenne (c'est par exemple le cas de la question sur le taux d'utilisation des capacités de production en 2004 dans l'enquête de conjoncture dans l'industrie), l'enquête de conjoncture dans les services n'est mensuelle que depuis 2000 et il n'y avait pas d'enquête de conjoncture en août avant 2008. Les différentes classifications des produits et des entreprises ont également pu évoluer avec les révisions des différentes nomenclatures. Enfin, séparer la tendance de long terme et le cycle de court terme nécessite d'avoir des séries longues alors que les méthodes de désaisonnalisation peuvent également s'appliquer sur des séries courtes (le logiciel X-13-ARIMA-SEATS peut

s'utiliser dès que l'on a 3 ans de données). La tendance-cycle peut donc également être qualifiée de « tendance de court terme ».

Pour l'estimation des différentes composantes, l'utilisation de moyennes mobiles (ou filtres linéaires) a rapidement été répandue¹, avec notamment Poynting (1884) qui suggère l'utilisation de moyennes mobiles arithmétiques pour réduire les variations résiduelles et Spencer (1904) qui propose l'utilisation de moyennes mobiles spécifiques pour lisser les taux de mortalité. Quelques années plus tard, Henderson (1916) propose des moyennes mobiles, encore utilisées aujourd'hui, maximisant un critère « lissage » (*smoothness*) de la série, sous contrainte de préservation de polynômes de degré 2. Il montre également que le lissage par polynômes locaux est équivalent à l'application de moyennes mobiles et donne les conditions pour que la réciproque soit vérifiée. Tous ces travaux ont conduit au développement d'un premier programme de désaisonnalisation basé sur les moyennes mobiles (voir notamment Shiskin 1957), appelé « Census Method I ». Cette méthode a fait l'objet de nombreuses variantes jusqu'à aboutir à la méthode de désaisonnalisation X-11 (pour une description complète de cette méthode voir notamment Ladiray et Quenneville 2011). Cette dernière est encore utilisée aujourd'hui puisqu'elle constitue le cœur de la méthode de décomposition de l'algorithme X-13-ARIMA-SEATS² (Monsell 2007), qui est [officiellement recommandée](#), avec la méthode paramétrique TRAMO-SEATS, par Eurostat et la Banque Centrale Européenne pour la désaisonnalisation des séries temporelles économiques.

De manière générale, pour les estimations finales, des moyennes mobiles symétriques sont utilisées : c'est-à-dire que pour estimer une composante à la date t , on utilise autant de point dans le passé (avant t) et dans le futur (après t) et que le même poids est donné aux observations passées et futures. Ces moyennes mobiles symétriques ont notamment l'avantage de ne pas créer de déphasage : il n'y a pas de décalage dans la détection des points de retournements³. Toutefois, pour l'estimation en temps réel, les points futurs n'étant pas encore connus, il n'est pas possible de s'appuyer sur des moyennes mobiles symétriques. Une première solution consiste à étendre la série pour ensuite appliquer une moyenne mobile symétrique. Cette solution semble remonter à De Forest (1877) qui suggère également de modéliser, en fin de période, une tendance polynomiale de degré au plus trois⁴. Une seconde solution consiste à utiliser des

1. Mais il ne s'agissait pas de l'unique méthode utilisée : on peut également citer des méthodes basées sur les médianes ou des régressions, comme notamment décrit par Persons.

2. Cet algorithme fonctionne en deux temps. Dans un premier temps, la série est pré-ajustée de plusieurs non-linéarités grâce à un modèle Reg-ARIMA (correction de points atypiques, de ruptures, des effets jours ouvrables non saisonniers, des effets fêtes mobiles, etc.). Dans un second temps, cette série linéarisée est décomposée grâce à la méthode X-11.

3. On parle de point de retournement lorsque l'on passe d'une phase de récession (diminutions successives) à une phase d'expansion de l'économie (augmentations successives) : on parle alors de redressement ou, dans le cas contraire, de ralentissement. Dans le cadre de l'analyse de la tendance-cycle, ces points de retournement sont associés au cycle classique (également appelé cycle des affaires) : voir Ferrara (2009a) pour une description des différents cycles économiques.

4. « *As the first m and last m terms of the series cannot be reached directly by the formula, the*

moyennes mobiles asymétriques (c'est-à-dire que pour l'estimation d'une composante à la date t , on n'utilise pas autant de points avant t et après t) pour prendre en compte le manque de données disponibles. Les prévisions étant des combinaisons linéaires de valeurs passées, ces deux méthodes sont *in fine* équivalentes. La première solution revient donc à appliquer des moyennes mobiles asymétriques dont les coefficients sont obtenus par minimisation de l'erreur quadratique moyenne de révision entre la première et dernière estimation puisque c'est le critère généralement utilisé dans les modèles de prévision. En fonction du cas d'usage, il peut donc être préférable d'utiliser des moyennes mobiles asymétriques spécifiques construites pour minimiser d'autres critères (comme le délai dans la détection de points de retournements). Dans certains cas, une approche hybride peut être utilisée : pour la désaisonnalisation de séries mensuelles, le filtre final de X-13-ARIMA-SEATS permettant d'extraire la composante saisonnière utilise, dans la majorité des cas, 7 ans de données dans le passé et dans le futur. Pour un horizon aussi grand, les prévisions ne sont généralement pas fiables. C'est pourquoi la méthode de désaisonnalisation X-13ARIMA-SEATS ne prolonge la série que de 1 an et utilise, en fin de période, des moyennes mobiles asymétriques spécifiques. En particulier, pour l'estimation de la tendance-cycle, les moyennes mobiles asymétriques associées aux moyennes mobiles de Henderson sont celles définies par Musgrave (1964).

Pour analyser les variations de court terme et les cycles économiques, une pratique courante était d'étudier les séries brutes en glissement annuel. Cette méthode est à proscrire car cela n'élimine pas tous les effets saisonniers. Par exemple, certains jours fériés, comme par Pâques, ne tombent pas le même jour, voire le même mois chaque année : si la date de ce jour influence la série étudiée, l'analyse en glissement annuel peut être trompeuse.

De façon similaire, l'analyse en glissement annuel ne tient pas compte des effets de jours ouvrables. Par exemple, la production de nombreuses entreprises est plus faible le samedi et le dimanche qu'en semaine. En 2023, le mois de mars contenait 8 samedis et dimanche alors qu'en 2024 il en contenait 10 : la simple analyse en glissement annuel ne tient pas compte de ces différences et pourrait donc conduire à une analyse erronée des variations.

Enfin, même lorsque les séries ne présentent aucun effet de calendrier, l'analyse en glissement annuel peut poser problème. D'une part, elle peut induire en erreur lorsque la composante irrégulière est importante (une valeur particulière est observée à une période donnée, par exemple pendant le COVID-19). D'autre part, les points de retournements (point à partir duquel une série croissante commence à décroître ou

series should be graphically extended by m terms at both ends, first plotting the observations on paper as ordinates, and then extending the curve along what seems to be its probable course, and measuring the ordinates of the extended portions. It is not necessary that this extension should coincide with what would be the true course of the curve in those parts. The important point is that the m terms thus added, taken together with the $m + 1$ adjacent given terms, should follow a curve whose form is approximately algebraic and of a degree not higher than the third. »

une série décroissante commence à croître) sont détectés avec retard en utilisant les glissements annuels (le risque est de ne pas voir les points de retournement sur l'année en cours). Par exemple, si la série brute est plus élevée en mars 2024 qu'en mars 2023, l'analyse en glissement annuel pourrait amener à conclure que l'activité a augmenté au cours de l'année alors qu'elle pourrait avoir augmenté jusqu'en septembre 2023 puis commencé à diminuer progressivement.

Toutes ces raisons font que la majorité des instituts statistiques publient des séries désaisonnalisées : on parle alors de séries corrigées des variations saisonnières et corrigées des jours ouvrables (CVS-CJO).

Par construction, la désaisonnalisation laisse l'effet conjoint de la tendance-cycle et de l'irrégulier. Lorsque la variabilité de la série est importante (i.e., lorsque l'irrégulier est important), il peut être difficile, à partir de la série CVS-CJO, de déterminer la direction de la tendance de court terme et d'évaluer la présence de points de retournement. Dans ce cas, il peut être utile de lisser la série CVS-CJO afin de retirer l'irrégulier et d'estimer la composante tendance-cycle. Estimer et publier la tendance-cycle, en plus de la série désaisonnalisée, présente de nombreux avantages :

1. Réduire le risque que les utilisateurs tirent des conclusions inappropriées sur la base de mouvements liés à l'irrégulier.
2. Permettre une comparaison appropriée dans le temps en réduisant l'impact des événements ponctuels.
3. Améliorer la compréhension et la détection des points de retournement.

Même si les méthodes de désaisonnalisation fournissent directement des estimations de la tendance-cycle, les rares instituts publiant régulièrement cette composante, Statistique Canada et Australian Bureau of Statistics, appliquent plutôt des moyennes mobiles à la série CVS-CJO (Picard et Matthews 2016, Australian Bureau of Statistics 2003). Cela a notamment l'avantage de simplifier le processus d'estimation de cette composante puisqu'il suffit de communiquer les coefficients des moyennes mobiles utilisées pour reproduire les résultats.

L'objectif de cette thèse, composée de quatre articles, est d'étudier et de comparer différentes méthodes de construction de moyennes mobiles asymétriques permettant l'estimation en temps réel de la tendance-cycle. L'intérêt est donc porté sur les estimations intermédiaires (i.e., lorsque des moyennes mobiles asymétriques doivent être utilisées, faute d'observations futures connues) plutôt que sur les estimations finales (i.e., lorsque des moyennes mobiles symétriques peuvent être utilisées). Tout d'abord, différentes méthodes récemment développées pour la construction de moyennes mobiles pour l'estimation de la tendance-cycle sont étudiées et comparées. Puis, nous montrons notamment comment la moyenne asymétrique de Musgrave (utilisée dans X-13-ARIMA-SEATS) peut être paramétrée localement afin de réduire les révisions et le délai de détection des points de retournement. Ensuite, nous étudions l'impact des points atypiques sur l'estimation de la tendance-cycle et montrons comment

les moyennes mobiles de Henderson et de Musgrave peuvent être étendues afin de modéliser ces chocs et ainsi réduire les révisions et mieux modéliser les points de retournement. Enfin, nous discutons des recommandations pour la mise en production de la composante tendance-cycle et de la façon de mettre en place une chaîne de production, en l’appliquant à une dizaine de publications de l’Insee.

Estimation de la tendance-cycle et formule générale de construction des moyennes mobiles

Ce premier article décrit et compare différentes approches récemment développées pour la construction de moyennes mobiles pour l’estimation de la tendance-cycle. Trois approches sont étudiées et comparées :

1. Moyennes mobiles obtenues grâce à l’approximation polynomiale locale (Proietti et Luati 2008, Gray et Thomson 1996).
2. Moyennes mobiles obtenues en utilisant la théorie des espaces de Hilbert à noyau reproduisant (RKHS, Dagum et Bianconcini 2008).
3. L’approche *Fidelity-Smoothness-Timeliness* (FST, Grun-Rehomme et alii 2018) sur une optimisation d’une somme pondérée de critères de qualités des moyennes mobiles.

Une quatrième approche, l’approche *Accuracy, Timeliness, Smoothness* (ATS, Wildi et McElroy 2019), est également décrite mais n’est pas comparées aux autres. En effet, celle-ci dépendant totalement des données, elle peut donc, contrairement aux autres méthodes, plus difficilement s’intégrer dans la logique des algorithmes non-paramétriques tels que X-11 qui s’appuient sur des moyennes mobiles.

Bien que toutes ces méthodes aient été présentées avec des approches générales de construction des moyennes mobiles (elles permettent par exemple toutes de reproduire la moyenne mobile de Henderson), leurs propriétés théoriques et leurs performances empiriques n’ont jamais été comparées.

La comparaison théorique des méthodes est réalisée en développant une formulation générale de construction des moyennes mobiles, permettant de mettre en évidence les équivalences entre les différentes méthodes.

Les méthodes polynomiales ont l’avantage d’être simples et facilement compréhensibles. Elles peuvent également prendre en compte des problèmes complexes (comme l’autocorrélation induite par l’utilisation d’un plan de sondage rotatif avec une période de recouvrement). En revanche, l’inconvénient est que le déphasage ne peut pas être contrôlé (ce qui peut introduire des délais plus importants dans la détection des points de retournement). Cette étude propose également deux extensions de ces méthodes polynomiales qui seront davantage mises en avant dans le deuxième article de cette

thèse.

Concernant les autres approches étudiées, les RKHS permettent de construire facilement des filtres adaptés à toutes les fréquences (y compris des fréquences irrégulières) mais ont notamment l'inconvénient d'être numériquement instables (des problèmes d'optimisation peuvent apparaître).

La méthode FST a l'avantage d'être analytiquement soluble mais a l'inconvénient d'être plus difficilement paramétrisable car les différents critères utilisés ne sont pas normalisés : les poids associés aux différents critères n'ont donc pas de sens.

Les estimations de tendance-cycle issues de ces méthodes sont également comparées empiriquement sur des séries mensuelles, simulées et réelles, selon deux critères :

1. Le déphasage. Celui-ci est habituellement défini comme le nombre de mois nécessaires pour détecter un point de retournement. Cette définition a l'inconvénient de ne pas prendre en compte les cas où il y aurait des révisions dans la détection du point de retournement lors des estimations intermédiaires successives (ce qui peut être notamment le cas avec filtres issus des RKHS) ou lorsque le point de retournement est détecté lors des estimations intermédiaires mais pas avec l'estimation finale (avec une moyenne mobile symétrique). Le déphasage est donc défini dans cet article comme le nombre de mois nécessaires pour détecter un point de retournement sans révision future. En minimisant le déphasage sur des séries simulées, ce critère est également utilisé pour obtenir des poids associés aux différents critères de la méthode FST.
2. Les révisions. Celles-ci sont mesurées par rapport à la dernière estimation finale mais également entre deux estimations intermédiaires successives. Cela permet de mettre en évidence des sous-optimalités dans certaines méthodes lorsque l'on se rapproche de l'estimation finale (par exemple avec filtres issus des RKHS ou lorsque l'on applique une moyenne mobile symétrique sur une série prolongée).

Cet article s'accompagne d'un *package* R, [rjd3filters](#), permettant de facilement mettre en œuvre les différentes méthodes et reproduire les résultats.

Amélioration des estimations de tendance-cycle grâce à la paramétrisation locale des filtres de régression polynomiale

La régression polynomiale locale permet de reproduire la moyenne mobile symétrique de Henderson et les moyennes mobiles asymétriques de Musgrave, utilisées dans l'algorithme de désaisonnalisation X-13ARIMA-SEATS. Ce deuxième article se concentre deux extensions de ces méthodes :

1. En ajoutant un critère permettant de contrôler le déphasage, grâce au critère de *Timeliness* de la méthode FST. Le poids associé à ce critère devant être défini par l'utilisateur et étant difficilement paramétrisable (car le critère utilisé n'est pas normalisé), cette extension n'est pas étudiée empiriquement dans cet article mais uniquement de manière théorique.
2. En proposant une procédure permettant de paramétrer localement les moyennes mobiles asymétriques. Les moyennes mobiles asymétriques sont en effet construites en utilisant un compromis biais-variance et dépendent d'un paramètre, associé au biais, devant être défini par l'utilisateur. Par exemple, les moyennes mobiles de Musgrave modélisent une tendance locale de degré 1 et reproduisent sans biais les constantes : le paramètre à définir correspond au rapport entre le coefficient associé à la pente et l'écart-type du résidu de la régression locale. Ce paramètre est généralement défini globalement (i.e., le paramètre est constant pour toutes les moyennes mobiles). Par exemple, dans X-13ARIMA-SEATS, ce paramètre ne dépend que de la longueur de la moyenne mobile de Henderson. Cette hypothèse n'est cependant pas plausible pour les estimations en temps réel et notamment autour des points de retournement (lors desquels la pente tend vers 0).

La comparaison des estimations en temps réel de la tendance-cycle sur des séries mensuelles simulées et réelles montre que cette seconde extension permet de réduire le délai de la détection des points de retournement et que, même lorsque les délais ne sont pas réduits, elle permet de réduire les révisions. Sur des séries trimestrielles, la fenêtre des moyennes mobiles étant réduite (i.e., moins de points sont utilisés pour l'estimation), les différentes méthodes de construction de moyennes mobiles asymétriques donnent des résultats similaires.

Toutefois, l'analyse des résultats sur des périodes à fortes turbulences, comme durant le COVID-19, montre que les estimations de la tendance-cycle peuvent être fortement biaisées par la présence de points atypiques importants, pouvant conduire à une détection erronée des points de retournement (dans le cadre du COVID-19, pic détecté trop tôt). Cela suggère donc de prendre en compte les points atypiques lorsque l'irrégulier est important.

Estimation de la tendance-cycle avec des méthodes robustes aux points atypiques

Comme tout opérateur linéaire, les moyennes mobiles sont fortement sensibles à la présence de points atypiques. C'est pourquoi la méthode de désaisonnalisation X-13ARIMA-SEATS possède deux modules de correction des points atypiques :

1. Un module de pré-ajustement où la série initiale est notamment corrigée des ruptures en niveau (affectant la tendance-cycle) et des chocs ponctuels (affectant l'irrégulier) mais aussi d'autres formes de ruptures (changements transitoires, ruptures de saisonnalité, etc.).
2. Cette série pré-ajustée est ensuite décomposée avec la méthode X-11, qui aussi possède un algorithme de correction des chocs ponctuels.

Lorsque la série est affectée par des chocs importants l'application directe de moyennes mobiles pour l'estimation de la tendance-cycle peut donc conduire à des estimations biaisées et à un diagnostic conjoncturel faussé (par exemple points de retournement détectés à la mauvaise date). C'est notamment pourquoi Statistique Canada et l'Australian Bureau of Statistics ont arrêté la publication de la composante tendance-cycle durant la crise du COVID-19.

L'objectif de cette étude est d'étudier et de comparer différentes approches permettant l'extraction de tendance-cycle en temps-réel. Nous décrivons également construction des moyennes mobiles linéaires, associées aux moyennes mobiles de Henderson et de Musgrave, qui prennent en compte des informations extérieures, permettant notamment de modéliser des chocs et donc de les rendre robustes à ces derniers. Cela permet notamment de correctement modéliser les points de retournements autour des chocs (par exemple durant le COVID-19) et de réduire les révisions. Cette étude montre comment construire des intervalles de confiance pour les estimations basées sur des moyennes mobiles et ainsi valider l'hypothèse retenue sur la modélisation de chocs. Ces moyennes mobiles sont également comparées à des méthodes non-linéaires robustes.

Et si l'on publiait la tendance-cycle ?

Qu'est-ce que la composante tendance-cycle ? Quel est l'intérêt de publier cette composante ? Comment l'estimer ? Quels sont les instituts qui publient cette composante et quelles méthodes utilisent-ils ? Y a-t-il des recommandations pour la publication de cette composante ? Comment concrètement mettre en place une chaîne de production de cette composante ? C'est à toutes ces questions que répond ce quatrième article.

Seuls deux instituts statistiques publient régulièrement la composante tendance-cycle : Statistique Canada et l'Australian Bureau of Statistics. Pour cela, ces deux instituts appliquent des moyennes mobiles à la série désaisonnalisée et corrigée des jours ouvrables (CVS-CJO) : les *cascade linear filter* (CLF) pour Statistique Canada (en utilisant la méthode « couper-et-normaliser » pour les estimations en temps réel) et la moyenne mobile de Henderson pour l'Australian Bureau of Statistics (en utilisant les moyennes mobiles de Musgrave pour les estimations en temps réel). Cette publication se fait conjointement aux séries CVS-CJO (et non en remplacement) et a de nombreux avantages, en particulier :

- Réduire le risque que les utilisateurs tirent des conclusions inappropriées en période de forte volatilité en leur permettant de distinguer les évolutions expliquées par l'irrégulier de celles de la tendance-cycle.
- Améliorer la compréhension et la détection des points de retournement.

Cet article décrit plusieurs recommandations de représentation de la tendance-cycle permettant de mettre en évidence l'incertitude autour des dernières estimations (intervalles de confiance, prévisions implicites) ou de mettre en évidence les points de retournement. Il montre comment mettre en place ces recommandations grâce au *package* R [publishTC](#) accompagnant cette étude. Celui-ci permet également de facilement reproduire les méthodes d'estimation de la tendance-cycle utilisées par Statistique Canada et l'Australian Bureau of Statistics, ainsi que les extensions des moyennes mobiles de Henderson/Musgrave proposées dans cette thèse :

1. Paramétrisation locale des moyennes mobiles asymétriques de Musgrave ;
2. Prise en compte des ruptures de niveau et des chocs ponctuels ;
3. Combinaison des deux extensions précédentes.

L'étude explique également comment mettre en place une production automatique de la composante tendance-cycle, grâce à la création de rapports automatisés. La maquette de production mise en place dans étude est appliquée à une dizaine de publications de l'Insee (environ 80 séries).

2 Estimation de la tendance-cycle et formule générale de construction des moyennes mobiles¹

2.1 Introduction

L'analyse du cycle économique, et en particulier la détection rapide des points de retournement d'une série, est un sujet de première importance dans l'analyse de la conjoncture économique. Pour cela, les indicateurs économiques sont généralement corrigés des variations saisonnières. Toutefois, afin d'améliorer leur lisibilité, il peut être nécessaire d'effectuer un lissage supplémentaire afin de réduire le bruit, et ainsi analyser la composante tendance-cycle. Par construction, les méthodes d'extraction de tendance-cycle sont étroitement liées aux méthodes de désaisonnalisation. En effet, afin d'estimer la composante saisonnière, les algorithmes de désaisonnalisation estiment préalablement une composante tendance-cycle. Ainsi, même si les méthodes d'extraction de tendance-cycle sont généralement appliquées sur des séries corrigées des variations saisonnières, l'estimation de ces séries dépend également des méthodes d'estimation de la tendance-cycle.

Les moyennes mobiles, ou les filtres linéaires, sont omniprésents dans les méthodes d'extraction du cycle économique et d'ajustement saisonnier². Ainsi, la méthode de désaisonnalisation X-13ARIMA-SEATS utilise des moyennes mobiles de Henderson et des moyennes mobiles composites pour estimer les principales composantes d'une série chronologique. Au centre de la série, des filtres symétriques sont appliqués. Pour l'extraction de la tendance-cycle, le filtre symétrique le plus connu est celui de Henderson (1916), notamment utilisé dans l'algorithme de désaisonnalisation X-13ARIMA.

1. Références de l'article : Quartier-la-Tente A (2024), *Estimation en temps réel de la tendance-cycle : apport de l'utilisation des moyennes mobiles asymétriques*, Document de travail Insee, M2024/01. <https://github.com/InseeFrLab/DT-est-tr-tc>.

2. Une moyenne mobile est une méthode statistique qui consiste à appliquer une moyenne pondérée glissante à une série temporelle : à chaque date t on calcule une moyenne pondérée de p points passés et q points futurs où $p, q \geq 0$ dépend de la moyenne mobile.

En revanche, pour les estimations en temps réel, en raison de l'absence d'observations futures, toutes ces méthodes doivent s'appuyer sur des filtres asymétriques pour estimer les points les plus récents. Par exemple, même si X-13ARIMA-SEATS applique des moyennes symétriques aux prévisions obtenues à partir d'un modèle ARIMA, cela revient à appliquer des filtres asymétriques en fin de série, car les valeurs prédites sont des combinaisons linéaires de valeurs passées.

Si ces moyennes mobiles asymétriques ont de bonnes propriétés concernant la taille des révisions futures induites par le processus de lissage³, elles induisent également, par construction, des déphasages qui retardent en général la détection en temps réel des points de retournement.

L'objectif de cette étude est de décrire et de comparer les approches récentes permettant l'extraction de tendance-cycle en temps-réel. Après une description des propriétés générales d'un filtre linéaire (section 2.2), différentes méthodes seront présentées : filtres polynomiaux locaux, filtres fondés sur les espaces de Hilbert à noyau reproduisant (RKHS, section 2.3) et méthodes fondées sur une optimisation des propriétés des filtres — *Fidelity-Smoothness-Timeliness* (FST, section 2.4) et *Accuracy, Timeliness, Smoothness* (ATS, section 2.5).

Bien que ces méthodes aient été présentées avec des approches générales de construction des filtres linéaires, leurs propriétés théoriques et leurs performances empiriques n'ont pas été comparées. Cette étude décrit l'ensemble de ces méthodes en développant une formulation générale pour la construction des filtres, permettant de mettre en exergue les spécificités de chacune.

Ainsi, les méthodes polynomiales ont l'avantage d'être simples et facilement compréhensibles. Elles peuvent également prendre en compte des problèmes complexes (comme l'autocorrélation induite par l'utilisation d'un plan de sondage rotatif avec une période de recouvrement). En revanche, l'inconvénient est que le déphasage ne peut pas être contrôlé (ce qui peut introduire des délais plus importants dans la détection des points de retournement). Cette analyse montre aussi comment les filtres polynomiaux peuvent être étendus en ajoutant un critère permettant de contrôler le déphasage ou en les paramétrisant localement.

Les RKHS permettent de construire facilement des filtres adaptés à toutes les fréquences (y compris des fréquences irrégulières) mais ont notamment l'inconvénient d'être numériquement instables (des problèmes d'optimisation peuvent apparaître, comme dans la méthode FST).

La méthode FST a l'avantage d'être analytiquement soluble mais a l'inconvénient d'être plus difficilement paramétrisable car les différents critères utilisés ne sont pas normalisés : les poids associés aux différents critères n'ont donc pas de sens.

Enfin, dans une dernière partie (section 2.6), toutes ces méthodes sont comparées empiriquement sur des séries simulées et sur des séries réelles désaisonnalisées. En raison du lien entre désaisonnalisation et extraction de la tendance-cycle, les applications

3. Voir par exemple Pierce (1980).

pratiques se concentreront sur les méthodes non-paramétriques qui pourraient être incluses dans X-13ARIMA-SEATS (la méthode ATS, paramétrique, est donc exclue). Cette analyse permet tout d'abord de montrer comment les problèmes d'optimisation des filtres issus des RKHS peuvent conduire à des filtres sous-optimaux (augmentation des révisions et du délai dans la détection des points de retournement). Ensuite, la méthode proposée pour paramétrer localement les filtres polynomiaux permet à la fois de détecter plus rapidement les points de retournement et de réduire les révisions dans les estimations successives de la tendance-cycle. Enfin, les résultats montrent que les futures études sur les méthodes d'estimations de la tendance-cycle peuvent probablement se restreindre à celles qui modélisent des tendances locales de degré au plus 2 : modéliser des tendances plus complexes aboutit à plus de révisions sans gain en termes de détection des points de retournement.

Cette étude est reproductible. Tous les codes utilisés sont disponibles sous <https://github.com/InseeFrLab/DT-est-tr-tc>. Par ailleurs, toutes les méthodes décrites sont implémentées dans le *package* R `rjd3filters`⁴ qui accompagne cette étude. Celui-ci propose également plusieurs outils pour manipuler les moyennes mobiles et évaluer la qualité des estimations.

2.2 Quelques propriétés sur les moyennes mobiles

Cette section présente les définitions et les propriétés des moyennes mobiles utiles pour comprendre les méthodes présentées dans les prochaines sections. Pour plus de détails sur les moyennes mobiles, voir par exemple Ladiray (2018).

Soient deux entiers p et f . Une *moyenne mobile* M_{θ} est un opérateur linéaire défini par un ensemble de coefficients $\theta = (\theta_{-p}, \dots, \theta_f)'$ qui transforme toute série temporelle X_t en :

$$M_{\theta}(X_t) = \sum_{k=-p}^{+f} \theta_k X_{t+k}.$$

On a les définitions suivantes :

- La quantité $p + f + 1$ est appelée *ordre de la moyenne mobile*.
- Lorsque $p = f$ la moyenne mobile est dite *centrée*. Si de plus on a $\forall k : \theta_{-k} = \theta_k$, la moyenne mobile M_{θ} est dite *symétrique*. Dans ce cas, la quantité $p = f$ est appelée *fenêtre (bandwidth)*.

4. <https://github.com/rjdverse/rjd3filters>.

2.2.1 Fonctions de gain et de déphasage

Pour interpréter les notions de gain et de déphasage, il est utile d'illustrer les effets des moyennes mobiles sur les séries harmoniques $X_t = e^{-i\omega t}$ avec $\omega \in [0, \pi]$. La moyenne mobile M_θ transforme X_t en :

$$Y_t = M_\theta X_t = \sum_{k=-p}^{+f} \theta_k e^{-i\omega(t+k)} = \left(\sum_{k=-p}^{+f} \theta_k e^{-i\omega k} \right) \cdot X_t.$$

La fonction $\Gamma_\theta(\omega) = \sum_{k=-p}^{+f} \theta_k e^{-i\omega k}$ est appelée *fonction de transfert* ou *fonction de réponse en fréquence* (*frequency response function*)⁵. Elle peut être réécrite en :

$$\Gamma_\theta(\omega) = \rho_\theta(\omega) e^{i\varphi_\theta(\omega)},$$

où $\rho_\theta(\omega) = G_\theta(\omega) = |\Gamma_\theta(\omega)|$ est la fonction de *gain* ou *d'amplitude* et $\varphi_\theta(\omega)$ est le *déphasage* (*phase shift* ou *time shift*)⁶. Pour tous les filtres symétriques on a $\varphi_\theta(\omega) \equiv 0 \pmod{\pi}$. En effet, la contribution du couple de termes d'ordre $k > 0$ s'écrit $\theta_k e^{i\omega k} + \theta_k e^{-i\omega k} = 2\theta_k \cos(\omega k)$, sa partie imaginaire est donc nulle. Le terme d'ordre 0 étant θ_0 , la partie imaginaire de la fonction $\Gamma_\theta(\omega)$ est nulle pour tout $\omega \in \mathbb{R}$ et donc $\varphi_\theta(\omega) \equiv 0 \pmod{\pi}$.

En somme, appliquer une moyenne mobile à une série harmonique (de la forme $X_t = e^{-i\omega t}$) la modifie de deux façons :

- en la multipliant par un coefficient égal à $\rho_\theta(\omega)$ (gain) ;
- en la « décalant » dans le temps de $\varphi_\theta(\omega)/\omega$, ce qui a un impact sur la détection des points de retournement (déphasage)⁷.

La décomposition de Fourier permet d'analyser toute série temporelle (stationnaire ou stationnaire autour d'une tendance) comme une somme de séries harmoniques et chaque composante (tendance, cycle, saisonnalité, irrégulier) est associée à un ensemble de fréquences. En effet, en notant $\omega = 2\pi/p$, la série harmonique de fréquence ω représente une série qui se répète toutes les p périodes. Par exemple, pour une série mensuelle (12 observations par an), les mouvements saisonniers sont ceux qui se répètent chaque année : ils sont donc associés aux fréquences $2\pi/12$ (périodicité annuelle), $2\pi/12 \times 2 = 2\pi/6, \dots, 2\pi/12 \times 5$. Nous considérons que la tendance-cycle est associée aux fréquences dans l'intervalle $[0, 2\pi/12[$, c'est-à-dire aux mouvements

5. La fonction de transfert peut être définie de manière équivalente par $\Gamma_\theta(\omega) = \sum_{k=-p}^{+f} \theta_k e^{i\omega k}$ ou $\Gamma_\theta(\omega) = \sum_{k=-p}^{+f} \theta_k e^{2\pi i \omega k}$.


6. Cette fonction est parfois définie comme $\phi_\theta(\omega) = \frac{\varphi_\theta(\omega)}{\omega}$ pour mesurer le déphasage en termes de période.

7. Lorsque $\varphi_\theta(\omega)/\omega < 0$ le déphasage est négatif : le point de retournement est détecté avec retard.

se répétant au moins tous les 12 mois⁸. Les autres fréquences, $[2\pi/12, \pi]$, sont ici associées à l'irrégulier (oscillations indésirables).

La figure 2.1 montre la fonction de gain et de déphasage pour le filtre asymétrique de Musgrave (voir section 2.3.1.2) souvent utilisé pour l'estimation en temps-réel de la tendance-cycle (c'est-à-dire lorsqu'aucun point dans le futur n'est connu). La fonction de gain est supérieure ou égale à 1 sur les fréquences associées à la tendance-cycle ($[0, 2\pi/12]$) : cela signifie que la tendance-cycle est bien conservée et que les cycles courts de 1 à 2 ans ($[2\pi/24, 2\pi/12]$) sont mêmes amplifiés. En revanche, les cycles de 8 à 12 mois ($[2\pi/12, 2\pi/8]$), considérés comme indésirables car associés à l'irrégulier, sont également amplifiés : cela peut engendrer la détection de faux points de retournement. Sur les autres fréquences, la fonction de gain est inférieure à 1 mais toujours positive : cela signifie que la série lissée par cette moyenne mobile contiendra toujours du bruit, même si celui-ci est atténué. L'analyse du déphasage montre que le déphasage est d'autant plus élevé que les cycles sont courts : cela signifie que sur les séries lissées par cette moyenne mobile, les points de retournement pourraient être détectés à la mauvaise date.

FIGURE 2.1 – Coefficients, fonction de gain et de déphasage pour le filtre de Musgrave en temps réel avec $I/C = 3, 5$.



8. Même si des fréquences différentes sont parfois retenues (par exemple $[0, 2\pi/36]$ pour ne considérer que les cycles d'au moins 36 mois), cela n'a pas d'impact sur les différentes simulations.

2.2.2 Propriétés souhaitables d'une moyenne mobile

Pour décomposer une série temporelle en une composante saisonnière, une tendance-cycle et l'irrégulier, l'algorithme de décomposition X-11 (utilisé dans X-13ARIMA) utilise une succession de moyennes mobiles ayant toutes des contraintes spécifiques.

Dans notre cas, on suppose que notre série initiale y_t est désaisonnalisée et peut s'écrire comme la somme d'une tendance-cycle, TC_t , et d'une composante irrégulière, I_t :

$$y_t = TC_t + I_t.$$

L'objectif va notamment être de construire des moyennes mobiles préservant au mieux la tendance-cycle ($M_\theta(TC_t) \simeq TC_t$) et réduisant au maximum le bruit ($M_\theta(I_t) \simeq 0$).

2.2.2.1 Préservation de tendances

Les tendances-cycles sont généralement modélisés par des tendances polynomiales locales (voir section 2.3). Afin de conserver au mieux les tendances-cycles, on cherche à avoir des moyennes mobiles qui conservent les tendances polynomiales. Une moyenne mobile M_θ conserve une fonction du temps $f(t)$ si $\forall t : M_\theta f(t) = f(t)$.

Nous avons les propriétés suivantes pour la moyenne mobile M_θ :

- Pour conserver les constantes $X_t = a$ il faut :

$$\forall t : M_\theta(X_t) = \sum_{k=-p}^{+f} \theta_k X_{t+k} = \sum_{k=-p}^{+f} \theta_k a = a \sum_{k=-p}^{+f} \theta_k = a.$$

C'est-à-dire qu'il faut que la somme des coefficients $\sum_{k=-p}^{+f} \theta_k$ soit égale à 1.

- Pour conserver les tendances linéaires $X_t = at + b$ il faut :

$$\forall t : M_\theta(X_t) = \sum_{k=-p}^{+f} \theta_k X_{t+k} = \sum_{k=-p}^{+f} \theta_k [a(t+k) + b] = a \sum_{k=-p}^{+f} k \theta_k + (at+b) \sum_{k=-p}^{+f} \theta_k = at+b.$$

Ce qui est équivalent à :

$$\sum_{k=-p}^{+f} \theta_k = 1 \quad \text{et} \quad \sum_{k=-p}^{+f} k \theta_k = 0.$$

- De manière générale, M_θ conserve les tendances de degré d si et seulement si :

$$\sum_{k=-p}^{+f} \theta_k = 1 \quad \text{et} \quad \forall j \in \llbracket 1, d \rrbracket : \sum_{k=-p}^{+f} k^j \theta_k = 0.$$

- Si M_θ est symétrique ($p = f$ et $\theta_{-k} = \theta_k$ pour tout k) et conserve les tendances de degré $2d$ alors elle conserve aussi les tendances de degré $2d + 1$ car :

$$\sum_{k=-p}^{+p} k^{2d+1} \theta_k = 0 \times \theta_0 + \sum_{k=1}^{+p} k^{2d+1} \theta_k + \sum_{k=1}^{+p} (-1) \times k^{2d+1} \underbrace{\theta_{-k}}_{=\theta_k} = 0.$$

2.2.2.2 Réduction du bruit

Toutes les séries temporelles sont affectées par du bruit qui peut brouiller l'extraction de la tendance et du cycle. C'est pourquoi on cherche à réduire ce bruit (en réduisant sa variance) tout en conservant les évolutions pertinentes. La somme des carrés des coefficients $\sum_{k=-p}^{+f} \theta_k^2$, généralement inférieure ou égale à 1, est le rapport de *réduction de la variance*.

En effet, soit $\{\varepsilon_t\}$ une suite de variables aléatoires indépendantes avec $\mathbb{E}[\varepsilon_t] = 0$, $\mathbb{V}[\varepsilon_t] = \sigma^2$. On a :

$$\mathbb{V}[M_\theta \varepsilon_t] = \mathbb{V}\left[\sum_{k=-p}^{+f} \theta_k \varepsilon_{t+k}\right] = \sum_{k=-p}^{+f} \theta_k^2 \mathbb{V}[\varepsilon_{t+k}] = \sigma^2 \sum_{k=-p}^{+f} \theta_k^2.$$

2.2.3 Estimation en temps réel et moyennes mobiles asymétriques

2.2.3.1 Moyennes mobiles asymétriques et prévision

Pour les filtres symétriques, la fonction de déphasage est égale à zéro (modulo π). Il n'y a donc aucun retard dans la détection de points de retournement. Du fait du manque de données disponibles, ils ne peuvent toutefois pas être utilisés au début et à la fin de la série.

Pour l'estimation en temps réel, plusieurs approches peuvent être utilisées :

1. Utiliser des moyennes mobiles asymétriques pour prendre en compte le manque de données disponibles ;
2. Appliquer les filtres symétriques sur les séries prolongées par prévision. Cette méthode semble remonter à De Forest (1877) qui suggère également de modéliser en fin de période une tendance polynomiale de degré au plus trois⁹. C'est éga-

9. « As the first m and last m terms of the series cannot be reached directly by the formula, the series should be graphically extended by m terms at both ends, first plotting the observations on paper as ordinates, and then extending the curve along what seems to be its probable course, and measuring the ordinates of the extended portions. It is not necessary that this extension should coincide with what would be the true course of the curve in those parts. The important point is that the m terms thus added, taken together with the $m + 1$ adjacent given terms, should follow a curve whose form is approximately algebraic and of a degree not higher than the third. »

lement l'approche utilisée dans la méthode de désaisonnalisation X-13ARIMA qui prolonge la série sur 1 an par un modèle ARIMA.

In fine, la seconde méthode revient à utiliser des moyennes mobiles asymétriques puisque les prévisions sont des combinaisons linéaires du passé.

Inversement, à partir d'une moyenne mobile symétrique de référence, on peut déduire les **prévisions implicites** d'une moyenne mobile asymétrique. Cela permet notamment de juger de la qualité des estimations en temps réel de la tendance-cycle et d'anticiper les futures révisions lorsque les prévisions sont éloignées des évolutions attendues.

Notons $\mathbf{v} = (v_{-h}, \dots, v_h)$ la moyenne mobile symétrique de référence et $\mathbf{w}^0, \dots, \mathbf{w}^{h-1}$ une suite de moyennes mobiles asymétriques, d'ordre $h+1$ à $2h$ utilisée pour l'estimation des h derniers points avec, pour convention, $w_t^q = 0$ pour $t > q$. C'est-à-dire que $\mathbf{w}^0 = (w_{-h}^0, \dots, w_0^0)$ est utilisée pour l'estimation en temps réel (lorsqu'on ne connaît aucun point dans le futur), $\mathbf{w}^1 = (w_{-h}^1, \dots, w_1^1)$ pour l'estimation de l'avant-dernier point (lorsqu'on ne connaît qu'un point dans le futur), etc. Notons également $y_{-h}, \dots, y_0$ la série étudiée observée et $y_1^*, \dots, y_h^*$ la prévision implicite induite par $\mathbf{w}^0, \dots, \mathbf{w}^{h-1}$. Cela signifie, que pour tout q on a :

$$\forall q, \quad \underbrace{\sum_{i=-h}^0 v_i y_i + \sum_{i=1}^h v_i y_i^*}_{\text{lissage par } v \text{ de la série prolongée}} = \underbrace{\sum_{i=-h}^0 w_i^q y_i + \sum_{i=1}^h w_i^q y_i^*}_{\text{lissage par } w^q \text{ de la série prolongée}}.$$

Ce qui est équivalent à :

$$\forall q, \quad \sum_{i=1}^h (v_i - w_i^q) y_i^* = \sum_{i=-h}^0 (w_i^q - v_i) y_i.$$

En somme, matriciellement, cela revient donc à résoudre :

$$\begin{pmatrix} v_1 & v_2 & \cdots & v_h \\ v_1 - w_1^1 & v_2 & \cdots & v_h \\ \vdots & \vdots & \cdots & \vdots \\ v_1 - w_1^{h-1} & v_2 - w_2^{h-1} & \cdots & v_h \end{pmatrix} \begin{pmatrix} y_1^* \\ \vdots \\ y_h^* \end{pmatrix} = \begin{pmatrix} w_{-h}^0 - v_{-h} & w_{-(h-1)}^0 - v_{-(h-1)} & \cdots & w_0^0 - v_0 \\ w_{-h}^1 - v_{-h} & w_{-(h-1)}^1 - v_{-(h-1)} & \cdots & w_0^1 - v_0 \\ \vdots & \vdots & \cdots & \vdots \\ w_{-h}^{h-1} - v_{-h} & w_{-(h-1)}^{h-1} - v_{-(h-1)} & \cdots & w_0^{h-1} - v_0 \end{pmatrix} \begin{pmatrix} y_{-h} \\ \vdots \\ y_0 \end{pmatrix}.$$

C'est ce qui implémenté dans la fonction `rjd3filters::implicit_forecast()`.

Comme notamment souligné par Wildi et Schips (2004), étendre la série par prévision d'un modèle ARIMA revient à calculer des filtres asymétriques dont les coefficients sont optimisés par rapport à la prévision à horizon d'une période — *one-step ahead forecasting*. Autrement dit, on cherche à minimiser les révisions entre la première et la dernière estimation (avec le filtre symétrique). Cependant, le déphasage induit par les filtres asymétriques n'est pas contrôlé : on pourrait préférer avoir une détection plus rapide des points de retournement et une révision plus grande plutôt que de

juste minimiser les révisions entre la première et la dernière estimation. Par ailleurs, puisque les coefficients du filtre symétrique (et donc le poids associé aux prévisions lointaines) décroissent lentement, il faudrait également s'intéresser à la performance des prévisions à horizon de plusieurs périodes — *multi-step ahead forecasting*. C'est pourquoi il peut être nécessaire de définir des critères alternatifs pour juger la qualité des moyennes mobiles asymétriques.

2.2.3.2 Indicateurs de qualité des moyennes mobiles asymétriques

Pour les filtres asymétriques, la majorité des critères proviennent de ceux définis par Grun-Rehomme et alii (2018) et Wildi et McElroy (2019) pour construire les filtres asymétriques. Ils sont résumés dans le table 2.1 et calculables avec la fonction `rjd3filters::diagnostic_matrix()`.

Grun-Rehomme et alii (2018) proposent une approche générale pour dériver des filtres linéaires, fondée sur un problème d'optimisation de trois critères : *Fidelity* (F_g , Fidélité), *Smoothness* (S_g , lissage) et *Timeliness* (T_g , rapidité). La fidélité peut être directement reliée à la réduction de variance créée par le filtre et la rapidité à la notion de déphasage, qu'on souhaite là encore faible.

Wildi et McElroy (2019) proposent une approche qui s'appuie sur la décomposition de l'erreur quadratique moyenne entre le filtre symétrique et le filtre asymétrique en quatre quantités : *Accuracy* (A_w , précision), *Timeliness* (T_w , rapidité), *Smoothness* (S_w , lissage) et *Residual* (R_w , résidus). Voir section 2.5 pour plus de détails.

2.2.3.3 Formule générale de construction des moyennes mobiles

Toutes les moyennes mobiles et tous les critères de qualité étudiés peuvent se voir comme des cas particuliers d'une formule générale de construction des filtres (symétriques et asymétriques). Celle-ci est décrite dans l'annexe 2.8.1, qui montre également les liens entre les différentes méthodes. Tous les filtres utilisés dans les simulations sont résumés dans l'annexe 2.8.2.

2.2.3.4 Illustration

Les différentes méthodes de construction de moyennes mobiles asymétriques seront illustrées à partir de l'exemple du lissage du climat des affaires dans le secteur des matériels de transport (C4), publié par l'Insee¹⁰, jusqu'en mai 2023.

10. https://bdm.insee.fr/series/sdmx/data/SERIES_BDM/001786505.

TABLE 2.1 – Critères de qualité d’une moyenne mobile $\theta = (\theta_k)_{-p \leq k \leq f}$ définie par une fonction de gain ρ_θ et une fonction de déphasage φ_θ .

Sigle	Description	Formule
b_c	Biais constant	$\sum_{k=-p}^{+f} \theta_k - 1$
b_l	Biais linéaire	$\sum_{k=-p}^{+f} k \theta_k$
b_q	Biais quadratique	$\sum_{k=-p}^{+f} k^2 \theta_k$
F_g	Réduction de la variance / Fidelity (Guggemos)	$\sum_{k=-p}^{+f} \theta_k^2$
S_g	Smoothness (Guggemos)	$\sum_j (\nabla^3 \theta_j)^2$
T_g	Timeliness (Guggemos)	$\int_0^{\omega_1} \rho_\theta(\omega) \sin(\varphi_\theta(\omega))^2 d\omega$
A_w	Accuracy (Wildi)	$2 \int_0^{\omega_1} (\rho_s(\omega) - \rho_\theta(\omega))^2 h(\omega) d\omega$
T_w	Timeliness (Wildi)	$8 \int_0^{\omega_1} \rho_s(\omega) \rho_\theta(\omega) \sin^2\left(\frac{\varphi_s(\omega) - \varphi_\theta(\omega)}{2}\right) h(\omega) d\omega$
S_w	Smoothness (Wildi)	$2 \int_{\omega_1}^{\pi} (\rho_s(\omega) - \rho_\theta(\omega))^2 h(\omega) d\omega$
R_w	Residual (Wildi)	$8 \int_{\omega_1}^{\pi} \rho_s(\omega) \rho_\theta(\omega) \sin^2\left(\frac{\varphi_s(\omega) - \varphi_\theta(\omega)}{2}\right) h(\omega) d\omega$

Notes : X_g critères provenant de Grun-Rehomme et alii (2018) et X_w critères provenant de Wildi et McElroy (2019).

ρ_s et φ_s représentent le gain et la fonction de déphasage du filtre symétrique d’Henderson.

h est la densité spectrale de la série en entrée, considérée comme étant celle d’un bruit blanc


($h_{WN}(x) = 1$) ou d’une marche aléatoire ($h_{RW}(x) = \frac{1}{2(1-\cos(x))}$).

L’indicateur synthétique du climat des affaires résume l’opinion des chefs d’entreprise sur la conjoncture du secteur associé (ici les matériels de transport) : plus sa valeur est élevée, plus les industriels considèrent que la conjoncture est favorable. Il est calculé à partir de soldes d’opinion issus des enquêtes de conjoncture de l’Insee. Toutefois, du fait de la volatilité des soldes d’opinion utilisés, les climats des affaires peuvent être bruités, ce qui peut rendre difficile l’identification des périodes de retournement conjoncturel (voir figure 2.2), c’est-à-dire les périodes où les industriels considèrent que la conjoncture passe d’un état favorable à un état moins favorable, ou l’inverse. Les méthodes présentées dans cette étude permettent de lisser les séries afin d’extraire la composante tendance-cycle pour faciliter l’analyse des retournements conjoncturels dans le cycle classique (également appelé cycle des affaires). On ne cherche donc pas à estimer séparément la tendance (qui représente les évolutions de long terme) et le cycle (qui représente les évolutions cycliques autour de la tendance) puisque ces composantes peuvent être difficiles à séparer (quelle définition prendre pour distinguer les cycles courts et des cycles longs ?). Par ailleurs, la décomposition entre tendance et cycle, associée à des méthodes de filtrage de type Hodrick-Prescott ou Baxter-King, sont plutôt utilisées pour analyser les points de retournement dans le cycle de croissance (voir Ferrara (2009a) pour une description des différents cycles économiques). Ces méthodes de décomposition tendance et cycle nécessitent d’avoir des séries longues (afin de distinguer cycles courts et tendance de long terme) alors que les méthodes utilisées dans cet article utilisent peu d’observations (en général 13 pour des séries mensuelles).

La figure 2.2 montre la série initiale et la série lissée avec le filtre symétrique d’Henderson

(présenté dans la section 2.3), qui sera utilisé pour les estimations finales de la tendance-cycle (c'est-à-dire lorsque suffisamment d'observations sont disponibles afin de permettre son utilisation). La série lissée permet, par construction, de localiser plus facilement les points de retournement et d'interpréter les évolutions mensuelles de l'indicateur. L'objectif de cette étude est de comparer différentes méthodes pour estimer les estimations intermédiaires des derniers points de la série lissée, avant que les points futurs ne soient disponibles. L'annexe 2.8.3 contient le code utilisé pour cet exemple illustratif.

FIGURE 2.2 – Série initiale et lissée, avec le filtre symétrique d'Henderson, du climat des affaires dans les matériels de transport.



2.3 Régression non paramétrique et régression polynomiale locale

De nombreuses méthodes d'extraction de la tendance-cycle sont fondées sur des régressions non-paramétriques, particulièrement souples car elles ne supposent pas de dépendance prédéterminée dans les prédicteurs. En pratique, on peut s'appuyer sur des régressions locales. Plus précisément, si on considère un ensemble de points $(x_i, y_i)_{1 \leq i \leq n}$, la régression non paramétrique consiste à supposer qu'il existe une fonction μ , à estimer, telle que $y_i = \mu(x_i) + \varepsilon_i$ avec ε_i un terme d'erreur. D'après le théorème de Taylor, pour tout point x_0 , si μ est différentiable d fois, alors :

$$\forall x : \mu(x) = \mu(x_0) + \mu'(x_0)(x - x_0) + \dots + \frac{\mu^{(d)}(x_0)}{d!}(x - x_0)^d + R_d(x), \quad (2.1)$$

où R_d est un terme résiduel négligeable au voisinage de x_0 . Dans un voisinage $h(x_0)$ autour de x_0 , μ peut être approchée par un polynôme de degré d . La quantité $h(x_0)$ est appelée *fenêtre* (*bandwidth*). Si ε_i est un bruit blanc, on peut donc estimer par les moindres carrés $\mu(x_0)$ en utilisant les observations qui sont dans $[x_0 - h(x_0), x_0 + h(x_0)]$.

En pratique, cela revient donc à faire l'hypothèse que la tendance est localement polynomiale. Différentes méthodes d'estimation peuvent être utilisées pour en déduire des moyennes mobiles symétriques et asymétriques.

Gray et Thomson (1996) (section 2.3.4) proposent un cadre statistique complet permettant notamment de modéliser l'erreur d'approximation de la tendance par des polynômes locaux. Toutefois, la spécification de cette erreur étant en général complexe, des modélisations plus simples peuvent être préférées, comme celle de Proietti et Luati (2008) (section 2.3.1).

Enfin, Dagum et Bianconcini (2008) (section 2.3.5) proposent une modélisation similaire de la tendance-cycle mais utilisant la théorie des espaces de Hilbert à noyau reproduisant pour l'estimation, ce qui a notamment l'avantage de faciliter le calcul des différentes moyennes mobiles à différentes fréquences temporelles.

Les équivalences entre ces différentes méthodes sont présentées dans l'annexe 2.8.1.

2.3.1 Régression polynomiale : approche de Proietti et Luati

Filtres locaux polynomiaux — Proietti et Luati (2008)

Approche fondée sur la modélisation locale de la tendance-cycle par des polynômes :

- Modèles avec une interprétation simple.
- Le filtre asymétrique est indépendant de la date d'estimation. Toutefois, il dépend indirectement des données car il est généralement calibré en utilisant les données.
- La *timeliness* n'est pas contrôlée (mais peut être introduite dans le programme de minimisation).

2.3.1.1 Filtres symétriques

En reprenant les notations de Proietti et Luati (2008), nous supposons que notre série temporelle y_t peut être décomposée en

$$y_t = \mu_t + \varepsilon_t,$$

où μ_t est la tendance et $\varepsilon_t \stackrel{i.i.d}{\sim} \mathcal{N}(0, \sigma^2)$ est le bruit¹¹. La tendance μ_t est localement approchée par un polynôme de degré d , de sorte que dans un voisinage h de t $\mu_t \simeq m_t$ avec :

$$\forall j \in \llbracket -h, h \rrbracket : y_{t+j} = m_{t+j} + \varepsilon_{t+j}, \quad m_{t+j} = \sum_{i=0}^d \beta_i j^i.$$

11. La série est donc désaisonnalisée.

Le problème d'extraction de la tendance est équivalent à l'estimation de $m_t = \beta_0$ (la constante dans la formule précédente).

En notation matricielle :

$$\underbrace{\begin{pmatrix} y_{t-h} \\ y_{t-(h-1)} \\ \vdots \\ y_t \\ \vdots \\ y_{t+(h-1)} \\ y_{t+h} \end{pmatrix}}_{\mathbf{y}} = \underbrace{\begin{pmatrix} 1 & -h & h^2 & \cdots & (-h)^d \\ 1 & -(h-1) & (h-1)^2 & \cdots & -(h-1)^d \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 1 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 1 & h-1 & (h-1)^2 & \cdots & (h-1)^d \\ 1 & h & h^2 & \cdots & h^d \end{pmatrix}}_{\mathbf{X}} \underbrace{\begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \vdots \\ \vdots \\ \beta_d \end{pmatrix}}_{\boldsymbol{\beta}} + \underbrace{\begin{pmatrix} \varepsilon_{t-h} \\ \varepsilon_{t-(h-1)} \\ \vdots \\ \varepsilon_t \\ \vdots \\ \varepsilon_{t+(h-1)} \\ \varepsilon_{t+h} \end{pmatrix}}_{\boldsymbol{\varepsilon}}.$$

Pour estimer $\boldsymbol{\beta}$ il faut $2h + 1 \geq d + 1$ et l'estimation est faite par moindres carrés pondérés — *weighted least squares* (WLS) —, ce qui revient à minimiser la fonction objectif suivante :

$$S(\hat{\beta}_0, \dots, \hat{\beta}_d) = \sum_{j=-h}^h \kappa_j (y_{t+j} - \hat{\beta}_0 - \hat{\beta}_1 j - \cdots - \hat{\beta}_d j^d)^2.$$

où κ_j est un ensemble de poids appelés *noyaux* (*kernel*). On a $\kappa_j \geq 0 : \kappa_{-j} = \kappa_j$, et en notant $\mathbf{K} = \text{diag}(\kappa_{-h}, \dots, \kappa_h)$, l'estimateur $\boldsymbol{\beta}$ peut s'écrire $\hat{\boldsymbol{\beta}} = (\mathbf{X}' \mathbf{K} \mathbf{X})^{-1} \mathbf{X}' \mathbf{K} \mathbf{y}$. Avec $\mathbf{e}_1 = (1 \ 0 \ \cdots \ 0)'$, l'estimateur de la tendance peut donc s'écrire :

$$\hat{m}_t = \mathbf{e}_1' \hat{\boldsymbol{\beta}} = \boldsymbol{\theta}' \mathbf{y} = \sum_{j=-h}^h \theta_j y_{t-j} \text{ avec } \boldsymbol{\theta} = \mathbf{K} \mathbf{X} (\mathbf{X}' \mathbf{K} \mathbf{X})^{-1} \mathbf{e}_1. \quad (2.2)$$

En somme, l'estimation de la tendance $\hat{m}_t$ est obtenue en appliquant une moyenne mobile symétrique $\boldsymbol{\theta}$ à y_t ¹². De plus, $\mathbf{X}' \boldsymbol{\theta} = \mathbf{e}_1$ donc :

$$\sum_{j=-h}^h \theta_j = 1, \quad \forall r \in \llbracket 1, d \rrbracket : \sum_{j=-h}^h j^r \theta_j = 0.$$

Ainsi, la moyenne mobile $\boldsymbol{\theta}$ préserve les polynômes de degré d .

L'annexe 2.8.4 présente différentes formes de noyaux ainsi que des estimateurs classiques associés.

Concernant le choix des paramètres, l'idée générale qui prévaut est que le choix entre ces différents noyaux est secondaire¹³ et qu'il vaut mieux se concentrer sur deux autres paramètres :

12. $\boldsymbol{\theta}$ est symétrique du fait de la symétrie des noyaux κ_j .

13. Voir par exemple Cleveland et Loader (1996) ou Loader (1999). Les seules contraintes souhaitées sur le noyau est qu'il accorde un poids plus important à l'estimation centrale (κ_0) et qu'il décroît vers 0 lorsqu'on s'éloigne de l'estimation centrale. Le noyau uniforme est donc à éviter.

- le degré du polynôme d : s'il est trop petit on risque d'avoir des estimations biaisées de la tendance-cycle et s'il est trop grand on risque d'avoir une trop grande variance dans les estimations (du fait d'un sur-ajustement) ;
- le nombre de voisins $2h + 1$ (ou la fenêtre h) : s'il est trop petit alors trop peu de données seront utilisées pour les estimations (ce qui conduira à une grande variance dans les estimations) et s'il est trop grand alors l'approximation polynomiale sera vraisemblablement fausse ce qui conduira à avoir des estimations biaisées.

2.3.1.2 Filtrés asymétriques

Comme mentionné dans la section 2.2.3.1, pour l'estimation en temps réel, plusieurs approches peuvent être utilisées :

1. Appliquer les filtres symétriques sur les séries prolongées par prévision $\hat{y}_{n+l|n}$, $l \in \llbracket 1, h \rrbracket$.
2. Construire un filtre asymétrique par approximation polynomiale locale sur les observations disponibles (y_t pour $t \in \llbracket n - h, n \rrbracket$).
3. Construire des filtres asymétriques qui minimisent l'erreur quadratique moyenne de révision sous des contraintes de reproduction de tendances polynomiales.

Proietti et Luati (2008) montrent que les deux premières approches sont équivalentes lorsque les prévisions sont faites par extrapolation polynomiale de degré d . Elles sont également équivalentes à la troisième approche sous les mêmes contraintes que celles du filtre symétrique. La troisième méthode est appelée *direct asymmetric filter* (DAF). C'est cette méthode qui est utilisée pour l'estimation en temps réel dans la méthode de désaisonnalisation STL (*Seasonal-Trend decomposition based on Loess*, voir Cleveland et alii (1990)). Même si les estimations des filtres DAF sont sans biais, c'est au coût d'une plus grande variance dans les estimations.

Pour résoudre le problème de la variance des estimations des filtres en temps réel, Proietti et Luati (2008) proposent une méthode générale pour construire les filtres asymétriques qui permet de faire un compromis biais-variance. Il s'agit d'une généralisation des filtres asymétriques de Musgrave (1964) (utilisés dans l'algorithme de désaisonnalisation X-13ARIMA).

On modélise ici la série initiale par :

$$\mathbf{y} = \mathbf{U}\boldsymbol{\gamma} + \mathbf{Z}\boldsymbol{\delta} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{D}). \quad (2.3)$$

où $[\mathbf{U}, \mathbf{Z}]$ est de rang plein et forme un sous-ensemble des colonnes de $\mathbf{X}$. L'objectif est de trouver un filtre $\mathbf{v}$ qui minimise l'erreur quadratique moyenne de révision (au filtre symétrique $\boldsymbol{\theta}$) sous certaines contraintes. Ces contraintes sont représentées par

la matrice $\mathbf{U} = \begin{pmatrix} \mathbf{U}'_p & \mathbf{U}'_f \end{pmatrix}' : \mathbf{U}'_p \mathbf{v} = \mathbf{U}' \boldsymbol{\theta}$ (avec $\mathbf{U}_p$ la matrice $(h + q + 1) \times (d + 1)$ qui contient les observations de la matrice $\mathbf{U}$ connues lors de l'estimation par le filtre asymétrique). Le problème est équivalent à trouver $\mathbf{v}$ qui minimise :

$$\varphi(\mathbf{v}) = \underbrace{(\mathbf{v} - \boldsymbol{\theta}_p)' \mathbf{D}_p (\mathbf{v} - \boldsymbol{\theta}_p)}_{\text{variance de l'erreur de révision}} + \underbrace{\boldsymbol{\theta}'_f \mathbf{D}_f \boldsymbol{\theta}_f + [\boldsymbol{\delta}' (\mathbf{Z}'_p \mathbf{v} - \mathbf{Z}' \boldsymbol{\theta})]^2}_{\text{biais}^2} + \underbrace{2\mathbf{l}' (\mathbf{U}'_p \mathbf{v} - \mathbf{U}' \boldsymbol{\theta})}_{\text{contraintes}}. \quad (2.4)$$

Erreur quadratique moyenne de révision

où $\mathbf{l}$ est le vecteur des multiplicateurs de Lagrange.

Lorsque $\mathbf{U} = \mathbf{X}$, la contrainte équivaut à préserver les polynômes de degré d : on retrouve les filtres directs asymétriques (DAF) lorsque $\mathbf{D} = \mathbf{K}^{-1}$.

Lorsque $\mathbf{U} = \begin{pmatrix} 1 & \cdots & 1 \end{pmatrix}'$, $\mathbf{Z} = \begin{pmatrix} -h & \cdots & +h \end{pmatrix}'$, $\boldsymbol{\delta} = \delta_1$, $\mathbf{D} = \sigma^2 \mathbf{I}$ et lorsque le filtre symétrique est le filtre d'Henderson, on retrouve les filtres asymétriques de Musgrave. Ce filtre suppose que, pour l'estimation en temps réel, les données sont générées par un processus linéaire et que les filtres asymétriques préservent les constantes ($\sum v_i = \sum \theta_i = 1$). Ces filtres asymétriques dépendent du rapport $|\delta_1/\sigma|$, qui est lié à l'I-C ratio $R = \frac{\bar{I}}{\bar{C}} = \frac{\sum |I_t - I_{t-1}|}{\sum |C_t - C_{t-1}|}$ (et l'on a $\delta_1/\sigma = 2/(R\sqrt{\pi})$), qui est notamment utilisé dans X-13ARIMA pour déterminer la longueur du filtre d'Henderson¹⁴.

Lorsque $\mathbf{U}$ correspond aux $d^* + 1$ premières colonnes de $\mathbf{X}$, $d^* < d$, la contrainte consiste à reproduire des tendances polynomiales de degré d^* . Cela introduit du biais mais réduit la variance. Ainsi, Proietti et Luati (2008) proposent trois classes de filtres asymétriques :

1. *Linear-Constant* (LC) : y_t linéaire ($d = 1$) et v préserve les constantes ($d^* = 0$). On obtient le filtre de Musgrave avec le filtre d'Henderson comme filtre symétrique.
2. *Quadratic-Linear* (QL) : y_t quadratique ($d = 2$) et v préserve les tendances linéaires ($d^* = 1$).
3. *Cubic-Quadratic* (CQ) : y_t cubique ($d = 3$) et v préserve les tendances quadratiques ($d^* = 2$).

La table 2.2 compare les critères de qualité des différentes méthodes en utilisant le filtre d'Henderson et $h = 6$ (filtre symétrique de 13 termes). Pour les filtres en temps réel ($q = 0$), plus le filtre asymétrique est complexe (en termes de préservation polynomiale), moins la *timeliness* est élevée et plus la *fidelity/smoothness* est grande : la réduction du déphasage se fait au détriment d'une augmentation de la variance. Ce résultat varie lorsque q augmente : pour $q = 2$ le filtre QL a une plus grande *timeliness* que le

14. Dans la majorité des cas un filtre de 13 termes est utilisé. Si le ratio est grand alors un filtre de 23 termes est utilisé (pour supprimer davantage de bruit) et si le ratio est petit un filtre de 9 termes est utilisé.

TABLE 2.2 – Critères de qualité des filtres asymétriques ($q = 0, 1, 2$) calculés par polynômes locaux en utilisant le noyau d’Henderson avec $h = 6$ et $R = 3, 5$.

Method	b_c	b_l	b_q	F_g	S_g	$T_g \times 10^{-3}$	A_w	S_w	T_w	R_w	EQM_w
$q = 0$											
LC	0	-0,41	-2,16	0,39	1,27	30,34	0,10	0,49	0,41	0,55	1,54
QL	0	0,00	-0,47	0,71	5,15	0,05	0,07	1,89	0,00	0,11	2,07
CQ	0	0,00	0,00	0,91	11,94	0,01	0,02	2,23	0,00	0,10	2,35
DAF	0	0,00	0,00	0,94	14,20	0,00	0,01	2,18	0,00	0,10	2,29
$q = 1$											
LC	0	-0,12	-0,52	0,27	0,43	4,80	0,01	0,12	0,06	0,11	0,30
QL	0	0,00	-0,06	0,29	0,71	0,69	0,00	0,19	0,01	0,04	0,25
CQ	0	0,00	0,00	0,37	0,57	0,16	0,02	0,58	0,00	0,06	0,66
DAF	0	0,00	0,00	0,41	0,37	0,06	0,02	0,76	0,00	0,06	0,84
$q = 2$											
LC	0	0,00	1,08	0,20	0,08	0,35	0,01	0,01	0,00	0,01	0,04
QL	0	0,00	0,03	0,22	0,05	2,08	0,00	0,01	0,02	0,07	0,10
CQ	0	0,00	0,00	0,37	0,66	0,13	0,02	0,56	0,00	0,06	0,64
DAF	0	0,00	0,00	0,40	0,77	0,02	0,02	0,68	0,00	0,05	0,74

Note : Avec $EQM_w = A_w + S_w + T_w + R_w$.

Note de lecture : dès qu’au moins deux points dans le futur sont connus ($q = 2$), le filtre LC conserve sans biais les tendances linéaires ($b_l = 0$). Pour ce filtre, dès lors que l’on utilise au moins deux points dans le futur ($q = 2$), l’erreur d’estimation provenant de l’utilisation d’un filtre asymétrique plutôt que symétrique (estimation finale) est quasiment nulle ($EQM_w \simeq 0$). Dès qu’au moins un point dans le futur est connu ($q = 1$), le filtre QL conserve quasiment sans biais les tendances quadratiques ($b_q \simeq 0$). Pour ce filtre, la timeliness est plus élevée lorsque deux points dans le futur sont connus ($q = 2$) que pour l’estimation en temps réel ($q = 0$; T_g et T_w augmentent).

filtre LC. Ce résultat étonnant souligne le fait que le déphasage n’est pas contrôlé par l’approche de Proietti et Luati (2008).

En termes de révision, ($A_w + S_w + T_w + R_w$), les filtres LC et QL donnent toujours de meilleurs résultats que les filtres CQ et DAF.

Ces propriétés « théoriques » sont conformes aux résultats empiriques observés dans la section 2.6 : les révisions sont plus importantes pour les filtres CQ et DAF (ce qui conduit à plus de variabilité dans les estimations et à un délai plus grand dans la détection des points de retournement) ; et le filtre QL paramétrisé de manière globale (paramètre R fixé pour tous les filtres asymétriques) peut conduire à une détection plus tardive des points de retournement que le filtre LC¹⁵.


15. En effet, pour détecter un point de retournement à la date t , il est nécessaire de connaître au moins 2 points après cette date afin de s’assurer qu’il y a bien un retournement de tendance.

Une application en ligne, disponible à l'adresse <https://aqlt.shinyapps.io/FilterProperties/>, permet de comparer les coefficients, les fonctions de gain et de déphasage entre les différentes méthodes et les différents noyaux.

La figure 2.3 montre les estimations successives de la série lissée du climat des affaires avec les filtres polynomiaux (paramétré à partir de l'IC-ratio). C'est-à-dire qu'il trace la tendance-cycle estimée en utilisant les données observées jusqu'en novembre 2022, celle estimée en utilisant les données observées jusqu'en décembre 2022, etc. La figure 2.4¹⁶ montre les prévisions implicites associées à ces différentes estimations successives : il s'agit des prévisions de la série brute qui, en appliquant le filtre symétrique sur la série prolongée, permettent d'obtenir la même tendance-cycle qu'en utilisant les moyennes mobiles asymétriques (voir section 2.2.3.1).


Sur cette série et sur ces points, c'est le filtre LC qui donne les meilleurs résultats avec des prévisions implicites naïves (prolongement par une droite) mais plus cohérentes que celles des autres filtres. Les filtres CQ et DAF conduisent à des estimations en temps-réel très éloignées des dernières estimations.

FIGURE 2.3 – Estimations successives de la série lissée du climat des affaires dans les matériels de transport avec des filtres polynomiaux locaux.



16. Afin qu'ils soient tous visibles, l'axe des ordonnées n'est pas le même entre les différents graphiques.

FIGURE 2.4 – Prévisions implicites liées aux estimations de la série lissée du climat des affaires dans les matériels de transport avec des filtres polynomiaux locaux.



Note : L'axe des ordonnées n'est pas le même entre les différents graphiques.

2.3.2 Paramétrisation locale des filtres asymétriques

Usuellement, les filtres asymétriques sont paramétrés de façon globale : $|\delta/\sigma|$ estimé sur l'ensemble des données à partir de l'IC-ratio ou d'un critère de validation croisée. En revanche, on pourrait préférer une paramétrisation locale : rapport $|\delta/\sigma|$ qui varie en fonction du temps. En effet, même si la paramétrisation globale est en moyenne valide, supposer le rapport $|\delta/\sigma|$ constant pour l'ensemble des filtres asymétriques ne paraît pas pertinent pour l'estimation en temps réel, en particulier pour des périodes de retournement conjoncturel. Par exemple, avec la méthode LC, effectuer une paramétrisation globale revient à supposer que la pente de la tendance est constante, alors que pendant les périodes de retournement conjoncturel, elle tend vers 0 jusqu'au point de retournement.

C'est ce qui est proposé dans cet article, avec une paramétrisation locale des filtres asymétriques en estimant séparément δ et σ^2 . Même si cela ne donne pas un estimateur sans biais du rapport $|\delta/\sigma|$, cela permet de capter les principales évolutions comme la décroissance vers 0 avant un point de retournement et la croissance après le point de retournement pour la méthode LC :


- La variance σ^2 peut être estimée en utilisant l'ensemble des données observées et à partir du filtre symétrique $(w_{-p}, \dots, w_p)$:

$$\hat{\sigma}^2 = \frac{1}{n - 2h} \sum_{t=h+1}^{n-h} \frac{(y_t - \hat{\mu}_t)^2}{1 - 2w_0^2 + \sum w_i^2}.$$

- Le paramètre δ peut être estimé par moyenne mobile à partir de l'équation 2.2. Par exemple, pour la méthode LC on peut utiliser la moyenne mobile $\theta_2 = \mathbf{KX}(\mathbf{X}'\mathbf{KX})^{-1}\mathbf{e}_2$ pour avoir une estimation locale de la pente et pour la méthode QL on peut utiliser $\theta_3 = \mathbf{KX}(\mathbf{X}'\mathbf{KX})^{-1}\mathbf{e}_3$ pour avoir une estimation locale de la concavité. La méthode DAF permet alors de simplement calculer les moyennes mobiles asymétriques associées.

Même si une moyenne mobile de longueur différente de celle utilisée pour l'estimation de la tendance pourrait être envisagée, cela semble dégrader les résultats en termes de déphasage (en utilisant la même méthodologie que dans la section 2.6). De plus, pour la construction des moyennes mobiles, la tendance peut être modélisée comme étant localement de degré 2 ou 3 (cela n'a pas d'impact pour l'estimation finale de la concavité). Nous retenons ici une modélisation de tendance de degré 2 : cela diminue le déphasage mais augmente légèrement les révisions liées à la première estimation de la tendance-cycle. La figure 2.5 montre les moyennes mobiles utilisées.

FIGURE 2.5 – Moyennes mobiles utilisées pour l'estimation en temps-réel de la pente et de la concavité.



Dans les applications empiriques de la section 2.6, la paramétrisation locale finale correspond à celle où δ est estimé en utilisant l'ensemble des données (c'est-à-dire en utilisant les filtres symétriques de la figure 2.5) mais en gardant une estimation en temps réel de σ^2 .

Les figure 2.6, figure 2.7 montrent les estimations successives de la série lissée du climat des affaires dans les matériels de transport avec une paramétrisation locale et avec une paramétrisation avec l'IC-ratio. Sur cette série et sur les points étudiés, la paramétrisation locale ne semble pas avoir d'impact sur le filtre LC à l'exception de la dernière estimation (pour laquelle les prévisions implicites des filtres avec paramétrisation locale semblent plus plausibles). Pour le filtre QL cela permet d'avoir moins de révisions dans les estimations intermédiaires (avec également des prévisions implicites plus plausibles avec la paramétrisation locale).

FIGURE 2.6 – Estimations successives de la série lissée du climat des affaires dans les matériels de transport avec des filtres polynomiaux locaux.





FIGURE 2.7 – Prévisions implicites liées aux estimations de la série lissée du climat des affaires dans les matériels de transport avec des filtres polynomiaux locaux.



Note : L'axe des ordonnées n'est pas le même entre les différents graphiques.

2.3.3 Extension avec le critère de *timeliness*

Un inconvénient de la méthode précédente est que le déphasage n'est pas contrôlé. Il est en revanche possible de généraliser davantage la modélisation en ajoutant le critère de *timeliness* défini par Grun-Rehomme et alii (2018) dans l'équation 2.4¹⁷.

En utilisant les mêmes notations que dans la section 2.3.1.2, θ le filtre symétrique et $\mathbf{v}$ le filtre asymétrique. Notons également $\theta = \begin{pmatrix} \theta_p \\ \theta_f \end{pmatrix}$ avec θ_p de même longueur que $\mathbf{v}$, et $\mathbf{g} = \mathbf{v} - \theta_p$. Le critère de *timeliness* s'écrit :

$$T_g(\mathbf{v}) = \mathbf{v}'\mathbf{T}\mathbf{v} = \mathbf{g}'\mathbf{T}\mathbf{g} + 2\theta_p'\mathbf{T}\mathbf{g} + \theta_p'\mathbf{T}\theta_p \quad (\mathbf{T} \text{ étant symétrique}).$$

17. C'est ce qui a été proposé par Jean Palate, puis codé en Java et intégré dans `rjd3filters`.

De plus, la fonction objectif φ de l'équation 2.4 peut se réécrire :

$$\begin{aligned}\varphi(\mathbf{v}) &= (\mathbf{v} - \boldsymbol{\theta}_p)' \mathbf{D}_p (\mathbf{v} - \boldsymbol{\theta}_p) + \boldsymbol{\theta}_f' \mathbf{D}_f \boldsymbol{\theta}_f + [\boldsymbol{\delta}' (\mathbf{Z}_p' \mathbf{v} - \mathbf{Z}' \boldsymbol{\theta})]^2 + 2\mathbf{l}' (\mathbf{U}_p' \mathbf{v} - \mathbf{U}' \boldsymbol{\theta}) \\ &= \mathbf{g}' \mathbf{Q} \mathbf{g} - 2\mathbf{P} \mathbf{g} + 2\mathbf{l}' (\mathbf{U}_p' \mathbf{v} - \mathbf{U}' \boldsymbol{\theta}) + \mathbf{c} \quad \text{avec} \quad \begin{cases} \mathbf{Q} = \mathbf{D}_p + \mathbf{Z}_p \boldsymbol{\delta} \boldsymbol{\delta}' \mathbf{Z}_p' \\ \mathbf{P} = \boldsymbol{\theta}_f \mathbf{Z}_f \boldsymbol{\delta} \boldsymbol{\delta}' \mathbf{Z}_p' \\ \mathbf{c} \text{ une constante indépendante de } \mathbf{v} \end{cases} .\end{aligned}$$

En ajoutant le critère de *timeliness*, on obtient :

$$\tilde{\varphi}(\mathbf{v}) = \mathbf{g}' \tilde{\mathbf{Q}} \mathbf{g} - 2\tilde{\mathbf{P}} \mathbf{g} + 2\mathbf{l}' (\mathbf{U}_p' \mathbf{v} - \mathbf{U}' \boldsymbol{\theta}) + \tilde{\mathbf{c}} \quad \text{avec} \quad \begin{cases} \tilde{\mathbf{Q}} = \mathbf{D}_p + \mathbf{Z}_p \boldsymbol{\delta} \boldsymbol{\delta}' \mathbf{Z}_p' + \alpha_T \mathbf{T} \\ \tilde{\mathbf{P}} = \boldsymbol{\theta}_f \mathbf{Z}_f \boldsymbol{\delta} \boldsymbol{\delta}' \mathbf{Z}_p' - \alpha_T \boldsymbol{\theta}_p \mathbf{T} \\ \tilde{\mathbf{c}} \text{ une constante indépendante de } \mathbf{v} \end{cases} ,$$

où α_T est le poids associé au critère de *timeliness*. Avec $\alpha_T = 0$ on retrouve $\varphi(\mathbf{v})$. Cette extension permet donc de retrouver tous les filtres symétriques et asymétriques présentés dans la section précédente mais généralise également l'approche de Gray et Thomson (1996) présentée dans la section 2.3.4.

2.3.4 Régression polynomiale : Gray et Thomson

Filtres locaux polynomiaux — Gray et Thomson (1996)

Approche fondée sur la modélisation locale de la tendance-cycle par des polynômes mais en prenant également en compte l'erreur d'approximation liée à cette modélisation :

- Modèles généraux qui permettent de prendre en compte l'autocorrélation entre les observations.
- Interprétation statistique des différentes méthodes.
- Le filtre asymétrique est indépendant de la date d'estimation. Toutefois, il dépend indirectement des données si le filtre est calibré sur l'I-C ratio.
- La *timeliness* n'est en revanche pas contrôlée.
- La spécification du modèle peut être compliquée : si la structure d'autocorrélation est estimée à partir des données, cela rajoute de l'incertitude dans les estimations, ce qui peut avoir des effets indésirables.

2.3.4.1 Filtres symétriques

L'approche de Gray et Thomson (1996) est proche de celles de Proietti et Luati (2008) et de Grun-Rehomme et alii (2018). De la même façon que pour les autres

méthodes, ils considèrent que la série initiale y_t peut se décomposer en une somme de la tendance-cycle g_t et d'un bruit blanc ε_t de variance σ^2 :

$$y_t = g_t + \varepsilon_t.$$

Toutefois, plutôt que de directement remplacer g_t par un polynôme local de degré d , ils prennent en compte l'erreur d'approximation de la tendance :

$$g_t = \sum_{j=0}^d \beta_j t^j + \xi_t,$$

où ξ_t est un processus stochastique de moyenne nulle, autocorrélé mais non corrélé à ε_t .

La tendance g_t est estimée par une moyenne mobile :

$$\hat{g}_t = \sum_{s=-r}^r \theta_s y_{t+s}.$$

Pour le filtre central, les auteurs cherchent à avoir un estimateur $\hat{g}_t$ qui soit sans biais (ce qui implique que θ conserve les tendances de degré d) et qui minimise une somme pondérée d'un critère de *fidelity* et d'un critère de *smoothness* :

$$Q = \underbrace{\alpha \mathbb{E} [(\hat{g}_t - g_t)^2]}_{=F_{GT}} + (1 - \alpha) \underbrace{\mathbb{E} [(\Delta^{d+1} \hat{g}_t)^2]}_{=S_{GT}}. \quad (2.5)$$

La solution est un filtre symétrique qui peut s'écrire sous la forme

$$\boldsymbol{\theta} = \mathbf{E}_\alpha^{-1} \mathbf{X} [\mathbf{X}' \mathbf{E}_\alpha^{-1} \mathbf{X}]^{-1} \mathbf{e}_1 \text{ avec } \mathbf{E}_\alpha = \alpha (\sigma^2 \mathbf{I} + \boldsymbol{\Omega}) + (1 - \alpha) (\sigma^2 \mathbf{B}_{d+1} + \boldsymbol{\Gamma}),$$

où :

$$\begin{cases} \Omega_{jk} &= cov(\xi_{t+j} - \xi_t, \xi_{t+k} - \xi_t) \\ \Gamma_{jk} &= cov(\Delta^{d+1} \xi_{t+j}, \Delta^{d+1} \xi_{t+k}) \\ \sigma^2 (B_{d+1})_{jk} &= cov(\Delta^{d+1} \varepsilon_{t+j}, \Delta^{d+1} \varepsilon_{t+k}) \end{cases}.$$

En ne minimisant que la *smoothness* et avec $\xi_t = 0$ on retrouve le filtre d'Henderson. En ne minimisant que la *fidelity*, cette méthode est équivalente à l'estimation de polynômes locaux par moindres carrés généralisés : on retrouve donc les filtres de Proietti et Luati (2008) avec $\sigma^2 = 0$ et $\boldsymbol{\Omega} = \mathbf{K}^{-1}$, ainsi que le filtre de Macaulay et alii (1931).

L'avantage de la modélisation de Gray et Thomson est que le paramètre ξ_t permet une spécification plus fine du modèle en prenant notamment en compte la corrélation entre les observations. Par exemple, McLaren et Steel (2001) ont étudié le lien entre le plan de sondage et l'estimation de la composante tendance-cycle et de la composante

saisonnrière. Cette modélisation leur permet de prendre en compte, dans l'estimation de la tendance-cycle, la structure de corrélation induite par le plan de sondage de l'enquête emploi mensuelle de l'Australie (groupe de rotations avec une période de recouvrement). Cependant, les auteurs avertissent que dans leur simulations (et dans la modélisation de Gray et Thomson) la structure d'autocorrélation de la variable aléatoire ξ_t est supposée connue. Ce n'est généralement pas le cas en pratique, où cette structure doit être estimée, ce qui rajoute de l'incertitude dans les estimations.

2.3.4.2 Filtres asymétriques

L'approche retenue par Gray et Thomson (1996) est une approche de minimisation des révisions sous contraintes. Étant donné un filtre symétrique θ^s utilisé pour estimer la tendance au centre de la série, l'objectif est de chercher un filtre asymétrique $v = (v_{-h}, \dots, v_q)$ de sorte à minimiser l'erreur quadratique moyenne de révision :

$$\mathbb{E} \left[(Y - \hat{Y})^2 \right] = \mathbb{E} \left[\left(\sum_{i=-h}^h \theta_i^s y_{t+s} - \sum_{i=-h}^q v_i y_{t+s} \right)^2 \right].$$

Les auteurs étudient deux cas :

1. Dans le premier cas, ils cherchent un estimateur sans biais : cela implique que v conserve les mêmes tendances polynomiales que θ^s . $\hat{Y}$ est alors le meilleur prédicteur linéaire sans biais — *best linear unbiased predictor* (BLUP) — de Y .
2. Dans le second cas, ils autorisent l'estimateur à être biaisé mais imposent que ce biais soit constant dans le temps : si l'on modélise localement la tendance par un polynôme de degré d , cela implique que v conserve les tendances polynomiales de degré $d - 1$. $\hat{Y}$ est alors le meilleur prédicteur linéaire à biais constant — *best linear time invariant predictor* (BLIP) — de Y . Cela permet notamment de reproduire les filtres asymétriques de Musgrave.

La méthode utilisée est donc très proche de celle de Proietti et Luati (2008) : on retrouve d'ailleurs le filtre DAF avec $\sigma^2 = 0$ et $\Omega = K^{-1}$ et en utilisant la première méthode (estimation du BLUP) et les méthodes LC (filtre de Musgrave), QL et CQ avec la seconde méthode en utilisant respectivement $d = 1$, $d = 2$ et $d = 3$.

Remarque. Pour la construction des filtres asymétriques, une approche alternative pourrait être d'utiliser la même méthode que celle utilisée pour construire les filtres symétriques. C'est-à-dire minimiser Q (équation 2.5) sous contrainte que le filtre asymétrique fournisse un estimateur sans biais de la tendance. Comme discuté dans Gray et Thomson (1996), les auteurs ne retiennent pas cette méthode pour deux raisons :

- Il n'est pas évident qu'il faille chercher à maintenir le même équilibre entre *smoothness* et *fidelity* en fin de série et au centre de la série. Le problème rencontré en fin de série est transitoire et disparaît au fur et à mesure que l'on a de nouvelles observations. Minimiser des critères de révision serait donc préférable puisque cela reviendrait à minimiser le coût de la transition (mais dans le cas où l'on ne minimise que la *fidelity* les deux méthodes sont équivalentes).
- Les valeurs de la *fidelity* et de la *smoothness* ne dépendent pas du temps au centre de la série mais en dépendent en fin de série. Ainsi, même si au centre de la série le choix des poids entre les deux critères contrôle indirectement le niveau des indicateurs, ce n'est plus le cas en fin de série. De plus, en fin de série, cela pourrait introduire des déphasages plus importants car S_{GT} dépend du temps et des valeurs passées (du fait de l'utilisation de l'opérateur différence).

Inversement, Grun-Rehomme et alii (2018) justifient de ne pas intégrer le critère de révision dans leur problème car ce critère est fortement corrélé à une combinaison fixée, donc non ajustable par l'utilisateur, des critères *fidelity* et *timeliness*.

2.3.5 Reproducing Kernel Hilbert Space (RKHS) : approche de Dagum et Bianconcini

RKHS filters — Dagum et Bianconcini (2008)

Approche fondée sur la modélisation locale de la tendance-cycle par des polynômes mais avec une estimation grâce à la théorie des RKHS et par optimisation sur un critère de qualité :

- Le filtre asymétrique est indépendant des données et de la date d'estimation.
- La méthode est généralisable à des séries avec des fréquences irrégulières (par exemple avec beaucoup de valeurs manquantes).
- Il peut y avoir des problèmes de minimisation.

La théorie des *Reproducing Kernel Hilbert Space* (RKHS) — espaces de Hilbert à noyau reproduisant — est une théorie générale dans l'apprentissage statistique non-paramétrique qui permet d'englober un grand nombre de méthodes. C'est par exemple le cas des méthodes de régression par moindres carrés pénalisés, des Support Vector Machine (SVM), du filtre d'Hodrick-Prescott (utilisé pour décomposer tendance et cycle) ou encore des moyennes mobiles telles que celle d'Henderson. Ainsi, Dagum et Bianconcini (2008) utilisent la théorie des RKHS pour approcher le filtre d'Henderson et en dériver des filtres asymétriques associés.

Un RKHS $\mathbb{L}^2(f_0)$ est un espace de Hilbert caractérisé par un noyau qui permet de reproduire toutes les fonctions de cet espace. Dit autrement, un RKHS est un espace

mathématique de fonctions (ensemble des séries temporelles, ensemble des séries temporelles polynomiales d'un certain degré...) qui possède une structure permettant de résoudre de nombreux problèmes. En particulier, il est caractérisé par un produit scalaire $\langle \cdot, \cdot \rangle$ et une fonction de densité f_0 qui permettent notamment de mesurer la proximité entre deux éléments de son espace (par exemple entre différentes estimations de la tendance-cycle). Il est également à noyau reproduisant, ce qui signifie que tout élément de l'espace étudié (par exemple les tendances polynomiales locales) peut s'écrire à partir du produit scalaire et d'une certaine fonction (le noyau). Comme nous le verrons, cette propriété permet notamment de calculer des moyennes mobiles pour l'estimation de la tendance-cycle.

Le produit scalaire $\langle \cdot, \cdot \rangle$ est défini par :

$$\langle U, V \rangle = \mathbb{E}[UV] = \int_{\mathbb{R}} U(t)V(t)f_0(t) dt \quad \forall U, V \in \mathbb{L}^2(f_0).$$

La fonction f_0 pondère donc chaque valeur en fonction de sa position temporelle : il s'agit de la version continue des noyaux définis dans la section 2.8.4.1.

Dans notre cas, on suppose que notre série initiale y_t est désaisonnalisée et peut s'écrire comme la somme d'une tendance-cycle, TC_t , et d'une composante irrégulière, I_t (qui peut être un bruit blanc ou suivre un modèle ARIMA) : $y_t = TC_t + I_t$. La tendance-cycle peut être déterministe ou stochastique. On suppose que c'est une fonction régulière du temps, elle peut être localement approchée par un polynôme de degré d :

$$TC_{t+j} = TC_t(j) = a_0 + a_1j + \dots + a_dj^d + \varepsilon_{t+j}, \quad j \in \llbracket -h, h \rrbracket,$$

où ε_t est un bruit blanc non corrélé à I_t .

Les coefficients $a_0, \dots, a_d$ peuvent être estimés par projection des observations au voisinage de y_t sur le sous-espace $\mathbb{P}_d$ des polynômes de degré d , ou, de manière équivalente, par minimisation de la distance entre y_t et $TC_t(j)$:

$$\min_{TC \in \mathbb{P}_d} \|y - TC\|^2 = \min_{TC \in \mathbb{P}_d} \int_{\mathbb{R}} (y(t+s) - TC_t(s))^2 f_0(s) ds. \quad (2.6)$$

L'espace $\mathbb{P}_d$ étant un espace de Hilbert à dimension finie, il admet un noyau reproduisant (voir, par exemple, Berlinet et Thomas-Agnan (2004)). Il existe ainsi une fonction $R_d(\cdot, \cdot)$ telle que :

$$\forall P \in \mathbb{P}_d : \forall t : R_d(t, \cdot) \in \mathbb{P}_d \quad \text{et} \quad P(t) = \langle R_d(t, \cdot), P(\cdot) \rangle.$$

Le problème de l'équation 2.6 admet une solution unique qui dépend d'une fonction K_{d+1} , appelée *fonction de noyau* (*kernel function*). Cette fonction est dite d'ordre $d+1$ car elle conserve les polynômes de degré d ¹⁸. Cette solution s'écrit :

$$\widehat{TC}(t) = \int_{\mathbb{R}} y(t-s)K_{d+1}(s) ds. \quad (2.7)$$

18. C'est-à-dire $\int_{\mathbb{R}} K_{d+1}(s) ds = 1$ et $\int_{\mathbb{R}} K_{d+1}(s)s^i ds = 1$ pour $i \in \llbracket 1, d \rrbracket$.

Généralement $f_0(t) = 0$ pour $|t| > 1$. Cette solution s'écrit alors :

$$\widehat{TC}(t) = \int_{[-1,1]} y(t-s) K_{d+1}(s) ds. \quad (2.8)$$

On peut, par ailleurs, montrer que K_{d+1} s'écrit en fonction de f_0 et du noyau reproduisant $R_d(\cdot, \cdot)$ et que ce dernier peut s'écrire en fonction de polynômes $(P_i)_{i \in \llbracket 0, d \rrbracket}$ qui forme une base orthonormée de $\mathbb{P}_d$ (voir par exemple Berlinet (1993)) :

$$K_{d+1}(t) = R_d(t, 0) f_0(t) = \sum_{i=0}^d P_i(t) P_i(0) f_0(t).$$

De plus, dans le cas discret, la solution de l'équation 2.8 s'écrit comme une somme pondérée au voisinage de y_t :

$$\widehat{TC}_t = \sum_{j=-h}^h w_j y_{t+j} \quad \text{où} \quad w_j = \frac{K_{d+1}(j/b)}{\sum_{i=-h}^h K_{d+1}(i/b)}. \quad (2.9)$$

Le paramètre b (la fenêtre du noyau) est choisi de sorte que les $2h + 1$ points autour de y_t soient utilisés avec un poids non nul.

Pour les filtres asymétriques, la formule de l'équation 2.9 est simplement adaptée au nombre d'observations connues :

$$\forall j \in \llbracket -h, q \rrbracket : w_{a,j} = \frac{K_{d+1}(j/b)}{\sum_{i=-h}^q K_{d+1}(i/b)}. \quad (2.10)$$

En utilisant $b = h + 1$ on retrouve les filtres symétriques obtenues par polynômes locaux.

Comme notamment montré par Dagum et Bianconcini (2016), K_{d+1} peut s'exprimer simplement à partir des moments de f_0 ¹⁹. Ainsi, notons $\mathbf{H}_{d+1}$ la matrice de Hankel associée aux moments de f_0 :

$$\forall i, j \in \llbracket 0, d \rrbracket : (\mathbf{H}_{d+1})_{i,j} = \langle X^i, X^j \rangle = \int s^{i+j} f_0(s) ds.$$

Notons également $\mathbf{H}_{d+1}[1, \mathbf{x}_t]$ la matrice obtenue en remplaçant la première ligne de $\mathbf{H}_{d+1}$ par $\mathbf{x}_t = (1 \quad t \quad t^2 \quad \dots \quad t^d)'$. On a :

$$K_{d+1}(t) = \frac{\det \mathbf{H}_{d+1}[1, \mathbf{x}_t]}{\det \mathbf{H}_{d+1}} f_0(t). \quad (2.11)$$

C'est cette formule qui est utilisée dans le *package* `rjd3filters` pour calculer les différentes moyennes mobiles.

19. Cela vient en fait du procédé d'orthonormalisation de Gram-Schmidt.

Comme discuté dans la section 2.3.1, le noyau d'Henderson dépend de la fenêtre utilisée. Ainsi, tous les moments de l'équation 2.11 doivent être recalculés pour chaque valeur de h . Pour éviter cela, Dagum et Bianconcini (2008) suggèrent d'utiliser le noyau quadratique (*biweight*) pour approcher le noyau d'Henderson lorsque h est petit ($h < 24$) et le noyau cubique (*triweight*) lorsque h est grand ($h \geq 24$).

Dans Dagum et Bianconcini (2015), les auteures suggèrent de faire une sélection optimale du paramètre b pour chaque moyenne mobile asymétrique. Notons Γ_s la fonction de transfert du filtre symétrique et Γ_θ celle du filtre asymétrique que l'on cherche à obtenir. Le filtre asymétrique utilisant q points dans le futur peut par exemple être obtenu en utilisant la fenêtre b_q qui minimise l'erreur quadratique moyenne (option "frequencyresponse" dans `rjd3filters::rkhs_filter()`)²⁰ :

$$b_{q,\Gamma} = \min_{b_q \in [h; 3h]} 2 \int_0^\pi |\Gamma_s(\omega) - \Gamma_\theta(\omega)|^2 d\omega.$$

Cela suppose en fait que la série entrée y_t soit un bruit blanc. En supposant y_t stationnaire, les critères définis dans l'article originel peuvent donc être étendus en multipliant les quantités sous les intégrales par la densité spectrale de y_t notée h :

$$b_{q,\Gamma} = \min_{b_q \in [h; 3h]} 2 \int_0^{\omega_1} |\Gamma_s(\omega) - \Gamma_\theta(\omega)|^2 h(\omega) d\omega,$$

avec $\omega_1 = \pi$ dans Dagum et Bianconcini (2015). Cette erreur quadratique moyenne peut également se décomposer en plusieurs termes (voir équation 2.13 de la section 2.5). Les fenêtres b_q peuvent donc également être obtenues en minimisant d'autres critères de qualité des moyennes mobiles (section 2.2.3.2). En notant ρ_s la fonction de gain du filtre symétrique, ρ_θ et φ_θ la fonction de gain et de déphasage du filtre asymétrique que l'on cherche à obtenir, les fenêtres b_q peuvent être obtenues en minimisant :

- l'*accuracy* qui correspond à la part de la révision liée aux différences de fonction de gain dans les fréquences liées à la tendance-cycle²¹ (avec $\omega_1 = \pi$ dans Dagum et Bianconcini (2015))

$$b_{q,G} = \min_{b_q \in [h; 3h]} 2 \int_0^{\omega_1} (\rho_s(\omega) - \rho_\theta(\omega))^2 h(\omega) d\omega$$

- la *smoothness* qui correspond à la part de la révision liée aux différences de fonction de gain dans les fréquences liées aux résidus²²

$$b_{q,s} = \min_{b_q \in [h; 3h]} 2 \int_{\omega_1}^\pi (\rho_s(\omega) - \rho_\theta(\omega))^2 h(\omega) d\omega$$

20. Dans leur article, les auteurs utilisent une formule différente pour la fonction de réponse ($\Gamma_\theta(\omega) = \sum_{k=-p}^{+f} \theta_k e^{2\pi i \omega k}$), ce qui conduit à des bornes d'intégrales légèrement différentes, sans effet sur le résultat.

21. Si l'on étudie des séries mensuelles et que l'on considère que la tendance-cycles correspondent aux cycles de 12 mois ou plus, on peut donc utiliser $\omega_1 = 2\pi/12$ (voir section 2.2.1).

22. Méthode non utilisée dans Dagum et Bianconcini (2015) mais implémentée dans `rjd3filters`.

TABLE 2.3 – Fenêtres optimales pour les filtres asymétriques associés à un filtre symétrique de 13 termes ($h = 6$) avec le noyau biweight.

	$q = 0$	$q = 1$	$q = 2$	$q = 3$	$q = 4$	$q = 5$
$b_{q,\Gamma}$						
$\omega_1 = \pi$ (valeurs utilisées)	9,54	7,88	7,07	6,88	6,87	6,94
$\omega_1 = 2\pi/12$	9,54	7,88	7,07	6,88	6,87	6,94
$b_{q,G}$						
$\omega_1 = \pi$ (valeurs utilisées)	11,78	9,24	7,34	6,85	6,84	6,95
$\omega_1 = 2\pi/12$	8,61	7,64	6,01	6,01	6,01	6,59
$b_{q,\varphi}$						
Valeurs de l'article (avec $\omega_1 = 2\pi/36$)	6,01	6,01	7,12	8,44	9,46	10,39
$\omega_1 = 2\pi/36$	6,01	6,01	7,21	8,47	9,46	6,01
$\omega_1 = 2\pi/12$	6,01	6,01	6,38	8,15	9,35	6,01

Notes : Avec $b_{q,\Gamma} = \min_{b_q \in [h; 3h]} 2 \int_0^{\omega_1} |\Gamma_s(\omega) - \Gamma_\theta(\omega)|^2 d\omega$, $b_{q,G} = \min_{b_q \in [h; 3h]} 2 \int_0^{\omega_1} (\rho_s(\omega) - \rho_\theta(\omega))^2 d\omega$ et

$$b_{q,\varphi} = \min_{b_q \in [h; 3h]} 8 \int_0^{\omega_1} \rho_s(\lambda) \rho_\theta(\lambda) \sin^2 \left(\frac{\varphi_\theta(\omega)}{2} \right) d\omega.$$

Le paramètre q désigne le nombre de points dans le futur utilisés par la moyenne mobile (pour $q = 0$, estimation en temps réel).

Les valeurs utilisées correspondent aux valeurs de Dagum et Bianconcini (2015). On les retrouve directement avec **rjd3filters**, sauf pour $b_{q,\varphi}$ du fait de la présence de plusieurs extrema.

- la *timeliness* qui correspond à la part de la révision liée au déphasage (avec $\omega_1 = 2\pi/36$ dans Dagum et Bianconcini (2015) et une formulation légèrement différente du critère à minimiser)

$$b_{q,\varphi} = \min_{b_q \in [h; 3h]} 8 \int_0^{\omega_1} \rho_s(\lambda) \rho_\theta(\lambda) \sin^2 \left(\frac{\varphi_\theta(\omega)}{2} \right) h(\omega) d\omega$$

Dans **rjd3filters**, h peut être fixée à la densité spectrale d'un bruit blanc ($h_{WN}(x) = 1$, comme c'est le cas dans Dagum et Bianconcini (2015)) ou d'une marche aléatoire ($h_{RW}(x) = \frac{1}{2(1-\cos(x))}$).


Un des inconvénients de cette méthode est qu'il n'y a pas unicité de la solution et donc qu'il y a parfois plusieurs extrema (uniquement pour le calcul de $b_{q,\varphi}$). Ainsi, la valeur optimale retenue par défaut par **rjd3filters** produit des discontinuités dans l'estimation de la tendance-cycle.

Par ailleurs, les valeurs de $b_{q,G}$ varient fortement en fonction de si l'on retient $\omega_1 = 2\pi/12$ ou $\omega_1 = \pi$ (table 2.3). Par cohérence et simplicité, nous utiliserons dans cet article les valeurs optimales présentées dans Dagum et Bianconcini (2015).

La figure 2.8 montre les estimations successives de la série lissée du climat des affaires dans les matériels de transport ainsi que les prévisions implicites pour les filtres RKHS

de Dagum et Bianconcini (2015). Ici les dernières estimations (lorsqu’aucun point dans le futur n’est connu) sont fortement révisées, ce qui s’observe notamment par la valeur de la dernière prévision implicite qui est éloignée des valeurs que l’on pourrait attendre pour l’évolution de l’indicateur.

FIGURE 2.8 – Estimations successives et prévisions implicites de la série lissée du climat des affaires dans les matériels de transport avec les filtres RKHS.



Note : L’axe des ordonnées n’est pas le même entre les différents graphiques.

Dans Dagum et Bianconcini (2023), les auteures montrent comment la théorie des RKHS permet de retrouver les *cascade linear filter* (CLF), qui sont des filtres alternatifs à celui de Henderson et qui n’ont pas été étudiés dans cette étude.

2.4 Approche *Fidelity-Smoothness-Timeliness* (FST)

Filtres FST — Grun-Rehomme, Guggemos, et Ladiray (2018)

Approche fondée sur l’optimisation d’une somme pondérée de critères :

- Le filtre asymétrique est indépendant du filtre symétrique, des données et de la date d’estimation.
- Le problème d’optimisation admet une solution unique (numériquement)

solvable).

- Les différents critères ne sont pas normalisés : les poids accordés aux différents critères ne peuvent être comparés.

Fonction R : `rjd3filters::fst_filter()`.

Pour construire les moyennes mobiles symétriques, Grun-Rehomme et Ladiray (1994) et Gray et Thomson (1996) proposent un programme de minimisation sous contrainte qui fait un compromis entre réduction de la variance et « lissage » de la tendance (les deux articles utilisent en revanche des notations différentes). Grun-Rehomme et alii (2018) étendent ces approches en les appliquant à la construction des filtres asymétriques et en ajoutant un critère permettant de contrôler le déphasage. Il s'agit de l'approche *Fidelity-Smoothness-Timeliness* — Fidélité-Lissage-Rapidité — (FST). Pour la construction des filtres asymétriques, un quatrième critère pourrait également être rajouté qui prendrait en compte les révisions par rapport à l'utilisation d'un filtre symétrique de référence (cette méthode pourrait alors être appelée la méthode FRST — *Fidelity-Revisions-Smoothness-Timeliness*). Cependant, le *package* `rjd3filters` n'ayant implémenté que l'approche FST, nous nous restreignons dans cette étude à la description de l'approche sans critère de révision.

Les trois critères utilisés sont les suivants :

- *Fidelity* (fidélité), F_g : c'est le rapport de réduction de la variance. Plus il est petit et plus la tendance-cycle estimée est un bon estimateur de la vraie tendance-cycle.

$$F_g(\boldsymbol{\theta}) = \sum_{k=-p}^{+f} \theta_k^2.$$

F_g peut également être écrite comme une forme quadratique positive : $F_g(\boldsymbol{\theta}) = \boldsymbol{\theta}' \mathbf{F} \boldsymbol{\theta}$ avec $\mathbf{F}$ la matrice identité d'ordre $p + f + 1$.

- *Smoothness* (lissage), S_g :

$$S_g(\boldsymbol{\theta}) = \sum_j (\nabla^d \theta_j)^2.$$

Ce critère mesure la proximité de la série lissée à une tendance polynomiale de degré $d - 1$. Henderson utilise par exemple ce critère avec $d = 3$ pour construire des moyennes mobiles conservant des polynômes de degré 2. S_g peut également s'écrire sous une forme quadratique positive $S_g(\boldsymbol{\theta}) = \boldsymbol{\theta}' \mathbf{S} \boldsymbol{\theta}$ avec $\mathbf{S}$ une matrice symétrique d'ordre $p + f + 1$ (voir annexe 2.8.1).

- *Timeliness* (rapidité), T_g : il mesure le déphasage entre la série initiale et la série lissée à des fréquences spécifiques. Lorsqu'un filtre linéaire est appliqué, le niveau de la série initiale est également modifié par la fonction de gain : il est donc intuitif de considérer que plus le gain est élevé, plus l'impact du déphasage le sera.

C'est pourquoi le critère de déphasage dépend des fonctions de gain et de déphasage (ρ_θ et φ_θ), le lien entre les deux fonctions étant fait à partir d'une fonction de pénalité f ²³ :

$$\int_{\omega_1}^{\omega_2} f(\rho_\theta(\omega), \varphi_\theta(\omega)) d\omega.$$

Comme fonction de pénalité, les auteurs suggèrent de prendre $f: (\rho, \varphi) \mapsto \rho^2 \sin(\varphi)^2$. Cela permet notamment d'avoir une *timeliness* qui peut s'écrire comme une forme quadratique positive ($T_g(\theta) = \theta' T \theta$ avec T une matrice carré symétrique d'ordre $p + f + 1$, voir Grun-Rehomme et alii (2018) pour la démonstration). Dans cet article nous utilisons $\omega_1 = 0$ et $\omega_2 = 2\pi/12$: on ne s'intéresse qu'à des séries mensuelles et au déphasage associé aux cycles d'au minimum 12 mois.

En somme, l'approche FST consiste à minimiser une somme pondérée de ces trois critères sous certaines contraintes (généralement préservation polynomiale).

$$\begin{cases} \min_{\theta} & \alpha F_g(\theta) + \beta S_g(\theta) + \gamma T_g(\theta) = \theta'(\alpha F + \beta S + \gamma T)\theta \\ \text{s.t.} & C\theta = a \end{cases}. \quad (2.12)$$

Les conditions $0 \leq \alpha, \beta, \gamma \leq 1$ et $\alpha + \beta \neq 0$ garantissent que $\alpha F_g(\theta) + \beta S_g(\theta) + \gamma T_g(\theta)$ soit strictement convexe et donc l'unicité de la solution. Dans ce cas, la solution s'écrit $\hat{\theta} = [\alpha F + \beta S + \gamma T]^{-1} C' (C[\alpha F + \beta S + \gamma T]^{-1} C')^{-1} a$.

Dans cette approche, les filtres asymétriques construits sont totalement indépendants des données, de la date d'estimation et du filtre symétrique choisis.

On obtient par exemple le filtre d'Henderson avec les paramètres suivants :

$$C = \begin{pmatrix} 1 & \cdots & 1 \\ -h & \cdots & h \\ (-h)^2 & \cdots & h^2 \end{pmatrix}, \quad a = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad \alpha = \gamma = 0, \quad \beta = 1, \quad d = 3.$$


Un des inconvénients de cette approche est que les différents critères ne sont pas normalisés : leurs valeurs ne peuvent pas être comparées et n'ont donc pas de sens. Il n'y a, par exemple, pas d'interprétation à donner à un poids deux fois plus important à la *timeliness* qu'à la *fidelity*.

La figure 2.9 montre les estimations successives de la série lissée du climat des affaires dans les matériels de transport ainsi que les prévisions implicites pour un ensemble

23. Grun-Rehomme et alii (2018) suggèrent 6 conditions de régularité à la fonction de pénalité afin qu'elle soit adaptée au problème de déphasage. Dans leur article, la fonction f ne dépend que du gain et du déphasage de θ et les 6 conditions sont : $f \geq 0$, $f(\rho, 0) = 0$, $f(0, \varphi) = 0$, $f(\rho, \varphi) = f(\rho, -\varphi)$, $\frac{\partial f}{\partial \rho} \geq 0$ et $\varphi \cdot \frac{\partial f}{\partial \varphi} \geq 0$.

particulier de poids α, β, γ (voir section 2.6 pour la méthode utilisée pour les sélectionner). Ici les dernières estimations (lorsqu’aucun point dans le futur n’est connu) sont fortement révisées, ce qui s’observe notamment par la valeur de la dernière prévision implicite qui est éloignée des valeurs que l’on pourrait attendre pour l’évolution de l’indicateur.

FIGURE 2.9 – Estimations successives et prévisions implicites de la série lissée du climat des affaires dans les matériels de transport avec la méthode FST en préservant les polynômes de degré 2 et avec $\alpha = 0,00$, $\beta = 0,05$ et $\gamma = 0,95$.



2.5 Filtrés dépendant des données : trilemme ATS

ATS-trilemma — Wildi et McElroy (2019)

Approche fondée sur l’optimisation d’une somme pondérée de critères :

- Les valeurs des différents critères peuvent être comparées et les poids associés peuvent être interprétés (contrairement à la méthode FST).
- Méthode généralisable aux cas multivariés.
- Les filtres dépendent des données, de la date d’estimation et du filtre symétrique utilisé.
- Il peut y avoir des problèmes d’optimisation (plusieurs minimums, etc.).

R : *package* MDFA <https://github.com/wiaidp/MDFA> ou `rjd3filters::dfa_filter()` (version simplifiée).

Wildi et McElroy (2019) proposent une approche dépendante des données (*data-dependent*) pour calculer des filtres linéaires. L’idée est la même que pour le filtre FST : les moyennes mobiles sont calculées par minimisation d’une somme pondérée de critères de qualité, mais les critères sont calculés différemment. Les auteurs décomposent

l'erreur quadratique moyenne de révision en un trilemme de trois quantités appelées *accuracy* (précision), *timeliness* (rapidité) et *smoothness* (lissage), d'où son nom *ATS-trilemma*.

Soient :

- $\{y_t\}$ notre série temporelle en entrée²⁴.
- $\{TC_t\}$ la série lissée finale (avec un filtre symétrique fini ou non), et soient respectivement Γ_s , ρ_s et φ_s les fonctions de transfert, de gain et de déphasage associées à ce filtre symétrique.
- $\{\widehat{TC}_t\}$ une estimation de $\{TC_t\}$, i.e. le résultat d'un filtre asymétrique (lorsque toutes les observations ne sont pas disponibles), et soient respectivement Γ_θ , ρ_θ et φ_θ les fonctions de transfert, de gain et de déphasage associées à ce filtre asymétrique.

Une approche directe²⁵, *Direct Filter Approach* (DFA), consiste à approcher directement la tendance-cycle finale par minimisation de l'erreur quadratique moyenne :

$$\min_{\widehat{TC}_t} \mathbb{E} [(TC_t - \widehat{TC}_t)^2].$$

Cette approche peut être approfondie en décomposant l'erreur quadratique moyenne en plusieurs éléments d'intérêt.

Si l'on suppose que la série $\{y_t\}$ est faiblement stationnaire²⁶ avec une densité spectrale continue h , l'erreur quadratique moyenne de révision, $\mathbb{E} [(TC_t - \widehat{TC}_t)^2]$, peut s'écrire dans le domaine spectral comme :

$$\begin{aligned} \mathbb{E} [(TC_t - \widehat{TC}_t)^2] &= \frac{1}{2\pi} \int_{-\pi}^{\pi} |\Gamma_s(\omega) - \Gamma_\theta(\omega)|^2 h(\omega) d\omega \\ &= \frac{1}{2\pi} \times 2 \times \int_0^{\pi} |\Gamma_s(\omega) - \Gamma_\theta(\omega)|^2 h(\omega) d\omega. \end{aligned} \quad (2.13)$$

On a :

$$\begin{aligned} |\Gamma_s(\omega) - \Gamma_\theta(\omega)|^2 &= \rho_s(\omega)^2 + \rho_\theta(\omega)^2 + 2\rho_s(\omega)\rho_\theta(\omega) (1 - \cos(\varphi_s(\omega) - \varphi_\theta(\omega))) \\ &= (\rho_s(\omega) - \rho_\theta(\omega))^2 + 4\rho_s(\omega)\rho_\theta(\omega) \sin^2 \left(\frac{\varphi_s(\omega) - \varphi_\theta(\omega)}{2} \right). \end{aligned} \quad (2.14)$$

L'intervalle $[0, \pi]$ peut être coupé en deux : une partie dite *pass-band* $[0, \omega_1]$ (l'intervalle de fréquences associé à la tendance-cycle) et une partie dite *stop-band* $[\omega_1, \pi]$ (l'intervalle

24. Par rapport à l'article originel, les notations ont été modifiées afin de garder une cohérence entre les différentes sections.

25. Par opposition aux approches indirectes par exemple utilisées dans X-13-ARIMA où le signal cible est approché en faisant une prévision sur la série initiale.

26. Les formules qui suivent peuvent également se généraliser aux processus intégrés non-stationnaires, par exemple en imposant une cointégration entre TC_t et $\widehat{TC}_t$ et en utilisant le pseudo-spectre, voir Wildi et McElroy (2013).

de fréquences associé aux résidus). Dans `rjd3filters` le paramètre ω_1 est fixé par l'utilisateur²⁷ et est par défaut égal à $2\pi/12$: pour des séries mensuelles, cela signifie que l'on souhaite conserver les cycles d'au moins 12 mois (voir section 2.2.1).

L'erreur de l'équation 2.13 peut être décomposée en 4 quantités :

$$\begin{aligned} \text{Accuracy} &= A_w(\boldsymbol{\theta}) = 2 \int_0^{\omega_1} (\rho_s(\omega) - \rho_{\boldsymbol{\theta}}(\omega))^2 h(\omega) d\omega, \\ \text{Timeliness} &= T_w(\boldsymbol{\theta}) = 8 \int_0^{\omega_1} \rho_s(\omega) \rho_{\boldsymbol{\theta}}(\omega) \sin^2 \left(\frac{\varphi_{\boldsymbol{\theta}}(\omega)}{2} \right) h(\omega) d\omega, \\ \text{Smoothness} &= S_w(\boldsymbol{\theta}) = 2 \int_{\omega_1}^{\pi} (\rho_s(\omega) - \rho_{\boldsymbol{\theta}}(\omega))^2 h(\omega) d\omega, \\ \text{Residual} &= R_w(\boldsymbol{\theta}) = 8 \int_{\omega_1}^{\pi} \rho_s(\omega) \rho_{\boldsymbol{\theta}}(\omega) \sin^2 \left(\frac{\varphi_{\boldsymbol{\theta}}(\omega)}{2} \right) h(\omega) d\omega. \end{aligned}$$

En général, le résidu R_w est petit puisque $\rho_s(\omega)\rho_{\boldsymbol{\theta}}(\omega)$ est proche de 0 dans l'intervalle *stop-band*²⁸. Il est de plus rare que les utilisateurs s'intéressent aux propriétés de déphasage dans les fréquences *stop-band*. C'est pourquoi, pour la construction de filtres linéaires les auteurs suggèrent de faire une minimisation d'une somme pondérée des trois premiers critères :

$$\mathcal{M}(\vartheta_1, \vartheta_2) = \vartheta_1 T_w(\boldsymbol{\theta}) + \vartheta_2 S_w(\boldsymbol{\theta}) + (1 - \vartheta_1 - \vartheta_2) A_w(\boldsymbol{\theta}).$$

Comme le montrent McElroy et Wildi (2020), cette méthode peut également être étendue au cas multivarié, ce qui permet de prendre en compte les corrélations entre les composantes de différentes séries.

Un des inconvénients de cette méthode est qu'il n'y a pas de garantie d'unicité de la solution. En revanche, son avantage par rapport à la méthode FST (section 2.4) est que la décomposition de l'erreur quadratique moyenne permet de normaliser les différents indicateurs, et les coefficients ϑ_1 , ϑ_2 et $1 - \vartheta_1 - \vartheta_2$ peuvent être comparés entre eux.

Cette méthode étant totalement dépendante des données, son intégration dans des algorithmes non-paramétriques tels que X-11 serait compliquée. C'est pourquoi elle n'est pour l'instant pas comparée aux autres. Pour avoir des critères qui ne dépendent pas des données, une idée serait de fixer la densité spectrale, par exemple à celle d'un bruit blanc ($h_{WN}(x) = 1$) ou d'une marche aléatoire ($h_{RW}(x) = \frac{1}{2(1-\cos(x))}$). C'est ce qui est implémenté dans la fonction `rjd3filters::dfa_filter()`.

27. Dans l'article originel, l'intervalle *pass-band* dépend de la fonction de gain du filtre symétrique (*pass-band* = $\{\omega | \rho_s(\omega) \geq 0,5\}$) : cela correspond donc à l'intervalle contenant les fréquences conservées sans trop de distorsion par le filtre symétrique. Dans le cas du filtre symétrique d'Henderson de 13 termes, cela correspond à l'intervalle $[0, 2\pi/8]$, c'est-à-dire aux cycles de plus de 8 mois.

28. En pratique ce n'est pas toujours le cas comme montré dans la section 2.3.1.2.

2.6 Comparaison des différentes méthodes

Les différentes méthodes de construction de moyennes mobiles asymétriques sont comparées sur des données simulées et des données réelles.

Pour toutes les séries, un filtre symétrique de 13 termes est utilisé. Ces méthodes sont également comparées aux estimations obtenues en prolongeant la série par un modèle ARIMA²⁹ puis en appliquant un filtre symétrique de Henderson de 13 termes.

La performance des différentes méthodes est jugée sur des critères relatifs aux révisions (entre deux estimations consécutives et par rapport à l'estimation finale) et sur le nombre de périodes nécessaires pour détecter les points de retournements.

2.6.1 Séries simulées

2.6.1.1 Méthodologie

En suivant une méthodologie proche de celle de Darné et Dagum (2009), neuf séries mensuelles sont simulées entre janvier 1960 et décembre 2020 avec différents niveaux de variabilité. Chaque série simulée $y_t = C_t + T_t + I_t$ peut s'écrire comme la somme de trois composantes :


- le cycle $C_t = \rho[\cos(2\pi t/\lambda) + \sin(2\pi t/\lambda)]$, λ est fixé à 72 (cycles de 6 ans, il y a donc 19 points de retournement détectables) ;
- la tendance $T_t = T_{t-1} + \nu_t$ avec $\nu_t \sim \mathcal{N}(0, \sigma_\nu^2)$, σ_ν étant fixé à 0,08 ;
- et l'irrégulier $I_t = e_t$ avec $e_t \sim \mathcal{N}(0, \sigma_e^2)$.

Pour les différentes simulations, nous faisons varier les paramètres ρ et σ_e^2 afin d'avoir des séries avec différents rapports signal sur bruit (voir figure 2.10) :

- Fort rapport signal sur bruit (c'est-à-dire un I-C ratio faible et une faible variabilité) : $\sigma_e^2 = 0,2$ et $\rho = 3,0, 3,5$ ou $4,0$ (I-C ratio compris entre 0,9 et 0,7) ;
- Rapport signal sur bruit moyen (c'est-à-dire un I-C ratio moyen et une variabilité moyenne) : $\sigma_e^2 = 0,3$ et $\rho = 1,5, 2,0$ ou $3,0$ (I-C ratio compris entre 2,3 et 1,4) ;
- Faible rapport signal sur bruit (c'est-à-dire un I-C ratio fort et une forte variabilité) : $\sigma_e^2 = 0,4$ et $\rho = 0,5, 0,7$ ou $1,0$ (I-C ratio compris entre 8,9 et 5,2).

29. Le modèle ARIMA est déterminé automatiquement en n'utilisant pas de retard saisonnier (les séries étant désaisonnalisées) et en n'utilisant aucune variable extérieure (comme des régresseurs externes pour la correction des points atypiques).

FIGURE 2.10 – Séries simulées à variabilité faible ($\sigma_e^2 = 0,2$ et $\rho = 3,5$), moyenne ($\sigma_e^2 = 0,3$ et $\rho = 2,0$) et forte ($\sigma_e^2 = 0,4$ et $\rho = 1,0$).



Pour chaque série et chaque date, la tendance-cycle est estimée en utilisant les différentes méthodes présentées dans ce rapport. Pour les régressions polynomiales locales, les filtres asymétriques sont calibrés en utilisant l'I-C ratio estimé à chaque date (en appliquant un filtre de Henderson de 13 termes) et pour la méthode FST, un quadrillage du plan est réalisé avec un pas de 0,05 et avec comme contraintes linéaires la préservation des polynômes de degrés 0 à 3. Trois critères de qualité sont également calculés :

1. Calcul du déphasage dans la détection des points de retournement. La définition de Zellner et alii ([1991](#)) est utilisée pour déterminer les points de retournement :
 - on parle de redressement (*upturn*) lorsqu'on passe d'une phase de récession à une phase d'expansion de l'économie. C'est le cas à la date t lorsque $y_{t-3} \geq y_{t-2} \geq y_{t-1} < y_t \leq y_{t+1}$.
 - on parle de ralentissement (*downturn*) lorsqu'on passe d'une phase d'expansion à une phase de récession. C'est le cas à la date t lorsque $y_{t-3} \leq y_{t-2} \leq y_{t-1} > y_t \geq y_{t+1}$.

Il faut donc au moins 2 mois pour détecter un point de retournement.

Le déphasage est souvent défini comme le nombre de mois nécessaires pour détecter le bon point de retournement (i.e., le point de retournement sur la composante cyclique). Nous utilisons ici un critère légèrement modifié : le déphasage est défini comme le nombre de mois nécessaires pour détecter le bon point de retournement sans aucune révision future. Il peut en effet

arriver que le bon point de retournement soit détecté par des filtres asymétriques mais ne le soit pas avec l'estimation finale avec un filtre symétrique (c'est le cas de 41 points de retournements sur l'ensemble des 9 séries avec les filtres asymétriques de Musgrave) ou qu'il y ait des révisions dans les estimations successives (c'est le cas de 7 points de retournements sur l'ensemble des 9 séries avec les filtres asymétriques de Musgrave). Finalement, relativement peu de points de retournement sont détectés à la bonne date avec l'estimation finale. Avec le filtre de Henderson de 13 termes, 18 sont correctement détectés sur les séries avec une faible variabilité (sur les 57 possibles), 11 sur les séries à variabilité moyenne et 12 sur les séries à forte variabilité.

2. Calcul de deux critères de révisions : la moyenne des écarts relatifs entre la q^e estimation et la dernière estimation $MAE_{fe}(q)$ et la moyenne des écarts relatifs entre la q^e et la $q + 1^e$ estimation $MAE_{qe}(q)$

$$MAE_{fe}(q) = \mathbb{E} \left[\left| \frac{y_{t|t+q} - y_{t|last}}{y_{t|last}} \right| \right] \quad \text{et} \quad MAE_{qe}(q) = \mathbb{E} \left[\left| \frac{y_{t|t+q} - y_{t|t+q+1}}{y_{t|t+q+1}} \right| \right].$$

Pour le choix des poids dans l'approche FST, l'idée retenue dans cette étude est de faire un quadrillage du plan $[0, 1]^3$ avec un pas de 0,05 et en imposant $\alpha + \beta + \gamma = 1$ ³⁰. Pour chaque combinaison de poids, quatre ensembles de moyennes mobiles sont construits en forçant dans la minimisation la préservation de polynômes de degré 0 à 3. Le filtre symétrique utilisé est toujours celui de Henderson. Le degré de préservation polynomiale et l'ensemble de poids retenus sont ceux minimisant (en moyenne) le déphasage sur les séries simulées : pour l'ensemble des degrés de liberté, il s'agit toujours du filtre préservant les polynômes de degré 2 avec $\alpha = 0,00$ (*fidelity*), $\beta = 0,05$ (*smoothness*) et $\gamma = 0,95$ (*timeliness*).

2.6.1.2 Comparaison

En excluant pour l'instant les paramétrisations locales des filtres polynomiaux, c'est le filtre FST qui semble donner les meilleurs résultats en termes de déphasage dans la détection des points de retournement (figure 2.11), suivi du filtre polynomial linéaire-constant (LC)³¹. Les performances sont relativement proches de celles obtenues en

30. Comme il n'est pas possible d'avoir un poids associé à la *timeliness* (γ) égal à 1 (sinon la fonction objectif n'est pas strictement convexe), on construit également un filtre avec un poids très proche de 1 ($1 - 1/1000$).

31. Par simplification, pour l'approche polynomiale locale, nous ne présenterons ici que les résultats avec le noyau de Henderson. Il est en effet difficile de comparer proprement les résultats entre les différents noyaux car le filtre symétrique n'est pas le même. Le filtre symétrique étant celui utilisé pour la détection finale des points de retournement, cela a pour conséquence que des points de retournement différents peuvent être détectés. Par exemple, pour le filtre LC, sur les trois séries ayant une variabilité moyenne, seul 1 point de retournement est correctement détecté par l'ensemble des


prolongeant la série grâce à un modèle ARIMA. Toutefois, lorsque la variabilité est faible, le filtre LC semble donner de moins bons résultats et c'est le filtre polynomial quadratique-linéaire (QL) qui semble donner les meilleurs résultats. C'est le filtre $b_{q,\varphi}$ qui minimise le déphasage qui donne les moins bons résultats. Les autres filtres issus des espaces de Hilbert à noyau reproduisant (RKHS) ont également une grande variabilité en termes de déphasage. Cela peut s'expliquer par le fait que la courbe des coefficients des moyennes mobiles asymétriques sont assez éloignées des coefficients du filtre symétrique³² : il y a donc potentiellement beaucoup de révisions dans la détection des points de retournement. En effet, lorsque le déphasage est défini comme la première date à laquelle le bon point de retournement est détecté, c'est le filtre $b_{q,G}$ qui donne les meilleurs résultats.

Pour les séries à variabilité moyenne, la paramétrisation locale des filtres LC et QL permet de réduire le déphasage. Pour les séries à variabilité forte, le déphasage est uniquement réduit en utilisant les paramètres finaux $\hat{\delta}$: l'estimation en temps réel semble ajouter plus de variabilité. Pour les séries à variabilité faible, les performances semblent légèrement améliorées uniquement avec le filtre LC.

noyaux. Toutefois, une première analyse des résultats montrent que les différents noyaux ont des performances proches en termes de déphasage et de révisions, sauf le noyau uniforme qui produit de moins bons résultats.

32. Cet écart provient du fait que la fenêtre optimale retenue $b_{q,\varphi}$ est croissante jusqu'à $b_{5,\varphi} = 10$, 39 et s'écarte donc de la valeur utilisée du filtre symétrique ($h + 1 = 7$).

FIGURE 2.11 – Distribution des déphasages sur les séries simulées.



Notes: Filtres polynomiaux : Linear-Constant (LC) et Quadratic-Linear (QL) avec paramétrisation locale de l'IC-ratio (en utilisant un estimateur en temps-réel et l'estimateur final de ce paramètre), Cubic-Quadratic (CQ) et direct (DAF).

Filtres RKHS : minimisant l'erreur quadratique moyenne ($b_{q,\Gamma}$), les révisions liées à la fonction de gain ($b_{q,G}$) et celles liées au déphasage ($b_{q,\varphi}$).

ARIMA : prolongement de la série par un ARIMA détecté automatiquement et utilisation du filtre symétrique d'Henderson.

FST : filtre obtenu en préservant les polynômes de degré 2 et avec $\alpha = 0,00$, $\beta = 0,05$ et $\gamma = 0,95$.

Concernant les révisions, la variabilité de la série a peu d'impact sur les performances respectives des différentes méthodes mais joue sur les ordres de grandeurs, c'est pourquoi les résultats ne sont présentés qu'avec les séries à variabilité moyenne (table 2.4). Globalement, les filtres LC minimisent toujours les révisions (avec globalement peu d'impact de la paramétrisation locale des filtres) et les révisions sont plus importantes avec les filtres polynomiaux cubique-quadratique (CQ), direct (DAF) et les filtres RKHS autres que $b_{q,\varphi}$. Par ailleurs, c'est le filtre $b_{q,\varphi}$ qui conduit à la révision la plus grande entre l'avant-dernière et la dernière estimation, ce qui s'explique par la différence importante entre la courbe des coefficients de la dernière moyenne mobile asymétrique et celle du filtre symétrique. Les autres filtres RKHS, $b_{q,\Gamma}$ et $b_{q,G}$, conduisent eux à de fortes révisions entre la quatrième et la cinquième estimation.

Pour le filtre QL, il y a une forte révision entre la deuxième et la troisième estimation : cela peut venir du fait que pour la deuxième estimation (lorsqu'on connaît un point dans le futur), le filtre QL associe un poids plus important à l'estimation en $t + 1$ qu'à

l'estimation en t , ce qui crée une discontinuité. Cette révision est fortement réduite avec la paramétrisation locale du filtre. Pour les filtres polynomiaux autres que le filtre LC, les révisions importantes à la première estimation étaient prévisibles au vu de la courbe des coefficients : un poids très important est associé à l'observation courante et il y a une forte discontinuité entre la moyenne mobile utilisée pour l'estimation en temps réel (lorsqu'aucun point dans le futur n'est connu) et les autres moyennes mobiles.

Enfin, pour le filtre issu de la méthode FST, la première estimation est fortement révisée, ce qui pouvait être attendu au vu de l'analyse de la courbe de coefficients (figure 2.25). Ainsi, pour cette méthode, utiliser le même ensemble de poids (α , β et γ) pour construire l'ensemble des moyennes mobiles asymétriques ne semble pas pertinent : pour le filtre utilisé en temps réel (lorsqu'aucun point dans le futur est connu), on pourrait préférer donner un poids plus important à la fidélité afin de minimiser ces révisions.

Le prolongement de la série par un modèle ARIMA donne des révisions avec les dernières estimations du même ordre de grandeur que le filtre LC mais des révisions légèrement plus importantes entre les estimations consécutives, notamment entre la quatrième et la cinquième estimation (on pouvait s'y attendre comme souligné dans la section 2.2.3.1).

2.6.2 Série réelle

Les différences entre les méthodes sont également illustrées à partir d'un exemple issu de la base FRED-MD (McCracken et Ng (2016)) contenant des séries économiques sur les États-Unis³³. La série étudiée est le niveau d'emploi aux États-Unis (série CE160V, utilisée en logarithme) autour du point de retournement de février 2001, cohérent avec la datation mensuelle des points de retournement. Ce point et cette série ont été choisis car le retournement conjoncturel est particulièrement visible sur la série brute (voir figure 2.12 présentant les prévisions implicites), que cette série est utilisée pour la datation des cycles conjoncturels de l'économie et que la base FRED-MD facilite la reproductibilité des résultats (grâce à la disponibilité des séries publiées aux dates passées). Cette série a une variabilité moyenne³⁴ (un filtre symétrique de 13 termes est donc adapté). La figure 2.13 montre les estimations successives de la tendance-cycle avec les différentes méthodes étudiées.

33. Les séries étudiées correspondent à la base publiée en novembre 2022.


34. La variabilité est déterminée en étudiant les séries jusqu'en janvier 2020.

TABLE 2.4 – Moyenne des écarts relatifs des révisions pour les différents filtres sur les séries simulées à variabilité moyenne.

Méthode	$q = 0$	$q = 1$	$q = 2$	$q = 3$	$q = 4$	$q = 5$
$MAE_{fe}(q) = \mathbb{E} \left[\left (y_{t t+q} - y_{t last}) / y_{t last} \right \right]$						
LC	0,21	0,10	0,03	0,03	0,03	0,01
LC param. locale (finale)	0,19	0,09	0,03	0,03	0,03	0,01
LC param. locale	0,29	0,10	0,03	0,03	0,03	0,01
QL	0,33	0,10	0,04	0,04	0,03	0,01
QL param. locale (finale)	0,21	0,10	0,03	0,03	0,03	0,01
QL param. locale	0,30	0,10	0,04	0,03	0,03	0,01
CQ	0,45	0,13	0,13	0,09	0,06	0,02
DAF	0,47	0,15	0,15	0,09	0,06	0,02
$b_{q,\Gamma}$	0,63	0,21	0,03	0,09	0,09	0,04
$b_{q,G}$	0,83	0,37	0,03	0,09	0,09	0,04
$b_{q,\varphi}$	0,31	0,11	0,03	0,05	0,07	0,09
ARIMA	0,22	0,10	0,03	0,03	0,03	0,01
FST	0,36	0,13	0,05	0,05	0,04	0,02
$MAE_{ce}(q) = \mathbb{E} \left[\left (y_{t t+q} - y_{t t+q+1}) / y_{t t+q+1} \right \right]$						
LC	0,19	0,10	0,02	0,01	0,07	0,01
LC param. locale (finale)	0,20	0,10	0,03	0,01	0,05	0,01
LC param. locale	0,24	0,11	0,03	0,01	0,05	0,01
QL	0,29	3,46	0,00	0,03	0,04	0,01
QL param. locale (finale)	0,31	0,11	0,02	0,01	0,04	0,01
QL param. locale	0,24	0,16	0,00	0,03	0,04	0,01
CQ	0,43	0,02	0,10	0,07	0,05	0,02
DAF	0,66	0,24	0,11	0,14	0,06	0,02
$b_{q,\Gamma}$	0,38	0,32	0,09	0,00	0,41	0,04
$b_{q,G}$	0,70	0,46	0,10	0,00	0,43	0,04
$b_{q,\varphi}$	0,22	0,16	0,08	0,05	0,03	0,09
ARIMA	0,21	0,13	0,02	0,02	0,25	0,01
FST	0,31	0,11	0,02	0,02	0,03	0,02

Note : Le paramètre q désigne le nombre de points dans le futur utilisés par la moyenne mobile (pour $q = 0$, estimation en temps réel).


FIGURE 2.12 – Série brute et lissée (tendance-cycle) de l’emploi (en logarithme) aux États-Unis autour du point de retournement de février 2001.



Sur cette série, le déphasage est de 6 mois pour les méthodes RKHS, la méthode LC, la méthode CQ et le prolongement par ARIMA de la série. Sauf pour la méthode LC (où le point de retournement est d’abord détecté en janvier 2001), le déphasage élevé provient de révisions dans le point de retournement détecté dans les estimations intermédiaires (même si le bon point de retournement est détecté au bout de 2 mois, il ne l’est plus au bout de 3 mois). Il est de deux mois pour les autres méthodes (QL, DAF et FST).

La paramétrisation locale ne permet pas ici de réduire le déphasage mais permet de réduire les révisions. Les polynômes CQ et DAF conduisent à plus de variabilité dans les estimations intermédiaires, en particulier en février 2001. Concernant les filtres RKHS, les estimations intermédiaires du filtre $b_{q,\varphi}$ semblent très erratiques, ce qui s’explique, encore une fois, par le fait que les moyennes mobiles asymétriques utilisées lorsqu’on se rapproche du cas symétrique sont éloignées de la moyenne mobile symétrique d’Henderson. Les filtres $b_{q,\Gamma}$ et $b_{q,G}$ conduisent à des estimations intermédiaires relativement constantes (estimations en temps réel proches des estimations lorsque quelques points dans le futur sont connus) : ces estimations intermédiaires (notamment celles en temps-réel) sont peu cohérentes en période de points de retournement et conduisent, dans ce cas, à un déphasage élevé.

FIGURE 2.13 – Estimations successives de la tendance-cycle de l’emploi (en logarithme) aux États-Unis.



Notes: Filtres polynomiaux : Linear-Constant (LC) et Quadratic-Linear (QL) avec paramétrisation locale de l'IC-ratio (en utilisant un estimateur en temps-réel et l'estimateur final de ce paramètre), Cubic-Quadratic (CQ) et direct (DAF).


Filtres RKHS : minimisant l'erreur quadratique moyenne ($b_{q,r}$), les révisions liées à la fonction de gain ($b_{q,G}$) et celles liées au déphasage ($b_{q,\phi}$).

ARIMA : prolongement de la série par un ARIMA détecté automatiquement et utilisation du filtre symétrique d'Henderson.

FST : filtre obtenu en préservant les polynômes de degré 2 et avec $\alpha = 0,00$, $\beta = 0,05$ et $\gamma = 0,95$.

La qualité des estimations intermédiaires peut également être analysée grâce aux prévisions implicites des différentes méthodes (figure 2.14). Pour rappel, il s'agit des prévisions de la série brute qui, en appliquant le filtre symétrique de Henderson sur la série prolongée, donnent les mêmes estimations que les moyennes mobiles asymétriques. Les prévisions du modèle ARIMA sont naïves et ne prennent pas en compte le point de retournement, contrairement aux autres méthodes. Autour du point de retournement, les prévisions implicites de la méthode FST sont peu plausibles (car assez éloignées de l'estimation finale), essentiellement du fait de la moyenne mobile utilisée pour l'estimation en temps réel (et donc pour la prévision à l'horizon de 6 mois). Enfin, la paramétrisation locale du filtre QL permet d'aboutir à des prévisions bien plus cohérentes même si le déphasage n'est pas modifié.

FIGURE 2.14 – Prévisions implicites liées aux estimations successives de la tendance-cycle de l'emploi (en logarithme) aux États-Unis.



Note : L'axe des ordonnées n'est pas le même entre les différents graphiques.

2.6.3 Discussion

Plusieurs enseignements peuvent être tirés de cette analyse empirique sur données simulées et réelles.

Sur les méthodes polynomiales locales, chercher à préserver des tendances polynomiales de degré supérieur à 2 (méthodes cubique-quadratique, CQ, et directe, DAF) augmente la variance des estimations (et donc l'ampleur des révisions) et le délai pour détecter des points de retournement. Ainsi, l'estimation en temps réel des méthodes utilisant les filtres asymétriques directs (DAF) peut être facilement améliorée en utilisant le filtre linéaire-constant (LC) ou quadratique-linéaire (QL). C'est par exemple le cas de la méthode de désaisonnalisation STL (*Seasonal-Trend decomposition based on Loess*) proposée par Cleveland et alii (1990) qui modélise par défaut une tendance locale de degré 1 : le gain à utiliser la méthode LC est donc dans ce cas limité mais il peut être important lorsque ce degré est modifié par l'utilisateur.

La paramétrisation locale des filtres polynomiaux locaux permet d'améliorer la qualité des estimations, surtout pour le filtre QL. Même lorsque le déphasage n'est pas diminué, elle permet de réduire les révisions et d'avoir des estimations plus cohérentes, notamment en termes de prévisions implicites. De plus, estimer localement et en temps réel les paramètres des méthodes polynomiale permet d'améliorer les estimations.

Concernant les méthodes fondées sur les espaces de Hilbert à noyau reproduisant (RKHS), les deux premières estimations des filtres $b_{q,\Gamma}$ et $b_{q,G}$ semblent peu cohérentes (ce qui a peu d'impact sur le déphasage puisqu'il faut au moins 2 mois pour détecter un point de retournement), comme les dernières estimations du filtre $b_{q,\varphi}$ (ce qui peut provenir d'un problème d'optimisation). Cela suggère que la méthode utilisée pour calibrer ces filtres n'est pas optimale pour tous les horizons de prévision. En effet, pour les premières estimations, on cherche plutôt à minimiser le déphasage ($b_{q,\varphi}$) et lorsque que l'on se rapproche du cas symétrique (lorsqu'au moins 4 points dans le futur sont connus, $q \geq 4$) on cherche plutôt à minimiser les révisions ($b_{q,\Gamma}$ ou $b_{q,G}$). Les performances du filtre $b_{q,\varphi}$ pourraient ainsi sûrement être améliorées en utilisant d'autres moyennes mobiles lorsqu'on se rapproche du filtre symétrique ($q \geq 4$).

Pour l'approche *Fidelity-Smoothness-Timeliness* (FST), les poids retenus pour les simulations ($\alpha = 0,00$ *fidelity*, $\beta = 0,05$ *smoothness* et $\gamma = 0,95$ *timeliness*) semblent donner de bons résultats en termes de déphasage et de révisions lorsqu'au moins un point dans le futur est connu ($q \geq 1$). Les critères utilisés dans cette méthode n'étant pas normalisés, les poids retenus reviennent à donner un poids plus important à la *timeliness* pour les premières estimations et un poids plus important à la *smoothness* lorsqu'on se rapproche du cas d'utilisation du filtre symétrique. En effet, plus q augmente (i.e., plus on utilise de points dans le futur), plus le déphasage et donc le critère associé à la *timeliness* est petit : le poids associé à la *smoothness* augmente donc et les moyennes mobiles trouvées se rapprochent du filtre symétrique d'Henderson (qui peut être construit en ne minimisant que la *smoothness*). En revanche, pour l'estimation en temps-réel ($q = 0$), les statistiques sur les révisions suggèrent que l'on pourrait améliorer les résultats en utilisant d'autres pondérations (par exemple avec un poids non nul à la *fidelity*). Cela suggère également que si l'on utilisait la méthode

ATS, où les critères sont normalisés, il faudrait sûrement associer un poids décroissant à la *timeliness* en fonction de l’horizon de prévision.

Enfin, dans cet article et dans ceux associés aux méthodes étudiées, les filtres asymétriques sont appliqués et comparés sur des séries déjà désaisonnalisées ou sans saisonnalité (séries simulées). Les révisions et donc le déphasage sont limités à 6 mois (lorsque le filtre symétrique est de 13 termes) et cela a l’avantage d’isoler les impacts des différents filtres des autres processus inhérents à la désaisonnalisation. Il y a toutefois deux inconvénients à cette simplification :

1. D’une part, l’estimation de la série désaisonnalisée dépend de la méthode utilisée pour extraire la tendance-cycle. Le choix de la méthode utilisée pour l’estimation de la tendance-cycle peut donc avoir un impact bien au-delà de 6 mois.
2. D’autre part, les moyennes mobiles étant des opérateurs linéaires, ils sont sensibles à la présence de points atypiques. L’application directe des méthodes peut donc conduire à des estimations biaisées, du fait de leur présence, alors que les méthodes de désaisonnalisation (comme la méthode X-13ARIMA) ont un module de correction des points atypiques. Par ailleurs, comme notamment montré par Dagum (1996), le filtre symétrique final utilisé par X-13ARIMA pour extraire la tendance-cycle (et donc celui indirectement utilisé lorsqu’on applique les méthodes sur les séries désaisonnalisées) laisse passer environ 72 % des cycles de 9 ou 10 mois (généralement associés à du bruit plutôt qu’à la tendance-cycle). Les filtres asymétriques finaux amplifient même les cycles de 9 ou 10 mois. Cela peut avoir pour conséquence l’introduction d’ondulations indésirables, c’est-à-dire la détection de faux points de retournement. Ce problème est réduit par la correction des points atypiques (ces cycles étant considérés comme de l’irrégulier). C’est ainsi que le *Nonlinear Dagum Filter* (NLDF) a été développé et consiste à :
 - a. appliquer l’algorithme de correction des points atypiques de X-13ARIMA sur la série désaisonnalisée, puis de la prolonger par un modèle ARIMA ;
 - b. effectuer une nouvelle correction des points atypiques en utilisant un seuil bien plus strict et appliquer ensuite le filtre symétrique de 13 termes. En supposant une distribution normale cela revient à modifier 48 % des valeurs de l’irrégulier.

Les *cascade linear filter* (CLF), notamment étudiés dans Dagum et Bianconcini (2023), correspondent à une approximation des NLDF en utilisant un filtre de 13 termes et lorsque les prévisions sont obtenues à partir d’un modèle ARIMA(0,1,1) où $\theta = 0, 40$.

Une piste d’étude serait alors d’étudier plus précisément l’effet des points atypiques sur l’estimation de la tendance-cycle et la détection des points de retournement, mais

aussi d'explorer de nouveaux types de filtres asymétriques fondés sur des méthodes robustes (comme les régressions locales robustes, les médianes mobiles, etc.).

2.7 Conclusion

Pour l'analyse conjoncturelle, la majorité des statisticiens fait directement ou indirectement appel à des méthodes d'extraction de la tendance-cycle. Elles sont par exemple utilisées pour réduire le bruit d'un indicateur afin d'en améliorer son analyse, et les modèles utilisés (comme les modèles de prévision) mobilisent généralement des séries désaisonnalisées qui s'appuient sur ces méthodes.

Le premier apport de cette étude est d'unifier la théorie autour des méthodes de construction des filtres asymétriques pour l'estimation en temps réel de la tendance-cycle. Toutes ces méthodes peuvent se voir comme des cas particuliers d'une formulation générale de construction des moyennes mobiles, ce qui permet de montrer leurs similitudes et leurs différences et ainsi les comparer plus facilement. Elles sont par ailleurs facilement mobilisables et comparables grâce à leur implémentation dans le *package* R `rjd3filters`. Celui-ci permet d'utiliser plusieurs outils, comme la construction des prévisions implicites, qui peuvent aider les statisticiens à évaluer la qualité des estimations récentes des différents filtres.

La comparaison des différentes méthodes permet de tirer quelques enseignements pour la construction de ces moyennes mobiles.

Premièrement, en période de retournement conjoncturel, des filtres asymétriques utilisés comme alternative au prolongement de la série par modèle ARIMA peuvent permettre de réduire les révisions des estimations intermédiaires de la tendance-cycle et une détection plus rapide des points de retournement.

Deuxièmement, en fin de période, modéliser des tendances polynomiales de degré supérieur à trois (cubique-quadratique, CQ, et directe, DAF) semble introduire de la variance dans les estimations (et donc plus de révisions) sans permettre de détection plus rapide des points de retournement. En fin de période, pour l'estimation de la tendance-cycle, nous pouvons donc nous restreindre aux méthodes modélisant des tendances polynomiales de degré au plus 2 (linéaire-constante, LC, et quadratique-linéaire, QL). Par ailleurs, paramétrer localement les filtres polynomiaux permet de détecter plus rapidement les points de retournement (surtout pour le filtre QL). Même lorsque le déphasage n'est pas diminué, la paramétrisation locale est recommandée car elle permet de réduire les révisions et d'avoir des estimations intermédiaires plus cohérentes avec les évolutions futures attendues. En revanche, avec ces méthodes, la longueur du filtre utilisé doit être adaptée à la variabilité de la série : si le filtre utilisé est trop long (c'est-à-dire si la variabilité de la série est « faible »), conserver des tendances polynomiales de degré au plus 1 (méthode LC) produit de moins bons résultats en termes de détection des points de retournement.

Enfin, sur les méthodes s'appuyant sur l'optimisation d'une somme pondérée de certains critères (espaces de Hilbert à noyau reproduisant, RKHS, approche *Fidelity-Smoothness-Timeliness*, FST, ou approche *accuracy-timeliness-smoothness*, ATS), les

performances pourraient être améliorées en utilisant des critères différents pour les différents filtres asymétriques. En effet, pour les premières estimations (lorsque peu de points dans le futur sont connus), le conjoncturiste peut préférer minimiser le déphasage alors que lorsqu'on se rapproche du cas d'utilisation du filtre symétrique (c'est-à-dire lorsqu'on se rapproche des estimations finales), le critère le plus important pourrait être la réduction des révisions. Par ailleurs, puisque les méthodes RKHS ou ATS sont sujettes à des problèmes d'optimisation (non unicité de la solution), une attention particulière doit être portée aux résultats de ces méthodes. Pour le filtre RKHS $b_{q,\varphi}$, minimisant le déphasage, cela conduit par exemple à de grandes révisions entre l'avant-dernière et la dernière estimation.

Cette étude pourrait être étendue de plusieurs manières.

Tout d'abord, elle n'est pas exhaustive et pourrait donc être complétée.

Parmi les approches étudiées, l'extension proposée aux méthodes polynomiales locales afin d'ajouter un critère sur le déphasage pourrait donner des résultats prometteurs. Parmi les approches récentes non étudiées, nous pouvons citer Vasyechko et Grun-Rehorme (2014) qui utilisent le noyau d'Epanechnikov pour construire des filtres asymétriques de 13 termes³⁵ ; Feng et Schäfer (2021) qui proposent, en fin de période, l'utilisation de poids optimaux (au sens de l'erreur quadratique moyenne) dans les régressions polynomiales locales ; ou Dagum et Bianconcini (2023) qui étudient également des filtres symétriques alternatifs à celui d'Henderson.

Parmi les pistes d'extension, on pourrait s'intéresser à l'impact de la longueur des filtres dans la détection des points de retournement. En effet, les filtres asymétriques sont calibrés avec des indicateurs calculés pour l'estimation des filtres symétriques (par exemple pour déterminer automatiquement sa longueur), alors qu'une estimation locale pourrait être préférée. Par ailleurs, nous nous sommes concentrés uniquement sur les séries mensuelles dont le filtre symétrique est de 13 termes, mais les résultats peuvent être différents si le filtre symétrique étudié est plus long/court et si l'on étudie des séries à d'autres fréquences (trimestrielles ou journalières par exemple).

Une autre piste pourrait être d'étudier l'impact des points atypiques : les moyennes mobiles, comme tout opérateur linéaire, sont très sensibles à la présence des points atypiques. Pour limiter leur impact, dans X-13ARIMA une forte correction des points atypiques est effectuée sur la composante irrégulière avant d'appliquer les filtres pour extraire la tendance-cycle. Cela amène donc à étudier l'impact de ces points sur l'estimation de la tendance-cycle et des points de retournement, mais aussi à explorer de nouveaux types de filtres asymétriques fondés sur des méthodes robustes (comme les régressions locales robustes ou les médianes mobiles).

35. Cela consiste à choisir la fenêtre par la méthode des plus proches voisins : quel que soit le nombre de points dans le futur connus, on utilisera toujours 13 observations pour estimer la tendance-cycle. Pour l'estimation en temps-réel, la moyenne mobile utilisera donc l'observation courante et 12 points passés. Ainsi, pour les estimations intermédiaires, on utilisera plus de points dans le passé que pour le filtre symétrique.

2.8 Annexes

2.8.1 Synthèse des liens entre les différentes méthodes de construction de moyennes mobiles

Cette annexe montre comment tous les filtres étudiés peuvent se retrouver à partir d'une formule générale de construction des moyennes mobiles. Elle décrit également les relations d'équivalences entre les différentes méthodes. Enfin, des graphiques synthétiques résument ces propriétés.

2.8.1.1 Formule générale de construction des filtres

Pour établir une formule générale englobant les principaux filtres linéaires, Grun-Rehorme et alii (2018) définissent deux critères. En changeant légèrement les notations utilisées par les auteurs afin d'avoir une formulation plus générale, ces deux critères peuvent s'écrire :

$$I(\boldsymbol{\theta}, q, y_t, u_t) = \mathbb{E} \left[(\Delta^q(M_{\boldsymbol{\theta}} y_t - u_t))^2 \right] \quad (2.15)$$

$$J(\boldsymbol{\theta}, f, \omega_1, \omega_2) = \int_{\omega_1}^{\omega_2} f[\rho_{\boldsymbol{\theta}}(\omega), \varphi_{\boldsymbol{\theta}}(\omega), \omega] d\omega \quad (2.16)$$

où y_t est la série étudiée, u_t une série de référence³⁶ et Δ est l'opérateur différence ($\Delta y_t = y_t - y_{t-1}$ et $\Delta^q = \underbrace{\Delta \circ \dots \circ \Delta}_{q \text{ fois}}$ pour $q \in \mathbb{N}$). Dans la majorité des cas, la fonction

f ne dépendra que de la fonction de gain, $\rho_{\boldsymbol{\theta}}$, et de la fonction de déphasage, $\varphi_{\boldsymbol{\theta}}$. Dans ce cas, par simplification on écrira $f[\rho_{\boldsymbol{\theta}}(\omega), \varphi_{\boldsymbol{\theta}}(\omega), \omega] = f[\rho_{\boldsymbol{\theta}}(\omega), \varphi_{\boldsymbol{\theta}}(\omega)]$.

La majorité des filtres linéaires peut s'obtenir par une minimisation d'une somme pondérée de ces critères, sous contrainte linéaire sur les coefficients :

$$\begin{cases} \min_{\boldsymbol{\theta}} & \sum_i \alpha_i I(\boldsymbol{\theta}, q_i, y_t, u_t^{(i)}) + \beta_i J(\boldsymbol{\theta}, f_i, \omega_{1,i}, \omega_{2,i}) \\ \text{s.t.} & \mathbf{C}\boldsymbol{\theta} = \mathbf{a} \end{cases}$$

En effet :

- L'extension des méthodes polynomiales de Proietti et Luati (2008) présentée dans la section 2.3.3 revient en effet à minimiser une somme pondérée de l'erreur quadratique de révision :

$$\mathbb{E} \left[\left(\sum_{i=-h}^h \theta_i^s y_{t+s} - \sum_{i=-h}^q v_i y_{t+s} \right)^2 \right] = I(v, 0, y_t, M_{\boldsymbol{\theta}^s} y_t),$$

36. La série de référence est en général un estimateur robuste de la tendance-cycle de Y_t que l'on cherche à approcher par application de la moyenne mobile $M_{\boldsymbol{\theta}}$ sur les observations y_t . Cet estimateur peut également dépendre de $M_{\boldsymbol{\theta}}$.

et du critère de *timeliness* :

$$T_g(\boldsymbol{\theta}) = J(f: (\rho, \varphi) \mapsto \rho^2 \sin(\varphi)^2, \omega_1, \omega_2).$$

sous une contrainte linéaire.

- Les critères des filtres symétriques de Gray et Thomson (1996) (section 2.3.4) sont :

$$\begin{aligned} F_{GT}(\boldsymbol{\theta}) &= I(\boldsymbol{\theta}, 0, y_t, g_t), \\ S_{GT}(\boldsymbol{\theta}) &= I(\boldsymbol{\theta}, d+1, y_t, 0). \end{aligned}$$

Les filtres asymétriques sont construits en minimisant l'erreur quadratique moyenne des révisions sous contraintes linéaires (préservation d'un polynôme de degré p).

- Les trois critères de la méthode FST de Grun-Rehorme et alii (2018) se retrouvent en notant $y_t = TC_t + \varepsilon_t$, $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ avec TC_t une tendance déterministe :

$$\begin{aligned} F_g(\boldsymbol{\theta}) &= I(\boldsymbol{\theta}, 0, y_t, \mathbb{E}[M_{\boldsymbol{\theta}} y_t]) \\ S_g(\boldsymbol{\theta}) &= I(\boldsymbol{\theta}, q, y_t, \mathbb{E}[M_{\boldsymbol{\theta}} y_t]) \\ T_g(\boldsymbol{\theta}) &= J(f: (\rho, \varphi) \mapsto \rho^2 \sin(\varphi)^2, \omega_1, \omega_2). \end{aligned}$$

- Les quatre critères A_w , T_w , S_w et R_w des filtres de Wildi et McElroy (2019) sont des cas particuliers du critère J défini dans l'équation 2.15. En notant :

$$\begin{cases} f_1: & (\rho, \varphi, \omega) \mapsto 2(\rho_s(\omega) - \rho)^2 h(\omega) \\ f_2: & (\rho, \varphi, \omega) \mapsto 8\rho_s(\omega)\rho \sin^2\left(\frac{\varphi}{2}\right) h(\omega) \end{cases},$$

on a :

$$\begin{aligned} A_w(\boldsymbol{\theta}) &= J(\boldsymbol{\theta}, f_1, 0, \omega_1), \\ T_w(\boldsymbol{\theta}) &= J(\boldsymbol{\theta}, f_2, 0, \omega_1), \\ S_w(\boldsymbol{\theta}) &= J(\boldsymbol{\theta}, f_1, \omega_1, \pi), \\ R_w(\boldsymbol{\theta}) &= J(\boldsymbol{\theta}, f_2, \omega_1, \pi). \end{aligned}$$

- Les filtres des espaces de Hilbert à noyau reproduisant correspondent à une sélection optimale du paramètre b selon les critères précédents, en imposant comme contrainte linéaire que les coefficients soient sous la forme $w_j = \frac{K_{d+1}(j/b)}{\sum_{i=-h}^p K_{d+1}(i/b)}$.

2.8.1.2 Liens entre les différentes méthodes

2.8.1.2.1 Critères de Gray et Thomson et ceux de Grun-Rehorme et alii

Les critères F_g et S_g peuvent se déduire de F_{GT} et S_{GT} . Les approches de Gray et Thomson (1996) et Grun-Rehomme et alii (2018) sont donc équivalentes pour la construction de filtres symétriques.

Notons $\mathbf{x}_t = (1 \ t \ t^2 \ \dots \ t^d)'$, $\boldsymbol{\beta} = (\beta_0 \ \dots \ \beta_d)'$.

Pour le critère de *fidelity* :

$$\hat{g}_t - g_t = \left(\sum_{j=-h}^{+h} \theta_j \mathbf{x}_{t+j} - \mathbf{x}_t \right) \boldsymbol{\beta} + \sum_{j=-h}^{+h} \theta_j \varepsilon_{t+j} + \sum_{j=-h}^{+h} \theta_j (\xi_{t+j} - \xi_t),$$

Si θ préserve les polynômes de degré d alors $\sum_{j=-h}^{+h} \theta_j \mathbf{x}_{t+j} = \mathbf{x}_t$. Puis, comme ξ_t et ε_t sont de moyenne nulle et sont non corrélés :

$$F_{GT}(\boldsymbol{\theta}) = \mathbb{E} [(\hat{g}_t - g_t)^2] = \boldsymbol{\theta}' (\sigma^2 \mathbf{I} + \boldsymbol{\Omega}) \boldsymbol{\theta}.$$

Si $\xi_t = 0$ alors $\boldsymbol{\Omega} = 0$ et $F_{GT}(\boldsymbol{\theta}) = F_g(\boldsymbol{\theta})$.

Pour la *smoothness* on a :

$$\nabla^q \hat{g}_t = \sum_{j=h}^h \theta_j \underbrace{\nabla^q ((x_j - x_0) \boldsymbol{\beta})}_{=0 \text{ si } q \geq d+1} + \sum_{j=h}^h \theta_j \nabla^q \varepsilon_{t+j} + \sum_{j=h}^h \theta_j \nabla^q \xi_{t+j}.$$

D'où pour $q = d + 1$:

$$S_{GT}(\boldsymbol{\theta}) = \mathbb{E} [(\nabla^q \hat{g}_t)^2] = \boldsymbol{\theta}' (\sigma^2 \mathbf{B}_q + \boldsymbol{\Gamma}_q) \boldsymbol{\theta}.$$

On peut, par ailleurs, montrer que pour toute série temporelle X_t ,

$$\nabla^q (M_{\boldsymbol{\theta}} X_t) = (-1)^q \sum_{k \in \mathbb{Z}} (\nabla^q \theta_k) X_{t+k-q},$$

avec $\theta_k = 0$ pour $|k| \geq h + 1$. Avec $\xi_t = 0$ on trouve donc que $S_{GT}(\boldsymbol{\theta}) = \sigma^2 S_g(\boldsymbol{\theta})$.

2.8.1.2.2 Équivalence avec les moindres carrés pondérés

Du fait de la forme des filtres obtenus par la méthode de Grun-Rehomme et alii (2018), lorsque les contraintes imposées sont la préservation des tendances de degré d , celle-ci est équivalente à une estimation locale d'une tendance polynomiale de degré d par moindres carrés généralisés. En effet, dans ce cas, la solution est $\hat{\boldsymbol{\theta}} = \boldsymbol{\Sigma}^{-1} \mathbf{X}'_p (\mathbf{X}_p \boldsymbol{\Sigma}^{-1} \mathbf{X}'_p)^{-1} \mathbf{e}_1$ avec $\boldsymbol{\Sigma} = \alpha \mathbf{F} + \beta \mathbf{S} + \gamma \mathbf{T}$, et c'est l'estimation de la constante obtenue par moindres carrés généralisés lorsque la variance des résidus est $\boldsymbol{\Sigma}$. L'équivalence entre les deux méthodes peut donc se voir comme un cas particulier de l'équivalence entre les moindres carrés pondérés et les moindres carrés généralisés. C'est par exemple le cas des filtres symétriques d'Henderson qui peuvent s'obtenir par les deux méthodes.

Dans ce sens, Henderson (1916) a montré que les poids $\mathbf{w} = (w_{-p}, \dots, w_f)$ associés à une moyenne mobile issue de la régression polynomiale locale par moindres carrés pondérés pouvaient s'écrire sous la forme :

$$w_i = \kappa_i P\left(\frac{i}{p+f+1}\right) \text{ où } P \text{ est un polynôme de degré } d.$$

Il a également montré l'inverse : toute moyenne mobile $\boldsymbol{\theta} = (\theta_{-p}, \dots, \theta_f)$ qui préserve les tendances de degré d et dont le diagramme des coefficients (c'est-à-dire la courbe de θ_t en fonction de t) change au plus d fois de signes peut être obtenue par une régression polynomiale locale de degré p estimée par moindres carrés pondérés. Pour cela il suffit de trouver un polynôme $P\left(\frac{x}{p+f+1}\right)$ de degré inférieur ou égal à d et dont les changements de signes coïncident avec les changements de signes de $\boldsymbol{\theta}$. Le noyau associé est alors $\kappa_i = \frac{\theta_i}{P\left(\frac{i}{p+f+1}\right)}$. C'est le cas de tous les filtres symétriques issus de l'approche FST et de la majorité des filtres asymétriques (figure 2.15).

FIGURE 2.15 – Ensemble des poids pour lesquels la méthode FST n'est pas équivalente aux moindres carrés pondérés pour $h = 6$ (filtre symétrique de 13 termes), sous contrainte de préservation des polynômes de degré au plus 3 ($d = 0, 1, 2, 3$).



Notes : La smoothness est calculée avec le paramètre $d = 3$ ($S_g(\boldsymbol{\theta}) = \sum_j (\nabla^3 \theta_j)^2$), comme pour le filtre symétrique d'Henderson.

Les poids sont calculés à partir d'un quadrillage de 200 points de l'intervalle $[0, 1]$ et en ne gardant que ceux tels que leur somme fasse 1.

Lorsque tous les filtres FST sont équivalents à une approche polynomiale, aucun graphique n'est tracé. Pour un filtre symétrique de 13 termes, la méthode FST est donc équivalente à une approche polynomiale sauf lorsqu'on ne contraint que la préservation des constante ($d = 0$), pour les filtres nécessitant au plus deux observations futures ($q = 0, 1$ ou 2) et seulement lorsque le poids associé à la timeliness est proche de 1.

Plus récemment, Luati et Proietti (2011) se sont intéressés aux cas d'équivalences entre les moindres carrés pondérés et les moindres carrés généralisés pour déterminer des noyaux optimaux (au sens de Gauss-Markov). Ils montrent que le noyau d'Epanechnikov est le noyau optimal associé à la régression polynomiale locale où le résidu, ε_t , est un processus moyenne mobile (MA) non inversible d'ordre 1 (i.e., $\varepsilon_t = (1 - B)\xi_t$, avec ξ_t un

bruit blanc). Dans ce cas, la matrice Σ de variance-covariance correspond à la matrice obtenue par le critère de *smoothness* avec le paramètre $q = 2$ ($\sum_j (\nabla^2 \theta_j)^2 = \theta' \Sigma \theta$) : il y a donc équivalence avec l'approche FST. De même, le noyau d'Henderson est le noyau optimal associé à la régression polynomiale locale où le résidu est un processus moyenne mobile (MA) non inversible d'ordre 2 (i.e., $\varepsilon_t = (1 - B)^2 \xi_t$, avec ξ_t un bruit blanc).

2.8.1.2.3 RKHS et polynômes locaux

Comme montré dans la section précédente, la théorie des espaces de Hilbert à noyau reproduisant permet de reproduire les filtres symétriques par approximation polynomiale locale. Comme le montrent Luati et Proietti (2011), cette théorie permet donc également de reproduire les filtres directs asymétriques (DAF), qui sont équivalents à l'approximation polynomiale locale mais en utilisant une fenêtre d'estimation asymétrique. Cependant, ils ne peuvent pas être obtenus par la formalisation de Dagum et Bianconcini (2008) mais par une discrétisation différente de la formule de l'équation 2.11 :

$$K_{d+1}(t) = \frac{\det \mathbf{H}_{d+1}[1, \mathbf{x}_t]}{\det \mathbf{H}_{d+1}} f_0(t),$$

où $\mathbf{H}_{d+1}[1, \mathbf{x}_t]$ est la matrice obtenue en remplaçant la première ligne de $\mathbf{H}_{d+1}$ par $\mathbf{x}_t = (1 \ t \ t^2 \ \dots \ t^d)'$. Dans le cas discret, $f_0(t)$ est remplacé par κ_j et en remplaçant les moments théoriques par les moments empiriques $\mathbf{H}_{d+1}$ devient $\mathbf{X}_p' \mathbf{K}_p \mathbf{X}_p$ et les coefficients du filtre asymétrique sont obtenus en utilisant la formule :

$$w_{a,j} = \frac{\det \mathbf{X}_p' \mathbf{K}_p \mathbf{X}_p [1, \mathbf{x}_j]}{\det \mathbf{X}_p' \mathbf{K}_p \mathbf{X}_p} \kappa_j.$$

En effet, la règle de Cramer permet de trouver une solution explicite à l'équation des moindres carrés $(\mathbf{X}_p' \mathbf{K}_p \mathbf{X}_p) \hat{\beta} = \mathbf{X}_p' \mathbf{K}_p \mathbf{y}_p$ où $\hat{\beta}_0 = \hat{m}_t$:

$$\hat{\beta}_0 = \frac{\det \mathbf{X}_p' \mathbf{K}_p \mathbf{X}_p [1, \mathbf{b}]}{\det \mathbf{X}_p' \mathbf{K}_p \mathbf{X}_p} f_0(t) \quad \text{où} \quad \mathbf{b} = \mathbf{X}_p' \mathbf{K}_p \mathbf{y}_p.$$

Comme $\mathbf{b} = \sum_{j=-h}^q \mathbf{x}_j \kappa_j y_{t+j}$ il vient :

$$\det \mathbf{X}_p' \mathbf{K}_p \mathbf{X}_p [1, \mathbf{b}] = \sum_{j=-h}^q \det \mathbf{X}_p' \mathbf{K}_p \mathbf{X}_p [1, \mathbf{x}_j] \kappa_j y_{t+j}.$$


Et enfin :

$$\hat{\beta}_0 = \hat{m}_t = \sum_{j=-h}^q \frac{\det \mathbf{X}_p' \mathbf{K}_p \mathbf{X}_p [1, \mathbf{x}_j]}{\det \mathbf{X}_p' \mathbf{K}_p \mathbf{X}_p} \kappa_j y_{t+j}.$$

2.8.1.3 Diagrammes synthétiques


Les figure 2.16, figure 2.17 résument les liens entre toutes les méthodes.

FIGURE 2.16 – Synthèse des méthodes de construction de moyennes mobiles symétriques $\boldsymbol{\theta} = (\theta_{-h}, \dots, \theta_h)$ de $2h + 1$ termes.



Note de lecture : $\mathbf{X} = \mathbf{X}_d = (\mathbf{x}_0 \quad \dots \quad \mathbf{x}_d)$ avec $\mathbf{x}_i = ((-h)^i \quad \dots \quad (h)^i)'$.

FIGURE 2.17 – Synthèse des méthodes de construction de moyennes mobiles asymétriques $\theta = (\theta_{-h}, \dots, \theta_q)$, $0 \leq q < h$ avec θ^s le filtre symétrique de référence de $2h + 1$ termes.



Note de lecture : $\mathbf{X}_d = (\mathbf{x}_0 \ \cdots \ \mathbf{x}_d)$ avec $\mathbf{x}_i = ((-h)^i \ \cdots \ (q)^i)'$ et $\mathbf{X} = \mathbf{X}_d$ avec $q = h$.

2.8.2 Coefficients, fonctions de gain et de déphasage

FIGURE 2.18 – Coefficients, fonctions de gain et de déphasage pour le filtre *Linear-Constant* (LC) avec $I/C = 3, 5$.




FIGURE 2.19 – Coefficients, fonctions de gain et de déphasage pour le filtre *Quadratic-Linear* (QL) avec $I/C = 3, 5$.




FIGURE 2.20 – Coefficients, fonctions de gain et de déphasage pour le filtre *Cubic-Quadratic* (CQ) avec $I/C = 3, 5$.




FIGURE 2.21 – Coefficients, fonctions de gain et de déphasage pour le filtre asymétrique direct (DAF).




FIGURE 2.22 – Coefficients, fonctions de gain et de déphasage pour le filtre RKHS $b_{q,\Gamma}$.




FIGURE 2.23 – Coefficients, fonctions de gain et de déphasage pour le filtre RKHS $b_{q,G}$.




FIGURE 2.24 – Coefficients, fonctions de gain et de déphasage pour le filtre RKHS $b_{q,\varphi}$.





FIGURE 2.25 – Coefficients, fonctions de gain et de déphasage pour le filtre FST préservant les polynômes de degré 2 avec $\alpha = 0,00$ (*fidelity*), $\beta = 0,05$ (*smoothness*) et $\gamma = 0,95$ (*timeliness*).



2.8.3 Exemple sous R

Cette annexe présente le code utilisé pour les exemples sur le climat des affaires dans l'industrie automobile.

```
# remotes::install_github("rjdverse/rjd3toolkit")
# remotes::install_github("rjdverse/rjd3filters")
# remotes::install_github("rjdverse/rjd3x11plus")
library(rjd3filters)
library(rjd3x11plus)
library(ggplot2)
library(patchwork)
library(zoo)
library(forecast)
library(insee)
y <- data.frame(insee::get_insee_idbank("001786505"))
y <- y[order(y[, "TIME_PERIOD"]), ]
first_date <- as.numeric(strsplit(y$TIME_PERIOD[1], "-")[[1]])
y <- ts(y$OBS_VALUE, start = first_date, frequency = 12)
y <- window(y, end = c(2023, 5))
```

```

y <- window(y, start = 2010)
last_dates <- c(tail(time(y), 7))
names(last_dates) <- as.character(zoo::as.yearmon(last_dates))
der_est <- lapply(last_dates, function(x) window(y, end = x))

# MM de longueur 13 adaptées :
select_trend_filter(y)
# Estimation finale
tc_f <- henderson(y, length = 13, musgrave = FALSE) # Estimation finale
plot(y)
lines(tc_f, col = "red")

forecast::autoplot(ts.union(y, tc_f))

## Méthode polynomiale

# Calcul des IC-ratios :
icr <- sapply(der_est, function(x) {
  ic_ratio(x, henderson(x, length = 13, musgrave = FALSE))
})
lp_est <- lapply(c("LC", "QL", "CQ", "DAF"), function(method) {
  res <- lapply(seq_along(icr), function(i) {
    lp_coef <- lp_filter(horizon = 6,
                        kernel = "Henderson",
                        endpoints = method,
                        ic = icr[i])
    rjd3filters::filter(der_est[[i]], lp_coef)
  })
  names(res) <- names(der_est)
  res
})
lp_if <- lapply(c("LC", "QL", "CQ", "DAF"), function(method) {
  res <- lapply(seq_along(icr), function(i) {
    lp_coef <- lp_filter(horizon = 6,
                        kernel = "Henderson",
                        endpoints = method,
                        ic = icr[i])
    implicit_forecast(der_est[[i]], lp_coef)
  })
  names(res) <- names(der_est)
  res
})

```



```

})
names(lp_est) <- names(lp_if) <- c("LC", "QL", "CQ", "DAF")

# Estimation locale des IC-ratios
# On réplique l'estimation directe pour avoir
# des estimateurs de la pente et de la concavité

gen_MM <- function(p=6, q=p, d=2){
  X_gen <- function(d = 1, p = 6, q = p){
    sapply(0:d, function(exp) seq(-p, q)^exp)
  }
  k = rjd3filters::get_kernel("Henderson", h = p)
  k = c(rev(k$coef[-1]), k$coef[seq(0,q)+1])
  K = diag(k)
  X = X_gen(d=d, p = p, q = q)
  e1 = e2 = e3 = matrix(0, ncol = 1, nrow = d+1)
  e1[1] = 1
  e2[2] = 1
  e3[3] = 1
  # Estimateur de la constante
  M1 = K %*% X %*% solve(t(X) %*% K %*% X, e1)
  # estimateur de la pente
  M2 = K %*% X %*% solve(t(X) %*% K %*% X, e2)
  # estimateur de la concavité
  M3 = K %*% X %*% solve(t(X) %*% K %*% X, e3)
  mm <- list(const = M1, pente = M2, concav = M3)
  lapply(mm, moving_average, lags = -p)
}

all_mm <- lapply(6:0, gen_MM, p = 6, d = 2)
est_pente <- finite_filters(all_mm[[1]]$pente,
                           lapply(all_mm[-1], `[`, "pente"))
est_concav <- finite_filters(all_mm[[1]]$concav,
                           lapply(all_mm[-1], `[`, "concav"))

henderson_f <- lp_filter(h=6)$sfilter
lp_filter2 <- function(icr, method = "LC", h = 6, kernel = "Henderson"){
  all_coef = lapply(icr, function(ic){
    lp_filter(horizon = h,
              kernel = kernel,
              endpoints = method,
              ic = ic)
  })
}

```

```

rfilters = lapply(1:h, function(i){
  q <- h - i
  all_coef[[i]][,sprintf("q=%i", q)]
})
finite_filters(henderson_f, rfilters = rfilters)
}
loc_lc_est <-
  lapply(der_est, function(x) {
    est_loc_pente <- c(tail(est_pente * x, 6))
    sigma2 <- var_estimator(x, henderson_f)
    icr = 2/(sqrt(pi) * (est_loc_pente / sqrt(sigma2)))
    lp_coef = lp_filter2(ic = icr,
                        method = "LC", h = 6, kernel = "Henderson")
    rjd3filters::filter(x, lp_coef)
  })
loc_lc_if <-
  lapply(der_est, function(x) {
    est_loc_pente <- c(tail(est_pente * x, 6))
    sigma2 <- var_estimator(x, henderson_f)
    icr = 2/(sqrt(pi) * (est_loc_pente / sqrt(sigma2)))
    lp_coef = lp_filter2(ic = icr,
                        method = "LC", h = 6, kernel = "Henderson")
    implicit_forecast(x, lp_coef)
  })
loc_ql_est <-
  lapply(der_est, function(x) {
    est_loc_concav <- c(tail(est_concav * x, 6))
    sigma2 <- var_estimator(x, henderson_f)
    icr = 2/(sqrt(pi) * (est_loc_concav / sqrt(sigma2)))
    lp_coef = lp_filter2(ic = icr,
                        method = "QL", h = 6, kernel = "Henderson")
    rjd3filters::filter(x, lp_coef)
  })
loc_ql_if <-
  lapply(der_est, function(x) {
    est_loc_concav <- c(tail(est_concav * x, 6))
    sigma2 <- var_estimator(x, henderson_f)
    icr = 2/(sqrt(pi) * (est_loc_concav / sqrt(sigma2)))
    lp_coef = lp_filter2(ic = icr,
                        method = "QL", h = 6, kernel = "Henderson")
    implicit_forecast(x, lp_coef)
  })

```

```

# Pour la méthode RKHS, pour le filtre b_q,phi on utilise
# le paramètre bw de l'article Dagum et Bianconcini (2015)
bw_phase <-c(`q=6` = 7, `q=5` = 6.95, `q=4` = 6.84,
            `q=3` = 6.85, `q=2` = 7.34,
            `q=1` = 9.24, `q=0` = 11.78)
rkhs_filter <- list(
  "$b_{q,\\Gamma}$" = rkhs_filter(
    horizon = 6, degree = 3,
    asymmetricCriterion = "FrequencyResponse",
    kernel = "Biweight", passband = pi
  ),
  "$b_{q,G}$" = rkhs_filter(
    horizon = 6, degree = 3,
    asymmetricCriterion = "Accuracy",
    kernel = "Biweight", passband = pi
  ),
  "$b_{q,\\phi}$" = finite_filters(
    do.call(cbind, lapply(seq_along(bw_phase), function(i){
      rkhs_filter(horizon = 6, degree = 3,
                  kernel = "Biweight",
                  optimalbw = FALSE,
                  bandwidth = bw_phase[i]))[,names(bw_phase)[i]]
    })))
)
)
rkhs_est <- lapply(rkhs_filter, function(method) {
  lapply(der_est, function(x) {
    x * method
  })
})

rkhs_if <- lapply(rkhs_filter, function(method) {
  lapply(der_est, function(x) {
    implicit_forecast(x, method)
  })
})

fst_f <- finite_filters(
  sfilter = fst_filter(lags = 6, leads = 6, pdegree=2,
                      smoothness.weight=0.05, smoothness.degree=3,
                      timeliness.weight=0.95,
                      timeliness.passband=2*pi/12,

```

```

        timeliness.antiphase=TRUE),
  rfilters = lapply(5:0, fst_filter, lags = 6, pdegree=2,
                    smoothness.weight=0.05, smoothness.degree=3,
                    timeliness.weight=0.95,
                    timeliness.passband=2*pi/12,
                    timeliness.antiphase=TRUE))
fst_est <- lapply(der_est, function(x) {
  x * fst_f
})
fst_if <- lapply(der_est, function(x) {
  implicit_forecast(x, fst_f)
})

## Graphiques

# Pour tracer toutes les estimations
plot_est <- function(data, nperiod = 6) {
  joint_data <- do.call(ts.union, data)
  joint_data <-
    window(joint_data,
           start = last_dates[1] - nperiod * deltat(joint_data))

  data_legend <-
    data.frame(x = last_dates,
              y = sapply(data, tail, 1),
              label = colnames(joint_data))

  forecast::autoplot(joint_data) + theme_bw() +
    scale_x_continuous(labels = zoo::as.yearmon) +
    geom_text(aes(x = x, y = y, label = label, colour = label),
              data = data_legend,
              check_overlap = TRUE, hjust = 0, nudge_x = 0.01,
              size = 2, inherit.aes = FALSE) +
    theme(legend.position = "none") +
    labs(x = NULL, y = NULL)
}

plot_prevs <- function (data, nperiod = 6) {
  joint_data <- do.call(ts.union, lapply(data, function(x) {
    first_date <- time(x)[1] - deltat(x)
    # On rajoute la dernière date observée par lisibilité
    ts(c(window(y, start = first_date, end = first_date), x),

```

```

        start = first_date, frequency = frequency(x))
    )))

data_legend <-
  data.frame(x = sapply(data, function(x) tail(time(x), 1)),
            y = sapply(data, tail, 1),
            label = colnames(joint_data))
forecast::autoplot(joint_data, linetype = "dashed") +
  forecast::autolayer(
    window(y, start = last_dates[1] - nperiod * deltat(y)),
    colour = FALSE
  ) +
  theme_bw() +
  scale_x_continuous(labels = zoo::as.yearmon) +
  geom_text(aes(x = x, y = y, label = label, colour = label),
            data = data_legend,
            check_overlap = TRUE, hjust = 0, nudge_x = 0.01,
            size = 2, inherit.aes = FALSE) +
  theme(legend.position = "none") +
  labs(x = NULL, y = NULL)
}

all_est <- c(lp_est, list("LC param. locale" = loc_lc_est),
            list("QL param. locale" = loc_ql_est),
            rkhs_est,
            list(FST = fst_est))
all_if <- c(lp_if, list("LC param. locale" = loc_lc_if),
            list("QL param. locale" = loc_ql_if),
            rkhs_if,
            list(FST = fst_if))
y_lim <- c(102, 105)
all_plots_est <- lapply(
  names(all_est),
  function(x) plot_est(all_est[[x]]) +
    ggtitle(latex2exp::TeX(sprintf("Tendance-cycle avec %s", x))) +
    coord_cartesian(ylim = y_lim)
)
all_plots_prev <- lapply(
  names(all_if),
  function(x) plot_prevs(all_if[[x]]) +
    ggtitle(latex2exp::TeX(sprintf("Prévisions implicites avec %s", x)))
)

```

```

wrap_plots(all_plots_est[1:4], ncol = 2)
wrap_plots(all_plots_prev[1:4], ncol = 2)

wrap_plots(all_plots_est[c(1,5,2,6)], ncol = 2)
wrap_plots(all_plots_prev[c(1,5,2,6)], ncol = 2)

wrap_plots(c(all_plots_est[7:9],
              all_plots_prev[7:9]), nrow = 2)

wrap_plots(c(all_plots_est[10], all_plots_prev[10]), nrow = 1)

```

2.8.4 Noyaux et régression locale

2.8.4.1 Les différents noyaux

Dans les problèmes d'extraction du signal, les observations sont généralement pondérées par rapport à leur distance à la date t : pour estimer la tendance-cycle à la date t , on accorde généralement plus d'importance aux observations qui sont proches de t .

Dans le cas continu, un noyau κ est une fonction positive, paire et intégrable telle que $\int_{-\infty}^{+\infty} \kappa(u) du = 1$ et $\kappa(u) = \kappa(-u)$. Dans le cas discret, un noyau est un ensemble de poids κ_j , $j = 0, \pm 1, \dots, \pm h$ avec $\kappa_j \geq 0$ et $\kappa_j = \kappa_{-j}$.

Une classe importante de noyaux est celle des noyaux Beta. Dans le cas discret, à un facteur multiplicatif près (de sorte que $\sum_{j=-h}^h \kappa_j = 1$) :

$$\kappa_j = \left(1 - \left|\frac{j}{h+1}\right|^r\right)^s, \quad \text{avec } r > 0, s \geq 0.$$

Cette classe englobe la majorité des noyaux présentés dans cette étude, à l'exception des noyaux d'Henderson, trapézoïdal et gaussien. Les principaux noyaux (qui sont également implémentés dans `rjd3filters`) sont :

— $r = 1, s = 0$ noyau uniforme :

$$\kappa_j^U = 1$$

(ou parabolique) :

$$\kappa_j^E = \left(1 - \left|\frac{j}{h+1}\right|^2\right)$$

— $r = s = 1$ noyau triangulaire :

$$\kappa_j^T = \left(1 - \left|\frac{j}{h+1}\right|\right)$$

— $r = s = 2$ noyau quadratique (*bi-weight*) :

$$\kappa_j^{BW} = \left(1 - \left|\frac{j}{h+1}\right|^2\right)^2$$

— $r = 2, s = 1$ noyau d'Epanechnikov

— $r = 2, s = 3$ noyau cubique (*tri-weight*) :

$$\kappa_j^{TW} = \left(1 - \left|\frac{j}{h+1}\right|^2\right)^3$$

— $r = s = 3$ noyau tricube :

$$\kappa_j^{TC} = \left(1 - \left|\frac{j}{h+1}\right|^3\right)^3$$

— noyau d'Henderson (voir section 2.8.4.2 pour plus de détails) :

$$\kappa_j = \left[1 - \frac{j^2}{(h+1)^2}\right] \left[1 - \frac{j^2}{(h+2)^2}\right] \left[1 - \frac{j^2}{(h+3)^2}\right] \kappa_j^G = \exp\left(-\frac{j^2}{2\sigma^2 h^2}\right)$$

— noyau trapézoïdal :

$$\kappa_j^{TP} = \begin{cases} \frac{1}{3(2h-1)} & \text{si } j = \pm h \\ \frac{2}{3(2h-1)} & \text{si } j = \pm(h-1) \\ \frac{1}{2h-1} & \text{sinon} \end{cases}$$

— noyau gaussien ³⁷ :

Les noyaux d'Henderson, trapézoïdal et gaussien sont particuliers :

- Les fonctions noyau d'Henderson et trapézoïdal changent avec la fenêtre (les autres dépendent uniquement du rapport $j/(h+1)$).
- Pour les noyaux trapézoïdal et gaussien, d'autres définitions pourraient être utilisées et ils sont donc définis arbitrairement. Pour le noyau trapézoïdal on pourrait par exemple prendre une pente utilisant moins de points (par exemple $\begin{cases} \frac{1}{4h} & \text{si } j = \pm h \\ \frac{2}{4h} & \text{sinon} \end{cases}$) ou donner un poids plus faible aux observations extrêmes (par exemple $\begin{cases} \frac{1}{6h-1} & \text{si } j = \pm h \\ \frac{3}{6h-1} & \text{sinon} \end{cases}$) ; pour le noyau gaussien on pourrait prendre une variance plus ou moins élevée.

Le noyau trapézoïdal implémenté dans `rjd3filters` permet de calculer les moyennes mobiles utilisées dans l'algorithme X-13ARIMA pour l'extraction des composantes saisonnières. Il n'est pas adapté dans le cas de l'extraction de la tendance-cycle.

2.8.4.2 Quelques filtres symétriques particuliers

Lorsque l'on effectue une régression locale en modélisant une constante locale ($d = 0$), on obtient l'estimateur de **Nadaraya-Watson** (ou l'estimateur par noyaux).

Avec le noyau uniforme on obtient le filtre de Macaulay et alii (1931). Lorsque $d = 0$ ou $d = 1$, on retrouve la moyenne arithmétique : $w_j = w = \frac{1}{2h+1}$.

Le noyau d'**Epanechnikov** est souvent recommandé comme le noyau optimal car il minimise l'erreur quadratique moyenne de l'estimation par polynômes locaux.

37. Dans `rjd3filters` σ^2 est fixé arbitrairement à $\sigma^2 = 0,25$.

Le **Loess**, *locally estimated scatterplot smoothing* (notamment utilisé dans la méthode de désaisonnalisation STL), est une régression locale pondérée qui utilise le noyau tricube.

Le **filtre d'Henderson** est un cas particulier de l'approximation locale cubique ($d = 3$), couramment utilisée pour l'extraction de la tendance-cycle (c'est par exemple le filtre utilisé dans le logiciel de désaisonnalisation X-13ARIMA). Pour une fenêtre fixée, Henderson a trouvé le noyau qui donnait l'estimation la plus lisse de la tendance. Il montre l'équivalence entre les trois problèmes suivants :

1. minimiser la variance de la différence d'ordre trois de la série lissée par l'application d'une moyenne mobile ;
2. minimiser la somme du carré de la différence d'ordre trois des coefficients du filtre, c'est le critère de lissage (*smoothness*) : $S = \sum_j (\nabla^3 \theta_j)^2$;
3. estimer une tendance localement cubique par les moindres carrés pondérés, où les poids sont choisis de sorte à minimiser la *smoothness* (cela conduit au noyau présenté dans la section [2.8.4.1](#)).

3 Amélioration des estimations de tendance-cycle grâce à la paramétrisation locale des filtres de régression polynomiale ¹

3.1 Introduction

Analysis of the economic cycle, and in particular the early detection of turning points, is a major topic in the analysis of economic outlook. To achieve this, economic indicators are generally seasonally adjusted. However, in order to improve their interpretability, it may be necessary to perform additional smoothing to reduce noise, thereby to analyse the trend-cycle component. By construction, trend-cycle extraction methods are closely related to seasonal adjustment methods, since they are generally applied to seasonally adjusted series.

A moving average, or linear filter, is a statistical method that consists of applying a rolling weighted mean to a times series: for each date t it computes a weighted mean of p past points and q future points where $p, q \geq 0$ depends on the moving average. They are ubiquitous in business cycle extraction and seasonal adjustment methods. For example, the X-11 seasonal adjustment method (Ladiray et Quenneville 2011), used in X-13ARIMA-SEATS software (Monsell 2007), uses several moving averages to estimate the main components of a time series. Symmetric filters are applied to the centre of the series and for trend-cycle extraction, the most popular symmetric filter is the Henderson (1916) moving average, which is used in the X-11 seasonal adjustment algorithm. However, for real-time estimates, due to the lack of future observations, all these methods must rely on asymmetric filters to estimate the most recent points. For example, for trend-cycle extraction, X-11 uses Henderson's symmetric filter and Musgrave (1964)'s asymmetric filters on an extended series using an ARIMA model. Since the predicted values are linear combinations of past values, this amounts to applying asymmetric moving averages at the end of the series. If the classic asymmetric

1. Références de l'article : Quartier-la-Tente, A. (2024). Improving Real-Time Trend Estimates Using Local Parametrization of Polynomial Regression Filters. *Journal of Official Statistics*, 40(4), 685-715. <https://doi.org/10.1177/0282423X241283207>.

moving averages have good properties regarding the future revisions induced by the process (for example Pierce (1980) shows similar performances in terms of revisions of X-11 compared to theoretically superior procedure based on ARIMA forecast models), they create, by construction, phase shifts that impact the real-time estimation of turning points, introducing time delay in the detection.

In the last decades, numerous authors proposed methods for the construction of alternative moving averages to derive trend-cycle estimates. In particular, Wildi et McElroy (2019) put forth a model-based approach based on the mean squared error decomposition, while Proietti et Luati (2008), Dagum et Bianconcini (2008) and Grun-Rehonne et alii (2018) proposed non-parametric methods based, respectively, on local polynomial regression, Reproducing Kernel Hilbert Space (RKHS) theory and minimising of a weighted sum of moving average quality criteria. All of the aforementioned approaches encompass both Henderson’s symmetric filter and Musgrave’s asymmetric filters. More recently, Quartier-la-Tente (2024a) conducted a comparative analysis of these methods by describing a general unifying framework to derive moving averages; Dagum et Bianconcini (2023) provided statistical tests to assess the main properties of the filters defined in terms of revisions and the detection of turning points.

The aim of this study is to propose two extensions to the Proietti et Luati (2008) class of filters in order to take account of two drawbacks of those methods: firstly adding, in the optimisation process, a timeliness criterion to directly control the phase shift (i.e., the delay in detecting turning points); secondly calibrating asymmetric filters locally, while they are generally calibrated globally using assumptions that may be wrong locally. Those extensions are implemented in the statistical software R (R Core Team 2022) through the `rjd3filters` package (Palate et Quartier-la-Tente 2024) and can therefore be easily used. All the code associated to this paper is available at <https://github.com/AQLT/joffstats2024>.

In section 3.2, we describe the general properties of moving averages and the associated quality criteria. This allows us to understand the foundations behind the construction of moving averages from local polynomial regressions, as well as those behind the two extensions proposed in this article (section 3.3). In section 3.4, all these methods are compared empirically on simulated and real series.

3.2 Local trend-cycle models and moving averages

The basic assumption used in time series decomposition methods is that the input observed time series, y_t , can be decomposed into a signal component μ_t and an erratic component ε_t (called irregular):

$$f(y_t) = \mu_t + \varepsilon_t$$

where f denotes some appropriate transformation (usually logarithmic or no transformation). To simplify further notations, y_t will denote the transformed observed series. The noise component ε_t is usually assumed to be a white noise. Assuming that the input time series is seasonally adjusted (or without seasonality), the signal μ_t represents the trend (sustained and systematic variations over a long period of time) and cycle (cyclical movements superimposed upon the long-term trend) components, here estimated jointly and called trend-cycle TC_t . This component can be locally approximated by a polynomial degree (section 3.3):

$$\mu_t = \sum_{j=0}^d \beta_j t^j + \xi_t$$

with ξ_t a stochastic process uncorrelated with ε_t . Even if some papers model ξ_t and ε_t separately (see for example Gray et Thomson 2002), a usual assumption, adopted in this paper, is to gather ξ_t and ε_t . Thus, the trend-cycle TC_t is considered as deterministic and modelled as a polynomial trend of degree d . The coefficients $(\beta_0, \dots, \beta_d)$ can be estimated by weighted least squares. The estimate $\hat{\beta}_0$ provides the trend-cycle estimate $\widehat{TC}_t$ and it can be shown that this equivalent to apply of moving average (section 3.3). The goal of this paper is to present two new methods to separate the trend-cycle component from the noise component in real-time (i.e., when no future point is known), using moving averages build on local polynomial smoothing techniques.

Numerous papers describe the definition and the properties of moving averages and linear filters; see for example Ladiray (2018). In this section we summarize some of the main results to understand the next sections.

Let p and f two integers, a moving average M_{θ} is defined by a set of coefficients $\theta = {}^t(\theta_{-p} \ \dots \ \theta_f)$ such that for all time series y_t :

$$M_{\theta}(y_t) = \sum_{k=-p}^{+f} \theta_k X_{t+k}.$$

- $p + f + 1$ is called the *moving average order*.
- When $p = f$ the moving average is said to be *centred*. If we also have $\forall k : \theta_{-k} = \theta_k$, the moving average M_{θ} is said to be *symmetric*. In this case, the quantity $h = p = f$ is called the *bandwidth*.

3.2.1 Gain and phase shift functions

To interpret the notions of gain and phase shift, it is useful to illustrate the effects of moving averages on harmonic series $y_t = e^{-i\omega t}$ with $\omega \in [0, \pi]$. The moving average

M_{θ} transforms y_t into:

$$Y_t = M_{\theta} y_t = \sum_{k=-p}^{+f} \theta_k e^{-i\omega(t+k)} = \left(\sum_{k=-p}^{+f} \theta_k e^{-i\omega k} \right) \cdot y_t.$$

The function $\Gamma_{\theta}(\omega) = \sum_{k=-p}^{+f} \theta_k e^{-i\omega k}$ is called the *transfer function* or *frequency response function*. The frequency response function can alternatively be defined as $\Gamma_{\theta}(\omega) = \sum_{k=-p}^{+f} \theta_k e^{i\omega k}$ or $\Gamma_{\theta}(\omega) = \sum_{k=-p}^{+f} \theta_k e^{2\pi i \omega k}$. It can be rewritten as:

$$\Gamma_{\theta}(\omega) = \rho_{\theta}(\omega) e^{i\varphi_{\theta}(\omega)},$$

where $\rho_{\theta}(\omega) = G_{\theta}(\omega) = |\Gamma_{\theta}(\omega)|$ is the *gain* or *amplitude* function and $\varphi_{\theta}(\omega)$ is the *phase shift* or *time shift* function. We thus have:

$$\begin{aligned} \rho_{\theta}(\omega) &= \sqrt{\left(\sum_{k=-p}^{+f} \theta_k \cos(\omega k) \right)^2 + \left(\sum_{k=-p}^{+f} \theta_k \sin(\omega k) \right)^2} \\ \tan \varphi_{\theta}(\omega) &= -\frac{\sum_{k=-p}^{+f} \theta_k \sin(\omega k)}{\sum_{k=-p}^{+f} \theta_k \cos(\omega k)} \text{ if } \sum_{k=-p}^{+f} \theta_k \cos(\omega k) \neq 0 \\ &= 0 \text{ if } \sum_{k=-p}^{+f} \theta_k \cos(\omega k) = 0. \end{aligned}$$

The phase shift is sometimes represented as $\phi_{\theta}(\omega) = \frac{\varphi_{\theta}(\omega)}{\omega}$ to measure it in number of periods. For all symmetric moving averages we have $\varphi_{\theta}(\omega) \equiv 0 \pmod{\pi}$.

To sum up, applying a moving average to a harmonic times series ($y_t = e^{-i\omega t}$) affects it in two different ways:


- by multiplying it by an amplitude coefficient $\rho_{\theta}(\omega)$ (gain);
- by “shifting” it in time by $\varphi_{\theta}(\omega)/\omega$ which directly affects the detection of turning points. When $\varphi_{\theta}(\omega)/\omega < 0$ the time shift is negative: the turning point is detected with delay.

Fourier decomposition allows us to analyse any time series as a sum of harmonic series, and each component (trend, cycle, seasonal, irregular) is associated with a set of frequencies. With $\omega = 2\pi/s$, the harmonic series of frequency ω represents a series that repeats itself every s periods. For example, for a monthly series ($s = 12$ observations per year), seasonal movements are those that repeat every year: they are therefore associated with frequencies $2\pi/12$ (annual periodicity), $2\pi/12 \times 2 = 2\pi/6, \dots, 2\pi/12 \times 5$. In this paper, we consider that the trend-cycle is associated with frequencies in the interval $[0, 2\pi/12]$, i.e., movements recurring at least every 12 months. Even if different frequencies are sometimes used (e.g. $[0, 2\pi/36]$ to consider only cycles of at least 36 months), this has no impact on the results of the study. The other frequencies, $[2\pi/12, \pi]$ are associated with the irregular component.

Figure 3.1 shows the gain and phase shift function for the asymmetric Musgrave filter (see section 3.3.2) often used for real-time trend-cycle estimation (i.e., when no point in the future is known). The gain function is greater than 1 on the frequencies associated with the trend-cycle ($[0, 2\pi/12]$): this means that the trend-cycle is well preserved and that short cycles of 1 to 2 years ($[2\pi/24, 2\pi/12]$) are even amplified. At other frequencies, the gain function is less than 1, but always positive: this means that the series smoothed by this moving average will always contain noise, even if it is attenuated. Analysis of the phase shift shows that the shorter the cycles, the greater the phase shift: this means that on series smoothed by this moving average, turning points could be detected at the wrong date.

Observed in figure 3.1 that for monthly times series, 12-month cycles (associated to the frequency $2\pi/12 = \pi/6$) are amplified by 10% ($G_\theta(\pi/6) \simeq 1.1$) and associated turning points are detected with a delay of 1 months ($\varphi_\theta(\pi/6)/(\pi/6) \simeq -1$). 8-month cycles (associated to the irregular) are only reduced by 6% ($G_\theta(\pi/4) \simeq 0.94$). Note that the Musgrave filter depends on a ratio denoted I/C (see section 3.3). In X-11, for monthly series, when the bandwidth is 6 (i.e.: a symmetric Henderson filter of order 13 is used, what is used in most cases), the ratio is fixed to 3.5 and this value is used in this figure.

FIGURE 3.1 – Coefficients, gain and phase shift function for the Musgrave filter used in X-11 in real-time (last estimate) for monthly series when the bandwidth is 6.



3.2.2 Desirable properties of a moving average

To decompose a time series into a seasonal component, a trend-cycle and the irregular, the X-11 decomposition algorithm (used in X-13ARIMA-SEATS) uses a succession of moving averages, all with specific constraints.

In this paper, we assume that our initial series y_t is seasonally adjusted and can be written as the sum of a trend-cycle, TC_t , and an irregular (noise) component, ε_t :

$$y_t = TC_t + \varepsilon_t.$$

The aim will be to build moving averages that best preserve the trend-cycle ($M_\theta(TC_t) \simeq TC_t$).

Trend-cycles are generally modelled by local polynomial trends (see section 3.3) and, in order to best preserve the trend-cycles, we thus design moving averages that preserve the polynomial trends. A moving average M_θ preserves a function of time $f(t)$ if $\forall t, M_\theta f(t) = f(t)$.

For a moving average M_θ , it can be shown that:

- M_θ preserves polynomials of degree d if and only if:

$$\sum_{k=-p}^{+f} \theta_k = 1 \text{ (preserves constant) and } \forall j \in \{1, 2, \dots, d\}, \sum_{k=-p}^{+f} k^j \theta_k = 0.$$

- If M_θ is symmetric ($p = f$ and $\theta_{-k} = \theta_k$) and preserves polynomials of degree $2d$ then it also preserves polynomials of degree $2d + 1$.

3.2.3 Real-time estimation and asymmetric moving average

For symmetric filters, the phase shift function is equal to 0 (modulo π). So there is no delay in detecting turning points. However, they cannot be used in the beginning and in the end of the time series because no past or future value can be used. Thus, for real-time estimation, it is needed to build asymmetric moving averages that approximate the symmetric moving average.

Several approaches can be used for real-time estimation:

1. Use asymmetric moving averages to take account of the lack of available data;
2. Apply symmetric filters to an extended forecast series (which is equivalent to using asymmetric moving averages, since forecasts are linear combinations of the past). This method seems to date back to De Forest (1877), which also suggests modelling a polynomial trend of degree three or less at the end of the period. A similar approach is used in the X-13ARIMA-SEATS seasonal

adjustment method: the series is extended by one year (by default) with an ARIMA model to minimise the revisions associated to asymmetric filters. Since the final filter used for the seasonal adjustment extraction is much longer than one year (in most of the cases, for monthly series, the bandwidth is 78), the input series is just partially extended (and asymmetric filters are still used) to prevent instability over long periods (e.g., outliers or model shifts).

Conversely, the *implicit forecasts* of an asymmetric moving average can be deduced from a reference symmetric moving average. This allows us to judge the quality of real-time estimates of the trend-cycle and to anticipate future revisions when forecasts are far from expected evolutions.

Let us denote $\mathbf{v} = (v_{-h}, \dots, v_h)$ the reference symmetric moving average (used to compute the final estimates) and $\mathbf{w}^0, \dots, \mathbf{w}^{h-1}$ a sequence of asymmetric moving averages used for the intermediate estimates. $\mathbf{w}^0 = (w_{-h}^0, \dots, w_0^0)$ is used for estimation in real-time estimate (when 0 point in the future is known), $\mathbf{w}^1 = (w_{-h}^1, \dots, w_0^1, w_1^1)$ is used for estimation of the penultimate point (when only 1 in the future is known), and so on. Let $y_{t-h}, \dots, y_t$ be the observed series during the last h periods (for which asymmetric moving averages are used to get the intermediate trend-cycle estimates for the dates $t-h$ to t). The *implicit forecast* $y_{t+1}^*, \dots, y_{t+h}^*$ induced by $w^0, \dots, w^{h-1}$ are the forecasts of the series y_t for which the estimates of the symmetric filter applied to the extended series $\mathbf{y}^* = (y_{t-h}, \dots, y_t, y_{t+1}^*, \dots, y_{t+h}^*)$ produce the same estimates as the asymmetric filter applied to the series $\mathbf{y}^*$. This means:

$$\begin{aligned}
\underbrace{\sum_{i=-h}^0 v_i y_{t+i} + \sum_{i=1}^h v_i y_{t+i}^*}_{\text{smoothing by } \mathbf{v} \text{ of the extended series}} &= \underbrace{\sum_{i=-h}^0 w_i^0 y_{t+i}}_{\text{smoothing by } \mathbf{w}^0 \text{ using 0 point after } t} \\
&= \underbrace{\sum_{i=-h}^0 w_i^1 y_{t+i} + w_1^1 y_{t+1}^*}_{\text{smoothing by } \mathbf{w}^1 \text{ using 1 point after } t} \\
&= \underbrace{\sum_{i=-h}^0 w_i^2 y_{t+i} + \sum_{i=1}^2 w_i^2 y_{t+i}^*}_{\text{smoothing by } \mathbf{w}^2 \text{ using 2 points after } t} \\
&= \dots \\
&= \underbrace{\sum_{i=-h}^0 w_i^{h-1} y_{t+i} + \sum_{i=1}^{h-1} w_i^{h-1} y_{t+i}^*}_{\text{smoothing by } \mathbf{w}^{h-1} \text{ using } h-1 \text{ points after } t}
\end{aligned}$$

For any integer q between 0 and $h-1$, using for convention $w_t^q = 0$ if $t > q$ we then have:

$$\sum_{i=1}^h (v_i - w_i^q) y_i^* = \sum_{i=-h}^0 (w_i^q - v_i) y_i.$$

In matrix form, this is equivalent to solving:

$$\begin{pmatrix} v_1 & v_2 & \cdots & v_h \\ v_1 - w_1^1 & v_2 & \cdots & v_h \\ \vdots & \vdots & \cdots & \vdots \\ v_1 - w_1^{h-1} & v_2 - w_2^{h-1} & \cdots & v_h \end{pmatrix} \begin{pmatrix} y_1^* \\ \vdots \\ y_h^* \end{pmatrix} = \begin{pmatrix} w_{-h}^0 - v_{-h} & w_{-(h-1)}^0 - v_{-(h-1)} & \cdots & w_0^0 - v_0 \\ w_{-h}^1 - v_{-h} & w_{-(h-1)}^1 - v_{-(h-1)} & \cdots & w_0^1 - v_0 \\ \vdots & \vdots & \cdots & \vdots \\ w_{-h}^{h-1} - v_{-h} & w_{-(h-1)}^{h-1} - v_{-(h-1)} & \cdots & w_0^{h-1} - v_0 \end{pmatrix} \begin{pmatrix} y_{-h} \\ \vdots \\ y_0 \end{pmatrix}.$$

This is implemented in the `rjd3filters::implicit_forecast()` function.

As highlighted by Wildi et Schips (2004), extending the series through forecasting with an ARIMA model is equivalent to calculating asymmetric filters whose coefficients are optimised in relation to the one-step ahead forecast. In other words, the aim is to minimise the revisions between the first and last estimates (with the symmetric filter). However, the phase shift induced by the asymmetric filters is not controlled: we might prefer to have faster detection of turning points and a larger revision rather than just minimising the revisions between the first and last estimates. Furthermore, since the coefficients of the symmetric filter (and therefore the weight associated with distant forecasts) decrease slowly, we should also be interested in the performance of multi-step ahead forecasting. This is why it may be necessary to define alternative criteria for judging the quality of asymmetric moving averages.

3.3 Non-parametric regression and local polynomial regression

Many trend-cycle extraction methods are based on non-parametric regressions, which are particularly flexible because they do not assume any predetermined dependency in the predictors. In practice, local regressions can be used. More specifically, consider a set of points $(x_t, y_t)_{1 \leq t \leq n}$ and we here consider that $x_t = t$ (no external regressor is used). Non-parametric regression involves assuming that there exists a function μ , to be estimated, such that $y_t = \mu(t) + \varepsilon_t$ with ε_t an error term. According to Taylor's theorem, for any date t_0 , if μ is differentiable d times, then:

$$\forall t, \mu(t) = \underbrace{\mu(t_0)}_{=TC_{t_0}} + \mu'(t_0)(t - t_0) + \cdots + \frac{\mu^{(d)}(t_0)}{d!}(t - t_0)^d + R_d(t), \quad (3.1)$$

where R_d is a negligible residual term in the neighbourhood of t_0 . In a neighbourhood $h(t_0)$ around t_0 , μ can therefore be approximated by a polynomial of degree d . The quantity $h(t_0)$ is called the *bandwidth*. If ε_t is white noise, we can estimate $\mu(t_0) = TC_{t_0}$ by least squares using the observations which are in $[t_0 - h(t_0), t_0 + h(t_0)]$. In practice, this means assuming that the trend is locally polynomial. We also generally assume

that the bandwidth is fixed over time: $h(t_0) = h$. This is also what is assumed in the seasonal adjustment algorithm X-11 and what will be assumed in this paper.

Various estimation methods can be used to derive symmetric and asymmetric moving averages. For example, Gray et Thomson (1996) propose a complete statistical framework that makes it possible, in particular, to model the error in approximating the trend by local polynomials. However, as the specification of this error is generally complex, simpler models may be preferred, such as that of Proietti et Luati (2008). Dagum et Bianconcini (2008) propose a similar modelling of the trend-cycle but using the theory of Hilbert spaces with reproducing kernels for estimation, which has the particular advantage of facilitating the calculation of different moving averages at different time frequencies. See Quartier-la-Tente (2024a) for a more detailed comparison of the different recent methods for trend-cycle extraction included in the `rjd3filters` package.

In this paper we will focus on Proietti et Luati (2008) approach. Section 3.3.1 and section 3.3.2 describes their approach to build symmetric moving averages (used for the final estimates of the trend-cycle component) and asymmetric moving averages (used for real-time estimates). This paper proposed two extensions of their approach to build asymmetric moving averages: a first one adding a criteria to control the phase shift (section 3.3.4), not used in the simulation (section 3.4) but which could be used in future studied; a second one using a local parametrisation of a parameter usually parametrised globally (section 3.3.3), which is used in the simulation.

3.3.1 Symmetric moving averages and local polynomial regression

Using Proietti et Luati (2008)'s framework, we assume that our time series y_t can be decomposed into

$$y_t = TC_t + \varepsilon_t,$$

where TC_t is the trend-cycle and $\varepsilon_t \stackrel{i.i.d}{\sim} \mathcal{N}(0, \sigma^2)$ is the noise (the series is therefore seasonally adjusted). Within a neighbourhood h of t , the local trend TC_t is approximated by a polynomial of degree d , such that $TC_t \simeq m_t$ with:

$$\forall j \in \{-h, -h+1, \dots, h\}, y_{t+j} = m_{t+j} + \varepsilon_{t+j}, \quad m_{t+j} = \sum_{i=0}^d \beta_i j^i.$$

The problem of trend extraction is equivalent to estimating $m_t = TC_t = \beta_0$ (the constant in the previous formula).

In matrix notation:

$$\underbrace{\begin{pmatrix} y_{t-h} \\ y_{t-(h-1)} \\ \vdots \\ y_t \\ \vdots \\ y_{t+(h-1)} \\ y_{t+h} \end{pmatrix}}_{\mathbf{y}} = \underbrace{\begin{pmatrix} 1 & -h & h^2 & \cdots & (-h)^d \\ 1 & -(h-1) & (h-1)^2 & \cdots & -(h-1)^d \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 1 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 1 & h-1 & (h-1)^2 & \cdots & (h-1)^d \\ 1 & h & h^2 & \cdots & h^d \end{pmatrix}}_{\mathbf{X}} \underbrace{\begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \vdots \\ \vdots \\ \beta_d \end{pmatrix}}_{\boldsymbol{\beta}} + \underbrace{\begin{pmatrix} \varepsilon_{t-h} \\ \varepsilon_{t-(h-1)} \\ \vdots \\ \varepsilon_t \\ \vdots \\ \varepsilon_{t+(h-1)} \\ \varepsilon_{t+h} \end{pmatrix}}_{\boldsymbol{\varepsilon}}. \quad (3.2)$$

Since $d + 1$ parameters are estimated with $\boldsymbol{\beta}$, we need at least $2h + 1$ observations (thus $2h \geq d$) and the estimation is made by weighted least squares (WLS), which is equivalent to minimising the following objective function:

$$S(\hat{\beta}_0, \dots, \hat{\beta}_d) = \sum_{j=-h}^h \kappa_j (y_{t+j} - \hat{\beta}_0 - \hat{\beta}_1 j - \cdots - \hat{\beta}_d j^d)^2.$$

where κ_j is a set of weights called a *kernel*. We have $\kappa_j \geq 0 : \kappa_{-j} = \kappa_j$, and with $\mathbf{K} = \text{diag}(\kappa_{-h}, \dots, \kappa_h)$, the estimate of $\boldsymbol{\beta}$ can be written as $\hat{\boldsymbol{\beta}} = (\mathbf{X}^t \mathbf{K} \mathbf{X})^{-1} \mathbf{X}^t \mathbf{K} \mathbf{y}$. With $\mathbf{e}_1 = {}^t(1 \ 0 \ \cdots \ 0)$, the estimate of the trend is:

$$\hat{m}_t = \widehat{TC}_t = \mathbf{e}_1 \hat{\boldsymbol{\beta}} = {}^t \boldsymbol{\theta} \mathbf{y} = \sum_{j=-h}^h \theta_j y_{t-j} \text{ with } \boldsymbol{\theta} = \mathbf{K} \mathbf{X} (\mathbf{X}^t \mathbf{K} \mathbf{X})^{-1} \mathbf{e}_1. \quad (3.3)$$

To conclude, the estimate of the trend $\widehat{TC}_t$ can be obtained applying the symmetric filter $\boldsymbol{\theta}$ to y_t ($\boldsymbol{\theta}$ is symmetric due to the symmetry of the kernel weights κ_j). Moreover, since $\mathbf{X}^t \boldsymbol{\theta} = \mathbf{e}_1$ we have:

$$\sum_{j=-h}^h \theta_j = 1, \quad \forall r \in \{1, 2, \dots, d\} : \sum_{j=-h}^h j^r \theta_j = 0.$$

Hence, the filter $\boldsymbol{\theta}$ preserves deterministic polynomials of order d .

Regarding parameter selection, the general consensus is that the choice between different kernels is not crucial. See, for example, Cleveland et Loader (1996) or Loader (1999). The only desired constraints on the kernel are that it assigns greater weight to the central estimation (κ_0) and decreases towards 0 as it moves away from the central observation. The uniform kernel should therefore be avoided. It is then preferable to focus on two other parameters:

- the degree of the polynomial, denoted by d : if it is too small, there is a risk of biased estimates of the trend-cycle, and if it is too large, there is a risk of excessive variance in the estimates (due to over-adjustment);

- the number of neighbours $2h + 1$ (or the window h): if it is too small, then there will be too little data for the estimates (resulting in high variance in the estimates), and if it is too large, the polynomial approximation will probably be wrong, leading to biased estimates.

In this paper we will use the Henderson kernel:

$$\kappa_j = \left[1 - \frac{j^2}{(h+1)^2} \right] \left[1 - \frac{j^2}{(h+2)^2} \right] \left[1 - \frac{j^2}{(h+3)^2} \right].$$

However, several other kernels are available in `rjd3filters`.

3.3.2 Asymmetric moving averages and local polynomial regression

As mentioned in section 3.2.3, for real-time estimation, several approaches can be used:

1. Apply symmetric filters to the series extended by forecasting $\hat{y}_{n+l|n}, l \in \{1, 2, \dots, h\}$.
2. Build an asymmetric filter by local polynomial approximation on the available observations (y_t for $t \in \{n-h, n-h+1, \dots, n\}$).
3. Build asymmetric filters that minimise the mean squared error of revision under polynomial trend reproduction constraints.

Proietti et Luati (2008) show that the first two approaches are equivalent when forecasts are made by polynomial extrapolation of degree d . They are also equivalent to the third approach under the same constraints as those of the symmetric filter. The third method is called *direct asymmetric filtering* (DAF). This method is used for real-time estimation in the STL seasonal adjustment method (*Seasonal-Trend decomposition based on Loess*, see Cleveland et alii (1990)). Although DAF filter estimates are unbiased, this is at the cost of greater variance in the estimates.

To solve the problem of the variance of real-time filter estimates, Proietti et Luati (2008) propose a general method for constructing asymmetric filters that allows a bias-variance trade-off. This is a generalisation of Musgrave (1964)'s asymmetric filters (used in the X-11 seasonal adjustment algorithm).

Rewriting equation 3.2:

$$\mathbf{y} = \begin{pmatrix} \mathbf{U} & \mathbf{Z} \end{pmatrix} \begin{pmatrix} \gamma \\ \delta \end{pmatrix} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \mathbf{D}). \quad (3.4)$$

where $[\mathbf{U}, \mathbf{Z}]$ is of full rank and forms a subset of the columns of $\mathbf{X}$. Defining the variance error as $\mathbf{D} = \sigma^2 \mathbf{K}^{-1}$ (to directly take into account the weights associated

to the observations) and with $[\mathbf{U}, \mathbf{Z}] = \mathbf{X}$ we thus find the model associated to symmetric filters. The objective is to find an asymmetric filter $\mathbf{v}$ which uses q points in the future and minimises the mean square error of revision (to the symmetric filter $\boldsymbol{\theta}$) under certain (polynomial) constraints. The matrices $\mathbf{y}$, $\mathbf{U}$, $\mathbf{Z}$ and $\boldsymbol{\theta}$ are partitioned as follows:

$$\mathbf{y} = \begin{pmatrix} \mathbf{y}_p \\ \mathbf{y}_f \end{pmatrix}, \quad \mathbf{U} = \begin{pmatrix} \mathbf{U}_p \\ \mathbf{U}_f \end{pmatrix}, \quad \mathbf{Z} = \begin{pmatrix} \mathbf{Z}_p \\ \mathbf{Z}_f \end{pmatrix}, \quad \boldsymbol{\theta} = \begin{pmatrix} \boldsymbol{\theta}_p \\ \boldsymbol{\theta}_f \end{pmatrix},$$

where $\mathbf{y}_p$ is a matrix $(h + q + 1) \times 1$ which denotes the set of available observations (from y_{t-h} to y_{t+q}) and $\mathbf{U}$, $\mathbf{Z}$ and $\boldsymbol{\theta}$ are partitioned in the same way. The constraints are defined as ${}^t\mathbf{U}_p\mathbf{v} = {}^t\mathbf{U}\boldsymbol{\theta}$: they represent the polynomial preservation constraints we want to impose on the asymmetric filter. $\mathbf{Z}$ is then associated to the polynomial constraints of the symmetric filter not imposed on asymmetric filter. Proietti et Luati (2008) show that the problem is equivalent to finding v which minimises:

$$\varphi(\mathbf{v}) = \underbrace{{}^t(\mathbf{v} - \boldsymbol{\theta}_p)\mathbf{D}_p(\mathbf{v} - \boldsymbol{\theta}_p) + {}^t\boldsymbol{\theta}_f\mathbf{D}_f\boldsymbol{\theta}_f}_{\text{revision error variance}} + \underbrace{[{}^t\boldsymbol{\delta}({}^t\mathbf{Z}_p\mathbf{v} - {}^t\mathbf{Z}\boldsymbol{\theta})]^2}_{\text{bias}^2} + \underbrace{2{}^t\mathbf{l}({}^t\mathbf{U}_p\mathbf{v} - {}^t\mathbf{U}\boldsymbol{\theta})}_{\text{constraints}}. \quad (3.5)$$

mean square revision error

where $\mathbf{l}$ is a vector of Lagrange multipliers.

When $\mathbf{U} = \mathbf{X}$ (and then $\mathbf{Z} = \mathbf{0}$), the constraint is equivalent to preserving polynomials of degree d and we find asymmetric direct filters (DAF) when $\mathbf{D} = \sigma^2\mathbf{K}^{-1}$.

When $\mathbf{U} = {}^t(1 \ \cdots \ 1)$, $\mathbf{Z} = {}^t(-h \ \cdots \ +h)$, $\boldsymbol{\delta} = \delta_1$, $\mathbf{D} = \sigma^2\mathbf{I}$ and when the symmetric filter is the Henderson filter, we find the asymmetric Musgrave filters. This filter assumes that, for real-time estimation, the data is generated by a linear process and that the asymmetric filters preserve the constants ($\sum v_i = \sum \theta_i = 1$). These asymmetric filters depend on the ratio $|\delta_1/\sigma|$, which, assuming that the trend is linear and the bias constant, can be linked to the I-C ratio $R = \frac{\bar{I}}{\bar{C}} = \frac{\sum |I_t - I_{t-1}|}{\sum |C_t - C_{t-1}|}$: $\delta_1/\sigma = 2/(R\sqrt{\pi})$. This ratio is used in particular in X-11 to determine the length of the Henderson filter. For monthly data:

- If the ratio is large ($3.5 < R$) then a 23-term filter is used (to remove more noise) and the ratio $R = 4.5$ is used in X-11 to define the Musgrave filter.
- If the ratio is small ($R < 1$) a 9-term filter is used and the ratio $R = 1$ is used in X-11 to define the Musgrave filter.
- Otherwise (most of the cases) a 13-term filter is used and the ratio $R = 3.5$ is used in X-11 to define the Musgrave filter.

When $\mathbf{U}$ corresponds to the first $d^* + 1$ columns of $\mathbf{X}$, $d^* < d$, the constraint is to reproduce polynomial trends of degree d^* . This introduces bias but reduces the variance. Thus, Proietti et Luati (2008) proposes three classes of asymmetric filters:

1. *Linear-Constant* (LC): y_t linear ($d = 1$) and $\mathbf{v}$ preserves constant signals ($d^* = 0$). We obtain Musgrave filters when the Henderson filter is used for the symmetric filter.
2. *Quadratic-Linear* (QL): y_t quadratic ($d = 2$) and $\mathbf{v}$ preserves linear signals ($d^* = 1$).
3. *Cubic-Quadratic* (CQ): y_t cubic ($d = 3$) and $\mathbf{v}$ preserves quadratic signals ($d^* = 2$).

Supplemental materials show the coefficients, gain and phase shift functions of the four asymmetric filters.

3.3.3 Extension with the timeliness criterion

One drawback of the approach of Proietti et Luati (2008) is the lack of control over the phase shift. However, it is possible to improve the modelling by incorporating in equation 3.5 the timeliness criterion defined by Grun-Rehomme et alii (2018). This was proposed by Jean Palate, then coded in Java and integrated into `rjd3filters`.

To measure the phase shift between the input series and the filtered one, Grun-Rehomme et alii (2018) introduces a criterion, T_g , called *timeliness*. When a moving average $\mathbf{v}$ is applied, the level input signal is also altered by the gain function. That's why the timeliness criterion depends on the gain and phase shift functions (ρ_v and φ_v), the link between both functions being made by a penalty function f . The criterion measures phase shift for the frequencies in the interval $[\omega_1, \omega_2]$:

$$T_g(\mathbf{v}) = \int_{\omega_1}^{\omega_2} f(\rho_v(\omega), \varphi_v(\omega)) d\omega$$

As mentioned in section 3.2, in the case of trend-cycle extraction we can set $\omega_1 = 0$ and for monthly series $\omega_2 = 2\pi/12$. For the penalty function, the authors suggest $f: (\rho, \varphi) \mapsto \rho^2 \sin(\varphi)^2$ and show that in that case the criteria can be written in a quadratic form:

$$T_g(\mathbf{v}) = {}^t\mathbf{v}\mathbf{T}\mathbf{v}$$

with $T = \int_{\omega_1}^{\omega_2} \mathbf{S}\mathbf{i}(\omega){}^t\mathbf{S}\mathbf{i}(\omega) d\omega$ and $\mathbf{S}\mathbf{i}(\omega) = (\sin(p\omega), \dots, \sin(f\omega))$ if $\mathbf{v}$ uses p points in the past and f points in the future.

Using the same notation as in section 3.3.2, $\boldsymbol{\theta}$ represents the symmetric filter and $\mathbf{v}$ the asymmetric filter. With $\boldsymbol{\theta} = {}^t(\boldsymbol{\theta}_p \quad \boldsymbol{\theta}_f)$ and $\boldsymbol{\theta}_p$ of the same length as $\mathbf{v}$, and $\mathbf{g} = \mathbf{v} - \boldsymbol{\theta}_p$, the timeliness criterion can be expressed as:

$$T_g(\mathbf{v}) = {}^t\mathbf{v}\mathbf{T}\mathbf{v} = {}^t\mathbf{g}\mathbf{T}\mathbf{g} + 2{}^t\boldsymbol{\theta}_p\mathbf{T}\mathbf{g} + {}^t\boldsymbol{\theta}_p\mathbf{T}\boldsymbol{\theta}_p \quad \text{with } \mathbf{T} \text{ a symmetric matrix.}$$

Furthermore, the objective function φ of equation 2.4 can be rewritten:

$$\begin{aligned}\varphi(\mathbf{v}) &= {}^t(\mathbf{v} - \boldsymbol{\theta}_p)\mathbf{D}_p(\mathbf{v} - \boldsymbol{\theta}_p) + {}^t\boldsymbol{\theta}_f\mathbf{D}_f\boldsymbol{\theta}_f + [{}^t\boldsymbol{\delta}({}^t\mathbf{Z}_p\mathbf{v} - {}^t\mathbf{Z}\boldsymbol{\theta})]^2 + 2{}^t\mathbf{l}({}^t\mathbf{U}_p\mathbf{v} - {}^t\mathbf{U}\boldsymbol{\theta}) \\ &= {}^t\mathbf{g}\mathbf{Q}\mathbf{g} - 2\mathbf{P}\mathbf{g} + 2{}^t\mathbf{l}({}^t\mathbf{U}_p\mathbf{v} - {}^t\mathbf{U}\boldsymbol{\theta}) + \mathbf{c},\end{aligned}$$

with $\mathbf{Q} = \mathbf{D}_p + \mathbf{Z}_p\boldsymbol{\delta}^t\boldsymbol{\delta}^t\mathbf{Z}_p$, $\mathbf{P} = \boldsymbol{\theta}_f\mathbf{Z}_f\boldsymbol{\delta}^t\boldsymbol{\delta}^t\mathbf{Z}_p$ and $\mathbf{c}$ a constant independent of $\mathbf{v}$.

Adding the timeliness criterion:

$$\tilde{\varphi}(\mathbf{v}) = {}^t\mathbf{g}\tilde{\mathbf{Q}}\mathbf{g} - 2\tilde{\mathbf{P}}\mathbf{g} + 2{}^t\mathbf{l}({}^t\mathbf{U}_p\mathbf{v} - {}^t\mathbf{U}\boldsymbol{\theta}) + \tilde{\mathbf{c}},$$

where $\tilde{\mathbf{Q}} = \mathbf{D}_p + \mathbf{Z}_p\boldsymbol{\delta}^t\boldsymbol{\delta}^t\mathbf{Z}_p + \alpha_T\mathbf{T}$, α_T is the weight associated with the timeliness criterion, $\tilde{\mathbf{P}} = \boldsymbol{\theta}_f\mathbf{Z}_f\boldsymbol{\delta}^t\boldsymbol{\delta}^t\mathbf{Z}_p - \alpha_T\boldsymbol{\theta}_p\mathbf{T}$ and $\tilde{\mathbf{c}}$ a constant independent of $\mathbf{v}$.

With $\alpha_T = 0$ we find $\varphi(\mathbf{v})$. This extension therefore makes it possible to find all the symmetric and asymmetric filters presented in the previous section. It is implemented in the R function `rjd3filters::lp_filter()`.

One drawback is that $T_g(\mathbf{v})$ is not normalized: the weight α_T has no economic sense. It is then difficult to calibrate the value of α_T since the value of $|\delta/\sigma|$ must also be defined. Hence, in this paper we will not compare this extension to the other methods and we will focus on the local calibration of $|\delta/\sigma|$. However, in future studies, we could imagine a two-step calibration: fix the value of $|\delta/\sigma|$ to find α_T by cross-validation and then use this weight with a local parametrisation of the ratio $|\delta/\sigma|$ (as in section 3.3.4).

3.3.4 Local parametrisation of asymmetric filters

Asymmetric filters are usually parametrised globally: $|\delta/\sigma|$ is fixed using all the data (with the IC-ratio or a cross-validation criterion). However, we might prefer a local parametrisation: a ratio $|\delta/\sigma|$ which varies as a function of time. Indeed, although the overall parametrisation is generally valid, assuming a constant value of the $|\delta/\sigma|$ ratio for all asymmetric filters does not appear relevant for real-time estimation, especially during periods of economic downturn. For example, with the LC method, global parametrisation means assuming that the slope of the trend is constant, whereas during economic downturns it tends towards 0 up around the turning point.

This is what is proposed in this article, with a local parametrisation of the asymmetric filters by estimating δ and σ^2 separately. Although this does not give an unbiased estimator of the ratio $|\delta/\sigma|$, it does allow the main evolutions to be captured, such as the decay towards 0 before a turning point and the growth after the turning point for the LC method. σ^2 and δ are estimated as follows:

- The variance σ^2 can be estimated using the observed data set and the symmetric filter $(\theta_{-h}, \dots, \theta_h)$. Indeed, as for example shown by Loader (1999), the variance σ^2 can be estimating using the normalized residual sum of squares:

$$\hat{\sigma}^2 = \frac{1}{(n - 2h) - 2\nu_1 + \nu_2} \sum_{t=h+1}^{n-h} (y_t - \widehat{TC}_t)^2.$$

Since the symmetric filter is used, only $n - 2h$ observations can be used to estimate σ^2 . ν_1 and ν_2 are two definitions of degrees of freedom of a local fit (generalization of the number of parameters of a parametric model). In the case of local polynomial smoothing, they can be linked to the coefficient of the associated filter: $\nu_1 = (n - 2h)\theta_0$ (number of observations multiplied by the central coefficient of the moving average) and $\nu_2 = (n - 2h) \sum_{i=-h}^h \theta_i^2$ (number of observations multiplied by the sum of squares of coefficients of the moving average). Thus, the variance can be estimated by:

$$\hat{\sigma}^2 = \frac{1}{n - 2h} \sum_{t=h+1}^{n-h} \frac{(y_t - \widehat{TC}_t)^2}{1 - 2\theta_0^2 + \sum_{i=-h}^h \theta_i^2}.$$


This is implemented in the function `rjd3filters::var_estimator()`. This estimator assumes that $\widehat{TC}_t$ is unbiased, so variance estimates intervals are usually computed at small bandwidths (h). In this paper we study monthly series with small bandwidth ($h = 6$), and the variance is estimated using local polynomial of degree 3 (Henderson filter), the biased of $\widehat{TC}_t$ is thus already small and using smaller bandwidths have almost no impact on the estimates (see supplemental materials).

- The parameter δ can be estimated by moving average from equation 3.3. For example, for the LC method we can use the moving average $\theta_2 = \mathbf{KX}(\mathbf{XKX})^{-1}\mathbf{e}_2$ to obtain a local estimate of the slope and for the QL method we can use $\theta_3 = \mathbf{KX}(\mathbf{XKX})^{-1}\mathbf{e}_3$ to obtain a local estimate of the concavity. The DAF method then simply allows us to calculate the associated asymmetric moving averages.

To avoid unrealistic estimates of $|\delta/\sigma| = 2/(|R|\sqrt{\pi})$ in real-time, where R is the I-C ratio defined in section 3.3.2, the value of $|R|$ is truncated to a maximum of 12 (the higher value used in X-11 being 4.5), which slightly reduces revisions and phase shift.

For the construction of moving averages, the trend can be modelled as being locally of degree 2 or 3 (this has no impact on the final estimate of concavity). In this paper, we have chosen to model a trend of degree 2: this slightly reduces the phase shift (see supplemental material) but slightly increases the revisions linked to the first estimate of the trend-cycle. Figure 3.2 shows the moving averages used.

FIGURE 3.2 – Moving averages used for real-time estimation of slope and concavity.




To distinguish the gain from the local parametrisation of the noise associated to the real-time estimates of the slope and concavity, in the empirical applications of section 3.4 we also compares the results to the final local parametrisation obtained by estimating δ using all the data (i.e., using the symmetric filters shown in figure 3.2), while maintaining a real-time estimate of σ^2 . Figure 3.3 shows an example of the comparison of estimates of the ratio $|\delta_1/\sigma|$ with a global estimator (IC ratio) and two local parametrisations:

- figure 3.3a: using a symmetric filter to estimate δ_1 (final local parametrisation).
- figure 3.3b: using the asymmetric filter which need two points in the future to estimate δ_1 . This is closed to the real-time estimates since two points in the future are needed to detect a turning point.


The turning points are clearly detected by the local estimators (slope tends towards zero) when $|\delta_1/\sigma|$ is estimated in the real-time. However, the real-time local estimates of $|\delta_1/\sigma|$ are noisy: the variability of these estimates, used to build asymmetric filters, will then lead to another source of revisions in the intermediate estimates.

FIGURE 3.3 – Comparison of the estimates of $|\delta_1/\sigma|$ with a local estimator and global estimator (with IC ratio) on a simulated series, the vertical lines being the simulated turning points.

(a) Symmetric moving average used for $\hat{\delta}_1$.



(b) Asymmetric moving average using two future points ($q = 2$) for $\hat{\delta}_1$.



There is no function in `rjd3filters` to directly compute those moving averages but they can be easily computed using matrix computation formula and applied to the series using `rjd3filters`. See for example the file `Simplified_example.R` available at <https://github.com/AQLT/joffstats2024>.

3.4 Comparison of different methods

The different methods are compared on simulated and real data. For all series, a symmetric 13-term filter is used: we then assume than the bandwidth is fixed, as in the seasonal adjustment method X-11. A nearest neighbour bandwidth is also tested (13-term asymmetric filters: real-time filter uses observations between y_{t-12} and y_t , the second asymmetric filter uses observations between y_{t-11} and y_{t+1} , etc.) but with no improvement in the results (see supplemental material). More complex methods to locally select bandwidth, like the one proposed by Fan et Irene Gijbels (1992), were not tested. All the methods to create asymmetric filters are also compared with estimates obtained by extending the series with an ARIMA model, then applying a 13-term symmetric Henderson filter. The ARIMA model is determined automatically,

using Hyndman et Khandakar (2008) algorithm (function `forecast::auto.arima()`) on the last 12 years, with no seasonal lag (the series being seasonally adjusted) and no external variables (such as external regressors for correction of atypical points). The performance of the different methods is judged on criteria relating to revisions (between two consecutive estimates and in relation to the final estimate) and the number of periods required to detect turning points.

3.4.1 Simulated series

3.4.1.1 Methodology


Following a methodology close to that of Darné et Dagum (2009), nine monthly series are simulated between January 1960 and December 2020 with different levels of variability. Each simulated series $y_t = C_t + T_t + I_t$ can be written as the sum of three components:

- the cycle $C_t = \rho[\cos(2\pi t/\lambda) + \sin(2\pi t/\lambda)]$, λ is fixed at 72 (6-year cycles, so there are 19 detectable turning points);
- the trend $T_t = T_{t-1} + \nu_t$ with $\nu_t \sim \mathcal{N}(0, \sigma_\nu^2)$, σ_ν being fixed at 0.08;
- and the irregular $I_t = e_t$ with $e_t \sim \mathcal{N}(0, \sigma_e^2)$.

For the different simulations, we vary the parameters ρ and σ_e^2 in order to obtain series with different signal-to-noise ratios (see figure 3.4):

- High signal-to-noise ratio (i.e., low I-C ratio and low variability): $\sigma_e^2 = 0.2$ and $\rho = 3.0, 3.5$ or 4.0 (I-C ratio between 0.9 and 0.7);
- Medium signal-to-noise ratio (i.e., medium I-C ratio and medium variability): $\sigma_e^2 = 0.3$ and $\rho = 1.5, 2.0$ or 3.0 (I-C ratio between 2.3 and 1.4);
- Low signal-to-noise ratio (i.e., high I-C ratio and high variability): $\sigma_e^2 = 0.4$ and $\rho = 0.5, 0.7$ or 1.0 (I-C ratio between 8.9 and 5.2).

FIGURE 3.4 – Simulated series with low ($\sigma_e^2 = 0.2$ and $\rho = 3.55$), medium ($\sigma_e^2 = 0.3$ and $\rho = 2.0$) and high variability ($\sigma_e^2 = 0.4$ and $\rho = 1.0$).



For each series and each date, the trend-cycle is estimated using the different methods presented in this paper. Three quality criteria are computed:

1. The *phase shift* in the detection of turning points. In this paper, we focus on turning points associated to business cycle: it is defined as the succession of phases of economic recession and expansion, delimited by peaks (highest level of activity) and troughs (lowest level of activity), see for example Ferrara (2009b) for a description of the different economic cycles. In this paper, following Zellner et alii (1991), we used an accepted definition for turning-points:

- An upturn occurs when the economy moves from a phase of recession to a phase of expansion. This is the case at date t when $TC_{t-3} \geq TC_{t-2} \geq TC_{t-1} < TC_t \leq TC_{t+1}$.
- A downturn occurs when the economy moves from a phase of expansion to a phase of recession. This is the case at date t when $TC_{t-3} \leq TC_{t-2} \leq TC_{t-1} > TC_t \geq TC_{t+1}$.

Let's denote $TC_{t|t'}$ the estimate of the trend-cycle at date t using the data up to date t' . The phase shift is often defined as the number of months required to detect the right turning point: it would then be equal to two if, in the case of a downturn, $TC_{t-3|t+1} \leq TC_{t-2|t+1} \leq TC_{t-1|t+1} > TC_{t|t+1} \geq TC_{t+1|t+1}$ (two observations, at dates t and $t + 1$, are needed to qualify the date t as turning point). Note that, in that case, the phase shift could be equivalently set to 1 (only one observation after t is needed to define t as a turning point), without

any difference on the comparison of the different methods.

In this paper we use a slightly modified criterion: the *phase shift* is defined as the number of months needed to detect the right turning point without any future revision. Thus, in the case of a downturn, the phase shift is two if $TC_{t-3|t+1} \leq TC_{t-2|t+1} \leq TC_{t-1|t+1} > TC_{t|t+1} \geq TC_{t+1|t+1}$ and, for all dates t' higher than $t + 1$: $TC_{t-3|t'} \leq TC_{t-2|t'} \leq TC_{t-1|t'} > TC_{t|t'} \geq TC_{t+1|t'}$. Since a 13-term Henderson filter is used for the final estimates of the trend-cycle, the phase shift is at most height (the final estimate of TC_{t+1} is compute at the date $t + 7$). This definition is used because it can happen that the right turning point is detected by asymmetric filters but is not detected by the final estimate using a symmetric filter (this is the case for 41 reversal points out of the 9 series with asymmetric Musgrave filters) or that there are revisions in successive estimates (this is the case for 7 turning points out of the 9 series with asymmetric Musgrave filters). Finally, relatively few turning points are detected at the right date with the final estimate. With the 13-term Henderson filter, 18 are correctly detected in series with low variability (out of 57 possible), 11 in series with medium variability and 12 in series with high variability.

2. The average of the relative deviations between to the last estimate (comparison of the q^{th} estimate and the last estimate):

$$MAE_{fe}(q) = \mathbb{E} \left[\left| \frac{TC_{t|t+q} - TC_{t|last}}{TC_{t|last}} \right| \right].$$

3. The average of the relative deviations between two consecutive estimates (the q^{th} estimate and the $q + 1^{\text{th}}$ estimate):

$$MAE_{ce}(q) = \mathbb{E} \left[\left| \frac{TC_{t|t+q} - TC_{t|t+q+1}}{TC_{t|t+q+1}} \right| \right].$$

The simulated series are of length 60 years, which is often not realistic for economic time series. However, since all the methods are local, the results are not affected by the length of the series. The length of the series would only have an impact for the identification and the estimation of the ARIMA model. In this case, since the same data generating process is used during the 60 years, it could be relevant to identify the ARIMA model using all the data. Even if it would improve the results in term of phase shift (see supplemental material) we prefer to only use the last 12 years to identify and estimate the ARIMA model, to be closer to what would have been done with a real-time series.

3.4.2 Comparison


Figure 3.5 represents box plots of the phase shift: the box represents the interquartile range, the central horizontal line represents the median, the dot represents the outliers

and the whisker the range of the data (if no outlier). For simulated series with medium variability (when a symmetric filter of length 13 is relevant), with the linear constant (LC) method, 50% of the turning point are detected with a phase shift of at most 5 months whereas when the LC filter is parametrised locally, 50% of the turning point are detected with a phase shift of at most 4 months. For the direct asymmetric filter (DAF), 25% of the turning are detected with a phase shift of at least 7 months (compares to 5 for the LC method).

Excluding for the moment the local parametrisations of the polynomial filters, the linear-constant polynomial filter (LC) seems to give the best results in terms of delay in the detection of turning points. Performance is relatively close to that obtained by extending the series using an ARIMA model. However, when variability is low, the LC filter seems to give poorer results and the quadratic-linear polynomial filter (QL) seems to give the best results.

For series with moderate variability, local parametrisation of the LC and QL filters reduces the phase shift. For series with high variability, the phase shift is only reduced by using the final $\hat{\delta}$ parameters: real-time estimates seem to add more variance. For series with low variability, performance seems to be slightly improved only with the LC filter.

FIGURE 3.5 – Distribution of phase shift on simulated series.



Observe table 3.1 the average of the relative deviations with medium variability. The estimates for $q = 0$ correspond to the first estimates of the trend-cycle (real-time

estimates when 0 point in the future is known), $q = 1$ correspond to the second estimates of the trend-cycle (when 1 point in the future is known). Since the final estimates are obtained using a symmetric filter of bandwidth 6, $q = 6$ corresponds to the final estimates of the trend-cycle (when 6 points in the future are known). $MAE_{fe}(0)$ compares the revision between the first estimate ($q = 0$) and the last estimate ($q = 6$) and $MAE_{ce}(0)$ compares the revision between the first estimate ($q = 0$) and the second estimate ($q = 1$).

In terms of revisions, the variability of the series has little effect on the respective performances of the different methods, but it does affect the orders of magnitude, which is why the results are presented only for series with medium variability. In general, LC filters always minimise revisions (with relatively small effect from the local parametrisation of the filters) and revisions are greater with cubic-quadratic (CQ) and direct (DAF) polynomial filters.

For the QL filter, there is a large revision between the second and third estimates: this may be due to the fact that for the second estimate (when one point in the future is known), the QL filter assigns a greater weight to the estimate in $t + 1$ than to the estimate in t , which creates a discontinuity. This revision is considerably reduced by parametrising the filter locally. For polynomial filters other than the LC filter, the large revisions at the first estimate were to be expected given the coefficient curve: a very large weight is associated with the current observation and there is a strong discontinuity between the moving average used for real-time estimation (when no point in the future is known) and the other moving averages.

Extending the series using an ARIMA model gives revisions with the latest estimates of the same order of magnitude as the LC filter, but slightly larger revisions between consecutive estimates, particularly between the fourth and fifth estimates (as might be expected as highlighted in section 3.2.3).

3.4.3 Real series


The differences between the methods are also illustrated using an example from the FRED-MD database (McCracken et Ng (2016)) containing economic series on the United States. This database facilitates the reproducibility of the results thanks to the availability of series published on past dates. The series studied correspond to the database published in November 2022. It is the level of employment in the United States (series CE160V, used in logarithm) around the February 2001 turning point, consistent with the monthly dating of the turning points. This turning point was chosen because it is particularly visible in the raw series (figure 3.7) and this series was selected because it is used for dating economic cycles. Studying the series up to January 2020, this series has a medium variability: a symmetric filter of 13 terms is therefore appropriate.

TABLE 3.1 – Average of the relative deviations of the revisions for the different filters on simulated series with medium variability.

Method	$q = 0$	$q = 1$	$q = 2$	$q = 3$	$q = 4$	$q = 5$
$MAE_{fe}(q) = \mathbb{E} \left[\left (TC_{t t+q} - TC_{t last}) / TC_{t last} \right \right]$						
LC	0.21	0.10	0.03	0.03	0.03	0.01
LC local param. (final estimates)	0.19	0.09	0.03	0.03	0.03	0.01
LC local param.	0.29	0.10	0.03	0.03	0.03	0.01
QL	0.33	0.10	0.04	0.04	0.03	0.01
QL local param. (final estimates)	0.21	0.10	0.03	0.03	0.03	0.01
QL local param.	0.30	0.10	0.04	0.03	0.03	0.01
CQ	0.45	0.13	0.13	0.09	0.06	0.02
DAF	0.47	0.15	0.15	0.09	0.06	0.02
ARIMA	0.22	0.10	0.03	0.03	0.03	0.01
$MAE_{ce}(q) = \mathbb{E} \left[\left (TC_{t t+q} - TC_{t t+q+1}) / TC_{t t+q+1} \right \right]$						
LC	0.19	0.10	0.02	0.01	0.07	0.01
LC local param. (final estimates)	0.20	0.10	0.03	0.01	0.05	0.01
LC local param.	0.24	0.11	0.03	0.01	0.05	0.01
QL	0.29	3.46	0.00	0.03	0.04	0.01
QL local param. (final estimates)	0.31	0.11	0.02	0.01	0.04	0.01
QL local param.	0.24	0.16	0.00	0.03	0.04	0.01
CQ	0.43	0.02	0.10	0.07	0.05	0.02
DAF	0.66	0.24	0.11	0.14	0.06	0.02
ARIMA	0.23	0.10	0.02	0.03	0.25	0.01

Figure 3.6 shows the successive estimates of the trend-cycle using the different methods studied. For this series, the phase shift is 6 months for the LC and CQ methods and the extension of the series by ARIMA. It is of two months for the other methods (QL, DAF). In this example, local parametrisation does not reduce the phase shift, but it does reduce revisions. The QL and DAF polynomials lead to greater variability in the intermediate estimates, especially in February 2001.


FIGURE 3.6 – Successive estimates of the trend-cycle in US employment (in logarithms). The dotted vertical line corresponds to the date of the turning point (February 2001). The curve “Feb 2001” corresponds to the estimates of the trend-cycle using the data observed until February 2001. Since a 13-term Henderson filter is used for the final estimates, for the curve “Feb 2001” estimates from September 2001 to February 2001 are intermediate estimates.



The quality of the intermediate estimates can also be analysed using the implicit forecasts of the different methods (figure 3.7). As a reminder, these are forecasts of the raw series which, by applying the symmetric Henderson filter to the extended series, give the same estimates as the asymmetric moving averages. The forecasts of the ARIMA model are naive and do not take the turning point into account, unlike

the other methods. Finally, local parametrisation of the QL filter produces much more consistent forecasts.

FIGURE 3.7 – Implicit forecasts linked to successive estimates of the trend-cycle in US employment (in logarithms) using local polynomial methods. The dotted vertical line corresponds to the date of the turning point (February 2001). The curve “Mar 2001” corresponds to the implicit forecasts associated to the asymmetric filters used for the trend-cycle estimations using the data observed until March 2001.



3.4.4 Discussion

In the section we discuss the applicability of the presented methods to other frequencies (section 3.4.4.1) and some limits of the presented methods (for example sensitivity to outliers like COVID-19, section 3.4.4.2) .

3.4.4.1 Other frequencies

In this paper, we focused on monthly series, but the methods presented can be applied to other frequencies. In general, for lower frequencies, the bandwidth of the symmetric filter reduced. For example, for quarterly series, X-11 uses a 5-term symmetric filter (in general) or 7-term symmetric filter for series with high variability. Mechanically, since fewer points are used, there will be less differences between methods in term of phase shift. For example, on simulated series the results are similar in terms of phase shift but revisions are reduced with local parametrisation (see supplemental material).

Since X-13ARIMA-SEATS can only be applied for series with frequency lower than monthly, for higher frequencies (weekly, daily, etc.), there is no reference on the length of the filters to uses. The length of the filters can be determined using local polynomial methods, for example minimising a statistic such as cross-validation (`rjd3filters::cv()`), CP (`rjd3filters::cp()`) or Rice's T (`rjd3filters::rt()`), or with more complex methods as describe by Loader (1999), but it will surely be necessary to use higher bandwidth than for monthly series. The larger the window, the greater the bias in assuming that the trend is locally of degree 1: the LC method will then be certainly less appropriate than other methods (QL, CQ or DAF). Moreover, since the bias is higher, the local parametrisation of the filters will surely have more impact.

3.4.4.2 Outliers and COVID-19

In this article and in those associated to trend-cycle extraction techniques, the moving averages are applied and compared on series already seasonally adjusted or without seasonality (simulated series). The revisions and the phase shift are limited to 8 months (when the symmetric filter is 13 terms) and this has the advantage of isolating the impacts of the different filters from the other processes inherent in seasonal adjustment. There are, however, two drawbacks to this simplification:

1. The estimation of the seasonally-adjusted series depends on the method used to extract the trend-cycle. The choice of method used to estimate the trend-cycle can therefore have an impact well beyond 6 months (when a 13-term Henderson filter is used).


2. As moving averages are linear operators, they are sensitive to the presence of atypical points. Direct application of the methods can therefore lead to biased estimates, due to their presence, whereas seasonal adjustment methods (such as the X-13ARIMA-SEATS method) have a correction module for atypical points. Furthermore, as shown in particular by Dagum (1996), the final symmetric filter used by X-13ARIMA-SEATS to extract the trend-cycle (and therefore the one indirectly used when applying the methods to seasonally-adjusted series), reduces by just 38% cycles of length 9 and 10 months (generally associated with noise rather than the trend-cycle). The final asymmetric filters even amplify 9 and 10-month cycles. This can result in the introduction of undesirable ripples, i.e., the detection of false turning points. This problem is reduced by correcting atypical points and the *Nonlinear Dagum Filter* (NLDF) was defined in this perspective:

- a. applying the X-11 atypical point correction algorithm (see for example Ladiray et Quenneville 2011, for a description) to the seasonally adjusted series, then extending it with an ARIMA model;
- b. perform a new atypical point correction using a much stricter threshold and then apply the 13-term symmetric filter. Assuming a normal distribution, this amounts to modifying 48% of the irregular values.

The *cascade linear filter* (CLF), studied in particular in Dagum et Bianconcini (2023), corresponds to an approximation of the NLDF using a 13-term filter and when the forecasts are obtained from an ARIMA(0,1,1) model where $\theta = 0.40$.


Figure 3.8 and figure 3.9 show the successive estimates of the trend-cycle and the associated implicit forecast for the US employment during the COVID-19. First, we observe that while the real turning point is in April 2020, the 13-term Henderson filter produces final estimates of the trend-cycles, biased by the presence of a huge outlier, which lead to a turning point detected in June 2020. Second, as in 2001, the CQ and DAF methods lead to lots of variability in the intermediate estimates. For the QL method, the local parametrisation seems to slightly reduce the revisions. For the LC method, local parametrisation has little impact on the estimates of the trend-cycle but the associated implicit forecasts are not plausible: the final estimate of the slope is biased by the outlier. Third, the ARIMA model can lead to unrealistic forecasts.

FIGURE 3.8 – Successive estimates of the trend-cycle in US employment (in logarithms) during the COVID-19.



Note: the dotted vertical line corresponds to the date of the turning point (June 2020) detected with the 13-term Henderson filter but the real one is June 2020. The curve “Apr 2020” corresponds to the estimates of the trend-cycle using the data observed until April 2020.

FIGURE 3.9 – Implicit forecasts linked to successive estimates of the trend-cycle in US employment (in logarithms) using local polynomial methods during the COVID-19.



Note: the curve “Apr 2020” corresponds to the implicit forecasts associated to the asymmetric filters used for the trend-cycle estimations using the data observed until April 2020.

To sum up, trend-cycle estimates are biased by the presence of outliers which can also impact the detection of turning-points. Several approach could be used to limit their impact of to directly take them into account:

- Adjustment of outliers prior to filtering, for example with a RegARIMA model or other correction modules like the one used in X-11.

- Increase the bandwidth of the filter used to extract the trend-cycle (it will smooth the trend-cycle by giving less weights to the atypical points).
- Since all the filters studied in this paper are equivalent to a local polynomial model, an external regressor can be added to the linear model to handle the outlier (the matrix $\mathbf{X}$ would then be modified). In the case of an additive outlier, this is equivalent to setting to 0 the coefficient of the moving average associated to the date of the outlier (using y_{t-h} to y_{t+h} for the trend-cycle estimates, if the outlier is at the date t the central coefficient is set to 0) and renormalise the sum of the coefficients to 1.
- Use of robust methods to estimate the trend-cycle, such as robust local regressions or moving medians.

3.5 Conclusion

For business cycle analysis, most statisticians use trend-cycle extraction methods, either directly or indirectly. They are used, for example, to reduce the noise of an indicator in order to improve its analysis, and models, such as forecasting models, usually use seasonally adjusted series based on these methods.

This paper presents the R package `rjd3filters`, which implements several methods to build moving averages for real-time trend-cycle estimation. It also offers various functions for the theoretical analysis of moving averages (gain functions, phase shift, quality criteria, etc.) and judging the quality of the latest estimates (for example with implicit forecasts). It also makes it easy to combine moving averages and also to integrate custom moving averages into the X-11 seasonal adjustment algorithm. `rjd3filters` thus facilitates research into the use of moving averages as part of real-time cycle trend estimation. This is the case, for example, with the local parametrisation of Musgrave moving averages and other asymmetric moving averages linked to local polynomial regression, presented in this article.

By comparing the different methods, we can learn a few lessons about the construction of these moving averages.

During economic downturns, asymmetric filters used as an alternative to extending the series using the ARIMA model can reduce revisions to intermediate estimates of the trend-cycle and enable turning points to be detected more quickly.

At the end of the period, modelling polynomial trends of degree greater than three (cubic-quadratic, CQ, and direct, DAF) seems to introduce variance into the estimates (and therefore more revisions) without allowing faster detection of turning points. For real-time estimates of the trend-cycle, we can therefore restrict ourselves to methods modelling polynomial trends of degree two or less (linear-constant, LC, and quadratic-linear, QL). In addition, parametrising polynomial filters locally as proposed in this paper enables turning points to be detected more quickly (especially

for the QL filter). Even when the phase shift is not reduced, local parametrisation is recommended because it reduces revisions and produces intermediate estimates that are more consistent with expected future trends. However, with these methods, the length of the filter used must be adapted to the variability of the series: if the filter used is too long (i.e., if the variability of the series is “low”), retaining polynomial trends of degree one or less (LC method) produces poorer results in terms of detecting turning points.

This study could be extended in many ways. One possible extension would be to look at the impact of filter length on the detection of turning points. Asymmetric filters are calibrated using indicators calculated for the estimation of symmetric filters (for example, to automatically determine their length), whereas a local estimate might be preferable. Furthermore, we have only focused on monthly series with a 13-term symmetric filter, but the results may be different if the symmetric filter studied is longer or shorter and if we study series with other frequencies (weekly or daily, for example).

Another possibility could be to study the impact of atypical points: moving averages, like any linear operator, are highly sensitive to the presence of atypical points. To limit their impact, in X-11 a strong correction for atypical points is performed on the irregular component before applying the filters to extract the trend-cycle. This leads to examining the impact of these outliers on the estimation of the trend-cycle and turning points, and also to explore new types of asymmetric filters based on robust methods (such as robust local regressions or moving medians).

3.6 Annexes

3.6.1 Coefficients, gain and phase shift functions

FIGURE 3.10 – Coefficients, gain and phase shift functions for the Linear-Constant (LC) filter with $I/C = 3.5$.




FIGURE 3.11 – Coefficients, gain and phase shift functions for the Quadratic-Linear (QL) filter with $I/C = 3.5$.




FIGURE 3.12 – Coefficients, gain and phase shift functions for the Cubic-Quadratic (CQ) filter with $I/C = 3.5$.





FIGURE 3.13 – Coefficients, gain and phase shift functions for the direct asymmetric filter (DAF).



3.6.2 Different specifications for the estimation of the slope and concavity

FIGURE 3.14 – Distribution of phase shift associated to the local parametrisation of the linear-constant (LC) filter using the final estimates of δ/σ , by the bandwidth h of the henderson filter used to estimate σ and the degree d of the trend to estimate δ .




FIGURE 3.15 – Distribution of phase shift associated to the local parametrisation of the linear-constant (LC) filter using the final estimates of δ/σ , by the bandwidth h of the henderson filter used to estimate σ and the degree d of the trend to estimate δ .




FIGURE 3.16 – Distribution of phase shift associated to the local parametrisation of the quadratic-linear (QL) filter using real-time estimates of δ/σ , by the bandwidth h of the henderson filter used to estimate σ and the degree d of the trend to estimate δ .






FIGURE 3.17 – Distribution of phase shift associated to the local parametrisation of the quadratic-linear (QL) filter using real-time estimates of δ/σ , by the bandwidth h of the henderson filter used to estimate σ and the degree d of the trend to estimate δ .



3.6.3 Impact of the span used to detect the ARIMA model

FIGURE 3.18 – Distribution of phase shift on simulated series by number of years used to identify and estimate the ARIMA model.



3.6.4 Nearest neighbour bandwidth

FIGURE 3.19 – Coefficients, gain and phase shift functions for the Linear-Constant (LC) filter with $I/C = 3.5$ and a nearest neighbour bandwidth.




FIGURE 3.20 – Coefficients, gain and phase shift functions for the Quadratic-Linear (QL) filter with $I/C = 3.5$ and a nearest neighbour bandwidth.




FIGURE 3.21 – Coefficients, gain and phase shift functions for the Cubic-Quadratic (CQ) filter with $I/C = 3.5$ and a nearest neighbour bandwidth.




FIGURE 3.22 – Coefficients, gain and phase shift functions for the direct asymmetric filter (DAF) with a nearest neighbour bandwidth.




FIGURE 3.23 – Distribution of phase shift using nearest neighbour bandwidth.





FIGURE 3.24 – Distribution of phase shift using nearest neighbour bandwidth for polynomial filters with local parametrisation.



Note: nearest bandwidth moving average are used to estimate slope and concavity. We thus do not distinguish local parametrisation and final local parametrisation which assumptions might not be plausible. Indeed, using the same framework as for fixed bandwidth, the final local parametrisation for real-time estimates would imply modelling a polynomial of degree 2 or 3 other 25 months (which doesn't seem plausible).

3.6.5 Quarterly data

FIGURE 3.25 – Distribution of phase shift on quarterly data.




TABLE 3.2 – Average of the relative deviations of the revisions for the different filters on simulated quarterly series with medium variability.

Method	$q = 0$	$q = 1$
$MAE_{fe}(q) = \mathbb{E} \left[\left (TC_{t t+q} - TC_{t last}) / TC_{t last} \right \right]$		
LC	0.76	0.11
LC local param. (final estimates)	0.73	0.11
LC local param.	0.71	0.12
QL	0.93	0.46
QL local param. (final estimates)	0.58	0.12
QL local param.	0.97	0.33
CQ	1.15	1.02
DAF	1.15	0.43
ARIMA	0.49	0.26
$MAE_{ce}(q) = \mathbb{E} \left[\left (TC_{t t+q} - TC_{t t+q+1}) / TC_{t t+q+1} \right \right]$		
LC	0.36	0.11
LC local param. (final estimates)	0.32	0.11
LC local param.	0.34	0.12
QL	1.75	0.46
QL local param. (final estimates)	0.23	0.12
QL local param.	0.40	0.33
CQ	0.07	1.02
DAF	0.75	0.43
ARIMA	0.27	0.26

4 Estimation de la tendance-cycle avec des méthodes robustes aux points atypiques¹

4.1 Introduction

L'analyse du cycle économique, et en particulier la détection rapide des points de retournement, est un sujet de première importance dans l'analyse de la conjoncture économique. Les séries chronologiques se décomposent en trois composantes : les effets saisonniers et les effets de calendrier, la tendance-cycle (permettant d'analyser les points de retournement) et l'irrégulier (le bruit lié à des erreurs d'échantillonnage, chocs économiques, etc.). Pour l'analyse conjoncturelle, les indicateurs économiques sont généralement uniquement corrigés des variations saisonnières et des jours ouvrables, laissant ainsi l'effet combiné de la tendance-cycle et de l'irrégulier. Toutefois, lorsque l'irrégulier est trop élevé, il peut être nécessaire d'effectuer un lissage supplémentaire afin d'analyser directement la composante tendance-cycle. Par construction, les méthodes d'extraction de tendance-cycle sont étroitement liées aux méthodes de désaisonnalisation. En effet, afin d'estimer la composante saisonnière, les algorithmes de désaisonnalisation estiment préalablement une composante tendance-cycle. Ainsi, même si les méthodes d'extraction de tendance-cycle sont généralement appliquées sur des séries corrigées des variations saisonnières, l'estimation de ces séries dépend également des méthodes d'estimation de la tendance-cycle.

Les moyennes mobiles, ou les filtres linéaires, sont omniprésents dans les méthodes d'extraction du cycle économique et d'ajustement saisonnier. Par exemple, la méthode de désaisonnalisation X-11 (Ladiray et Quenneville 2011), utilisée dans le logiciel X-13ARIMA-SEATS (Monsell 2007), utilise des moyennes mobiles pour estimer les principales composantes d'une série chronologique. Au centre de la série, des filtres symétriques sont appliqués (utilisation d'autant de points dans le passé et dans le futur et le même poids est associé aux observations passées et futures). Pour l'extraction de la tendance-cycle, le filtre symétrique le plus connu est celui de Henderson (1916),

1. Références de l'article : Quartier-la-Tente, A. (2025). Estimation de la tendance-cycle avec des méthodes robustes aux points atypiques. arXiv : 2507.10704 [stat.ME]. <https://aqlt.github.io/robustMA/>.

notamment utilisé dans l'algorithme de désaisonnalisation X-13ARIMA-SEATS. En revanche, pour les estimations en temps réel, en raison de l'absence d'observations futures, toutes ces méthodes doivent s'appuyer sur des filtres asymétriques pour estimer les points les plus récents. Par exemple, pour l'extraction de la tendance-cycle tendances-cycles, X-11 utilise le filtre symétrique de Henderson et les filtres asymétriques de Musgrave (1964) sur une série étendue utilisant un modèle ARIMA. Comme les valeurs prédites sont des combinaisons linéaires des valeurs passées, cela revient à appliquer des moyennes mobiles asymétriques à la fin de la série.

Ces moyennes mobiles, comme tout opérateur linéaire, sont sensibles à la présence de points atypiques. L'application directe des méthodes peut donc conduire à des estimations biaisées, du fait de leur présence. alors que les méthodes de désaisonnalisation (comme X-13ARIMA-SEATS) ont un module de correction des points atypiques.

L'objectif de cette troisième étude est d'étudier et de comparer différentes approches permettant l'extraction de tendance-cycle en temps-réel en présence de chocs. Les moyennes mobiles linéaires classiques sont comparées à des méthodes non-linéaires robustes. Nous montrons également comment étendre les moyennes mobiles de Henderson et de Musgrave pour prendre en compte des informations extérieurs et permettant notamment de modéliser des chocs et donc de les rendre robustes à ces derniers : nous parlerons alors de moyennes mobiles « robustes ». Nous décrivons aussi comment construire des intervalles de confiance pour les estimations à l'aide de moyennes mobiles, permettant de valider les modélisations retenues pour les moyennes mobiles « robustes ».

Toutes ces méthodes sont comparées sur des séries simulées (en modélisant des chocs ponctuels et des ruptures en niveau) et sur des séries réelles (autour de chocs et de points de retournement). Cela permet de montrer que les moyennes mobiles « robustes » permettent, par rapport aux moyennes mobiles classiques, de réduire les révisions et de mieux modéliser les points de retournement autour de chocs (par exemple pendant la crise financière de 2008 ou le COVID-19), sans dégrader les estimations lorsqu'aucun choc n'est observé. En revanche, les méthodes non-linéaires robustes étudiées ne permettent pas d'extraire une composante tendance-cycle satisfaisante pour l'analyse conjoncturelle, avec parfois des révisions importantes.

4.2 Méthodologie

L'hypothèse de base utilisée dans les méthodes de décomposition de séries temporelles est que la série chronologique observée, y_t , peut être décomposée en une composante de signal μ_t et une composante erratique ε_t (appelée composante irrégulière) :

$$f(y_t) = \mu_t + \varepsilon_t$$

où f désigne une transformation appropriée (généralement logarithmique ou aucune transformation). Pour simplifier les notations ultérieures, y_t désignera la série observée transformée. La composante de bruit ε_t est généralement supposée être un bruit blanc. En supposant que la série chronologique initiale est désaisonnalisée (ou sans saisonnalité), le signal μ_t représente la tendance (variations sur une longue période) et le cycle (mouvements cycliques superposés à la tendance à long terme), estimés ici conjointement et appelé tendance-cycle TC_t . L'estimation de la composante tendance-cycle permet faciliter l'analyse des retournements conjoncturels dans le cycle classique (également appelé cycle des affaires)². On parle de point de retournement lorsque l'on passe d'une phase de récession (diminutions successives) à une phase d'expansion de l'économie (augmentations successives) : on parle alors de redressement ou, dans le cas contraire, de ralentissement. Même si plusieurs formules peuvent être utilisées pour définir ces phases, la définition de Zellner et alii (1991) est généralement utilisée pour déterminer les points de retournement : on a un point de retournement à la date t lorsque $TC_{t-3} \geq TC_{t-2} \geq TC_{t-1} < TC_t \leq TC_{t+1}$ (redressement) ou $TC_{t-3} \leq TC_{t-2} \leq TC_{t-1} > TC_t \geq TC_{t+1}$ (ralentissement).

La composante tendance-cycle peut être déterministe ou stochastique. En effet, autour d'un voisinage h de t , cette composante peut être approximée localement par un polynôme de degré d :

$$TC_{t+i} = \sum_{j=0}^d \beta_j i^j + \xi_{t+i} \quad \forall i \in \{-h, -h+1, \dots, t+h\}$$

avec ξ_t un processus stochastique non corrélé avec ε_t représentant l'erreur d'approximation. Même si certains articles modélisent ξ_t et ε_t séparément (voir par exemple Gray et Thomson 2002), une hypothèse habituelle, utilisée dans cet article, est de rassembler ξ_t et ε_t ³. Les coefficients $(\beta_0, \dots, \beta_d)$ peuvent être estimés par la méthode des moindres carrés pondérés. L'estimation $\hat{\beta}_0$ fournit l'estimation du cycle de tendance $\widehat{TC}_t$ et on peut montrer que cela équivaut à appliquer une moyenne mobile. Cette moyenne mobile est généralement symétrique ($\widehat{TC}_t$ est estimée en utilisant autant d'observations avant et après t) mais pour l'estimation des derniers points (lorsque l'on ne peut pas utiliser autant d'observations avant et après t) il est nécessaire de s'appuyer sur des moyennes mobiles *ad hoc* qui sont asymétriques.

L'estimation de $\widehat{TC}_t$ étant faite par une méthode linéaire, elle est sensible à la présence de points atypiques qui peuvent notamment entraîner des révisions importantes. C'est par exemple le cas pendant la crise du COVID-19 qui a conduit Statistiques Canada

2. Dans cet article, on ne cherche donc pas à estimer séparément la tendance et le cycle, associée à des méthodes de filtrage de type Hodrick-Prescott ou Baxter-King, qui sont plutôt utilisées pour analyser les points de retournement dans le cycle de croissance (voir Ferrara (2009a) pour une description des différents cycles économiques).

3. Cela revient à supposer que le biais d'approximation de la tendance-cycle par un polynôme local est nul.

et Australian Bureau of Statistics à suspendre la publication des tendances-cycles pendant cette période. Lors de périodes de fortes « turbulences » (comme la crise du COVID-19) où les points atypiques sont importants, les estimations directes de la tendance-cycle peuvent être biaisées. Comme notamment discuté par Matthews (2022), différentes stratégies peuvent alors être adoptées :

- Ne pas publier les estimations pendant cette période : c’est ce qui est fait par l’Australian Bureau of Statistics pour la période du COVID-19 en ne publiant pas d’estimation tendance-cycle entre avril 2020 et mars 2022.
- Estimer les points atypiques avec un modèle RegARIMA, estimer la tendance-cycle sur la série corrigée et « réintroduire » les effets corrigés sur la tendance-cycle. L’inconvénient de cette approche est que l’estimation des points atypiques dépend du modèle ARIMA utilisé et de la période d’estimation. Si le modèle est réestimé à chaque nouvelle observation, la tendance-cycle peut donc potentiellement être révisée pendant de nombreuses périodes. Par exemple, Ladiray et Quartier-la-Tente (2018) montrent que dans la majorité des cas il faut attendre au moins 3 ans pour que l’estimation du coefficient associé à une rupture converge. C’est l’approche privilégiée par l’Australian Bureau of Statistics lors de ruptures dans la tendance (Trewin 2003).
- Estimer la tendance-cycle sur l’ensemble de la période et remplacer les données estimées après la rupture par celles estimées en commençant la série après la rupture (série segmentée d’un côté). L’inconvénient de cette approche est que les estimations avant la rupture vont être biaisées par la présence du choc et que celles après la rupture reposent sur des moyennes mobiles asymétriques (avec un biais plus important que les moyennes mobiles symétriques utilisées pour les estimations finales, et peuvent créer un déphasage, c’est-à-dire un décalage dans les points de retournement).
- Diviser la série en deux au niveau de la rupture et estimer la tendance-cycle sur chaque segment (série segmentée des deux côtés). L’inconvénient de cette approche est que les estimations avant la rupture et après la rupture reposent sur des moyennes mobiles asymétriques (avec les mêmes inconvénients que précédemment). C’est l’approche privilégiée par Statistique Canada pendant le COVID-19 (Matthews 2022) et celle qui était par l’Australian Bureau of Statistics lors des premières publications des estimations de la tendance-cycle (Australian Bureau of Statistics 1987).

L’objectif de cet article est d’étudier des approches alternatives à celles de Matthews (2022). D’une part en étudiant les estimations en temps réel de méthodes non-linéaires robustes à la présence de points (section 4.2.1) ; d’autre part en les comparant aux estimations des moyennes mobiles classiques (section 4.2.2) et en proposant une méthode de construction de moyennes mobiles linéaires robustes (section 4.2.3). Nous montrons également comment construire des intervalles de confiance pour les estimations issues de moyennes mobiles (section 4.2.4), ce qui permet de valider le choix de construction d’une moyenne mobile linéaire robuste.

4.2.1 Méthodes robustes

Dans cette étude nous étudions six méthodes robustes d'estimation locale de la moyenne implémentées dans la fonction `robfilter::robreg.filter()` (Fried et alii 2024). Dans le *package* `robfilter`, la tendance-cycle est supposée être localement linéaire :

$$y_{t+i} = \underbrace{\beta_{0,t} + \beta_{1,t}i}_{TC_{t+i}} + \varepsilon_{t,i}$$

On a donc $\widehat{TC}_t = \hat{\beta}_{0,t}$ et l'on note $r_{t+i} = y_{t+i} - (\beta_{0,t} + \beta_{1,t}i)$.

Les différentes méthodes étudiées sont :

- Médiane mobile (MED) :

$$\widehat{TC}_t = \text{med}_{i=-h,\dots,h} y_{t+i}.$$

- Régression médiane répétée — *Repeated Median* (RM) (Siegel 1982)

$$\hat{\beta}_{1,t} = \text{med}_{i=-h,\dots,h} \left\{ \text{med}_{i \neq j} \frac{y_{t+i} - y_{t+j}}{i - j} \right\}$$

et

$$\widehat{TC}_t = \text{med}_{i=-h,\dots,h} \{y_{t+i} - i\hat{\beta}_{1,t}\}.$$

- Régression des moindres carrés médians — *Least Median of Squares* (LMS) (Peter J Rousseeuw 1984) :

$$(\widehat{TC}_t, \hat{\beta}_{1,t}) = \underset{\beta_{0,t}, \beta_{1,t}}{\text{argmin}} \left\{ \text{med}_{i=-h,\dots,h} r_{t+i}^2 \right\}.$$

- Régression des moindres carrés élagués — *Least Trimmed Squares* (LTS) (Peter J. Rousseeuw 1985) :

$$(\widehat{TC}_t, \hat{\beta}_{1,t}) = \underset{\beta_{0,t}, \beta_{1,t}}{\text{argmin}} \left\{ \sum_{i=-h}^h r_{t+i}^2 \right\}.$$

- Régression des moindres quartiles différenciés — *Least Quartile Difference* (LQD) (Christophe Croux et Hössjer 1994) :

$$\hat{\beta}_{1,t} = \underset{\beta_{1,t}}{\text{argmin}} Q_{2h+1}(r_{t-h}, \dots, r_{t+h})$$

avec

$$Q_{2h+1}(r_{t-h}, \dots, r_{t+h}) = \{|r_i - r_j|; i < j\}_{\binom{h_p}{2}: (2h+1)}$$

le quantile d'ordre $\binom{h_p}{2}$ sur les $\binom{2h+1}{2}$ éléments de l'ensemble $\{|r_i - r_j|; i < j\}$ et $h_p = [(2h+1+p+1)/2]$ avec $p = 1$ le nombre de régresseurs (hors constante). La fonction objectif ne dépendant pas de la constante, elle est estimée a posteriori par exemple en utilisant la formule :

$$\widehat{TC}_t = \text{med}_{i=-h, \dots, h} y_{t+i} - \hat{\beta}_{1,t} i.$$

— Régression profonde — *Deepest Regression* (DR) (Rousseeuw et Hubert 1999)

$$(\widehat{TC}_t, \hat{\beta}_{1,t}) = \underset{\tilde{\beta}_0, \tilde{\beta}_1}{\operatorname{argmax}} \left\{ rdepth(\tilde{\beta}_0, \tilde{\beta}_1) \right\}$$

où la profondeur de la régression — *regression depth* ($rdepth$) — d'un ajustement $(\tilde{\beta}_0, \tilde{\beta}_1)$ est définie comme :

$$rdepth(\tilde{\beta}_0, \tilde{\beta}_1) = \min_{-h \leq i \leq h} \left\{ \min \left\{ L^+(i) + R^-(i); R^+(i) + L^-(i) \right\} \right\}$$

avec :

$$\begin{cases} L^+(i) = L_{\tilde{\beta}_0, \tilde{\beta}_1}^+(i) = \text{cardinal} \left\{ j \in \{-h, \dots, i\} : r_j(\tilde{\beta}_0, \tilde{\beta}_1) \leq 0 \right\} \\ R^-(i) = R_{\tilde{\beta}_0, \tilde{\beta}_1}^-(i) = \text{cardinal} \left\{ j \in \{i+1, \dots, h\} : r_j(\tilde{\beta}_0, \tilde{\beta}_1) < 0 \right\} \end{cases}$$

et $L^-(i)$ et $R^+(i)$ définis de manière analogue.

Pour les estimations intermédiaires (i.e., lorsque pour estimer la tendance-cycle à la date t on ne possède pas h observations avant ou après t), le *package* **robfilter** extrapole les données à partir du dernier modèle estimé. C'est-à-dire que si les données observées sont $y_1, \dots, y_n$, alors pour $q \in \{1, \dots, 6\}$:

$$\widehat{TC}_{n-h+q} = \widehat{TC}_{n-h} + q \times \hat{\beta}_{1,n-h}.$$

Pour la médiane mobile, cela revient à prolonger par la dernière valeur connue. Cette méthode n'est pas pertinente pour l'analyse conjoncturelle puisque les points de retournement sont détectés avec h périodes de retard. Une approche alternative consiste à appliquer les mêmes modèles mais en n'utilisant que les observations disponibles (pour estimer $\widehat{TC}_{n-h+1}$ on utilise les $2h$ observations entre $n-2h+1$ et n , ..., et pour estimer $\widehat{TC}_n$ on utilise les $h+1$ observations entre $n-h$ et n). Cette approche n'est pas implémentée dans **robfilter** mais peut être obtenue en ajoutant h valeurs manquantes au début et à la fin de la série : c'est ce qui sera effectué dans cet article.

Dans le cadre de l'analyse conjoncturelle, il n'est généralement pas plausible de modéliser, autour des points de retournement, une tendance de degré 1⁴. Il n'est

4. Dans l'utilisation de méthodes robustes, il est courant de localement modéliser une tendance de degré 1. Par exemple, dans la méthode de lissage Loess, Cleveland (1979) recommande d'utiliser une tendance de degré 1 qui permet d'avoir un « bon compromis entre facilité de calcul et besoin de flexibilité ». Idem, dans la méthode de désaisonnalisation STL (*Seasonal-Trend decomposition based on Loess*), Cleveland et alii (1990) indiquent : « Il est raisonnable de prendre $d = 1$ si le modèle sous-jacent des données présente une légère courbure. Mais si la courbure est importante, par exemple avec des pics et des creux, il est préférable d'opter pour $d = 2$. »

toutefois pas possible de changer cela dans le *package* **robfilter** et il n'existe pas d'autre *package* permettant d'appliquer simplement toutes ces méthodes. Même si cette modélisation n'est pas toujours optimale, elle reste plausible dans la majorité des cas et la facilité d'utilisation de **robfilter** font de ces méthodes un bon point de comparaison aux moyennes mobiles linéaires classiquement utilisées pour l'estimation de la tendance-cycle et présentées dans la section suivante. Toutefois, les méthodes LTS et LMS sont implémentées dans le *package* **MASS** (Venables et Ripley 2002)⁵, il est possible de réimplémenter le processus d'estimation locale avec une tendance de degré 2, ce qui a été fait dans l'annexe 4.5.4.

4.2.2 Moyennes mobiles linéaires classiques

4.2.2.1 Moyenne mobile de Henderson et de Musgrave

Les moyennes mobiles classiques peuvent être obtenues par analogie avec la régression polynomiale locale. En reprenant les notations de Proietti et Luati (2008), on suppose que notre série chronologique y_t peut être décomposée en :

$$y_t = TC_t + \varepsilon_t,$$

où TC_t est la tendance-cycle et $\varepsilon_t \stackrel{i.i.d}{\sim} \mathcal{N}(0, \sigma^2)$ est le bruit. La tendance-cycle TC_t est localement approchée par un polynôme de degré d , de sorte que dans un voisinage h de t on a $TC_t \simeq m_t$ avec :

$$\forall j \in \{-h, -h+1, \dots, h\}, y_{t+j} = m_{t+j} + \varepsilon_{t+j}, \quad m_{t+j} = \sum_{i=0}^d \beta_{i,t} j^i.$$

En notation matricielle :

$$\underbrace{\begin{pmatrix} y_{t-h} \\ y_{t-(h-1)} \\ \vdots \\ y_t \\ \vdots \\ y_{t+(h-1)} \\ y_{t+h} \end{pmatrix}}_{\mathbf{y}_t} = \underbrace{\begin{pmatrix} 1 & -h & h^2 & \dots & (-h)^d \\ 1 & -(h-1) & (h-1)^2 & \dots & -(h-1)^d \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & h-1 & (h-1)^2 & \dots & (h-1)^d \\ 1 & h & h^2 & \dots & h^d \end{pmatrix}}_{\mathbf{X}} \underbrace{\begin{pmatrix} \beta_{0,t} \\ \beta_{1,t} \\ \vdots \\ \beta_{d,t} \end{pmatrix}}_{\boldsymbol{\beta}_t} + \underbrace{\begin{pmatrix} \varepsilon_{t-h} \\ \varepsilon_{t-(h-1)} \\ \vdots \\ \varepsilon_t \\ \vdots \\ \varepsilon_{t+(h-1)} \\ \varepsilon_{t+h} \end{pmatrix}}_{\boldsymbol{\varepsilon}_t}. \quad (4.1)$$

5. Nous n'avons pas trouvé d'autres fonctions permettant d'utiliser les autres méthodes, même si elles pourraient être réimplémentées facilement.

L'estimation des paramètres β_t peut être obtenue moindres carrés pondérés — *weighted least squares* (WLS) — à partir d'un ensemble de poids $(\kappa_j)_{-h \leq j \leq h}$ appelés noyaux. En notant $\mathbf{K} = \text{diag}(\kappa_{-h}, \dots, \kappa_h)$ il vient $\hat{\beta}_t = (\mathbf{X}^t \mathbf{K} \mathbf{X})^{-1} \mathbf{X}^t \mathbf{K} \mathbf{y}_t$. Avec $\mathbf{e}_1 = {}^t(1 \ 0 \ \dots \ 0)$, l'estimation de la tendance-cycle est :

$$\widehat{TC}_t = \hat{\beta}_{0,t} = {}^t \mathbf{e}_1 \hat{\beta}_t = {}^t \boldsymbol{\theta} \mathbf{y}_t = \sum_{j=-h}^h \theta_j y_{t-j} \text{ avec } \boldsymbol{\theta} = \mathbf{K} \mathbf{X} (\mathbf{X}^t \mathbf{K} \mathbf{X})^{-1} \mathbf{e}_1. \quad (4.2)$$

En somme, l'estimation de la tendance $\hat{m}_t$ est obtenue en appliquant une moyenne mobile symétrique $\boldsymbol{\theta}$ à y_t .

On retrouve la moyenne mobile de Henderson avec $d = 2$ (ou $d = 3$) et en utilisant les noyaux :

$$\kappa_j = \left[1 - \frac{j^2}{(h+1)^2} \right] \left[1 - \frac{j^2}{(h+2)^2} \right] \left[1 - \frac{j^2}{(h+3)^2} \right].$$

Pour le cas asymétrique, Proietti et Luati (2008) proposent une méthode générale pour construire les filtres asymétriques qui permet de faire un compromis biais-variance. Il s'agit d'une généralisation des filtres asymétriques de Musgrave (1964) (utilisés dans l'algorithme de désaisonnalisation X-13ARIMA-SEATS). En récrivant l'équation 4.1 :

$$\mathbf{y}_t = \begin{pmatrix} \mathbf{U} & \mathbf{Z} \end{pmatrix} \begin{pmatrix} \gamma_t \\ \delta_t \end{pmatrix} + \varepsilon_t = \mathbf{U} \gamma_t + \mathbf{Z} \delta_t + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \mathbf{D}). \quad (4.3)$$

où $[\mathbf{U}, \mathbf{Z}]$ est de rang plein et forme un sous-ensemble des colonnes de $\mathbf{X}$. L'objectif est de trouver une moyenne mobile asymétrique $\boldsymbol{\theta}^{(a)}$ qui minimise l'erreur quadratique moyenne de révision (à la moyenne mobile symétrique $\boldsymbol{\theta}$) sous certaines contraintes. Ces contraintes sont représentées par la matrice $\mathbf{U} = {}^t(\mathbf{U}_p \ \mathbf{U}_f) : \mathbf{U}_p \boldsymbol{\theta}^{(a)} = \mathbf{U} \boldsymbol{\theta}$ (avec $\mathbf{U}_p$ la matrice $(h+q+1) \times (d+1)$ qui contient les observations de la matrice $\mathbf{U}$ connues lors de l'estimation par le filtre asymétrique). C'est ce qui est implémenté dans la fonction `rjd3filters::mmsre_filter()` du *package* `R rjd3filters` (Palate et Quartier-la-Tente 2024).

Lorsque $\mathbf{U}$ correspond aux $d^* + 1$ premières colonnes de $\mathbf{X}$, $d^* < d$, la contrainte consiste à reproduire des tendances polynomiales de degré d^* . Cela introduit du biais (sur les tendances de degré $d^* + 1$ à d) mais réduit la variance. Le filtre de Musgrave se retrouve en modélisant une tendance localement linéaire ($d = 1$), en imposant que $\boldsymbol{\theta}^{(a)}$ préserve les constantes ($d^* = 0$) et en prenant le filtre d'Henderson comme filtre symétrique. C'est-à-dire que l'on a $\mathbf{U} = {}^t(1 \ \dots \ 1)$, $\mathbf{Z} = {}^t(-h \ \dots \ +h)$, $\delta_t = \delta_{1,t}$, $\mathbf{D} = \sigma^2 \mathbf{I}$. Ce filtre dépend du rapport $|\delta_{1,t}/\sigma|$ (modélisant le biais), qui est à fixer par l'utilisateur. En supposant que la tendance est linéaire et le biais constant ($\delta_{1,t} = \delta_1$), ce rapport est lié à l'I-C ratio $R = \frac{\bar{I}}{\bar{C}} = \frac{\sum |I_t - I_{t-1}|}{\sum |C_t - C_{t-1}|}$ (et l'on a $\delta_1/\sigma = 2/(R\sqrt{\pi})$), qui est notamment utilisé dans X-11 pour déterminer la longueur de la moyenne mobile de Henderson à utiliser. Pour des données mensuelles :

- Si le rapport est élevé ($3, 5 < R$), un filtre symétrique à 23 termes est utilisé (pour éliminer plus de bruit) et le rapport $R = 4, 5$ est utilisé dans X-11 pour définir le filtre de Musgrave.
- Si le rapport est faible ($R < 1$), un filtre symétrique à 9 termes est utilisé et le rapport $R = 1$ est utilisé dans X-11 pour définir le filtre de Musgrave.
- Dans le cas contraire ($1 \leq R \leq 3, 5$, la plupart des cas), un filtre symétrique à 13 termes est utilisé et le rapport $R = 3, 5$ est utilisé dans X-11 pour définir le filtre de Musgrave.

Dans cet article, seules des séries mensuelles sont étudiées et le filtre de Henderson à 13 termes sera utilisé comme filtre symétrique. Par simplification et par cohérence avec ce qui est utilisé dans X-11, le ratio δ_1/σ sera fixé de sorte à avoir $R = 3, 5$. C'est également ce qui est fait par l'Australian Bureau of Statistics (Trewin 2003). Toutefois, comme notamment montré dans Quartier-la-Tente (2024b), une paramétrisation locale de ce paramètre pourrait être préférée.

Par simplification, dans cette étude on parle d'estimation via la moyenne mobile de Henderson pour désigner l'utilisation des moyennes mobiles de Henderson pour l'estimation finale et des moyennes mobiles de Musgrave pour les estimations intermédiaires. Les coefficients des différentes moyennes mobiles étudiées dans cet article sont représentés dans l'annexe 4.5.1.

4.2.2.2 Filtres cascade

Les moyennes mobiles étant des opérateurs linéaires, ils sont sensibles à la présence de points atypiques. Du fait de leur présence, l'application directe des méthodes peut donc conduire à des estimations biaisées alors que les méthodes de désaisonnalisation (comme la méthode X-13ARIMA-SEATS) ont un module de correction des points atypiques. Par ailleurs, comme notamment montré par Dagum (1996), le filtre symétrique final utilisé par X-11 pour extraire la tendance-cycle (et donc celui indirectement utilisé lorsqu'on applique les méthodes sur les séries désaisonnalisées) laisse passer environ 72 % des cycles de 9 ou 10 mois (généralement associés à du bruit plutôt qu'à la tendance-cycle). Les filtres asymétriques finaux amplifient même les cycles de 9 ou 10 mois. Cela peut avoir pour conséquence l'introduction d'ondulations indésirables, c'est-à-dire la détection de faux points de retournement. Ce problème est réduit par la correction des points atypiques (ces cycles étant considérés comme de l'irrégulier). C'est ainsi que le *Nonlinear Dagum Filter* (NLDF) a été développé et consiste à :

1. appliquer l'algorithme de correction des points atypiques de X-11 sur la série désaisonnalisée, puis la prolonger par un modèle ARIMA ;
2. effectuer une nouvelle correction des points atypiques en utilisant un seuil bien plus strict et appliquer ensuite le filtre symétrique de 13 termes. En supposant une distribution normale cela revient à modifier 48 % des valeurs de l'irrégulier.

Les *cascade linear filter* (CLF, Dagum et Luati 2009), correspondent à une approximation des NLDF en utilisant un filtre de 13 termes et lorsque les prévisions sont obtenues à partir d'un modèle ARIMA(0,1,1) où $\theta = 0,40$. De manière similaire, des moyennes mobiles asymétriques, *Asymmetric Linear Filter* (ALF), peuvent être construites.

C'est la moyenne mobile CLF qui est utilisée par Statistique Canada pour l'estimation de la tendance-cycle⁶. Pour l'estimation en temps réel, Statistique Canada utilise la méthode « couper-et-normaliser » qui consiste à recalculer les poids, à partir de la moyenne mobile symétrique, en n'utilisant que les poids associées aux observations disponibles (couper) et en renormalisant pour que la somme des coefficients soit égale à 1 (normaliser). C'est l'approche qui sera utilisé dans cet article (plutôt que l'utilisation des ALF).

Remarque. Les CLF ne préservent, localement, que les droites (tendances de degré 1) et les moyennes mobiles asymétriques associées que les constantes (tendances de degré 0). En revanche la moyenne mobile de Henderson préserve les tendances locales de degré 3 et les moyennes mobiles de Musgrave que les constantes.

4.2.3 Construction de moyennes mobiles robustes

Une autre façon de construire des moyennes mobiles robustes aux points atypiques est d'exploiter l'approche polynomiale locale présentée dans la section 4.2.2.1. Pour la construire la moyenne mobile utilisée pour l'estimation finale de la tendance-cycle, il suffit pour cela d'ajouter dans l'équation 4.1 un ou plusieurs régresseurs $\mathbf{O}_t$ pour prendre en compte l'effet du point atypique modélisé :

$$y_{t+j} = \sum_{i=0}^d \beta_{i,t} j^i + \mathbf{O}_{t+j} \boldsymbol{\zeta}_t + \varepsilon_{t+j}.$$

On a alors :

$$\widehat{TC}_t = {}^t\boldsymbol{\theta}_t^{(r)} \mathbf{y}_t = \sum_{j=-h}^h \theta_{j,t}^{(r)} y_{t-j}$$

avec

$$\boldsymbol{\theta}_t^{(r)} = \mathbf{K} \begin{pmatrix} \mathbf{X} & \mathcal{O}_t \end{pmatrix} \left({}^t \begin{pmatrix} \mathbf{X} & \mathcal{O}_t \end{pmatrix} \mathbf{K} \begin{pmatrix} \mathbf{X} & \mathcal{O}_t \end{pmatrix} \right)^{-1} \mathbf{e}_1 \text{ et } \mathcal{O}_t = \begin{pmatrix} \mathbf{O}_{t-h} \\ \vdots \\ \mathbf{O}_{t+h} \end{pmatrix}.$$

Le filtre de Henderson peut être obtenu par approximation locale d'un polynôme de degré 2. Puisqu'il est symétrique, il préserve également les tendances de degré 3 et

6. Voir par exemple <https://www.statcan.gc.ca/fr/quo/bdd/tendance-cycle>.

peut également être obtenu par approximation locale d'un polynôme de degré 3. En revanche, même si la moyenne mobile $\theta_t^{(r)}$ est centrée (autant de points avant et après t sont utilisés pour estimer $\widehat{TC}_t$), elle n'est plus forcément symétrique (pour au moins un $i \in \{1, \dots, h\}$ on a $\theta_{-i,t}^{(r)} \neq \theta_{i,t}^{(r)}$). Pour construire une moyenne mobile robuste associée au filtre de Henderson, le choix entre modélisation d'un polynôme local de degré 2 ($d = 2$) ou 3 ($d = 3$) aura donc un impact sur la moyenne mobile finale. Dans cet article nous utiliserons par convention la valeur $d = 3$ afin de préserver sans biais les mêmes tendances que la moyenne mobile de Henderson.

Pour la construction des moyennes mobiles asymétriques, le même principe est appliqué à l'équation 4.3 en estimant sans biais ζ_t :

$$\mathbf{y}_t = \begin{pmatrix} \mathbf{U} & \mathcal{O}_t \end{pmatrix} \begin{pmatrix} \gamma_t \\ \zeta_t \end{pmatrix} + \mathbf{Z}\delta_t + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{D}).$$

La moyenne mobile asymétrique $\theta_t^{(a)(r)}$ est trouvée par minimisation de l'erreur quadratique moyenne de révision (à la moyenne mobile $\theta_t^{(r)}$) sous contraintes. Ces contraintes sont représentées par la matrice $\begin{pmatrix} \mathbf{U} & \mathcal{O}_t \end{pmatrix} = \begin{pmatrix} \mathbf{U}_p & \mathcal{O}_{p,t} \\ \mathbf{U}_f & \mathcal{O}_{f,t} \end{pmatrix}$:

$${}^t(\mathbf{U}_p \quad \mathcal{O}_{p,t}) \theta^{(a)} = {}^t(\mathbf{U} \quad \mathcal{O}_t) \theta_t^{(r)}.$$

Par convention, lorsque $\mathcal{O}_t$ ou $\mathcal{O}_{p,t}$ est la matrice nulle, on garde la modélisation de la section 4.2.2.1 (sans introduction de régresseur supplémentaire).

Dans cette étude, les deux types de points atypiques les plus couramment rencontrés dans l'analyse de données macroéconomiques sont étudiés :

- Les points atypiques additifs (AO, *additive outlier*) : un choc ponctuelle à une date particulière puis un retour à la normal (grève, mesure exceptionnelle, erreur de mesure par exemple liée à de la non réponse, etc.). Le choc affecte donc l'irrégulier et ne devrait pas avoir d'impact sur la tendance-cycle. Si le choc apparaît à la date t_0 il peut être modélisé par le régresseur $O_t^{AO} = \mathbb{1}_{t=t_0}$ qui vaut 1 à la date t_0 et 0 sinon. Si l'on souhaite que le choc soit affecté à la tendance-cycle et non pas à l'irrégulier (par exemple pendant la période du COVID-19), il faut utiliser le régresseur $O_{t+j} = O_{t+j}^{AO} = \mathbb{1}_{t+j=t_0}$ lorsque $t < t_0$ ou $t = t_0 + h$ (estimations des points avant le choc et dernière moyenne mobile modifiée) et $O_{t+j} = 1 - O_{t+j}^{AO} = \mathbb{1}_{t+j \neq t_0}$ lorsque $t_0 \leq t < t_0 + h$ (estimations des points après le choc sauf dernière moyenne mobile modifiée). Une distinction est faite pour $t = t_0 + h$ car dans ce cas le régresseur $\mathbb{1}_{t+j \neq t_0}$ est égal à $\mathbb{1}_{t+j > t_0}$ ce qui revient à créer une rupture en niveau (cf. *infra*) et introduit un pic indésirable à l'estimation en $t_0 + h$.

- Les ruptures en niveau (LS, *level shift*) : un changement soudain et durable du niveau moyen de la série (choc structurel, changement de politique économique, etc.). Le choc affecte donc la tendance-cycle et ne devrait pas avoir d'impact sur l'irrégulier. Si le choc est à la date t_0 il peut être modélisé par le régresseur $O_{t+j} = 1 - \mathbb{1}_{t+j < t_0}$ si $t \leq t_0$ (l'estimation de $\beta_{0,t}$ ne prend pas en compte le choc en niveau) et $O_{t+j} = \mathbb{1}_{t+j \geq t_0}$ si $t_0 < t$ (l'estimation de $\beta_{0,t}$ prend en compte le choc en niveau).

Cette méthode a été implémentée dans la fonction `publishTC:henderson_robust_smoothing()` du *package* `publishTC` (Quartier-la-Tente 2025b) qui permet de modéliser des chocs ponctuels (affectés à l'irrégulier ou à la tendance-cycle) et des ruptures en niveau (affectées à la tendance-cycle).

L'inconvénient de cette approche, par rapport aux méthodes robustes présentées dans la section 4.2.1, est que cela suppose de connaître la date et la nature du point atypique. Une approche en deux temps peut être utilisée :

1. Partir sur un a priori basé sur une information économique (ex : baisse attendue de l'économie au moment des confinements durant le COVID-19, hausse attendue suite à une mise en place d'une politique. ...) ou sur des modèles statistiques (comme le module de détection des points atypiques de X-13ARIMA-SEATS basé sur un modèle RegARIMA).
2. Valider la modélisation retenue en comparant l'intervalle de confiance de l'estimation de la tendance-cycle avec les moyennes mobiles de Henderson et de Musgrave avec l'estimation en utilisant les moyennes mobiles robustes. La section 4.2.4 décrit la méthodologie pour la construction d'intervalles de confiance pour des estimations basées sur des moyennes mobiles.

Toutefois, pour l'estimation en temps réel, sauf à avoir une information extérieure, il est difficile de distinguer un *level shift* (LS) d'un ou plusieurs *additive outlier* (AO) consécutifs. Le choix du type de point atypique aura une influence forte sur l'estimation (puisque les LS affectent la tendance-cycle et les AO l'irrégulier) et passer d'une spécification à l'autre entraînera des révisions importantes. Ces révisions seront même plus importantes que si, avant de décider de la bonne modélisation à adopter, les premières estimations avaient été faites avec des moyennes mobiles classiques.

Par rapport au préajustement des points atypiques par un modèle *ad hoc*, comme le module de pré-ajustement de X-13ARIMA-SEATS basé sur un modèle RegARIMA, l'approche ici présentée a l'avantage de ne pas être dépendante de l'identification d'un modèle et de la période d'estimation (pas de biais lié à l'identification des paramètres ou à l'utilisation d'une période d'estimation trop courte ou trop longue).

Dans la suite ces moyennes mobiles seront appelées moyennes mobiles de Henderson ou de Musgrave robustes. Par simplification, nous appellerons également moyenne mobile de Henderson robuste l'utilisation des moyennes de mobiles de Henderson

(pour l'estimation finale) et de Musgrave (pour les estimations intermédiaires) robustes construits selon la même méthodologie.

4.2.4 Construction d'intervalles de confiance pour des moyennes mobiles

Soit $y_1, \dots, y_n$ une série chronologique observée. On suppose qu'elle peut être décomposée en

$$y_t = \mu_t + \varepsilon_t,$$

où μ_t est une composante signal à estimer et $\varepsilon_t \stackrel{i.i.d}{\sim} \mathcal{N}(0, \sigma^2)$ est le bruit.

Soit $\boldsymbol{\theta} = (\theta_{-p}, \dots, \theta_f)$ une moyenne mobile permettant d'estimer localement la composante inobservable μ_t (dans cette étude la tendance-cycle TC_t) à partir de y_t . Cette estimation est donnée par $\hat{\mu}_t = \sum_{i=-p}^{+f} \theta_i y_{t+i}$.

Un intervalle de confiance de $\mathbb{E}[\hat{\mu}_t]$ au seuil α peut être calculé à partir de la formule :

$$I_t = \left[\hat{\mu}_t - |q_{\alpha/2}| \sqrt{\hat{\sigma}^2} \sqrt{\sum_{i=-p}^{+f} \theta_i^2}; \hat{\mu}_t + |q_{1-\alpha/2}| \sqrt{\hat{\sigma}^2} \sqrt{\sum_{i=-p}^{+f} \theta_i^2} \right] \quad (4.4)$$

où

$$\hat{\sigma}^2 = \frac{1}{(n - p - f) \left(1 - 2\theta_0^2 + \sum_{i=-p}^{+f} \theta_i^2\right)} \sum_{t=p+1}^{n-f} (y_t - \hat{\mu}_t)^2$$

et $q_{\alpha/2}$ est le quantile d'ordre $\alpha/2$ d'une certaine loi de Student. C'est un intervalle de confiance de μ_t lorsque l'on a un estimateur sans biais de μ_t ($\mathbb{E}[\hat{\mu}_t] = \sum_{i=-p}^{+f} \theta_i y_{t+i} = \mu_t$), ce qui n'est généralement pas le cas, mais le biais est négligeable lorsque la fenêtre $p + f + 1$ est petite.

Ces formules se retrouvent par analogie avec la régression polynomiale locale. En reprenant les notations de Loader (1999) pour la régression polynomiale locale et en adaptant à l'utilisation de moyennes mobiles, la variance $\hat{\sigma}^2$ peut être estimée par la somme des carrés des résidus normalisés :

$$\hat{\sigma}^2 = \frac{1}{(n - p - f) - 2\nu_1 + \nu_2} \sum_{t=p+1}^{n-f} (y_t - \hat{\mu}_t)^2.$$

$n - p - f$ termes sont utilisés car avec la moyenne mobile $\boldsymbol{\theta}$ seulement $n - p - f$ observations peuvent être utilisées pour estimer σ^2 . ν_1 et ν_2 sont deux définitions de degrés de liberté d'une estimation locale (généralisation du nombre de paramètres

d'un modèle paramétrique). Notons $\mathbf{H}$ la *matrice chapeau* de taille $n \times n$ permettant de faire correspondre les données aux valeurs estimées :

$$\begin{pmatrix} \hat{\mu}_1 \\ \vdots \\ \hat{\mu}_n \end{pmatrix} = \mathbf{H}\mathbf{Y} \text{ avec } \mathbf{Y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

En considérant par convention que $\hat{\mu}_1 = \dots = \hat{\mu}_p = \hat{\mu}_{n-f+1} = \dots = \hat{\mu}_n = 0$ (puisque l'on ne peut pas estimer ces quantités avec la moyenne mobile θ), on a donc :

$$\mathbf{H} = \begin{pmatrix} & & \mathbf{0}_{p \times n} & & & \\ \theta_{-p} & \dots & \theta_f & 0 & \dots & \\ 0 & \theta_{-p} & \dots & \theta_f & 0 & \dots \\ & \ddots & & & \ddots & \\ 0 & \dots & 0 & \theta_{-p} & \dots & \theta_f \\ & & \mathbf{0}_{f \times n} & & & \end{pmatrix},$$

où $\mathbf{0}_{p \times n}$ est la matrice de taille $p \times n$ ne contenant que de zéros. On a :

$$\begin{cases} \nu_1 = \text{tr}(\mathbf{H}) = (n - p - f)\theta_0 \\ \nu_2 = \text{tr}({}^t\mathbf{H}\mathbf{H}) = (n - p - f) \sum_{i=-p}^{+f} \theta_i^2 \end{cases}.$$

Si les bruits ε_t sont indépendants et de variance σ^2 , alors :

$$\mathbb{V}[y_t - \hat{\mu}_t] = \sigma^2 - 2 \underbrace{\text{Cov}(y_t, \hat{\mu}_t)}_{=\theta_0\sigma^2} + \underbrace{\mathbb{V}[\hat{\mu}_t]}_{=\sigma^2 \sum_{i=-p}^{+f} \theta_i^2}$$

et l'on a donc :

$$\mathbb{E}[\hat{\sigma}^2] = \sigma^2 + \frac{1}{(n - p - f) - 2\nu_1 + \nu_2} \sum_{t=p+1}^{n-f} (\mathbb{E}[\hat{\mu}_t] - \mu_t)^2.$$

L'estimateur $\hat{\sigma}^2$ est donc sans biais si $\hat{\mu}_t$ l'est aussi.

La somme des carrés des résidus peut s'écrire sous forme quadratique :

$$\sum_{t=p+1}^{n-f} (y_t - \hat{\mu}_t)^2 = {}^t\mathbf{Y}\mathbf{\Delta}\mathbf{Y}$$

avec $\mathbf{Y} = {}^t(y_1 \dots y_n)$ et :

$$\mathbf{\Delta} = {}^t(\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H}), \mathbf{I} = \begin{pmatrix} & & \mathbf{0}_{p \times n} & & \\ \mathbf{0}_{(n-p-f) \times p} & \mathbf{I}_{n-p-f} & \mathbf{0}_{(n-p-f) \times f} & & \\ & & \mathbf{0}_{f \times n} & & \end{pmatrix}$$

et $\mathbf{I}_{n-p-f}$ la matrice identité de taille $n - p - f$. On a donc :

$$\hat{\sigma}^2 = \frac{1}{\text{tr } \mathbf{\Delta}} {}^t\mathbf{Y} \mathbf{\Delta} \mathbf{Y}.$$

Si les bruits ε_t sont normalement distribués indépendants et $\hat{\sigma}^2$, la distribution est :

$${}^t\mathbf{Y} \mathbf{\Delta} \mathbf{Y} \stackrel{\mathcal{L}}{=} \sigma^2 \sum_{j=1}^n \lambda_j Z_j,$$

où les λ_j sont les valeurs propres de $\mathbf{\Delta}$ et les Z_j sont des lois indépendantes du chi-deux à 1 degré de liberté. Il vient :

$$\begin{cases} \mathbb{E} [\hat{\sigma}^2] = \sigma^2 \underbrace{\frac{1}{\text{tr } \mathbf{\Delta}} \sum_{j=1}^n \lambda_j}_{=\text{tr } \mathbf{\Delta}} = \sigma^2 \\ \mathbb{V} [\hat{\sigma}^2] = \sigma^4 \frac{1}{(\text{tr } \mathbf{\Delta})^2} \sum_{j=1}^n 2\lambda_j^2 = 2\sigma^4 \frac{\text{tr}(\mathbf{\Delta}^2)}{(\text{tr } \mathbf{\Delta})^2} \end{cases}.$$

En notant $\nu = \text{tr}(\mathbf{\Delta})^2 / \text{tr}(\mathbf{\Delta}^2)$, on a donc :

$$\begin{cases} \mathbb{E} \left[\nu \frac{\hat{\sigma}^2}{\sigma^2} \right] = \nu \\ \mathbb{V} \left[\nu \frac{\hat{\sigma}^2}{\sigma^2} \right] = 2\nu \end{cases}.$$

Les deux premiers moments de $\nu \hat{\sigma}^2 / \sigma^2$ sont donc identiques à ceux d'une loi du chi-deux avec ν degrés de liberté. La loi $\hat{\sigma}^2$ étant difficile à calculer dans le cadre de la régression locale, on peut approximer sa distribution par une loi du chi-deux.

Puisque $\mathbb{V} [\mu_t] = \sigma^2 \sum_{i=-p}^{+f} \theta_i^2$, on retrouve la formule de l'intervalle de confiance de l'équation 4.4 :

$$\frac{\hat{\mu}_t - \mathbb{E} [\mu_t]}{\sqrt{\mathbb{V} [\mu_t]}} = \frac{\hat{\mu}_t - \mathbb{E} [\mu_t]}{\sqrt{\sigma^2 \sum_{i=-p}^{+f} \theta_i^2}} \text{ et } \frac{\hat{\mu}_t - \mathbb{E} [\mu_t]}{\sqrt{\hat{\sigma}^2} \sqrt{\sum_{i=-p}^{+f} \theta_i^2}} \sim \mathcal{T}(\nu).$$

Le numérateur de ν se calcule facilement puisque l'on a :

$$\text{tr}(\mathbf{\Delta}) = (n - p - f) \left(1 - 2\theta_0 + \sum_{i=-p}^{+f} \theta_i^2 \right).$$

En revanche il est difficile d'avoir une formule simplifiée pour le dénominateur $\text{tr}(\mathbf{\Delta}^2)$. Ce dernier peut être calculé en reconstruisant la matrice $\mathbf{\Delta}$ (produit de matrices de taille $n \times n$) ou, comme proposé dans cet article, par le produit d'une matrice de taille $1 \times (p + f + 1)$ et d'une matrice de taille $(p + f + 1) \times (p + f + 1)$ pour réduire le temps de calcul (annexe 4.5.2) :

$$\text{tr}(\mathbf{\Delta}^2) = (n - (p + f))L_0^2 + 2 \sum_{k=1}^{p+f} (n - (p + f) - k)L_k^2$$

où $L_0, \dots, L_{p+f}$ sont définis par :

$$(w_{-p} \quad \dots \quad w_f) \begin{pmatrix} w_{-p} & 0 & 0 & \dots & 0 \\ w_{-p+1} & w_{-p} & 0 & \ddots & \vdots \\ w_{-p+2} & w_{-p+1} & w_{-p} & \ddots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ w_f & w_{f-1} & w_{f-2} & \ddots & w_{-p} \end{pmatrix} = (L_0 \quad \dots \quad L_{p+f})$$

avec $\mathbf{w} = (w_{-p}, \dots, w_f)$ la moyenne mobile telle que $w_0 = 1 - \theta_0$ et $w_i = -\theta_i$ pour $i \neq 0$. C'est la méthode de calcul utilisée par défaut dans `rjd3filters`. Le calcul de ν peut aussi être approximé par $\text{tr}(\Delta)$ (`rjd3filters::confint_filter(exact_df = FALSE)`) ce qui permet de réduire davantage le temps de calcul⁷.

Remarque. Lorsque l'estimation de la tendance-cycle est basée sur des moyennes mobiles construites à l'aide d'un régresseur externe (section 4.2.3), les formules ici présentées ne sont pas applicables puisque des moyennes mobiles différentes sont utilisées pour l'estimation finale. Pour la construction d'intervalles de confiance, le plus simple est alors de reconstruire la matrice $\mathbf{H}$. Pour les estimations récentes, lorsque des moyennes mobiles asymétriques sont utilisées, le calcul des intervalles de confiance nécessite la création d'une matrice $\mathbf{H}$ fictive (qui correspondrait à la matrice utilisée si toutes les estimations étaient faites avec une moyenne mobile asymétrique). Toutefois, lorsque plusieurs *outliers* consécutifs sont utilisés dans le passé, la construction d'une moyenne mobile asymétrique robuste n'est pas toujours possible : dans ce cas il est possible d'utiliser par défaut la moyenne mobile asymétrique linéaire de référence (ce qui a pour effet d'augmenter la variance estimée). C'est l'approche implémentée dans `rjd3filters`.

Remarque. La matrice $\mathbf{H}$ pourrait également être construite en complétant les p premières et f dernières lignes par les moyennes mobiles asymétriques utilisées. Toutefois, puisque les modèles sous-jacents aux moyennes mobiles asymétriques sont différents de ceux des moyennes mobiles symétriques (par exemple Musgrave modélise une tendance de degré 1 alors que Henderson modélise une tendance de degré 3), on peut supposer les variances différentes pour chaque moyenne mobile et estimer celles associées aux moyennes mobiles asymétriques en utilisant l'ensemble des données. C'est l'approche implémentée dans `rjd3filters`.

7. Sur une série mensuelle de 19 ans ($n = 228$), en utilisant la moyenne mobile de Henderson de 13 termes ($p = f = 6$), le temps de calcul ν est d'en moyenne 0,11 seconde (sur 1 000 évaluations). Il est divisé d'environ 350 en utilisant la formule proposée dans cet article (environ 0,31 milliseconde) et d'environ 5 800 en utilisant l'approximation $\nu \simeq \text{tr}(\Delta)$ (environ 0,02 milliseconde).


4.3 Résultats

Les différentes méthodes sont tout d'abord comparées sur des séries simulées (choc de 10 %, tendance de degré 0, 1 ou 2, section 4.3.1) puis sur des séries réelles (section 4.3.2).

4.3.1 Séries simulées

Afin d'illustrer les performances des différentes méthodes, les estimations sont comparées sur des séries simulées dans un cas extrême : lorsque l'irrégulier est nul. Trois tendances sont simulées, de degré 0, 1 ou 2, et un choc positif de 10 % est introduit en janvier 2022 : soit un choc ponctuel (*additive outlier*, affectant l'irrégulier) soit un choc permanent (*level shift*, affectant la tendance-cycle). Les séries simulées commencent en janvier 2018, soit 4 ans avant le choc afin de limiter l'impact des points atypiques sur le calcul des intervalles de confiance (puisque l'irrégulier est nul, l'intervalle de confiance est également nul avant l'introduction du choc). La figure 4.1 montre les différentes séries simulées.

FIGURE 4.1 – Séries simulées avec un choc ponctuel (*additive outlier*, AO) ou permanent (*level shift*, LS) en janvier 2022



Pour les chocs ponctuels (*additive outlier*, AO), lorsque la tendance est de degré 0, aucune des méthodes robustes n'est influencée par la présence de l'AO, tout comme la moyenne mobile de Henderson robuste (figure 4.2). Les estimations avec les moyennes mobiles de Henderson et CLF sont biaisées avec des révisions importantes à la date du choc, légèrement plus petites pour la méthode CLF. L'analyse des intervalles de confiance valident clairement la présence du point atypique (figure 4.3).


Lorsque la tendance est de degré 1 les résultats sont similaires sauf pour la médiane mobile qui sous-estime la tendance pour les estimations intermédiaires (figures 4.4 et 4.5). Comme notamment indiqué par Gather et alii (2006), cela suggère d'utiliser

des quantiles plus élevés que la médiane pour les estimations en temps réel avec les méthodes robustes. Un léger biais négatif s’observe pour la méthode de Henderson robuste : cela provient du fait que pour la création de ces moyennes mobiles la pente est fixé (ratio δ_1/σ fixé et σ a priori fixé) à une valeur différente de la pente simulée. Cela suggère de préférer une paramétrisation locale de ce paramètre, comme proposé par Quartier-la-Tente (2024b)⁸.

Lorsque la tendance est de degré 2, les résultats avec les moyennes mobiles sont similaires (révisions importantes autour du choc pour Henderson et CLF et faibles pour Henderson robuste, figures 4.6 et 4.7). Pour les méthodes robustes, les estimations finales reproduisent bien le retournement de tendance malgré le fait qu’elles ne modélisent qu’une tendance de degré 1. Pour les estimations en temps réel, les tendances sont surestimées mais les révisions faibles : cela s’explique par le faible degré de courbure de la série simulée et pourraient être minimisées en modélisant des tendances de degré supérieur (voir annexe 4.5.4 pour les résultats avec les méthodes LMS et LTS).

8. C’est ce qui a été implémenté dans la fonction `publishTC::henderson_robust_smoothing(local_icr = TRUE)`.

FIGURE 4.2 – Estimations en temps réel de la tendance-cycle pour une série simulée avec une tendance de degré 0 et un choc ponctuel (*additive outlier*, AO) en janvier 2022



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.3 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes pour une série simulée avec une tendance de degré 0 et un choc ponctuel (*additive outlier*, AO) en janvier 2022





FIGURE 4.4 – Estimations en temps réel de la tendance-cycle pour une série simulée avec une tendance de degré 1 et un choc ponctuel (*additive outlier*, AO) en janvier 2022



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.5 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes pour une série simulée avec une tendance de degré 1 et un choc ponctuel (*additive outlier*, AO) en janvier 2022






FIGURE 4.6 – Estimations en temps réel de la tendance-cycle pour une série simulée avec une tendance de degré 2 et un choc ponctuel (*additive outlier*, AO) en janvier 2022



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.7 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes pour une série simulée avec une tendance de degré 1 et un choc ponctuel (*additive outlier*, AO) en janvier 2022




Pour les chocs permanents (*level shift*, LS), à l'exception de la régression profonde (DR) et de la régression médiane répétée (RM), les estimations finales de la tendance-cycle avec les méthodes robustes ne sont pas influencées par la présence du choc (figures 4.8, 4.10 et 4.12). En revanche, aucune des estimations intermédiaires ne prend en compte le changement de niveau à la bonne date : il faut attendre l'estimation de juin 2022 pour que le changement de niveau soit pris en compte à la bonne date pour la méthode LQD et juillet 2022 (soit l'estimation finale) pour les autres méthodes, même lorsque la tendance est de degré 0. Modéliser, dans ces méthodes, une tendance de degré 2 ne change pas ce résultat (annexe 4.5.4). Cela suggère encore d'utiliser des quantiles plus élevés que la médiane pour les estimations en temps réel.

Les moyennes mobiles linéaires classiques (Henderson et CLF) donnent des résultats similaires : la rupture en niveau est lissée, les points avant le choc sont donc surestimés et ceux après le choc sous-estimés. Il y a également d'importantes révisions pour la première estimation de janvier 2022 (date du choc). Il n'y a en revanche quasiment aucune révision pour les moyennes mobile de Henderson robuste à un choc permanent en janvier 2022.

Les intervalles de confiance des estimations de la moyenne mobile de Henderson sont comparés à la moyenne mobile de Henderson robuste à un choc permanent en janvier 2022 ou à un choc ponctuel en janvier et février 2022 (figures 4.9, 4.11 et 4.13). Cela permet de simuler le cas où on ne sait pas, en temps réel, trancher sur la nature du choc : soit un choc permanent, soit un choc ponctuel (lorsque l'on se place en janvier 2022), soit deux chocs ponctuels (lorsque l'on se place en février 2022). En mars 2022, l'observation de trois chocs de même ampleur confirme qu'il s'agit d'un choc permanent et non ponctuel. Si l'on s'est trompé dans la nature du choc, jusqu'en février 2022

les révisions sont nulles pour les estimations avant le choc mais importantes pour celles après (janvier et février, puisque le choc est affecté à l'irrégulier et non pas à la tendance-cycle).

FIGURE 4.8 – Estimations en temps réel de la tendance-cycle pour une série simulée avec une tendance de degré 0 et un choc permanent (*level shift*, LS) en janvier 2022



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.9 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes pour une série simulée avec une tendance de degré 0 et un choc permanent (*level shift*, LS) en janvier 2022





FIGURE 4.10 – Estimations en temps réel de la tendance-cycle pour une série simulée avec une tendance de degré 1 et un choc permanent (*level shift*, LS) en janvier 2022



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.11 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robuste robuste pour une série simulée avec une tendance de degré 1 et un choc permanent (*level shift*, LS) en janvier 2022






FIGURE 4.12 – Estimations en temps réel de la tendance-cycle pour une série simulée avec une tendance de degré 2 et un choc permanent (*level shift*, LS) en janvier 2022



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.13 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robuste robuste pour une série simulée avec une tendance de degré 2 et un choc permanent (*level shift*, LS) en janvier 2022



4.3.2 Séries réelles

Puisque les résultats sont similaires à ceux sur les données simulées, les performances des différentes méthodes sur des séries réelles lors d'un choc ponctuel (AO) et d'un choc permanent (LS) sont données dans l'annexe 4.5.3 : les moyennes mobiles classiques (Henderson/Musgrave et CLF) donnent de fortes révisions autour des chocs et ces révisions sont faibles avec les moyennes mobiles robustes. Contrairement aux données simulées, sur les données réelles, même lorsque la tendance semble être linéaire, les estimations intermédiaires issues des méthodes robustes peuvent être très erratiques, conduisant à des estimations parfois peu plausibles et des révisions importantes.

Dans cette section, nous nous concentrerons sur l'illustration d'autres cas :


- Un choc ponctuel suivi d'un choc permanent (section 4.3.2.1) à partir de l'analyse des immatriculations de voitures particulières neuves, corrigée des variations saisonnières (CVS) et des jours ouvrables (CJO), publiée par l'Insee (série [010756763](#) téléchargée en octobre 2024). Le choc ponctuel s'observe en août 2018, suivi d'un choc permanent en septembre 2018.
- La crise financière de 2008 (section 4.3.2.2) à partir des ventes au détail et services de restauration aux États-Unis. Les données issues de la base FRED-MD (McCracken et Ng 2016) contenant des séries économiques sur les États-Unis⁹ (série RETAILx). Pour cette série la crise financière de 2008 peut s'étudier comme deux chocs permanents consécutifs en octobre et novembre 2008.

9. Les séries étudiées correspondent à la base publiée en novembre 2022.

- La crise du COVID-19 (section 4.3.2.3) à partir l'indice de la production industrielle (IPI) dans l'industrie manufacturière CVS-CJO, publié par l'Insee (série 010768307 publiée le 04 octobre 2024). Deux autres exemples sont donnés dans l'annexe 4.5.3.
- Un point de retournement qui n'est pas associé à un choc (section 4.3.2.4) à partir du niveau d'emploi aux États-Unis (série CE160V de la base FRED-MD). Un autre exemple est donné dans l'annexe 4.5.3.

Toutes ces séries sont représentées dans la figure 4.14.

FIGURE 4.14 – Séries des immatriculations de voitures particulières neuves en France, ventes au détail et services de restauration aux États-Unis, IPI dans l'industrie manufacturière en France et niveau d'emploi aux États-Unis




4.3.2.1 Choc ponctuel (AO) suivi d'un choc permanent (LS)

L'entrée en vigueur de la procédure d'essai mondiale harmonisée pour les véhicules légers (*Worldwide harmonized Light vehicles Test Procedures*, WLTP) en septembre 2018 a eu pour effet une forte hausse des immatriculations de voitures particulières neuves en août 2018 (choc ponctuel), les constructeurs ayant déstocké des modèles qui n'étaient plus autorisés à la vente à partir de cette date. À partir du mois de septembre, le niveau des immatriculations était plus faible par contre-coup de la hausse du mois d'août. Même si ce choc en niveau semble temporaire sur 5 mois (retour au niveau de juillet 2018 à partir de février), il est, par simplification, modélisé dans la construction des moyennes mobiles robustes comme un choc permanent.

Les méthodes robustes ne sont pas affectées par le choc ponctuel mais ne reproduisent pas le changement de niveau à la bonne date (figure 4.15). Les moyennes mobiles linéaires de Henderson et CLF ont des résultats similaires : fortes révisions en août 2018, un point de retournement détecté en avance (juillet 2018). Les moyennes mobiles robustes conduisent à peu de révisions autour des chocs. Lorsque l'on ne modélise que


le choc ponctuel d'août (figure 4.16) un point de retournement est détecté en mars 2018, ce qui paraît peu plausible.

FIGURE 4.15 – Estimations en temps réel de la tendance-cycle des immatriculations de voitures particulières neuves à partir d'août 2018



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.


FIGURE 4.16 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour les immatriculations de voitures particulières neuves à partir d'août 2018



4.3.2.2 Crise financière de 2008 (deux chocs permanents consécutifs)


La crise financière de 2008 est illustrée à partir des ventes au détail et services de restauration. Sur cette série, on observe deux chocs consécutifs en niveau : en octobre et en novembre 2008. Seules deux méthodes robustes (médiane mobile et LMS) reproduisent ces chocs dans les estimations finales (figure 4.17) ; certaines estimations intermédiaires sont éloignées des estimations finales (par exemple pour les médianes mobiles ou les points de décembre 2008 et janvier 2009 RM, LMS, LTS et LQD) ce qui conduit à des révisions importantes. Les moyennes mobiles linéaires donnent des estimations avec relativement peu de révisions (en particulier pour les moyennes mobiles robustes) mais le retournement conjoncturel est détecté trop tôt pour Henderson et CLF. En temps-réel, si l'on ne sait pas que ce sont des chocs permanents, les chocs peuvent être modélisés comme deux chocs ponctuels dont on attribuerait l'effet à la tendance-cycle. Cette modélisation conduit à des révisions importantes entre novembre et décembre 2008 (figure 4.18). En mars 2009 (où l'on se doute que les chocs sont permanents et non ponctuels), l'utilisation de cette mauvaise spécifications donnent des estimations de la tendance-cycle proches des moyennes mobiles de Henderson avant octobre 2008 (avec un point de retournement qui est donc détecté trop tôt) et proches des moyennes mobiles robustes à deux chocs permanents après octobre 2008.

FIGURE 4.17 – Estimations en temps réel de la tendance-cycle des ventes au détail et services de restauration aux États-Unis à partir d’octobre 2008



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.18 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour les ventes au détail et services de restauration aux États-Unis à partir d'octobre 2008



4.3.2.3 COVID-19


Le COVID-19 est illustré sur l'indice de la production industrielle (IPI) CVS-CJO dans l'industrie manufacturière. Sur cette série, on observe deux chocs négatifs en mars et avril 2020, suivis d'une remontée progressive jusqu'en juillet 2020 vers un niveau légèrement inférieur à celui d'avant crise. Pour cette période, il est attendu de l'estimation finale de la tendance-cycle qu'elle permette de détecter les deux points de retournement en février 2020 (pic) et avril 2020 (creux). Les méthodes robustes peinent à reproduire ces retournements : les estimations finales sont robustes aux chocs, les révisions sont importantes et les retournement conjoncturels détectés semblent plutôt provenir des périodes post-chocs, ce qui conduit à détecter les points de retournement avec décalage (figure 4.19) Les moyennes mobiles de Henderson et CLF conduisent, encore une fois, à détecter les points de retournement avec un décalage ; les révisions sont importantes autour des chocs (mars, mai et juin) et plus faibles pour les autres mois.

Pour la construction des moyennes mobiles robustes, même si l'on pourrait construire des régresseurs spécifiques, il a ici été choisi de rester sur la modélisation de chocs ponctuels et permanents ce qui permet de garder une approche simple et plus facilement généralisable à d'autres cas. La figure 4.20 compare les estimations des moyennes mobiles robustes construites en modélisant deux chocs ponctuels consécutifs (dont on attribuerait l'effet à la tendance-cycle plutôt qu'à l'irrégulier), deux chocs permanents consécutifs ou un choc ponctuel suivi d'un choc permanent. La modélisation de deux chocs permanents consécutifs en mars et avril 2020 permet de détecter les points

de retournement aux bonnes dates, la reprise de la production en mai est détecté dès la première estimation. Ce n'est pas le cas de la modélisation par deux chocs ponctuels consécutifs : il faut attendre les estimations de juin 2020 pour reproduire le creux d'avril (les estimations de mai et juin donne une baisse entre avril et mai) et le pic de février n'est pas conservé. La modélisation d'un choc ponctuel suivi d'un choc permanent permet bien de tracer le pic d'avril et le creux d'avril mais un pic indésirable est créé en juin 2020. C'est donc la modélisation par deux chocs permanents consécutifs qui donne ici les meilleurs résultats.


D'autres exemples sont donnés dans l'annexe 4.5.3.3.

FIGURE 4.19 – Estimations en temps réel de la tendance-cycle de l'IPI CVS-CJO dans l'industrie manufacturière à partir de mars 2020



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.


FIGURE 4.20 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour l'IPI dans l'industrie manufacturière à partir de mars 2020



4.3.2.4 Points de retournement


Un point de retournement, non associé à un choc, est illustré à partir du niveau d'emploi aux États-Unis autour de février 2001. Parmi les méthodes robustes, seule la régression profonde (DR) permet de détecter le point de retournement à la bonne date (à partir des estimations de juin 2021, figure 4.21) : les médianes mobiles (MED) et les médianes répétées (RM) ne détectent aucun point de retournement et les autres méthodes le détectent en janvier 2001 (à partir des estimations de juillet 2001, pour les estimations antérieures il est bien détecté en février). En revanche, modéliser une tendance locale de degré 2 permet de détecter le point de retournement à la bonne date (annexe 4.5.4) Les révisions sont plus faibles pour les estimations issues de moyennes mobiles et le fait de considérer à tort le mois de février comme un choc ponctuel n'a pas d'impact sur les estimations. Les estimations issues des moyennes mobiles robustes restent dans l'intervalle de confiance des estimations des moyennes mobiles de Henderson (figure 4.22).

FIGURE 4.21 – Estimations en temps réel de la tendance-cycle de l'emploi aux États-Unis à partir de février 2001



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.22 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour l’emploi aux États-Unis à partir de février 2001



4.4 Conclusion

En conclusion, cette étude montre comment, à partir des moyennes mobiles de Henderson et de Musgrave (répandues pour l’extraction de la tendance-cycle) il est possible d’ajouter des régresseurs externe pour construire des moyennes mobiles avec une meilleure décomposition tendance-cycle et irrégulier. Cela permet notamment de modéliser des chocs ponctuels (dont l’effet est généralement associé à l’irrégulier) et des chocs permanents (dont l’effet est associé à la tendance-cycle).

Les moyennes mobiles linéaires classiques (Henderson, Musgrave, *cascade linear filter*...) vont naturellement conduire à des estimations biaisées : lors d’un choc permanent positif, la rupture va être lissée et la tendance-cycle va être surestimée avant le choc et sous-estimée après le choc ; lors d’un choc ponctuel (dont l’effet est attribué à l’irrégulier), la tendance-cycle va être sur ou sous-estimée autour du choc (en fonction du signe du choc). Cela va également mener à de fortes révisions des estimations autour des chocs. Lorsqu’un choc est associé à un point de retournement de l’économie (par exemple lors de la crise financière de 2008 ou lors de la pandémie du COVID-19), les estimations de la tendance-cycle vont conduire à un décalage dans la détection des points de retournement (contraction détectée en avance et reprise en retard), ce qui peut perturber l’utilisateur lors de l’analyse de ces séries. À l’inverse, la construction de moyennes mobiles robustes permet de minimiser les révisions des chocs et de bien détecter les points de retournement. La comparaison entre moyennes mobiles robustes et classiques, à l’aide de la construction d’intervalles de confiance et d’une analyse

économique, permet de valider la modélisation retenue. De plus, lorsque aucun choc n'est observé, l'utilisation à tort d'une moyenne mobile robuste donnera des résultats très proches des moyennes mobiles classiques et ne dégrade donc pas les résultats. En revanche, lors de l'estimation en temps réel, le choix d'une mauvaise spécification (par exemple choc ponctuel, affecté à l'irrégulier, plutôt que choc permanent, affecté à la tendance-cycle) peut entraîner des révisions importantes lorsque la bonne spécification est finalement retenue. Pour minimiser les révisions, en cas de doute sur la nature du choc il est donc préférable d'utiliser les moyennes mobiles linéaires classiques avant d'être sûr de la spécification à adopter.

Afin d'éviter le biais lié à la présence de points atypiques, le logiciel de désaisonnalisation X-13ARIMA-SEATS (où sont notamment utilisées les moyennes mobiles de Henderson et de Musgrave) possède plusieurs modules de correction des chocs : la série est d'abord pré-correctée et les chocs sont à la fin réintroduit dans la bonne composante (saisonnalité, tendance-cycle ou irrégulier). Toutefois, les rares instituts qui publient des estimations de la tendance-cycle (comme Statistique Canada et l'Australian Bureau of Statistics) ne semblent pas utiliser le logiciel X-13ARIMA-SEATS pour l'estimation de cette composante et appliquent plutôt une moyenne mobile sur la série désaisonnalisées. Cela peut par exemple s'expliquer lorsque ce ne sont pas les mêmes équipes qui effectuent la désaisonnalisation et l'estimation de la tendance-cycle ou pour simplifier le processus. Même si ces modules de corrections peuvent être appliqués sur les séries désaisonnalisées (par exemple via un modèle RegARIMA), l'estimation de l'ampleur du choc dépend du modèle utilisé et de la période d'estimation retenue, ce qui augmente le risque de mauvaise spécification et l'incertitude autour des estimations. À l'inverse, l'approche proposée dans cet article garde les mêmes spécifications que celle des moyennes mobiles de Henderson et de Musgrave et, par construction, le nombre de périodes révisées ne dépend que de la longueur de la moyenne mobile.

Dans cette étude, les performances des moyennes mobiles linéaires sont également comparées à des méthodes non-linéaires robustes pour la plupart basées sur la médiane. Lorsque les tendances sont lisses et le bruit faible (par exemple sur des séries simulées), ces méthodes fournissent des bonnes alternatives aux méthodes classiques en étant robustes aux chocs ponctuels et en reproduisant, dans la tendance-cycle, les chocs permanents (mais pour qu'ils soient reproduits à la bonne date il faut attendre l'estimation finale). Toutefois, sur des séries réelles, les révisions sont plus importantes (avec parfois des estimations intermédiaires non cohérentes), ce qui suggère, comme notamment indiqué par Gather et alii (2006), d'utiliser des quantiles plus élevés que la médiane pour les estimations en temps réel. Par ailleurs, lorsque les points de retournement sont associés à des chocs (comme lors du COVID-19), en étant naturellement robustes aux chocs, ces méthodes ne vont pas permettre d'estimer une tendance-cycle qui reproduirait les points de retournement.

En somme, pour l'analyse de la conjoncture et des points de retournement, l'utilisation de méthodes linéaires locales (telles que des moyennes mobiles) est à privilégier. Afin de

mieux représenter la réalité économique et de minimiser les révisions, il est important d'avoir une analyse locale par série : en analysant les chocs et en les prenant en compte dans la construction des moyennes mobiles comme proposé dans cette étude ; ou encore en fixant localement les hyperparamètres utilisés dans les moyennes mobiles asymétriques (lorsque l'on ne possède pas assez de point dans le futur pour utiliser une moyenne mobile symétrique), comme suggéré par Quartier-la-Tente (2024b), pour réduire les révisions en évitant des biais systématiques lorsque la tendance est localement linéaire (par exemple reprise d'activité progressive après un choc). Toutefois, pour la production de données, il peut être difficile d'avoir le temps d'analyser chaque série pour déterminer les chocs. Il peut alors être intéressant d'étudier des procédures automatiques pour identifier ces chocs, par exemple via des modèles *ad hoc* (du type modèles RegARIMA) ou bien en reproduisant le processus de lissage des moyennes mobiles par une modélisation plus générale (par exemple modélisation espace-état).

4.5 Annexes

4.5.1 Moyennes mobiles utilisées

FIGURE 4.23 – Moyennes mobiles de Henderson et de Musgrave ($R = 3, 5$)




FIGURE 4.24 – Cascade linear filter (CLF) et *Asymmetric Linear Filter* (ALF) ou méthode « couper-et-normaliser »




FIGURE 4.25 – Moyennes mobiles de Henderson et de Musgrave ($R = 3, 5$) robustes à la présence d'un choc ponctuel (AO) à la dernière date




FIGURE 4.26 – Moyennes mobiles de Henderson et de Musgrave ($R = 3, 5$) à un choc ponctuel (AO) suivi d'un choc permanent (LS) à la dernière date





FIGURE 4.27 – Moyennes mobiles de Henderson et de Musgrave d'un ou deux chocs permanents (LS) présents à la dernière date (ou deux dernières dates)



4.5.2 Calcul du degré de liberté de la variance

Soient $\theta = (\theta_{-p}, \dots, \theta_f)$ et $\Delta = {}^t(I - H)(I - H)$ avec :

$$H = \begin{pmatrix} \mathbf{0}_{p \times n} & & & & & \\ \theta_{-p} & \cdots & \theta_f & 0 & \cdots & \\ 0 & \theta_{-p} & \cdots & \theta_f & 0 & \cdots \\ & \ddots & & & \ddots & \\ 0 & \cdots & 0 & \theta_{-p} & \cdots & \theta_f \\ \mathbf{0}_{f \times n} & & & & & \end{pmatrix} \text{ et } I = \begin{pmatrix} \mathbf{0}_{p \times n} & \mathbf{0}_{p \times n} & \mathbf{0}_{(n-p-f) \times f} \\ \mathbf{0}_{(n-p-f) \times p} & \mathbf{I}_{n-p-f} & \mathbf{0}_{(n-p-f) \times f} \\ \mathbf{0}_{f \times n} & \mathbf{0}_{f \times n} & \mathbf{I}_f \end{pmatrix},$$

où $\mathbf{0}_{p \times n}$ est la matrice de taille $p \times n$ ne contenant que de zéros et $\mathbf{I}_{n-p-f}$ la matrice identité de taille $n - p - f$.

L'objectif de cette annexe est de montrer que le calcul de $\text{tr}(\Delta^2)$ peut se simplifier par le produit d'une matrice de taille $1 \times (p + f + 1)$ et d'une matrice de taille $(p + f + 1) \times (p + f + 1)$, ce qui permet de réduire le temps de calcul du degré de liberté de la loi de Student utilisée pour la construction d'intervalles de confiance :

$$\text{tr}(\Delta^2) = (n - (p + f))L_0^2 + 2 \sum_{k=1}^{p+f} (n - (p + f) - k)L_k^2$$

où $L_0, \dots, L_{p+f}$ sont définis par :

$$(w_{-p} \quad \dots \quad w_f) \begin{pmatrix} w_{-p} & 0 & 0 & \dots & 0 \\ w_{-p+1} & w_{-p} & 0 & \ddots & \vdots \\ w_{-p+2} & w_{-p+1} & w_{-p} & \ddots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ w_f & w_{f-1} & w_{f-2} & \ddots & w_{-p} \end{pmatrix} = (L_0 \quad \dots \quad L_{p+f})$$

avec $\mathbf{w} = (w_{-p}, \dots, w_f)$ la moyenne mobile telle que $w_i = \mathbf{1}_{i=0} - \theta_i$.

Soient $i, j \in \{1, \dots, n\}$, posons par convention $w_i = 0$ pour $i \notin [-p, f]$. Notons $\mathbf{\Gamma} = \mathbf{I} - \mathbf{H}$. On a $\mathbf{H}_{i,j} = \theta_{i-j} \mathbf{1}_{i \in [p+1, n-f]}$ et donc $\mathbf{\Gamma}_{i,j} = w_{i-j} \mathbf{1}_{i \in [p+1, n-f]}$ et ensuite :

$$\begin{aligned} (\mathbf{t}\mathbf{\Gamma})_{i,j} &= \sum_{k=1}^n \mathbf{\Gamma}_{k,i} \mathbf{\Gamma}_{k,j} = \sum_{k=1}^n w_{k-i} w_{k-j} \mathbf{1}_{(i,j) \in [p+1, n-f]^2} \\ &= \sum_{k=-p}^f w_k w_{i-j+k} \mathbf{1}_{(i,j) \in [p+1, n-f]^2}. \end{aligned}$$

Puis :

$$\begin{aligned} ((\mathbf{t}\mathbf{\Gamma})^2)_{i,i} &= \sum_{j=1}^n (\mathbf{t}\mathbf{\Gamma})_{i,j} (\mathbf{t}\mathbf{\Gamma})_{j,i} \\ &= \sum_{j=1}^n (\mathbf{t}\mathbf{\Gamma})_{i,j}^2 \text{ car la matrice } \mathbf{t}\mathbf{\Gamma} \text{ est symétrique} \\ &= \sum_{j=1}^n \left(\sum_{k=-p}^f w_k w_{i-j+k} \mathbf{1}_{(i,j) \in [p+1, n-f]^2} \right)^2 \\ &= \sum_{j=p}^{n-f} \left(\sum_{k=-p}^f w_k w_{i-j+k} \right)^2 \mathbf{1}_{i \in [p+1, n-f]}. \end{aligned}$$

Donc $((\mathbf{t}\mathbf{\Gamma})^2)_{i,i} = 0$ si $i \notin [p+1, n-f]$. Pour $i \in [p+1, n-f]$, comme pour tout $k \in [-p, f]$ on a $w_{i-j+k} = 0$ si $j < i - (f+p)$ ou si $j > i - (f+p)$, il vient :

$$\begin{aligned} ((\mathbf{t}\mathbf{\Gamma})^2)_{i,i} &= \sum_{j=\max(i-(f+p), 1)}^{\min(i+(f+p), n)} \left(\sum_{k=-p}^f w_k w_{i-j+k} \right)^2 \\ &= \sum_{j=-(f+p)}^{f+p} \left(\sum_{k=-p}^f w_k w_{k-j} \right)^2 \mathbf{1}_{j \in [1-i, n-i]} \\ &= \sum_{j=-(f+p)}^{f+p} (L_{|j|})^2 \mathbf{1}_{j \in [1-i, n-i]} \text{ par symétrie autour de 0.} \end{aligned}$$

En somme :

$$\begin{aligned}
\text{tr}(\Delta^2) &= \sum_{i=p}^{n-f} \sum_{j=-(f+p)}^{f+p} \left(L_{|j|} \right)^2 \mathbb{1}_{j \in [1-i, n-i]} \\
&= (n - (p + f))L_0^2 + 2(n - (p + f) - 1)L_1^2 + 2(n - (p + f) - 2)L_2^2 + \\
&\quad \cdots + 2(n - 2(p + f))L_{p+f}^2 \\
&= (n - (p + f))L_0^2 + 2 \sum_{k=1}^{p+f} (n - (p + f) - k)L_k^2.
\end{aligned}$$

Cette optimisation computationnelle a ensuite été implémentée dans la fonction `rjd3filters::confint_filter()`.

4.5.3 Autres exemples sur des séries réelles

4.5.3.1 Chocs ponctuels (*additive outlier*, AO)

Les chocs ponctuels (*additive outlier*, AO) sont illustrés sur l'indice de la production industrielle (IPI) dans la construction de véhicules automobiles, corrigé des variations saisonnières (CVS) et des jours ouvrables (CJO), publié par l'Insee (série [010768140](#) publiée le 04 octobre 2024). Trois chocs ponctuels s'observent clairement sur les mois d'août de 1998, 1999 et 2004 (figure 4.28).

FIGURE 4.28 – IPI CVS-CJO dans la construction de véhicules automobiles autour des points atypiques d'août 1998, 1999 et 2004





FIGURE 4.29 – Estimations en temps réel de la tendance-cycle pour l'IPI dans la construction de véhicules automobiles à partir d'août 1998



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.30 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour l'IPI dans la construction de véhicules automobiles à partir d'août 1998





FIGURE 4.31 – Estimations en temps réel de la tendance-cycle pour l'IPI dans la construction de véhicules automobiles à partir d'août 1999



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.32 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour l'IPI dans la construction de véhicules automobiles à partir d'août 1999






FIGURE 4.33 – Estimations en temps réel de la tendance-cycle pour l'IPI dans la construction de véhicules automobiles à partir d'août 2004



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.34 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour l'IPI dans la construction de véhicules automobiles à partir d'août 2004



4.5.3.2 Choc permanent (*level shift*, LS)

Les chocs permanents (*level shift*, LS) sont illustrés sur l'indice de la production industrielle (IPI) dans l'extraction de pétrole brut, corrigé des variations saisonnières (CVS) et des jours ouvrables (CJO), publié par l'Insee (série [010767578](#)) le 04 octobre 2024 (données alors disponibles jusqu'en août 2024). Un choc permanent s'observe en juin 2010. Pour la construction des intervalles de confiance, la série est tronquée pour ne prendre que les valeurs après janvier 2001 avant d'éviter que le début de la série, dont le profil est assez différent de celui sur la fin de la série, n'augmente l'estimation de la variance de l'irrégulier.

FIGURE 4.35 – IPI CVS-CJO dans l'extraction de pétrole brut autour du choc permanent de juin 2010






FIGURE 4.36 – Estimations en temps réel de la tendance-cycle pour l'IPI dans l'extraction de pétrole brut à partir de juin 2010



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.37 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour l'IPI dans l'extraction de pétrole brut à partir de juin 2010



4.5.3.3 COVID-19

Deux autres exemples de l'estimation de la tendance-cycle pendant le COVID-19 sont données à partir du niveau d'emploi (série CE160V) et des ventes au détail et services de restauration (série RETAILx) aux États-Unis, séries issues de la base FRED-MD. Les points de retournement officiels de la datation du National Bureau of Economic Research (NBER) sont en février et avril 2020¹⁰. Pour l'emploi le retour à la normal est progressif à partir d'avril 2020 alors qu'il est rapide pour les ventes au détail et services de restauration (figure 4.38).

Comme pour l'IPI dans l'industrie manufacturière, les méthodes robustes effacent le choc (figures 4.39 et 4.41), ce qui ne permet pas d'analyser les points de retournement. Les moyennes mobiles linéaires classiques (Henderson/Musgrave et CLF) détectent les points de retournement avec un décalage : pic en octobre 2019 et creux en avril 2020 pour les ventes au détail et services de restauration et juin 2020 pour l'emploi. Pour les moyennes mobiles robustes, le choc est modélisé par deux chocs permanents en mars et avril 2020. Les révisions sont faibles et cela permet de bien détecter les deux retournement conjoncturels contrairement aux moyennes mobiles robustes où l'on considère mars et avril 2020 comme des chocs ponctuels et associant le choc à la tendance-cycle (figures 4.40 et 4.42).

10. <https://www.nber.org/research/data/us-business-cycle-expansions-and-contractions>

FIGURE 4.38 – Emploi et ventes au détail et services de restauration aux États-Unis autour de mars 2020




FIGURE 4.39 – Emploi aux États-Unis à partir de mars 2020




FIGURE 4.40 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour l'emploi aux États-Unis à partir de mars 2020






FIGURE 4.41 – Estimations en temps réel de la tendance-cycle des ventes au détail et services de restauration aux États-Unis à partir de mars 2020



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.42 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour les ventes au détail et services de restauration aux États-Unis à partir de mars 2020



4.5.3.4 Points de retournement

Un autre exemple de point de retournement est illustré à partir des ventes au détail et services de restauration aux États-Unis (série **RETAILx** de la base FRED-MD) autour du point de retournement de novembre 2007.

FIGURE 4.43 – Ventes au détail et services de restauration aux États-Unis autour du point de retournement de novembre 2007






FIGURE 4.44 – Estimations en temps réel de la tendance-cycle des ventes au détail et services de restauration aux États-Unis à partir de novembre 2007



Note : Henderson : Henderson (estimation finale) et Musgrave (estimations intermédiaires) ; Henderson robuste : moyennes mobiles robustes de Henderson (estimation finale) et de Musgrave (estimations intermédiaires) ; CLF : *cascade linear filter* (estimation finale) et méthode « couper-et-normaliser » (estimations intermédiaires) ; MED : Médiane mobile ; RM : médiane répétée ; LMS : moindres carrés médians ; LTS : moindres carrés élagués ; LQD : moindres quartiles différenciés ; DR : Régression profonde.

FIGURE 4.45 – Intervalles de confiance pour les filtres de Henderson et filtres de Henderson robustes robuste pour les ventes au détail et services de restauration aux États-Unis à partir de novembre 2007



4.5.4 Moindres carrés médians (LMS) et moindres carrés élagués (LTS) avec une tendance de degré 2

Cette annexe présente les résultats des estimations de la réimplémentation des processus d'estimations locale des moindres carrés médians (LMS, figure [4.46](#)) et moindres carrés élagués (LTS, figure [4.47](#)) avec une tendance de degré 2.

FIGURE 4.46 – Estimations en temps réel de la tendance-cycle pour la méthode des moindres carrés médians (LMS) en modélisant une tendance locale de degré 2





FIGURE 4.47 – Estimations en temps réel de la tendance-cycle pour la méthode des moindres carrés élagués (LTS) en modélisant une tendance locale de degré 2



5 Et si l'on publiait la tendance-cycle ? ¹

5.1 Introduction

Dans les instituts nationaux de statistiques, il est courant de publier des séries chronologiques corrigées des variations saisonnières (CVS) et des jours ouvrables (CJO). Cela permet aux utilisateurs d'interpréter et de comparer plus facilement les évolutions des séries au cours du temps. Les méthodes de désaisonnalisation décomposent les séries chronologiques en trois composantes : la saisonnalité (y compris les effets de calendrier), la tendance-cycle et l'irrégulier. Les effets saisonniers représentent les variations régulières dans les données qui se manifestent durant le même mois ou le même trimestre chaque année ; la tendance-cycle représente la tendance de court-terme, c'est-à-dire l'estimation conjointe de la tendance de long-terme et des variations, de court-terme, du cycle conjoncturel ; l'irrégulier représente les fluctuations inattendues qui ne font pas partie des composantes précédentes (grèves, conditions météorologiques inhabituelles, erreurs de mesures liées à l'échantillonnage...). Par construction, la désaisonnalisation n'élimine donc pas l'effet des événements irrégulier : lorsque celui-ci est important, il se peut donc que la série CVS-CJO ne soit pas lisse ou soit difficile à analyser.

Le calcul et la publication de la tendance-cycle présente plusieurs avantages. pour enrichir l'analyse de la conjoncture économique, notamment une meilleure lecture du cycle conjoncturel classique (également appelé cycle des affaires) et des points de retournement associés² (Fonds monétaire international 2017, Menezes et alii 2006, Huot et Chhab 1989, Australian Bureau of Statistics 2001). En estimant la tendance de court-terme (tendance de long terme plus cycle conjoncturel) C'est également la composante à privilégier pour effectuer des prévisions à long-terme. Pourtant, seuls quelques instituts statistiques, comme Statistique Canada ou l'Australian Bureau of Statistics (ABS), diffusent régulièrement cette composante.

1. Références de l'article : Quartier-la-Tente, A. (2025). Et si l'on publiait la tendance-cycle ? *XVèmes Journées de Méthodologie Statistique de l'Insee*. <https://github.com/AQLT/publishTC.wp>

2. On parle de point de retournement lorsque l'on passe d'une phase de récession (diminutions successives) à une phase d'expansion de l'économie (augmentations successives), ou d'une phase d'expansion à une phase de récession.

Cette étude explique l'intérêt de publier la composante tendance-cycle et les recommandations pour le faire. Elle présente également les méthodes, basées sur des moyennes mobiles, utilisées par Statistique Canada et l'Australian Bureau of Statistics. Elle montre comment ces méthodes peuvent être étendues pour :

- 1) Réduire le biais des estimations intermédiaires, notamment autour de points de retournement ;
- 2) Modéliser les points atypiques afin d'éviter qu'ils biaisent l'estimation de la tendance-cycle.

L'étude s'accompagne d'un *package* R, `publishTC` (<https://github.com/AQLT/publishTC>), qui facilite la mise en œuvre et la comparaison de ces méthodes. Elle explique également comment mettre en place une production automatique de cette composante, l'appliquant à une dizaine de publications de l'Insee (<https://aqlt.github.io/publishTC.wp/>).

L'ensemble des codes étant librement publié, cette étude est entièrement reproductible.

5.2 Qu'est-ce que la composante tendance-cycle, pourquoi l'estimer et la publier ?

Dans le cadre de l'analyse des séries temporelles, il est courant de supposer que la série chronologique observée, y_t , peut être décomposée en une composante saisonnalité (y.c. effets de calendrier), S_t , une composante tendance-cycle, TC_t , et une composante erratique ε_t (appelée composante irrégulière) :

$$f(y_t) = S_t + TC_t + \varepsilon_t,$$

où f désigne une transformation appropriée (généralement logarithmique ou aucune transformation). Il est courant de publier des séries corrigées des variations saisonnières (CVS) et corrigées des jours ouvrables (CJO) : les séries CVS-CJO sont donc composées de la tendance-cycle et de l'irrégulier. Pour simplifier les notations ultérieures, y_t désignera la série observée transformée et, puisque l'on s'intéresse à l'estimation de la tendance-cycle, on considérera la série désaisonnalisée ou sans saisonnalité ($S_t = 0$)³ :

$$y_t = TC_t + \varepsilon_t.$$

3. Lorsque la série contient de la saisonnalité (pas exemple dans le cadre de la désaisonnalisation), la série brute est modélisée comme une combinaison des trois composantes (saisonnalité, tendance-cycle et irrégulier) qui sont estimées simultanément.

La composante de bruit ε_t est généralement supposée être un bruit blanc. TC_t représente l'effet combiné de la tendance (variations sur une longue période) et du cycle (mouvements cycliques superposés à la tendance à long terme), estimés ici conjointement et appelé tendance-cycle TC_t . Par construction, l'estimation de la composante tendance-cycle permet faciliter l'analyse des retournements conjoncturels dans le cycle classique (également appelé cycle des affaires)⁴. On parle de point de retournement lorsque l'on passe d'une phase de récession (diminutions successives) à une phase d'expansion de l'économie (augmentations successives) : on parle alors de redressement ou, dans le cas contraire, de ralentissement. Même si plusieurs formules peuvent être utilisées pour définir ces phases, la définition de Zellner et alii (1991) est généralement utilisée, dans le cadre de l'estimation de tendance-cycle, pour déterminer les points de retournement : il y a un point de retournement à la date t lorsque $TC_{t-3} \geq TC_{t-2} \geq TC_{t-1} < TC_t \leq TC_{t+1}$ (redressement) ou $TC_{t-3} \leq TC_{t-2} \leq TC_{t-1} > TC_t \geq TC_{t+1}$ (ralentissement).

La majorité des instituts nationaux de statistique publient des séries CVS-CJO et c'est cette série qui est utilisée pour effectuer de l'analyse conjoncturelle et structurelle, effectuer des prévisions, étudier les points de retournement, etc. Toutefois, lorsque l'irrégulier est important, sa présence peut perturber l'analyse dans certains cas d'usage (comme l'analyse de la direction sous-jacente de la série ou la détection de points de retournements) : l'étude de la tendance-cycle paraît alors plus appropriée car tous les effets saisonniers et irréguliers sont éliminés de la série originale. L'Autorité statistique du Royaume-Uni (United Kingdom Statistics Authority) considérait par exemple que les utilisateurs de l'indice de ventes au détail accordaient trop d'importances aux variations mensuelles de la série CVS-CJO car en période de forte volatilité cela ne donnait pas une bonne indication de la tendance de long terme (Office for Statistics Regulation 2008).

La figure 5.1 montre le solde d'opinion CVS-CJO de la tendance prévue de la production dans l'industrie manufacturière (série 001586103), entre 2021 et 2025, publié par l'Insee en mai 2025 ainsi qu'une estimation de la tendance-cycle estimée par la moyenne mobile de Henderson de 13 termes (voir section 5.3). La série CVS-CJO est erratique et il paraît donc difficile d'analyser les évolutions du solde d'opinion et de distinguer ce qui provient ou non de l'irrégulier. La tendance-cycle est, par construction, plus lisse et la direction sous-jacente est clairement lisible.

4. On ne cherche donc pas à estimer séparément la tendance et le cycle, associée à des méthodes de filtrage de type Hodrick-Prescott ou Baxter-King, qui sont plutôt utilisées pour analyser les points de retournement dans le cycle de croissance (voir Ferrara (2009a) pour une description des différents cycles économiques). Par ailleurs, les méthodes de décomposition entre tendance et cycle nécessitent d'avoir des séries longues alors que les méthodes de lissages peuvent être appliquées sur des séries courtes.

FIGURE 5.1 – Tendence prévue de la production dans l'industrie manufacturière (solde d'opinion publié par l'Insee en mai 2025) corrigée des variations saisonnières et des jours ouvrables (CVS-CJO) et tendance-cycle (estimée par la moyenne mobile de Henderson de 13 termes).



Comme le montre cet exemple, il y a donc un intérêt à publier la tendance-cycle, en complément et non en remplacer des séries CVS-CJO, pour enrichir l'analyse de la conjoncture économique. Ainsi, la composante tendance-cycle est à privilégier pour l'analyse du cycle conjoncturel, la détection des points de retournements et les prévisions à long-terme (Fonds monétaire international [2017](#)). En particulier, par rapport à la série CVS-CJO, la tendance-cycle permet une estimation plus rapide du point de retournement mais avec le risque de détecter des faux points de retournement (Menezes et alii [2006](#)). Naturellement, l'intérêt de publier la tendance-cycle sera d'autant plus grand que la série est bruitée (i.e., l'irrégulier est important).

Pour la prévision de court terme, la série désaisonnalisée peut être privilégiée, notamment si l'analyse de l'irrégulier est importante (Australian Bureau of Statistics [2001](#)). C'est notamment le cas lorsque les évolutions de la composante irrégulières peuvent être associées à des événements économiques ou des mesures politiques et a donc un intérêt pour le conjoncturiste.

En somme, comme notamment indiqué par McLaren et Zhang ([2010](#)), les trois principales raisons de calculer et publier la tendance-cycle, en plus de la série désaisonnalisée, sont :

1. Réduire le risque que les utilisateurs tirent des conclusions inappropriées sur la base de mouvements liés à l'irrégulier.
2. Permettre une comparaison appropriée dans le temps en réduisant l'impact des événements ponctuels.

3. Améliorer la compréhension et la détection des points de retournement.

5.3 Comment estimer une tendance-cycle ?

Il existe de très nombreuses façons de modéliser et d'estimer la tendance-cycle, voir notamment Alexandrov et alii (2012) pour une revue des méthodes. Toutefois, les seuls instituts statistiques qui diffusent régulièrement cette composante (Statistique Canada et l'Australian Bureau of Statistics (ABS)), utilisent des moyennes mobiles avec une méthodologie similaire à celle utilisée dans la méthode de désaisonnalisation X-13ARIMA-SEATS.

Une *moyenne mobile* M_{θ} est un opérateur linéaire défini par un ensemble de coefficients $\theta = (\theta_{-p}, \dots, \theta_f)'$ qui transforme toute série temporelle X_t en :

$$M_{\theta}(X_t) = \sum_{k=-p}^{+f} \theta_k X_{t+k}.$$

La quantité $p + f + 1$ est appelée *ordre de la moyenne mobile*. Lorsque $p = f$ la moyenne mobile est dite *centrée*. Si de plus on a $\forall k : \theta_{-k} = \theta_k$, la moyenne mobile M_{θ} est dite *symétrique*. Dans ce cas, la quantité $p = f$ est appelée *fenêtre (bandwidth)*.

Dans cette section nous décrivons les moyennes mobiles utilisées par Statistique Canada et ABS ainsi que deux extensions possibles. Voir notamment Quartier-la-Tente (2024a) pour une description plus complète des méthodes récentes de construction de moyennes mobiles pour l'estimation de la tendance-cycle.

Dans le cadre de l'estimation par moyenne mobile, la composante tendance-cycle est estimée de manière locale. Autour d'un voisinage h de t , cette composante peut être approximée localement par un polynôme de degré d :

$$TC_{t+i} = \sum_{j=0}^d \beta_j i^j + \xi_{t+i} \quad \forall i \in \{-h, -h+1, \dots, t+h\}$$

avec ξ_t un processus stochastique non corrélé avec ε_t représentant l'erreur d'approximation. Même si certains articles modélisent ξ_t et ε_t séparément (voir par exemple Gray et Thomson 2002), une hypothèse habituelle, est de rassembler ξ_t et ε_t ⁵. Ainsi, la tendance-cycle TC_t est considérée comme déterministe et modélisée localement comme une tendance polynomiale de degré d . Les coefficients $(\beta_0, \dots, \beta_d)$ peuvent être estimés par la méthode des moindres carrés pondérés. L'estimation $\hat{\beta}_0$ fournit l'estimation de $\widehat{TC}_t$ et on peut montrer que cela équivaut à appliquer une moyenne mobile (voir

5. Cela revient à supposer que le biais d'approximation de la tendance-cycle par un polynôme local est nul.

notamment Proietti et Luati (2008). Cette moyenne mobile est généralement symétrique ($\widehat{TC}_t$ est estimée en utilisant autant d'observations avant et après t) mais pour l'estimation des derniers points (lorsque l'on ne peut pas utiliser autant d'observations avant et après t) il est nécessaire de s'appuyer sur des moyennes mobiles *ad hoc* qui sont asymétriques.

5.3.1 Moyenne mobile de Henderson et de Musgrave

Pour l'extraction de la tendance-cycle, la moyenne symétrique la plus connue est celle de Henderson (1916). Elle est notamment utilisée dans l'algorithme de désaisonnalisation X-13ARIMA-SEATS. C'est également la moyenne mobile utilisée par ABS pour obtenir l'estimation finale de la tendance-cycle (Australian Bureau of Statistics 2003). Notons h la fenêtre de la moyenne mobile d'Henderson, c'est-à-dire que pour estimer la tendance-cycle à la date t (h points avant et après t sont utilisés) : la longueur de la moyenne mobile est donc $2h + 1$. Les coefficients de la moyenne mobile d'Henderson d'ordre h sont donnés par :

$$\theta_k^H = \frac{315 [(n-1)^2 - k^2] [n^2 - k^2] [(n+1)^2 - k^2] [3n^2 - 16 - 11k^2]}{8n (n^2 - 1) (4n^2 - 1) (4n^2 - 9) (4n^2 - 25)} \text{ avec } n = h + 2.$$

Comme montré par Proietti et Luati (2008), celle-ci peut être obtenue en modélisant localement une tendance de degré 2 ($d = 2$) et en utilisant les noyaux :

$$\kappa_j = \left[1 - \frac{j^2}{(h+1)^2} \right] \left[1 - \frac{j^2}{(h+2)^2} \right] \left[1 - \frac{j^2}{(h+3)^2} \right].$$

Cette moyenne mobile étant symétrique et préservant les tendances de degré 2, elle préserve également les tendances de degré 3 et peut, de manière équivalente, être obtenue en modélisant localement une tendance de degré 3 ($d = 3$).

Dans X-13-ARIMA-SEATS, permettant de désaisonnaliser des séries qui sont au plus mensuelles, la longueur de la moyenne mobile (i.e., le paramètre h déterminant le nombre de points utilisés pour l'estimation de la tendance-cycle) est déterminée à partir de l'I/C ratio, noté R , défini par :

$$R = \frac{\bar{I}}{\bar{C}} = \frac{\sum |I_t - I_{t-1}|}{\sum |TC_t - TC_{t-1}|},$$

où I_t est l'irrégulier et TC_t la tendance-cycle. Le calcul de ce ratio nécessite de disposer d'une estimation de la tendance-cycle : en notant s la fréquence de la série ($s = 12$ pour une série mensuelle, $s = 4$ pour une série trimestrielle...), une première estimation de la tendance-cycle est effectuée à partir d'une moyenne mobile de Henderson de longueur $s + 1$ (13 termes pour une série mensuelle donc $h = 6$, 5 termes pour série trimestrielle donc $h = 2$...). La longueur retenue par X-13-ARIMA-SEATS est ensuite déterminée en fonction de la valeur du ratio R et de la fréquence de la série :

- Pour les séries trimestrielles ($s = 4$), la moyenne mobile de Henderson est de 5 termes si le ratio est petit ($R < 3,5/3$, majorité des cas) et de 7 termes sinon ;
- Pour les séries mensuelles ($s = 12$), la moyenne mobile de Henderson est de 9 termes si le ratio est petit ($R < 1$), 23 termes si le ratio est grand ($3,5 < R$) et 13 termes sinon (majorité des cas).

Pour l'estimation en temps réel, les moyennes mobiles utilisées dans X-13-ARIMA-SEATS sont celle de Musgrave (1964). Comme montré par Proietti et Luati (2008), ces moyennes mobiles peuvent également s'obtenir par approximation polynomiale locale en supposant en fin de période que la tendance-cycle est linéaire ($d = 1$) :

$$y_t = \beta_0 + \delta t + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2).$$

Les coefficients de la moyenne mobile de Musgrave sont alors obtenus en faisant un compromis biais-variance : la moyenne mobile asymétrique minimise l'erreur quadratique moyenne de révision (au filtre symétrique de Henderson), sous la contrainte de préserver sans biais les constantes (il y a donc un biais dans l'estimation de la pente). Ces moyennes mobiles dépendent du rapport $|\delta/\sigma|$ qui doit être défini par l'utilisateur. En supposant le biais δ constant dans le temps et la tendance est linéaire, ce rapport peut être relié à l'I/C ratio R par la relation :

$$\left| \frac{\delta}{\sigma} \right| = \frac{2}{R\sqrt{\pi}}.$$

Dans X-13-ARIMA-SEATS, pour la construction des moyennes mobiles de Musgrave, ce rapport est fixé de la façon suivante :

- Pour les séries trimestrielles : $R = 0,001$ si une moyenne mobile de Henderson de 5 termes est utilisée (majorité des cas) et $R = 4,5$ sinon ;
- Pour les séries mensuelles : $R = 0,001$ si une moyenne mobile de Henderson de 9 termes est utilisée, $R = 3,5$ pour une moyenne mobile de 13 termes (majorité des cas) et $R = 4,5$ sinon.

Pour l'estimation de la tendance-cycle, l'Australian Bureau of Statistics reproduit l'approche de X-13ARIMA-SEATS mais sans faire de détection automatique de la longueur de la série. Pour les séries mensuelles, une moyenne mobile de Henderson de 13 termes est toujours utilisée et les moyennes mobiles de Musgrave associées sont construites en utilisant le paramètre $R = 3,5$ (Trewin 2003). Cela a un avantage de simplicité : les mêmes moyennes mobiles sont utilisées pour l'ensemble des séries. Les coefficients des moyennes mobiles utilisées par ABS sont résumés dans la table 5.1.


TABLE 5.1 – Coefficients des moyennes mobiles utilisées par Australian Bureau of Statistics (Henderson et Musgrave avec $R = 3, 5$), $q = 0$ étant la moyenne mobile asymétrique utilisée en temps-réel (0 point dans le futur connu) et $q = 6$ la moyenne mobile finale (lorsqu’au moins 6 points dans le futur sont connus).

	q=6	q=5	q=4	q=3	q=2	q=1	q=0
t-6	-0,019	-0,016	-0,011	-0,008	-0,016	-0,043	-0,092
t-5	-0,028	-0,026	-0,022	-0,020	-0,025	-0,039	-0,058
t-4	0,000	0,001	0,003	0,004	0,003	0,002	0,012
t-3	0,065	0,066	0,066	0,066	0,068	0,080	0,120
t-2	0,147	0,147	0,146	0,144	0,149	0,174	0,244
t-1	0,214	0,213	0,210	0,208	0,216	0,254	0,353
t	0,240	0,238	0,233	0,230	0,241	0,292	0,421
t+1	0,214	0,211	0,205	0,201	0,215	0,279	
t+2	0,147	0,144	0,135	0,130	0,148		
t+3	0,065	0,061	0,051	0,045			
t+4	0,000	-0,005	-0,017				
t+5	-0,028	-0,034					
t+6	-0,019						

Cette méthode d’estimation de la tendance-cycle peut être appliquée en utilisant la fonction `publishTC::henderson_smoothing()`. Si la longueur de la moyenne mobile de Henderson n’est pas fixée (paramètre `length = NULL`, par défaut), elle est déterminée en utilisant l’algorithme de X-13ARIMA-SEATS décrit ci-dessus. Si elle est spécifiée par l’utilisateur et que l’I/C ratio n’est pas défini (paramètre `icr = NULL`, par défaut), alors ce dernier est également déterminé en utilisant la méthode de X-13ARIMA-SEATS.

Pour l’estimation en temps réel, supposer le biais constant et la tendance linéaire ne paraît pas une hypothèse plausible. Par exemple, lors d’un retournement conjoncturel, la pente de la tendance-cycle tend vers 0 jusqu’au point de retournement. Ainsi Quartier-la-Tente (2024b) propose une méthode de paramétrisation locale des moyennes mobiles de Musgrave, implémentée dans `publishTC::henderson_smoothing()` en utilisant le paramètre `local_icr = TRUE`. Cela permet de réduire les révisions et le délai dans la détection des points de retournement, sans changer les estimations finales de la tendance-cycle (toujours estimées via une moyenne mobile de Henderson). À titre illustratif, prenant le cas extrême d’une tendance constante de degré 1 sans bruit : l’I/C ratio devrait donc être nul. L’utilisation du paramètre $R = 3, 5$ conduit à des révisions dans les estimations en temps réel de la tendance-cycle alors que la paramétrisation locale permet d’obtenir des estimations en temps-réel égales aux estimations finales (figure 5.2).

FIGURE 5.2 – Lissage d’une tendance simulée de degré 1 par une moyenne mobile de Henderson de 13 termes et des moyennes mobiles de Musgrave avec l’I/C ratio égal à 3,5 (`henderson_smoothing()`) ou une paramétrisation locale de l’I/C ratio (`henderson_smoothing(local_icr = TRUE)`).



5.3.2 Cascade Linear Filters (CLF)

Les moyennes mobiles étant des opérateurs linéaires, elles sont sensibles à la présence de points atypiques. Du fait de leur présence, l’application directe des méthodes peut donc conduire à des estimations biaisées alors que les méthodes de désaisonnalisation (comme la méthode X-13ARIMA-SEATS) ont un module de correction des points atypiques. Par ailleurs, comme notamment montré par Dagum (1996), le filtre symétrique final utilisé par la méthode de désaisonnalisation X-11 pour extraire la tendance-cycle (et donc celui indirectement utilisé lorsqu’on applique les méthodes sur les séries désaisonnalisées) laisse passer environ 72 % des cycles de 9 ou 10 mois (généralement associés à l’irrégulier plutôt qu’à la tendance-cycle). Les filtres asymétriques finaux amplifient même les cycles de 9 ou 10 mois. Cela peut avoir pour conséquence l’introduction d’ondulations indésirables⁶, c’est-à-dire la détection de faux points de retournement. Ce problème est réduit par la correction des points atypiques (ces cycles étant considérés comme de l’irrégulier). C’est ainsi que le *Nonlinear Dagum Filter* (NLDF) a été développé et consiste à :

1. appliquer l’algorithme de correction des points atypiques de X-11 sur la série désaisonnalisée, puis la prolonger par un modèle ARIMA ;

6. On parle d’ondulation indésirable lorsque deux points de retournement se produisent en moins de dix mois.

2. effectuer une nouvelle correction des points atypiques en utilisant un seuil bien plus strict et appliquer ensuite le filtre symétrique de 13 termes. En supposant une distribution normale cela revient à modifier 48 % des valeurs de l'irrégulier (afin d'éviter qu'ils ne biaisent l'estimation de la tendance-cycle).

Utiliser une moyenne mobile de Henderson et des prévisions obtenues à partir d'un modèle ARIMA(0,1,1) où $\theta = 0,40$ conduit à avoir une moyenne mobile de 31 termes. Les *cascade linear filter* (CLF, Dagum et Luati 2009), correspondent à une approximation des NLDF où l'on a tronqué la moyenne mobile afin qu'elle soit de longueur 13 et effectué une procédure spécifique de normalisation des poids (de sorte à préserver sans biais les constantes). De manière similaire, des moyennes mobiles asymétriques, *Asymmetric Linear Filter* (ALF), peuvent être construites.

C'est la moyenne mobile CLF qui est utilisée par Statistique Canada pour l'estimation de la tendance-cycle (Picard et Matthews 2016). Pour l'estimation en temps réel, Statistique Canada utilise la méthode « couper-et-normaliser » qui consiste à recalculer les poids, à partir de la moyenne mobile symétrique, en n'utilisant que les poids associées aux observations disponibles (couper) et en renormalisant pour que la somme des coefficients soit égale à 1 (normaliser). Les coefficients des moyennes mobiles utilisées par Statistique Canada sont résumés dans la table 5.2.

TABLE 5.2 – Coefficients des moyennes mobiles utilisées par Statistique Canada pour l'estimation de la tendance-cycle (CLF et méthode « couper-et-normaliser »), $q = 0$ étant la moyenne mobile asymétrique utilisée en temps-réel (0 point dans le futur connu) et $q = 6$ la moyenne mobile finale (lorsqu'au moins 6 points dans le futur sont connus).

	q=6	q=5	q=4	q=3	q=2	q=1	q=0
t-6	-0,027	-0,026	-0,026	-0,027	-0,029	-0,034	-0,044
t-5	-0,007	-0,007	-0,007	-0,007	-0,007	-0,009	-0,011
t-4	0,031	0,030	0,030	0,031	0,033	0,039	0,051
t-3	0,067	0,065	0,065	0,067	0,072	0,084	0,109
t-2	0,136	0,132	0,132	0,136	0,145	0,170	0,222
t-1	0,188	0,183	0,182	0,187	0,201	0,235	0,307
t	0,224	0,218	0,217	0,223	0,239	0,280	0,366
t+1	0,188	0,183	0,182	0,187	0,201	0,235	
t+2	0,136	0,132	0,132	0,136	0,145		
t+3	0,067	0,065	0,065	0,067			
t+4	0,031	0,030	0,030				
t+5	-0,007	-0,007					
t+6	-0,027						

L'inconvénient de la moyenne mobile CLF est qu'elle ne préserve localement que les

droites (tendances de degré 1), contrairement à la moyenne mobile de Henderson qui préserve les tendances locales de degré 3. Même si la moyenne mobile CLF permet de réduire le nombre d'ondulations indésirables et les révisions dans les estimations intermédiaires, c'est au coût d'un biais plus important dans l'approximation d'une tendance de degré 1.

Cette méthode d'estimation de la tendance-cycle peut être appliquée en utilisant la fonction `publishTC::clf_smoothing()`. Par défaut, pour les moyennes mobiles asymétriques, la méthode « couper-et-normaliser » est utilisée. Les moyennes mobiles ALF peuvent être utilisées en utilisant l'option `endpoints = "ALF"`.

5.3.3 Que faire en cas de rupture de tendance ?

Lors de périodes de fortes « turbulences » (comme la crise du COVID-19) où les points atypiques sont importants, les estimations directes de la tendance-cycle peuvent être biaisées. De la même façon, lorsqu'une rupture brutale de la tendance est observée, les estimations de la tendance-cycle seront biaisées. Dans ce cas, plusieurs approches sont possibles :

- Ne pas publier les estimations pendant cette période : c'est ce qui est fait par l'Australian Bureau of Statistics pour la période du COVID-19 en ne publiant pas d'estimation tendance-cycle entre avril 2020 et mars 2022.
- Estimer les points atypiques avec un modèle RegARIMA, estimer la tendance-cycle sur la série corrigée et « réintroduire » les effets corrigés sur la tendance-cycle. L'inconvénient de cette approche est que l'estimation des points atypiques dépend du modèle ARIMA utilisé et de la période d'estimation, ce qui complexifie la reproductibilité des résultats. Si le modèle est réestimé à chaque nouvelle observation, la tendance-cycle peut donc potentiellement être révisée pendant de nombreuses périodes. Par exemple, Ladiray et Quartier-la-Tente (2018) montrent que dans la majorité des cas il faut attendre au moins 3 ans pour que l'estimation du coefficient associé à une rupture converge. C'est l'approche privilégiée par l'Australian Bureau of Statistics lors de ruptures dans la tendance (Trewin 2003).
- Estimer la tendance-cycle sur l'ensemble de la période et remplacer les données estimées après la rupture par celles estimées en commençant la série après la rupture (série segmentée d'un côté). L'inconvénient de cette approche est que les estimations juste avant la rupture vont être biaisées par la présence du choc et que celles juste après la rupture reposent sur des moyennes mobiles asymétriques (avec un biais plus important que les moyennes mobiles symétriques utilisées pour les estimations finales, et peuvent créer un déphasage, c'est-à-dire un décalage dans les points de retournement).
- Diviser la série en deux au niveau de la rupture et estimer la tendance-cycle sur chaque segment (série segmentée des deux côtés). L'inconvénient de cette

approche est que les estimations avant la rupture et après la rupture reposent sur des moyennes mobiles asymétriques (avec les mêmes inconvénients que précédemment). C’est l’approche privilégiée par Statistique Canada pendant le COVID-19 (Matthews 2022) et celle qui était par l’Australian Bureau of Statistics lors des premières publications des estimations de la tendance-cycle (Australian Bureau of Statistics 1987).

- Une dernière approche consiste à construire des moyennes mobiles qui prennent en compte la présence d’un choc modélisé par l’utilisateur. Dans le cadre des moyennes mobiles de Henderson et de Musgrave, cela revient à ajouter un régresseur supplémentaire dans la régression et dans le cadre de la moyenne mobile CLF, cela revient à ajouter ce régresseur dans la modélisation ARIMA. C’est l’approche proposée par Quartier-la-Tente (2025a) pour les moyennes mobiles de Henderson et de Musgrave : on parlera alors de « Henderson robuste » ou de « Musgrave robuste ». Elle est implémentée dans la fonction `publishTC::henderson_robust_smoothing()` où :
 - Le paramètre `ao` permet de spécifier les dates des points atypiques additifs (AO, *additive outlier*) : un choc ponctuelle à une date particulière puis un retour à la normal (grève, mesure exceptionnelle, erreur de mesure par exemple liée à de la non réponse, etc.). Le choc affecte donc l’irrégulier et ne devrait pas avoir d’impact sur la tendance-cycle.
 - Le paramètre `ls` permet de spécifier les dates des ruptures en niveau (LS, *level shift*) : un changement soudain et durable du niveau moyen de la série (choc structurel, changement de politique économique, etc.). Le choc affecte donc la tendance-cycle et ne devrait pas avoir d’impact sur l’irrégulier.

C’est cette dernière approche que nous recommandons de faire : comme montré dans Quartier-la-Tente (2025a), cela permet de minimiser les révisions dans les estimations intermédiaires, de correctement modéliser les retournements conjoncturels et de mieux contrôler les corrections faites. Cette approche facilite également la reproductibilité des estimations puisqu’il suffit de communiquer sur les ruptures modélisés. Comme toutes les approches, la construction des moyennes mobiles « robustes » nécessite de connaître la date et la nature du choc : sans information extérieur, la détection des chocs peut se faire via des modules ad-hoc comme le module de pré-ajustement de X-13ARIMA-SEATS basé sur la modélisation ARIMA. C’est ce qui est implémenté dans la fonction `publishTC::x13_regarima_outliers()`. Puisque cela a un impact important sur la série publiée, il est préférable de confronter les choix d’algorithmes automatiques aux connaissances économiques de la série.

La figure 5.3 montre les estimations de la tendance-cycle sur des séries simulées avec une tendance nulle et un choc ponctuel sur l’irrégulier ou un choc permanent sur la tendance en janvier 2022. Autour du choc, les moyennes mobiles de Henderson et CLF conduisent à des estimations biaisées et, dans le cas du choc sur la tendance-cycle, à considérer une augmentation de la tendance bien plusieurs mois avant le choc et le

niveau est sous-estimé après le choc. Au contraire, l'utilisation de moyenne mobiles robustes à ces chocs permet de bien prendre en compte la nature des chocs et leur influence sur la tendance-cycle.

La figure 5.4 montre les estimations de la tendance-cycle sur l'indice de production industrielle (IPI) dans l'industrie manufacturière durant la période du COVID-19. Sur cette période, la propriété souhaitée par la tendance-cycle publiée est de reproduire les points de retournement conjoncturel à la bonne date : un pic en février 2020 et un creux en mars 2020. Seule l'utilisation de moyennes mobiles robustes à deux chocs en niveau en mars et avril 2020 permet de reproduire ce phénomène économique.

FIGURE 5.3 – Lissage une série simulée avec un choc ponctuel sur l'irrégulier ou un choc permanent sur la tendance en janvier 2022.





FIGURE 5.4 – Lissage de la série de l'indice de production industrielle (IPI) CVS-CJO dans l'industrie manufacturière (CZ) autour de la période du COVID-19.



5.3.4 Quelle méthode choisir ?

Une critique classique des estimations de la tendance-cycle (et de manière plus générale des méthodes de décomposition) est qu'elles ne sont pas définies de manière unique et qu'il n'y a donc pas de définition unique et acceptée par tous. Les critères classiquement utilisés dans la littérature afin de comparer les méthodes d'estimations de la tendance-cycle (voir par exemple Martín et alii 2009, Picard et Matthews 2016, Dagum et Bianconcini 2023) sont :

1. Les révisions entre la première et la dernière estimation.
2. Le nombre de mois nécessaire pour détecter les points de retournement.
3. Le nombre d'ondulations indésirables, en parlant d'ondulation indésirable lorsque deux points de retournement se produisent en moins de dix mois.

Toutefois, plusieurs critiques peuvent être faites à ces critères :

- Comme notamment montré dans Quartier-la-Tente (2024a), il est utile d'étudier à la fois les révisions entre deux estimations consécutives ainsi que les révisions entre toutes les estimations intermédiaires et la dernière estimation. Cela permet de mettre en évidence des sous-optimalités dans certaines méthodes pour les moyennes mobiles asymétriques utilisées lorsque plusieurs points dans le futur sont connus. De la même façon, pour l'analyse du délai dans la détection des points de retournement, il est préférable de calculer le nombre de mois nécessaires pour détecter le bon point de retournement **sans aucune révision**

- future.** Cela permet d'éviter des cas où le point de retournement est détecté par des filtres asymétriques mais ne l'est pas avec l'estimation finale avec un filtre symétrique.
- Plus la tendance-cycle sera lisse, plus les révisions et le nombre de points de retournements détectés seront faibles. Dès lors, le nombre d'ondulations indésirables sera donc réduit⁷. C'est notamment le cas lorsque l'on compare le filtre CLF à la moyenne mobile de Henderson : la première moyenne mobile modélisant une tendance locale de degré 1 (contrairement à une tendance locale de degré 3 pour la seconde), elle conduira à des estimations plus lisses moins révisées et avec moins d'ondulations indésirables.
 - La comparaison de deux méthodes utilisant des moyennes mobiles symétriques différentes (comme Henderson et CLF) peut être perturbée par le fait que les points de retournement peuvent être détectés à des dates différentes. Par ailleurs, la définition utilisée pour qualifier les oscillations indésirables (deux points de retournement en moins de 10 mois) ne permet pas de prendre en compte les faux points de retournement et les périodes du type COVID-19 (où deux points de retournement apparaissent en moins de 10 mois). Il est donc préférable d'avoir une analyse approfondie des séries étudiées afin de connaître les points de retournement à détecter et ainsi en déduire les faux points de retournement.

Par cohérence et transparence envers les utilisateurs des données, nous recommandons d'utiliser la même méthode d'estimation pour l'ensemble des séries. Nous recommandons de faire le choix de celle-ci en se basant sur la réalité économique que l'on souhaite représenter. Parmi les méthodes présentées dans cet article, ce sont les moyennes mobiles robustes de Henderson qui semblent le mieux satisfaire ces critères puisque la prise en compte des points atypiques, directement dans la méthode d'estimation, permet de correctement modéliser les pics et les creux associés aux grandes crises économiques (notamment crise financière de 2009 et la crise du COVID-19).

5.4 Recommandations de présentation de la tendance-cycle

Cette section décrit les principales recommandations concernant la publication et la présentation de la tendance-cycle. Ces différentes recommandations seront illustrées avec l'estimation de la tendance-cycle de l'IPI dans l'industrie manufacturière à partir de la moyenne mobile d'Henderson de 13 termes et des moyennes mobiles de Musgrave avec $R = 3,5$ (comme ce qui est effectué par ABS). Cette estimation se fait via le code :

7. Par exemple, en prenant le cas extrême d'une tendance-cycle constante sur l'ensemble de la période, les révisions et le nombre d'ondulations indésirables seront nuls !

```
library(publishTC)
tc_h <- henderson_smoothing(french_ipi[, "manufacturing"], length = 13)
```


La principale recommandation de présentation est que la tendance-cycle doit être présentée conjointement avec la série désaisonnalisée (Australian Bureau of Statistics 2008, Martín et alii 2009, McLaren et Zhang 2010, Fonds monétaire international 2017). Cela permet aux utilisateurs de clairement discerner l'ampleur et le signe de l'irrégulier (par différenciation) et les confronter à sa propre connaissance de l'activité économique (Australian Bureau of Statistics 1987).

5.4.1 Refléter l'incertitude des dernières estimations

La principale critique des estimations de la tendance-cycle est l'ampleur des révisions : mêmes si celles-ci sont finalement moins importantes que celles de la séries CVS-CJO, elles sont concentrées sur les 3 premières estimations. De nombreux auteurs s'accordent donc à recommander que la présentation des estimations de la tendance-cycle doit mettre en lumière le moindre degré de fiabilité de la tendance-cycle sur les dernières observations (Huot et Chhab 1989, Kenny et Durbin 1982, Fonds monétaire international 2017). Il faut en particulier être prudent sur l'analyse des points de retournement sur les dernières périodes (lorsque l'estimation n'est pas définitive, Australian Bureau of Statistics 1987, 2008, McLaren et Zhang 2010). La façon la plus simple de mettre en œuvre cette recommandation est de mettre les dernières estimations de la tendance-cycle en pointillé. ABS ne met pas en œuvre cette recommandation mais Statistique Canada ajoute l'avertissement « La plus grande variabilité associée aux estimations de la tendance-cycle est indiquée au moyen d'une ligne pointillée dans le graphique pour le mois de référence en cours et pour les trois mois précédents ».

Dans `publishTC`, la tendance-cycle peut être représentée conjointement avec la série désaisonnalisée en utilisant les fonctions `plot()` et `ggplot2::autoplot()`. Par défaut, les quatre dernières estimations de la tendance-cycle sont en pointillés (comme dans les publications de Statistique Canada). Ces pointillés peuvent être supprimés en utilisant le paramètre `n_last_tc = 0`. En reprenant notre exemple :

```
library(ggplot2)
# On commence le graphique en 2022 :
autoplot(tc_h, xlim = c(2022, NA))
```



Martín et alii (2009) recommandent que le nombre de mois en pointillés soit déterminé par la statistique MCD (*month of cyclical dominance*) qui est le nombre de mois ou de trimestres nécessaires pour que la variation moyenne absolue de la tendance-cycle soit supérieure à celle de l'irrégulier. Pour une série mensuelle, notons :

$$R_k = \frac{\bar{I}_k}{\bar{C}_k} = \frac{\sum |I_t - I_{t-k}|}{\sum |TC_t - TC_{t-k}|} \text{ pour } k \in \{1, 2, \dots, 12\}.$$

L'ampleur de la tendance-cycle tend à augmenter avec la durée alors que la variation de la composante irrégulière devrait être constante : R_k devrait donc être décroissante. La statistique MCD est le premier délai d pour lequel tous les ratios $(R_k)_{k \geq d}$ sont inférieurs à 1 : il s'agit donc du nombre de mois pour que la composante tendance-cycle devienne dominante par rapport à la composante irrégulière. Elle peut être calculée en utilisant la fonction `publishTC::mcd()` et la recommandation de Martín et alii (2009) peut être appliquée en utilisant le paramètre `n_last_tc = NULL`. Dans notre exemple, cette valeur est de 4 mois :

```
mcd(tc_h)
```

```
[1] 4
```


L'incertitude autour des dernières estimations de la tendance-cycle peut aussi être reflétée en construisant des intervalles de confiance (section 5.4.1.1) ou en calculant les prévisions implicites associées aux estimations en temps réel (section 5.4.1.2).

5.4.1.1 Construction des intervalles de confiance

Il est possible de construire des intervalles de confiance pour l'estimation de la tendance-cycle par des moyennes mobile en prenant l'analogie entre le lissage par une moyenne

mobile et la régression locale (Quartier-la-Tente 2025a). Ces intervalles sont directement calculables via la fonction `confint()` et ils peuvent être tracés à partir des fonctions `publishTC::confint_plot()` et `publishTC::ggconfint_plot()`.

```
ggconfint_plot(tc_h, xlim = c(2022, NA))
```



L'inconvénient de cette représentation est qu'elle peut laisser croire qu'il n'y a pas d'incertitude autour des estimations de la série brute ou désaisonnalisée.

5.4.1.2 Construction des prévisions implicites

Afin de juger de la qualité des estimations en temps réel de la tendance-cycle et d'anticiper les futures révisions, il est possible de calculer les prévisions implicites associées à l'utilisation d'une moyenne mobile asymétrique (Quartier-la-Tente 2024b).

Notons $\mathbf{v} = (v_{-h}, \dots, v_h)$ la moyenne mobile symétrique utilisée pour calculer les estimations finales et $\mathbf{w}^0, \dots, \mathbf{w}^{h-1}$ les moyennes mobiles asymétriques utilisées pour les estimations intermédiaires. $\mathbf{w}^0 = (w_{-h}^0, \dots, w_0^0)$ est utilisée pour les estimations en temps-réel (lorsque 0 point dans le futur est connu), $\mathbf{w}^1 = (w_{-h}^1, \dots, w_0^1, w_1^1)$ pour l'avant dernière estimation (lorsque 1 point dans le futur est connu), etc. Soit $y_{t-h}, \dots, y_t$ la série observée sur les h dernières dates (lesquelles les moyennes mobiles asymétriques sont utilisées pour obtenir les estimations intermédiaires aux dates $t-h$ à t). Les prévisions implicites $y_{t+1}^*, \dots, y_{t+h}^*$ induites par $w^0, \dots, w^{h-1}$ sont les prévisions y_t pour lesquelles la moyenne mobile asymétrique appliquée à la série étendue $\mathbf{y}^* = (y_{t-h}, \dots, y_t, y_{t+1}^*, \dots, y_{t+h}^*)$ produise les mêmes estimations que les moyennes

mobiles asymétriques appliquées sur $\mathbf{y}^*$:


$$\begin{aligned}
\underbrace{\sum_{i=-h}^0 v_i y_{t+i} + \sum_{i=1}^h v_i y_{t+i}^*}_{\text{lissage par } \mathbf{v} \text{ de la série étendue}} &= \underbrace{\sum_{i=-h}^0 w_i^0 y_{t+i}}_{\text{lissage par } \mathbf{w}^0 \text{ utilisant 0 point après } t} \\
&= \underbrace{\sum_{i=-h}^0 w_i^1 y_{t+i} + w_1^1 y_{t+1}^*}_{\text{lissage par } \mathbf{w}^1 \text{ utilisant 1 point après } t} \\
&= \underbrace{\sum_{i=-h}^0 w_i^2 y_{t+i} + \sum_{i=1}^2 w_i^2 y_{t+i}^*}_{\text{lissage par } \mathbf{w}^2 \text{ utilisant 2 points après } t} \\
&= \dots \\
&= \underbrace{\sum_{i=-h}^0 w_i^{h-1} y_{t+i} + \sum_{i=1}^{h-1} w_i^{h-1} y_{t+i}^*}_{\text{lissage par } \mathbf{w}^{h-1} \text{ utilisant } h-1 \text{ points après } t}
\end{aligned}$$

Elles sont calculables en utilisant la fonction `publishTC::implicit_forecasts()` et elles peuvent être tracés à partir des fonctions `publishTC::implicit_forecasts_plot()` et `publishTC::ggimplicit_forecasts_plot()`.

```

library(patchwork) # Pour combiner les graphiques
# Estimation en utilisant la moyenne mobile CLF et coupe et normalise :
tc_clf <- clf_smoothing(french_ipi[, "manufacturing"])
(ggimplicit_forecasts_plot(tc_h, xlim = c(2022, NA)) +
  ggtitle("Henderson et Musgrave")) /
(ggimplicit_forecasts_plot(tc_clf, xlim = c(2022, NA)) +
  ggtitle("CLF et coupe et normalise"))


```

5.4.2 Graphique *lollypop* (en bâtonnet)

Afin de mettre de mettre l'accent sur la tendance-cycle et le niveau de l'irrégulier présent dans la série CVS-CJO, McLaren et Zhang (2010) suggèrent de réaliser des graphiques en bâtonnet, également appelés *lollypop*. Ils permettent également de mettre en évidence les points de retournement : trois valeurs irrégulières du même côté de la tendance (i.e., du même signe) peut suggérer le début d'un point d'inflexion et d'un changement de la direction sous-jacente. Ce graphique est réalisable à partir des fonctions `publishTC::lollypop()` et `publishTC::gglollypop()`.

```
gglollypop(tc_h, xlim = c(2022, NA))
```




5.4.3 Représentation des taux de croissance

Afin de mettre en avant les évolutions de la tendance-cycle, pour représenter les taux de croissance des séries McLaren et Zhang (2010) suggèrent de faire un graphique en bâton pour les évolutions de la série désaisonnalisée et de garder une représentation en lignes pour les évolutions de la tendance-cycle. Cela permet : 1) d'éviter d'accorder trop d'importance aux évolutions de la série désaisonnalisée qui peuvent être fortement influencées par l'irrégulier ; et 2) de donner une direction claire des mouvements cycliques en indiquant la position dans le cycle.

Ce graphique est réalisable à partir des fonctions `publishTC::growthplot()` et `publishTC::gggrowthplot()`. Par défaut, le taux de croissance représenté correspond au glissement mensuel, ce qui peut être modifié en utilisant le paramètre `lag` (par exemple, pour une série mensuelle `lag = -4` permet de représenter les glissements trimestriels et `lag = -12` les glissements annuels). Les taux de croissance de la série désaisonnalisée peuvent être représentés en ligne en utilisant le paramètre `sa_bar_line = FALSE`.

```
library(patchwork) # Pour combiner les graphiques
(gggrowthplot(tc_h, xlim = c(2022, NA)) +
  ggtitle("Glissement mensuel")) /
(gggrowthplot(tc_h, xlim = c(2022, NA), lag = -4, sa_bar_line = FALSE) +
  ggtitle("Glissement trimestriel"))
```



5.5 Comment mettre en place une chaîne de production automatique ?

Cet article présente le *package* `publishTC` qui permet d'estimer et de présenter facilement plusieurs estimations de la tendance-cycle ce facilite la mise en production de cette composante. Une mise en production automatique peut alors être mise en place et c'est ce qui a été fait sur des séries de dix publications de l'Insee (environ 80 séries) :

- Climats des affaires France (2 séries) ;
- Enquête de conjoncture dans l'Industrie (11 séries) ;
- Enquête de conjoncture dans les services (7 séries) ;
- Enquête de conjoncture dans le commerce de détail et l'automobile (5 séries) ;
- Enquête de conjoncture auprès des ménages (13 séries) ;
- Consommation mensuelle des ménages en biens (16 séries) ;
- Nombre de créations d'entreprises (14 séries) ;
- Indice de chiffre d'affaires (5 séries) ;
- Indice de production industrielle (5 séries) ;
- Indice de volume des ventes (4 séries).

Le modèle simplifié de mise en production développé ici permet, pour chaque publication, d'estimer la tendance-cycle pour toutes les méthodes présentées et de créer un rapport automatique avec l'ensemble des résultats. L'ensemble de ces rapports est disponible à l'adresse <https://aqtl.github.io/publishTC.wp/> et les données sont stockées sous <https://github.com/AQTL/publishTC.wp/tree/master/data>. Cette section décrit ce modèle de mise en production et comment facilement ajouter de nouvelles publications ou de nouvelles séries.

Pour chaque publication, un fichier de paramètre `.yaml` est créé sous <https://github.com/AQTL/publishTC.wp/tree/master/data> contenant l'ensemble des informations nécessaire à la mise en production. Ainsi, pour ajouter une nouvelle publication il suffit de créer un nouveau fichier de paramètre. Décrivons ici le fichier `IPI.yaml` associé à l'indice de production industrielle et contenant 5 séries (IPI dans l'industrie manufacturière, dans l'agro-alimentaire, dans les biens d'équipement, les matériels de transport et les autres industries). Celui-ci se décompose en 6 blocs :

```
dataset: IPI ①
datasetname: Indice de production industrielle ②
series: ③
  [...]
methods: ④
  [...]
```

```
plots: ⑤
[...]
```

- ① Nom du dossier qui contiendra les séries.
- ② Nom de la publication (titre du rapport).
- ③ Informations sur les séries.
- ④ Méthodes d'estimation de la tendance-cycle.
- ⑤ Différents paramètres graphiques.

5.5.1 Bloc **series** : informations sur les séries à publier

Le bloc **series** contient les mêmes paramètres pour chaque série. À chaque série de l'Insee est associé un identifiant, appelé `idBank`, permettant, grâce au service web SDMX de l'Insee, de facilement récupérer les données. Par exemple, l'`idBank` associé à l'IPI dans l'industrie manufacturière est `010768307` : la dernière publication de cette série est disponible à l'adresse <https://www.insee.fr/fr/statistiques/serie/010768307>. Ce lien contient également d'autres informations : graphique, documentation et parfois les révisions associées aux publications successives.

```
series:
  ipi_cz: ①
    idbank: 010768307 ②
    description: Industrie manufacturière (CZ) ③
    outliers: ④
      ao: ⑤
        - 2020.25
        - 2020.4166667
      ao_tc: ~ ⑥
      ls: ⑦
        - 2020.1666667
        - 2020.4166667
    first_date: 2012.0 ⑧
    length: 13.0 ⑨
  ipi_c1: ⑩
    [...]
  ipi_c3:
    [...]
  ipi_c4:
    [...]
  ipi_c5:
    [...]
```

- ① Nom de stockage de la série dans la base de données.
- ② IdBank de la série (pour la télécharger automatiquement).
- ③ Nom de la série (pour affichage dans le rapport).
- ④ Points atypiques à utiliser pour le lissage par des moyennes mobiles robustes de Henderson et de Musgrave.
- ⑤ Dates associées aux points atypiques additifs (AO) dont l'effet est associé à l'irrégulier.
- ⑥ Dates associées aux points atypiques additifs dont l'effet est associé à la tendance-cycle (cas particulier non décrit dans cet article, voir Quartier-la-Tente 2025a).
- ⑦ Dates associées aux ruptures en niveau (LS) dont l'effet est associé à la tendance-cycle
- ⑧ Première date à partir de laquelle la tendance-cycle est estimée.
- ⑨ Longueur de la moyenne mobile symétrique. Si `null` alors une sélection automatique sera effectuée comme décrit à la section 5.3.1.
- ⑩ Bloc associé à la deuxième série contenant les mêmes paramètres.

Pour le lissage par des moyennes mobiles robustes de Henderson et de Musgrave, les points atypiques sont initialisées via la fonction `publishTC::x13_regarima_outliers()`. Même s'il est préférable de les analyser pour chaque série, cela permet de faire une initialisation rapide. Par ailleurs, afin d'éviter des révisions sur les points atypiques retenus, ces derniers ne sont plus modifiés : lors d'une mise en production, il est recommandé d'analyser les nouveaux points afin de déterminer s'il ne faut pas en rajouter.

Pour l'ensemble des publications, la première date d'estimation est fixée à janvier 2012 : cela permet d'éviter d'avoir des potentielles ruptures dans les données lointaines⁸ qui perturberaient l'analyse des points atypiques et la construction des intervalles de confiance. Par ailleurs, puisque l'intérêt est principalement porté sur les observations, il n'a pas paru nécessaire d'étudier le passé lointain.

De la même façon que dans les publications de Statistique Canada et ABS, la longueur de la moyenne mobile symétrique est ici fixée à 13 termes pour l'ensemble des publications.

5.5.2 Bloc `methods` : méthodes d'estimation

Le bloc `methods` décrit les méthodes d'estimation de la tendance-cycle à utiliser ainsi que les noms à afficher dans les différents graphiques :

8. Par exemple, il n'y avait pas d'enquête de conjoncture en août avant 2008 et l'enquête de conjoncture dans les services n'est mensuelle que depuis 2000.

```

methods:
  henderson: ①
    name: Henderson
    eval: yes
  henderson_localic: ②
    name: Henderson local I/C
    eval: yes
  henderson_robust: ③
    name: Henderson (robust)
    eval: no
  henderson_robust_localic: ④
    name: | -
      Henderson (robust)
      local I/C
    eval: yes
  clf_cn: ⑤
    name: CLF and cut-and-normalize
    eval: yes
  clf_alf: ⑥
    name: CLF and alf
    eval: no

```

- ① Lissage par moyennes mobiles de Henderson et de Musgrave (comme pour ABS). La longueur de la moyenne mobile de Henderson étant de 13 termes (bloc **series**), l'I/C ratio utilisé est de 3,5.
- ② Lissage par moyennes mobiles de Henderson et de Musgrave avec paramétrisation locale de l'I/C ratio.
- ③ Lissage par moyennes mobiles robustes de Henderson et de Musgrave. La longueur de la moyenne mobile de Henderson étant de 13 termes (bloc **series**), l'I/C ratio utilisé est de 3,5.
- ④ Lissage par moyennes mobiles robustes de Henderson et de Musgrave avec paramétrisation locale de l'I/C ratio.
- ⑤ Lissage par CLF et méthode « couper-et-normaliser » (comme pour Statistique Canada).
- ⑥ Lissage par CLF et ALF.

Pour l'ensemble des publications, deux méthodes ne sont pas étudiées :

- Lissage par moyennes mobiles robustes de Henderson et de Musgrave avec ratio I/C **fixé** puisque l'on recommande plutôt d'effectuer une paramétrisation locale de ce paramètre afin de minimiser les révisions en temps-réel.

- Lissage par CLF et ALF : puisqu’aucun institut semble utiliser les moyennes mobiles asymétriques ALF, par simplification nous nous sommes restreint à la méthode « couper-et-normaliser » utilisée par Statistique Canada.

5.5.3 Bloc plots : paramètres graphiques

Le bloc `plots` permet de configurer les différents rendus du rapport : graphiques, tableaux, etc.

```
plots:
  nyears: 4.0 ①
  digits: 2.0 ②
  bymethods: ③
    enabled: no
    name: Par méthode
  byplots: ④
    enabled: yes
    name: Par graphique
  kind: ⑤
    normal: yes
    confint: yes
    lollypop: yes
    implicit_forecasts: yes
  comparison_plot: ⑥
    enabled: yes
    interactive: yes
    name: Comparaison des méthodes
  revision_history: ⑦
    enabled: yes
    name: Analyse des révisions
    nobs: 7 ⑧
    table: ⑨
      enabled: yes
      contribution_of_sa: yes
  extra_info: ⑩
    enabled: yes
    name: Statistiques générales
```

- ① Nombre d’années à afficher sur les graphiques.
② Nombre de décimales.
③ Faut-il ajouter un bloc avec l’ensemble des graphiques (usuel, bâtonnet, etc.) pour chaque méthode ? Bloc ici non affiché.

- ④ Faut-il ajouter un bloc avec, pour chaque type de graphique, l'ensemble des méthodes ?
- ⑤ Quels sont les graphiques à tracer : usuel (**normal**), intervalles de confiance (**confint**), en bâtonnet (**lollypop**) et prévisions implicites **implicit_forecasts**.
- ⑥ Faut-il ajouter des graphiques comparant l'ensemble des méthodes d'estimation ? Si **interactive: yes** un graphique interactif est ajouté avec les estimations sur l'ensemble de la période.
- ⑦ Faut-il faire des graphiques analysant les différentes révisions ?
- ⑧ Nombre maximal d'observations à afficher dans les graphiques et tableau xdes révisions.
- ⑨ Faut-il ajouter un tableau avec l'ensemble des révisions (**enabled: yes**) ? Par ailleurs, si **contribution_of_sa: yes** un second tableau est ajouté en calculant la part des révisions de la tendance-cycle liées aux révisions de la série CVS-CJO.
- ⑩ Faut-il ajouter des informations générales ? Il s'agit pour chaque méthode les valeurs de l'I/C ratio, MCD, la longueur de la moyenne mobile symétrique et également des points atypiques modélisés pour le lissage par moyennes mobiles robustes.

Afin d'isoler les révisions liées à l'ajout d'une nouvelle date de celle associée à la mise à jour des données passées, il est possible de calculer la part des révisions liées à la mise à jour des séries CVS-CJO. Étudions par exemple les révisions par rapport à la publication de mai 2025. Notons $y_{t|t'}$ la série CVS-CJO à la date t publiée à la date t' et $\hat{T}C_t(y_{t|t'})$ l'estimation de la tendance-cycle associée à ces données. $y_{t|2025.05}$ correspond donc à la série CVS-CJO publiée en mai 2025 et $y_{t|2025.04}$ à la série publiée en avril 2025. Par rapport au mois de mai 2025, la révision totale de la tendance-cycle correspond donc, pour chaque date t , à $\hat{T}C_t(y_{t|2025.05}) - \hat{T}C_t(y_{t|2025.04})$. Notons maintenant $y_{t|2025.05}^{2025.04}$ la série CVS-CJO publiée en mai 2025 dont on a tronqué les valeurs jusqu'en avril 2025 (i.e., en supprimant la dernière donnée). La révision totale peut donc s'écrire :

$$\underbrace{\hat{T}C_t(y_{t|2025.05}) - \hat{T}C_t(y_{t|2025.04})}_{\text{Révision totale à la dernière publication}} = \underbrace{\hat{T}C_t(y_{t|2025.05}) - \hat{T}C_t(y_{t|2025.05}^{2025.04})}_{\text{Révision liées à l'ajout d'un nouveau point}} + \underbrace{\hat{T}C_t(y_{t|2025.05}^{2025.04}) - \hat{T}C_t(y_{t|2025.04})}_{\text{Révision liées à la mise à jour de la CVS-CJO}} .$$

5.6 Conclusion

En somme, afin d'éclairer le débat public et réduire le risque que les utilisateurs tirent des conclusions inappropriées, il est intéressant de publier la composante tendance-cycle en même temps que les séries désaisonnalisées, notamment lorsque ces dernières sont

bruitées. En effet, en n'enlevant que la composante saisonnière et les jours ouvrables, la désaisonnalisation laisse dès lors l'influence de la tendance-cycle et de l'irrégulier. Lorsque l'irrégulier est important (i.e., lorsque la série est bruitée), lisser les séries pour analyser directement la tendance de court terme (i.e., la composante tendance-cycle) apporte une information supplémentaire pour le diagnostic conjoncturel en améliorant la compréhension et la détection des points de retournement et en réduisant l'impact des événements ponctuels, ce qui peut contribuer à une prise de décision opportune et éclairée. La publication de la tendance-cycle n'a pas vocation à remplacer celle des séries désaisonnalisées, ni celle des séries brutes. Ces trois séries doivent être utilisées de manière complémentaire : chaque composante a ses forces et ses faiblesses et répond à des besoins différents et leur publication conjointe aide à prendre des décisions impartiales et éclairées.

Les seuls instituts publiant régulièrement la composante tendance-cycle, Australian Bureau of Statistics (ABS) et Statistique Canada, utilisent des moyennes mobiles. Pour l'estimation finale, une moyenne mobile symétrique est utilisée (en utilisant autant de point dans le passé que dans le futur) : les estimations intermédiaires doivent donc être basées sur des moyennes mobiles asymétriques, ce qui conduira à des révisions au fur et à mesure que de nouvelles observations sont disponibles. Même si les séries désaisonnalisées sont davantage révisées sur une plus longues périodes, les révisions de la tendance-cycle sont concentrées sur les trois premières estimations : lors de la publication de cette composante, il est donc recommandé de mettre en avant l'incertitude des dernières estimations (via des pointillés, la construction d'intervalles de confiance ou l'ajout des prévisions implicites). Il est également recommandé de présenter conjointement la tendance-cycle et la série désaisonnalisée : cela permet aux utilisateurs de clairement discerner l'ampleur et le signe de l'irrégulier et les confronter à sa propre connaissance de l'activité économique.

Cet article présente également deux extensions possibles aux moyennes mobiles de Henderson et de Musgrave (utilisées par ABS et la méthode X-13ARIMA-SEATS) permettant : 1) de réduire les révisions dans les estimations intermédiaires, en particulier autour des points de retournement ; 2) de prendre directement en compte, dans la construction des moyennes mobiles, des chocs (ponctuels ou permanents) afin d'éviter qu'ils ne biaisent les estimations de la tendance-cycle et afin de correctement représenter les points de retournement autour de périodes de fortes turbulences (comme le COVID-19). Ces deux extensions peuvent également être combinées et sont implémentées dans le *package* R **publishTC**. Ce dernier permet également de reproduire le lissage avec les méthodes utilisées par ABS et Statistique Canada, ainsi que de produire des visualisations. Sa facilité d'utilisation permet de mettre en place une chaîne de production de la composante tendance-cycle : le modèle simplifié proposé dans cet article pour des publications de l'Insee permet de facilement ajouter de nouvelles publications et de nouvelles séries. Il a été appliqué sur dix publications de l'Insee (environ 80 séries, <https://aqlt.github.io/publishTC.wp/>) permettant d'étudier l'intérêt de la composante tendance-cycle sur différents cas d'usage, de comparer

plusieurs méthodes d'estimation et de faire des analyses de révisions. Pour une mise en production officielle de la tendance-cycle il est toutefois recommandé d'analyser précisément les résultats en utilisant l'expertise économique que le producteur a sur les séries, permettant notamment de choisir la méthode représentant au mieux la réalité économique de la série et ses points de retournement.

6 Conclusion générale

En somme, afin d'éclairer le débat public et de réduire le risque que les utilisateurs tirent des conclusions inappropriées, il est intéressant de publier conjointement la composante tendance-cycle et la série désaisonnalisée, notamment lorsque cette dernière est bruitée. En effet, en n'enlevant que la composante saisonnière et les jours ouvrables, la désaisonnalisation laisse, par construction, l'influence de la tendance-cycle et de l'irrégulier. Lorsque l'irrégulier est important (i.e., lorsque la série est bruitée), lisser les séries pour analyser directement la tendance de court terme (i.e., la composante tendance-cycle) apporte une information supplémentaire pour le diagnostic conjoncturel : en améliorant la compréhension et la détection des points de retournement et en réduisant l'impact des événements ponctuels, ce qui peut contribuer à une prise de décision opportune et éclairée.

Les seuls instituts publiant régulièrement la composante tendance-cycle, Australian Bureau of Statistics (ABS) et Statistique Canada, utilisent des moyennes mobiles appliquées sur les séries désaisonnalisées. Cette approche est cohérente avec la méthode de désaisonnalisation utilisée par ces instituts (méthode de décomposition X-11 utilisée dans le logiciel X-13ARIMA-SEATS), qui s'appuie sur des moyennes mobiles. Pour l'estimation finale de la tendance-cycle, une moyenne mobile symétrique est utilisée (en utilisant autant de point dans le passé que dans le futur) : les estimations intermédiaires doivent donc être basées sur des moyennes mobiles asymétriques, ce qui conduira à des révisions au fur et à mesure que de nouvelles observations sont disponibles. Cette thèse étudie plusieurs façons d'améliorer ces moyennes mobiles, pour réduire les révisions, le délai dans la détection des points de retournement et mieux rendre compte de la réalité économique autour de chocs.

Le premier apport de cette thèse est d'unifier la théorie autour des méthodes de construction des moyennes mobiles symétriques et asymétriques pour l'estimation en temps réel de la tendance-cycle. Ceci est fait par le développement d'une formulation générale permettant notamment de regrouper les approches récemment développées, basées sur l'approche polynomiale locale, la théorie des espaces de Hilbert à noyau reproduisant (RKHS) ou une optimisation d'une somme pondérée de critères de qualité des moyennes mobiles. La comparaison de toutes ces approches selon une méthodologie commune permet de souligner l'importance de bien construire les critères de qualité de moyennes mobiles. Ainsi, pour analyser le délai de détection des points de retournement, il est important de prendre en compte les révisions qu'il peut y avoir dans les points

de retournement détectés. Cela permet par exemple de montrer des sous-optimalités de certaines moyennes mobiles asymétriques lorsque l'on se rapproche de l'estimation finale, comme dans le cas des filtres RKHS. Pour l'analyse des révisions, il est également important de tenir en compte des révisions entre les différentes estimations successives puisque certaines approches peuvent avoir des faibles révisions par rapport à la dernière estimation mais des révisions plus importantes entre les estimations intermédiaires. C'est par exemple le cas pour l'approche basée l'application d'une moyenne mobile symétrique sur la série prolongée par prévision.

En étudiant les révisions et le délai de détection des points de retournement, nous soulignons aussi l'importance d'adapter la méthode et la longueur de la moyenne mobile à la variabilité de la série : lorsque la variabilité de la série est « faible » (i.e., lorsque l'irrégulier est petit comparativement à la tendance-cycle et que la longueur de la moyenne mobile utilisée est trop longue), les méthodes modélisant des tendances de degré un produisent de moins bons résultats. Dans ce cas, il est possible d'utiliser des moyennes mobiles plus courtes (afin d'avoir une estimation plus précise de la tendance-cycle) ou de modéliser des tendances plus complexes (le bruit étant faible, les nouveaux paramètres pourront être estimés avec précision).

Il est également important d'adapter les critères utilisés pour la construction des moyennes mobiles au nombre de points connus dans le futur : lorsque peu de points sont connus, on peut préférer minimiser le déphasage alors que lorsqu'on se rapproche du cas d'utilisation du filtre symétrique (c'est-à-dire lorsqu'on se rapproche des estimations finales), le critère le plus important pourrait être la réduction des révisions (le déphasage étant alors quasi nul). C'est ce qui peut expliquer les sous-optimalités des moyennes mobiles basées sur les RKHS.

En exploitant l'approche polynomiale locale, cette thèse propose deux extensions aux moyennes mobiles utilisées dans X-11 pour l'estimation de la tendance-cycle : la moyenne mobile symétrique de Henderson et les moyennes mobiles asymétriques de Musgrave.

La première consiste à effectuer une paramétrisation locale des moyennes mobiles asymétriques de Musgrave. En effet, ces dernières dépendent d'un paramètre qui doit être fixé par l'utilisateur et est généralement fixé globalement. Par exemple, dans X-11, ce paramètre ne dépend que de la longueur de la moyenne mobile de Henderson et est donc fixe pour toutes les moyennes mobiles et pour toutes les estimations. Même si l'hypothèse sous-jacente à cette façon de définir le paramètre peut être plausible dans le cadre où la tendance est linéaire et fixe, elle est sous-optimale pour les périodes de retournement conjoncturel. L'extension proposée permet de réduire les délais dans la détection des points de retournement ainsi que les révisions.

La seconde extension montre comment construire des moyennes mobiles, associées aux moyennes mobiles de Henderson et de Musgrave, qui intègrent une information extérieure afin d'avoir une meilleure décomposition tendance-cycle et irrégulier. Cela

permet notamment de modéliser des chocs ponctuels (dont l'effet est généralement associé à l'irrégulier) et des chocs permanents (dont l'effet est associé à la tendance-cycle) à certaines dates définies par l'utilisateur : nous parlerons alors de moyennes mobiles « robustes ».

Les moyennes mobiles étant des opérateurs linéaires, elles sont en effet sensibles à la présence de chocs. Par exemple, lors d'un choc permanent positif (affectant la tendance-cycle), la rupture va être lissée par la moyenne mobile et la tendance-cycle va être sur-estimée avant le choc et sous-estimée après le choc ; lors d'un choc ponctuel (affectant l'irrégulier), la tendance-cycle va être sur ou sous-estimée autour du choc (en fonction du signe du choc). Cela va également mener à de fortes révisions des estimations autour des chocs. Lorsqu'un choc est associé à un point de retournement de l'économie (par exemple lors de la crise financière de 2008 ou lors de la pandémie du COVID-19), l'estimation directe de la tendance-cycle va conduire à un décalage dans la détection des points de retournement (contraction détectée en avance et reprise en retard), ce qui peut perturber l'utilisateur lors de l'analyse de ces séries. C'est notamment ce qui a conduit Statistique Canada et l'Australian Bureau of Statistics à suspendre leurs publications de tendance-cycle pendant la période du COVID-19.

À l'inverse, la construction de moyennes mobiles « robustes » permet de minimiser les révisions autour des chocs et de bien détecter les points de retournement associés à ces chocs. Par rapport à l'utilisation de modèles ad-hoc (comme l'utilisation d'un modèle RegARIMA), cette approche a l'avantage de modéliser directement les points atypiques dans la méthodologie associée aux moyennes mobiles et va ainsi réduire les révisions et les limiter au nombre de points utilisés par les moyennes mobiles. Cela évite également les sous-optimalités associées aux approches consistant à couper la série autour du choc et à estimer la tendance-cycle sur chaque partie, du fait de l'utilisation de moyennes mobiles asymétriques autour du choc, comme ce qui est par exemple fait par Statistique Canada pour la période du COVID-19. Par ailleurs, lorsqu'aucun choc n'est observé, les résultats ne sont pas dégradés par l'utilisation des moyennes mobiles « robustes » et les estimations sont proches de celles des moyennes mobiles classiques. Pour éviter la modélisation de chocs, l'application de méthodes non linéaires (qui ne sont donc pas basées sur des moyennes mobiles) robustes peut être envisagée. Toutefois, ces méthodes conduisent à des estimations intermédiaires non cohérentes (i.e., très éloignées de ce que l'on pourrait économiquement s'attendre) : elles fournissent donc de moins bons résultats que les moyennes mobiles « robustes » pour l'estimation de la tendance-cycle.

Ces deux extensions peuvent également être combinées afin de minimiser les révisions sur les estimations intermédiaires lorsque l'on modélise des chocs sur les derniers points.

Cette thèse s'inscrit dans une démarche de science ouverte par la publication de l'ensemble des codes utilisés, mais aussi par le développement de deux *packages* R, [rjd3filters](#) et [publishTC](#).

Le premier *package*, `rjd3filters`, implémente toutes les méthodes décrites dans cette thèse avec des paramètres supplémentaires non étudiés ici, comme par exemple l'ajout d'un critère associé au déphasage dans les méthodes polynomiales locales. Il permet également de facilement créer et combiner des moyennes mobiles et étudier leurs propriétés théoriques (fonctions de gain, déphasage, critères de qualité, statistiques de validation croisée, etc.). Il est ainsi facile de reproduire l'algorithme de décomposition X-11 et d'étudier l'effet du changement d'une moyenne mobile dans cet algorithme. Ce *package* a donc davantage vocation à être utilisé par des chercheurs.

Le second *package*, `publishTC`, a été développé pour faciliter la production de la composante tendance-cycle. Il permet de reproduire les méthodes utilisées par ABS et Statistique Canada, ainsi que les extensions proposées dans cette thèse. Il facilite également la production de graphiques illustrant notamment la qualité des dernières estimations grâce à des outils décrits dans cette thèse, comme les prévisions implicites ou les intervalles de confiance. Ce *package* a donc davantage vocation à être utilisé par des producteurs de statistiques officielles. Il a conduit au développement d'une chaîne de production simplifiée de la composante tendance-cycle, qui a été appliquée sur dix publications de l'Insee (environ 80 séries, <https://aqlt.github.io/publishTC.wp/>) démontrant l'intérêt de la composante tendance-cycle dans différents cas d'usage, comparant plusieurs méthodes d'estimation et analysant les révisions.

Les travaux de cette thèse pourraient être étendus de différentes façons.

Tout d'abord, dans l'algorithme X-11 et dans cette thèse, la longueur de la moyenne mobile utilisée est supposée fixe dans le temps (pour l'estimation finale, sur des séries mensuelles nous utilisons toujours 13 termes). Toutefois, dans cette thèse nous montrons qu'il est important d'adapter la longueur de la moyenne mobile (la fenêtre) à la variabilité de la série : lorsque l'irrégulier est faible, une moyenne mobile plus courte est à préférer, afin de mieux estimer la tendance-cycle, et inversement lorsque l'irrégulier est fort, afin de le supprimer davantage. Cette variabilité peut également dépendre de la période étudiée : on peut par exemple s'attendre à une variabilité plus forte des séries autour d'une crise. Le passage par la modélisation polynomiale locale, comme ce qui est fait pour la prise en compte de chocs, permettrait d'avoir une estimation locale de la variance et d'utiliser des méthodes avancées de sélection de la fenêtre¹, qu'elle soit supposée fixe (comme par exemple dans Ruppert et alii 1995) ou variable (voir par exemple Fan et Irène Gijbels 1992). L'implémentation de ces méthodes de sélection aiderait à appliquer les estimations moyennes mobiles à des séries haute fréquence (hebdomadaires, journalières, etc.) et ainsi étendre l'algorithme X-11. En effet, pour ces séries, la principale difficulté réside dans le choix de la longueur des moyennes mobiles qui doit être fixée par l'utilisateur, comme par exemple dans les

1. Une sélection de la fenêtre basée sur des critères statistiques facilement calculables (AIC, validation croisée, Cp de Mallow, etc.) ne sera pas assez discriminante (il y a peu de différences entre les fenêtres proches).

méthodes basées sur STL, et qu'il n'existe pas de méthode automatique permettant de le faire. Cela fait que le choix est souvent arbitraire et correspond à celui par défaut dans le logiciel utilisé.

Ensuite, la construction de moyennes mobiles « robustes » pourrait être approfondie. L'algorithme de décomposition X-11 est basé sur un processus itératif estimant une à une chaque composante (saisonnalité, tendance-cycle et irrégulier) via des moyennes mobiles spécifiques. Il possède également un module de correction des chocs ponctuels qui implique que le processus itératif précédent soit répété plusieurs fois, afin d'éviter qu'un point trop important ne biaise les estimations. La construction de moyennes mobiles « robustes » pourrait simplifier ce processus en ne reproduisant qu'une fois la procédure d'estimation. La détection des chocs pourrait s'appuyer sur la méthode déjà utilisée dans X-11 (basée sur le calcul de l'écart de l'irrégulier à une estimation locale de sa variance) ou sur la construction d'intervalles de confiance comme proposée dans cette thèse. En limitant le nombre de moyennes mobiles utilisées pour la décomposition, cela faciliterait également la construction d'intervalles de confiance pour les différentes composantes.

Enfin, il est, de manière générale, difficile de juger en temps réel de la présence de chocs dans une série. Il est en effet souvent nécessaire d'avoir plusieurs points après le choc pour en être sûr, ou bien de s'appuyer sur des informations extérieures. Cela qui contribue à augmenter les révisions lors des estimations en temps-réel. Pour cela, l'idée derrière le programme **TERROR** de Caporello et Maravall (2003) est d'estimer un modèle RegARIMA sans utiliser le dernier point, de faire une prévision et de la comparer à la valeur observée : si l'erreur de prévision est grande (en valeur absolue) alors cette dernière observation peut être considérée comme atypique. Cette idée peut être étendue pour étudier la probabilité qu'un point soit atypique en étudiant la distribution des prévisions grâce, par exemple, aux prévisions quantiles.

Bibliographie

- Alexandrov, Theodore, Silvia Bianconcini, Estela Dagum, Peter Maass et Tucker McElroy. 2012. "A Review of Some Modern Approaches to the Problem of Trend Extraction". *Econometric Reviews* 31 (novembre) : 593-624. doi :[10.1080/07474938.2011.608032](https://doi.org/10.1080/07474938.2011.608032).
- Australian Bureau of Statistics. 1987. *A Guide to Smoothing Time Series – Estimates of "Trend"*. Canberra, Australia : Australian Bureau of Statistics. <https://www.abs.gov.au/AUSSTATS/abs@.nsf/productsbyCatalogue/C3AFF081DB2BC4B5CA2585A00012ACFA>.
- . 2001. *Feature article: Interpreting Time Series Data*. Canberra, Australia : Australian Bureau of Statistics. [https://www.abs.gov.au/Ausstats/abs@.nsf/0/cfa19371d1bfab40ca256f2a000feb10/\\$FILE/ATTQPLS5/Time%20Series_Final.pdf](https://www.abs.gov.au/Ausstats/abs@.nsf/0/cfa19371d1bfab40ca256f2a000feb10/$FILE/ATTQPLS5/Time%20Series_Final.pdf).
- . 2003. *A Guide to Interpreting Time Series – Monitoring Trends*. Canberra, Australia : Australian Bureau of Statistics. <https://www.abs.gov.au/ausstats/abs@.nsf/mf/1349.0>.
- . 2008. *Australian Bureau of Statistics Guidelines for Presentation and Analysis of Time Series Data*. Canberra, Australia : Australian Bureau of Statistics. <http://unstats.un.org/unsd/dnss/docViewer.aspx%3FdocID%3D2058&ved=2ahUKEwiQ19qI-ISNAxUHU6QEHWaKlwQFnoECBYQAQ&usg=AOvVaw025uOFvGdH9PvjKiizOIbD>.
- Berlinet, Alain. 1993. "Hierarchies of higher order kernels". *Probability Theory and Related Fields* 94 : 489-504.
- Berlinet, Alain, et Christine Thomas-Agnan. 2004. *Reproducing Kernel Hilbert Spaces in Probability and Statistics*. Springer.
- Caporello, Gianluca, et Agustín Maravall. 2003. *A Tool for Quality Control of Time Series Data. Program ERROR*. Occasional Paper 0301. Banco de España, Research Department.
- Christophe Croux, Peter J. Rousseeuw, et Ola Hössjer. 1994. "Generalized S-Estimators". *Journal of the American Statistical Association* 89 (428) : 1271-1281. doi :[10.1080/01621459.1994.10476867](https://doi.org/10.1080/01621459.1994.10476867).

- Cleveland, Robert B., William S. Cleveland, Jean E. McRae et Irma Terpenning. 1990. “STL: A Seasonal-Trend Decomposition Procedure Based on Loess (with Discussion)”. *Journal of Official Statistics* 6 : 3-73. <https://www.scb.se/contentassets/ca21efb41fee47d293bb5bf7be7fb3/stl-a-seasonal-trend-decomposition-procedure-based-on-loess.pdf>.
- Cleveland, William S. 1979. “Robust Locally Weighted Regression and Smoothing Scatterplots”. *Journal of the American Statistical Association* 74 (368) : 829-836. ISSN : 01621459, 1537274X, visité le 25 juin 2025. doi :[10.2307/2286407](https://doi.org/10.2307/2286407).
- Cleveland, William S., et Clive Loader. 1996. “Smoothing by local regression: Principles and methods”. In *Statistical theory and computational aspects of smoothing: Proceedings of the COMPSTAT'94 Satellite Meeting held in Semmering, Austria, 27-28 August 1994*, 10-49. Springer. doi :[10.1007/978-3-642-48425-4_2](https://doi.org/10.1007/978-3-642-48425-4_2).
- Dagum, Estela Bee. 1996. “A new method to reduce unwanted ripples and revisions in trend-cycle estimates from X-11-ARIMA”. *Survey Methodology* 22 : 77-84. <https://www150.statcan.gc.ca/n1/en/pub/12-001-x/1996001/article/14383-eng.pdf?st=UY9RsNkK>.
- Dagum, Estela Bee, et Silvia Bianconcini. 2008. “The Henderson Smoother in Reproducing Kernel Hilbert Space”. *Journal of Business & Economic Statistics* 26 : 536-545. doi :[10.1198/073500107000000322](https://doi.org/10.1198/073500107000000322).
- . 2015. “A new set of asymmetric filters for tracking the short-term trend in real-time”. *The Annals of Applied Statistics* 9 (3) : 1433-1458. doi :[10.1214/15-AOAS856](https://doi.org/10.1214/15-AOAS856).
- . 2016. *Seasonal adjustment methods and real time trend-cycle estimation*. Springer.
- . 2023. “Monitoring the direction of the short-term trend of economic indicators”. *Econometric Reviews* 42 (5) : 421-440. doi :[10.1080/07474938.2023.2209008](https://doi.org/10.1080/07474938.2023.2209008).
- Dagum, Estela Bee, et Alessandra Luati. 2009. “A Cascade Linear Filter to Reduce Revisions and False Turning Points for Real Time Trend-Cycle Estimation”. *Econometric Reviews* 28 (1-3) : 40-59. doi :[10.1080/07474930802387837](https://doi.org/10.1080/07474930802387837).
- Darné, Olivier, et Estelle Bee Dagum. 2009. “Performance of short-term trend predictors for current economic analysis”. *Economics Bulletin* 29 (1) : 79-89. <http://www.accessecon.com/Pubs/EB/2009/Volume29/EB-09-V29-I1-P7.pdf>.
- De Forest, Erastus L. 1877. “On adjustment formulas”. *The Analyst* 4 (3) : 79-86. doi :[10.2307/2636257](https://doi.org/10.2307/2636257).
- Fan, Jianqing, et Irene Gijbels. 1992. “Variable bandwidth and local linear regression smoothers”. *The Annals of Statistics*, 2008-2036. doi :[10.1214/aos/1176348890](https://doi.org/10.1214/aos/1176348890).

- Fan, Jianqing, et Irène Gijbels. 1992. “Variable Bandwidth and Local Linear Regression Smoothers”. *The Annals of Statistics* 20 (4) : 2008-2036. ISSN : 00905364, 21688966. doi :[10.1214/aos/1176348900](https://doi.org/10.1214/aos/1176348900).
- Feng, Yuanhua, et Bastian Schäfer. 2021. *Boundary modification in local polynomial regression*. Working Papers CIE 144. Paderborn University, CIE Center for International Economics, août. <https://ideas.repec.org/p/pdn/ciepap/144.html>.
- Ferrara, Laurent. 2009a. “Caractérisation et datation des cycles économiques en zone euro”. *Revue économique* 60 (3) : 703-712. doi :[10.3917/reco.603.0703](https://doi.org/10.3917/reco.603.0703).
- . 2009b. “Characterization and Dating of Economic Cycles in the Euro Area”. Place: Paris Publisher: Presses de Sciences Po, *Revue économique* 60 (3) : 703-712. ISSN : 9782724631388. doi :[10.3917/reco.603.0703](https://doi.org/10.3917/reco.603.0703).
- Fonds monétaire international. 2017. *Manuel des comptes nationaux trimestriels*. Édition 2017. Washington, D.C. : Fonds monétaire international. <https://www.imf.org/external/pubs/ft/qna/pdf/2017/QNAManual2017FRE.pdf>.
- Fourier, Joseph. 1822. *Théorie analytique de la chaleur*. Paris : Firmin Didot.
- Fried, Roland, Karen Schettlinger et Matthias Borowski. 2024. *robfilter: Robust Time Series Filters*. R package version 4.1.5. doi :[10.32614/CRAN.package.robfilter](https://doi.org/10.32614/CRAN.package.robfilter).
- Funkhouser, H. Gray. 1936. “A Note on a Tenth Century Graph”. *Osiris* 1 : 260-262. doi :[10.1086/368425](https://doi.org/10.1086/368425).
- Gather, Ursula, Karen Schettlinger et Roland Fried. 2006. “Online signal extraction by robust linear regression”. *Computational Statistics* 21 (1) : 33-51. doi :[10.1007/s00180-006-0249-8](https://doi.org/10.1007/s00180-006-0249-8).
- Gray, Alistair G, et Peter J Thomson. 1996. “Design of Moving-Average Trend Filters using Fidelity and Smoothness Criteria”. In *Athens Conference on Applied Probability and Time Series Analysis*, sous la direction de P. M. Robinson et Murray Rosenblatt, 205-219. New York, NY : Springer New York. ISBN : 978-1-4612-2412-9. <https://www.census.gov/library/working-papers/1996/adrm/rr96-01.html>.
- . 2002. “On a Family of Finite Moving-Average Trend Filters for the Ends of Series”. *Journal of Forecasting* 21, n° 2 (mars) : 125-149. doi :[10.1002/for.817](https://doi.org/10.1002/for.817).
- Grun-Rehomme, Michel, Fabien Guggemos et Dominique Ladiray. 2018. “Asymmetric Moving Averages Minimizing Phase Shift”. *Handbook on Seasonal Adjustment*, <https://ec.europa.eu/eurostat/web/products-manuals-and-guidelines/-/KS-GQ-18-001>.
- Grun-Rehomme, Michel, et Dominique Ladiray. 1994. “Moyennes mobiles centrées et non-centrées. Construction et comparaison”. *Revue de Statistique Appliquée* 42 (3) : 33-61. http://www.numdam.org/item/RSA_1994__42_3_33_0/.

- Henderson, Robert. 1916. "Note on graduation by adjusted average". *Transactions of the actuarial society of America* 17 : 43-48.
- Huot, Guy, et Norma B Chhab. 1989. "A note on the use of trend-cycle estimates for the help-wanted index", publications.gc.ca/pub?id=9.838212&sl=0.
- Hyndman, Rob J., et Yeasmin Khandakar. 2008. "Automatic Time Series Forecasting: The forecast Package for R". *Journal of Statistical Software* 27 (3) : 1-22. doi :[10.18637/jss.v027.i03](https://doi.org/10.18637/jss.v027.i03).
- Kendall, Maurice G. 1973. *Time-series*. London : Charles Griffin.
- Kenny, P. B., et J. Durbin. 1982. "Local Trend Estimation and Seasonal Adjustment of Economic and Social Time Series". *Journal of the Royal Statistical Society. Series A (General)* 145 (1) : 1-41. ISSN : 00359238, 23972327. doi :[10.2307/2981420](https://doi.org/10.2307/2981420).
- Ladiray, Dominique. 2018. "Moving Average Based Seasonal Adjustment". *Handbook on Seasonal Adjustment*, <https://ec.europa.eu/eurostat/web/products-manuals-and-guidelines/-/KS-GQ-18-001>.
- Ladiray, Dominique, et Alain Quartier-la-Tente. 2018. "Du bon usage des modèles Reg-ARIMA en désaisonnalisation". *XIIIèmes Journées de Méthodologie Statistique de l'Insee*, https://journées-methodologie-statistique.insee.net/wp-content/uploads/2018/S05_1_ACTEv3_QUARTIERLATENTE_JMS2018.pdf.
- Ladiray, Dominique, et Benoît Quenneville. 2011. *Seasonal Adjustment with the X-11 Method*. Springer. ISBN : 9781461301769. doi :[10.1007/978-1-4613-0175-2](https://doi.org/10.1007/978-1-4613-0175-2).
- Loader, Clive. 1999. *Local regression and likelihood*. 290. New York: Springer-Verlag. ISBN : 978-0-387-98775-0. doi :[10.1007/b98858](https://doi.org/10.1007/b98858).
- Luati, Alessandra, et Tommaso Proietti. 2011. "On the equivalence of the weighted least squares and the generalised least squares estimators, with applications to kernel smoothing". *Annals of the Institute of Statistical Mathematics* 63 (4) : 851-871. ISSN : 1572-9052. doi :[10.1007/s10463-009-0267-8](https://doi.org/10.1007/s10463-009-0267-8). <https://doi.org/10.1007/s10463-009-0267-8>.
- Macaulay, Frederick R, et alii. 1931. "The smoothing of time series". *NBER Books*.
- Martín, Begoña, Peter Meszaros, Duncan Elliott et Craig McLaren. 2009. "Issues in Trend-Cycle Estimates for Official Statistics". In *Proceedings of the Survey Research Section, American Statistical Association, Joint Statistics Meeting, Washington, DC*.
- Matthews, Steve. 2022. "Trend-Cycle Estimation in Topsy-Turvy Times". In *4th Seasonal Adjustment Practitioners Workshop (SAPW)*. Juin. <https://community.amstat.org/governmentstatisticssection/conferences/pastconference210/seasonal-adjustment-practitioners-workshop-2022>.

- McCracken, Michael W., et Serena Ng. 2016. "FRED-MD: A Monthly Database for Macroeconomic Research". *Journal of Business & Economic Statistics* 34 (4) : 574-589. doi : [10.1080/07350015.2015.1086655](https://doi.org/10.1080/07350015.2015.1086655).
- McElroy, Tucker, et Marc Wildi. 2020. "The Multivariate Linear Prediction Problem: Model-Based and Direct Filtering Solutions". *Econometrics and Statistics* 14 (C) : 112-130. doi : [10.1016/j.ecosta.2019.12.004](https://doi.org/10.1016/j.ecosta.2019.12.004). <https://ideas.repec.org/a/eee/ecosta/v14y2020icp112-130.html>.
- McLaren, Craig H, et David G Steel. 2001. "Rotation patterns and trend estimation for repeated surveys using rotation group estimates". *Statistica Neerlandica* 55 (2) : 221-238. https://documents.uow.edu.au/~craigmc/sn_2001.pdf.
- McLaren, Craig H, et Xichuan (Mark) Zhang. 2010. "The Importance of Trend-Cycle Analysis for National Statistics Institutes". *Estudios de Economía Aplicada* 28 (3) : 607-624. <http://www.revista-eea.net/documentos/28312.pdf>.
- Menezes, Zuleika, Craig H McLaren, Nick Von Sanden, Xichuan (Mark) Zhang et Melanie Black. 2006. "Timely detection of turning points: Should I use the seasonally adjusted or trend estimates?" In *Proceedings of the conference on Seasonality, Seasonal Adjustment and their implications for Short-Term Analysis and Forecasting*. <https://ec.europa.eu/eurostat/documents/3888793/5842329/KS-DT-06-021-EN.PDF/d5eb2df1-71b8-4086-88f8-94ad2e7d2c6e>.
- Monsell, Brian C. 2007. "The X-13A-S seasonal adjustment program". In *Proceedings of the Federal Committee On Statistical Methodology Research Conference, November 5-7, 2007*, 515. Arlington, Virginia. https://nces.ed.gov/FCSM/pdf/2007/FCSM_Monsell-II-B.pdf.
- Musgrave, John C. 1964. "A set of end weights to end all end weights". *US Census Bureau [custodian]*, <https://www.census.gov/library/working-papers/1964/adrm/musgrave-01.html>.
- Office for Statistics Regulation. 2008. *Volatility of the Retail Sales Index*. Monitoring & Assessment Note M&A Note 1/2008. Consulté le 13 juin 2025. UK Statistics Authority, octobre.
- Palate, Jean, et Alain Quartier-la-Tente. 2024. *rjd3filters: Trend-Cycle Extraction with Linear Filters*. R package version 2.1.0. <https://github.com/rjdverse/rjd3filters>.
- Persons, Warren M. 1919. "Indices of general business conditions". 1 (1) : 5-107.
- Picard, Frédéric, et Steve Matthews. 2016. *The Addition of Trend-Cycle Estimates to Selected Publications at Statistics Canada*. Proceedings of the Survey Methods Section, Statistical Society of Canada (SSC) Annual Meeting. https://ssc.ca/site/default/files/imce/pdf/picard_ssc2016.pdf.

- Pierce, David A. 1980. “Data revisions with moving average seasonal adjustment procedures”. *Journal of Econometrics* 14 (1) : 95-114. ISSN : 0304-4076. doi :[10.1016/0304-4076\(80\)90075-5](https://doi.org/10.1016/0304-4076(80)90075-5).
- Poynting, John Henry. 1884. “A Comparison of the Fluctuations in the Price of Wheat and in the Cotton and Silk Imports into Great Britain”. *Journal of the Royal Statistical Society, A*, 47 : 34-64. doi :[10.2307/2979211](https://doi.org/10.2307/2979211).
- Proietti, Tommaso, et Alessandra Luati. 2008. “Real time estimation in local polynomial regression, with application to trend-cycle analysis”. *Ann. Appl. Stat.* 2, n° 4 (décembre) : 1523-1553. doi :[10.1214/08-AOAS195](https://doi.org/10.1214/08-AOAS195).
- Quartier-la-Tente, Alain. 2024a. “Estimation en temps réel de la tendance cycle : apport de l’utilisation de moyennes mobiles asymétriques”. *Document de travail méthodologique Insee*, n°s M2024/01, <https://github.com/InseeFrLab/DT-est-tr-tc>.
- . 2024b. “Improving real-time trend estimates using local parametrisation of polynomial regression filters”. *Journal of Official Statistics* 40 (4) : 685-715. doi :[10.1177/0282423X241283207](https://doi.org/10.1177/0282423X241283207).
- . 2025a. *Estimation de la tendance-cycle avec des méthodes robustes aux points atypiques*. arXiv : [2507.10704](https://arxiv.org/abs/2507.10704) [stat.ME]. <https://aqlt.github.io/robustMA/>.
- . 2025b. *publishTC: Tools to Help to Publish the Trend-Cycle Component*. R package version 0.2.2. Available at: <https://github.com/AQLT/publishTC>.
- R Core Team. 2022. *R: A Language and Environment for Statistical Computing*. Vienna, Austria : R Foundation for Statistical Computing. <https://www.R-project.org/>.
- Rousseeuw, Peter J. 1984. “Least median of squares regression”. *Journal of the American statistical association* 79 (388) : 871-880.
- . 1985. “Multivariate estimation with high breakdown point”. *Mathematical Statistics and Applications B*, doi :[10.2307/2288718](https://doi.org/10.2307/2288718).
- Rousseeuw, Peter J., et Mia Hubert. 1999. “Regression Depth”. *Journal of the American Statistical Association* 94 (446) : 388-402. doi :[10.1080/01621459.1999.10474129](https://doi.org/10.1080/01621459.1999.10474129).
- Ruppert, D., S. J. Sheather et M. P. Wand. 1995. “An Effective Bandwidth Selector for Local Least Squares Regression”. *Journal of the American Statistical Association* 90 (432) : 1257-1270. doi :[10.1080/01621459.1995.10476630](https://doi.org/10.1080/01621459.1995.10476630).
- Schuster, Arthur. 1898. “On the Investigation of Hidden Periodicities with Application to a Supposed 26 Day Period of Meteorological Phenomena”. *Terrestrial Magnetism* 3 (1) : 13-41. doi :[10.1029/TM003I001P00013](https://doi.org/10.1029/TM003I001P00013).

- Shiskin, Julius. 1957. *Electronic Computers and Business Indicators*. Occasional Paper No. 57. National Bureau of Economic Research. <https://www.nber.org/books-and-chapters/electronic-computers-and-business-indicators>.
- Siegel, Andrew F. 1982. "Robust regression using repeated medians". *Biometrika* 69 (1) : 242-244. doi :[10.2307/2335877](https://doi.org/10.2307/2335877).
- Spencer, John. 1904. "On the Graduation of the Rates of Sickness and Mortality". *Journal of the Institute of Actuaries* 38 : 334-343. doi :[10.1017/S0020268100008076](https://doi.org/10.1017/S0020268100008076).
- Trewin, Dennis. 2003. "A guide to interpreting time series - Monitoring trends". *Australian Bureau of Statistics Information Paper*, <https://www.abs.gov.au/AUSSTATS/abs@.nsf/Lookup/1349.0Main+Features12003?OpenDocument>.
- Vasyechko, Olga, et Michel Grun-Rehomme. 2014. "A new smoothing technique for univariate time series: the endpoint problem". *Economics Bulletin* 34 (3) : 1419-1430. <https://EconPapers.repec.org/RePEc:ebl:ecbull:eb-13-00344>.
- Venables, W. N., et B. D. Ripley. 2002. *Modern Applied Statistics with S*. Fourth. ISBN 0-387-95457-0. New York : Springer. <https://www.stats.ox.ac.uk/pub/MASS4/>.
- Wildi, Marc, et Tucker McElroy. 2013. "Optimal Real-Time Filters for Linear Prediction Problems". *Journal of Time Series Econometrics* 8 (décembre). doi :[10.1515/jtse-2014-0019](https://doi.org/10.1515/jtse-2014-0019).
- . 2019. "The trilemma between accuracy, timeliness and smoothness in real-time signal extraction". Forecasting issues in developing economies, *International Journal of Forecasting* 35 (3) : 1072-1084. ISSN : 0169-2070. doi :[10.1016/j.ijforecast.2019.03.008](https://doi.org/10.1016/j.ijforecast.2019.03.008).
- Wildi, Marc, et Bernd Schips. 2004. *Signal Extraction: How (In)efficient Are Model-Based Approaches? An Empirical Study Based on TRAMO/SEATS and Census X-12-ARIMA*. KOF Working papers 04-96. KOF Swiss Economic Institute, ETH Zurich, décembre. doi :[10.3929/ethz-a-004957347](https://doi.org/10.3929/ethz-a-004957347).
- Zellner, Arnold, Chansik Hong et Chung-ki Min. 1991. "Forecasting turning points in international output growth rates using Bayesian exponentially weighted autoregression, time-varying parameter, and pooling techniques". *Journal of Econometrics* 49 (1) : 275-304. ISSN : 0304-4076. doi :[10.1016/0304-4076\(91\)90016-7](https://doi.org/10.1016/0304-4076(91)90016-7).

Titre : Estimation en temps réel de la tendance-cycle à l'aide de moyennes mobiles : apports dans l'analyse conjoncturelle

Mots clés : Séries chronologiques ; Cycles économiques ; Moyennes mobiles ; Désaisonnalisation ; Points de retournement

Résumé : Les séries désaisonnalisées sont couramment utilisées pour l'analyse conjoncturelle et l'identification des points de retournement. Toutefois, lorsqu'elles sont trop bruitées, un lissage supplémentaire est nécessaire pour extraire la tendance de court terme, appelée tendance-cycle, qui combine la tendance de long terme et les fluctuations cycliques de court terme. Cette extraction repose généralement sur des moyennes mobiles symétriques. Pour l'estimation en temps réel, en l'absence d'observations futures, il est toutefois nécessaire de s'appuyer sur des filtres asymétriques. Cela entraîne retards dans la détection des points de retournement et révisions au fur et à mesure que de nouvelles observations sont disponibles. Cette thèse vise à préciser pourquoi et comment publier la tendance-cycle et les recommandations pour le faire.

Différentes approches récentes de construction de moyennes mobiles asymétriques sont comparées, tant sur le plan théorique qu'empirique. Deux extensions des filtres de Henderson et de Musgrave, classiquement utilisées pour l'estimation de la tendance-cycle, sont proposées : 1) réduction des révisions et délais dans la détection des points de retournement via une paramétrisation locale ; 2) intégration de régresseurs externes pour construire des filtres robustes à certains chocs.

Ces travaux s'accompagnent de deux paquets R, `rjd3filters` et `publishTC`, qui facilitent l'application des méthodes proposées, l'étude des propriétés des filtres, l'estimation de la tendance-cycle et leur mise en production.

Title: Real-time time trend-cycle estimation with moving averages: contributions to business cycle analysis

Keywords: Time series; Business cycle; Moving averages; Seasonal adjustment; Turning points

Abstract: Seasonally adjusted series are commonly used for business cycle analysis and turning point identification. However, when they are too noisy, additional smoothing is required to extract the short-term trend, known as the trend-cycle, which combines the long-term trend and short-term cyclical fluctuations. This extraction typically relies on symmetric moving averages. For real-time estimation, in the absence of future observations, it is necessary to use asymmetric filters. This leads to delays in turning point detection and revisions as new observations become available. This thesis aims to clarify why and how to publish the trend-cycle and provide recommendations for doing so.

Different recent approaches to building asymmetric moving averages are compared, both theoretically and empirically. Two extensions of the Henderson and Musgrave filters, traditionally used for trend-cycle estimation, are proposed: 1) reduction of revisions and delays in turning point detection through local parameterization; 2) integration of external regressors to build filters robust to certain shocks.

This work is accompanied by two R packages, `rjd3filters` and `publishTC`, which facilitate the application of the proposed methods, the study of filter properties, trend-cycle estimation, and their implementation in production.

